

Glosario — MMIA 6013

Glosario y notación — MMIA 6013

Fija el vocabulario proyectado. **Consultar antes de usar un término nuevo; agregarlo aquí antes de usarlo en una diapositiva.** El sílabo oficial está en español y varios términos del área no tienen traducción asentada: la columna “Cómo se dice en clase” resuelve cada caso una sola vez, para que la sesión 17 no llame distinto a lo mismo que la sesión 03.

Regla general de idioma

Se traduce lo que tiene equivalente asentado en español (*embedding* → representación vectorial, *retrieval* → recuperación) y se conserva en inglés lo que la industria usa como nombre propio de una técnica (*chunking*, *prompt*, *tool use*, *guardrail*). La primera aparición en un deck lleva el par: **recuperación aumentada con generación (RAG)**. Después, la sigla.

Notación

Símbolo	Significado	Nota
$P(X)$	distribución sobre los datos — lo que modela un modelo generativo	el hilo conductor del curso
$P(Y\backslash X)$	distribución de la etiqueta dada la entrada — lo que modela un discriminativo	
$P(x_t \ \backslash \ x_{<t})$	próximo token dado el prefijo	la factorización autorregresiva
θ	parámetros del modelo; en un LLM, los pesos	
$P(\theta)$	prior: lo que se supone de θ antes de ver los datos	
$P(X\backslash \theta)$	verosimilitud: se lee como función de θ , con X fijo en lo observado	no es una distribución sobre θ : su integral en θ no vale 1 (Bishop 2006, p. 22)
$P(\theta\backslash X)$	posterior sobre parámetros , después de ver los datos	no confundir con el posterior sobre la clase, $P(Y\backslash X)$

Símbolo	Significado	Nota
z	variable latente: no se observa, se infiere	componente en un GMM, estado oculto en un HMM, código en un VAE. Reservado: no usar z para el vector de contexto de la atención —aunque Vaswani (2017) y Raschka (2024) lo hagan— ni para los logits de salida
Q, K, V	query, key, value de atención	mayúsculas, sin traducir
d	dimensión del espacio de embeddings	reservado para la dimensión: un documento del corpus no se escribe d (ver s_i). ⚠ La fórmula de BM25 de fuentes/notas-teoricas/s2-rag-y-vector-search.md §5.1, línea 163, usa d para <i>documento</i> : el deck la reescribe o advierte la colisión en voz alta
d_{model}	dimensión del modelo: la que comparten embeddings, subcapas y conexiones residuales	Vaswani (2017), §3.1. No es la ventana de contexto
d_k, d_v	dimensión de keys/queries y de values por cabeza	el escalado de la atención es por $\sqrt{d_k}$, no por $\sqrt{d_{model}}$ (Vaswani 2017, ec. 1)
h	número de cabezas de atención	h = 8 en el modelo base de Vaswani (2017)
n	longitud de la secuencia, en tokens ; y, cuando la factorización se escribe entera, el índice corriente que la recorre	el costo por capa de la auto-atención es $O(n^2 \cdot d)$ (Vaswani 2017, Tabla 1). Reservado: el número de vectores de un índice se escribe N (ver abajo). ⚠ Dos formas de la misma identidad, y las dos se proyectan: la corriente es $P(x_t \setminus x_{<t})$ y la desplegada $P(x_1, \dots, x_n) = \prod_{t=1}^n P(x_t \setminus x_{<t})$. En las dos, t es el índice y n la longitud . Bishop ec. 13.1, p. 607 la escribe con n de índice y N de longitud; este curso no puede seguirle la letra , porque N está reservada más abajo para el número de vectores indexados de la sesión 07 y darle un tercer significado la rompe. La grafía es del curso; la identidad, de Bishop. Las sesiones 01, 02, 03 y 04 proyectan la desplegada con esta misma grafía, y las 02, 03 y 04 la corriente. No son notaciones distintas: es la misma factorización escrita corta y larga. ⚠ Mayúscula siempre, y el producto siempre con sus límites: sin t = 1 hasta n la expresión es un esquema y no la identidad exacta que la lámina afirma (Bishop 2006, ec. 13.1, p. 607, que lo escribe con sus límites)
$\pi_\theta(y \setminus x)$	la política : el modelo que se está entrenando, leído como distribución sobre respuestas dado el prompt	Rafailov et al. (2023), §3, p. 3
$\pi_{ref}(y \setminus x)$	la política de referencia , congelada	$\pi_{ref} = \pi^{SFT}$ cuando esta existe (Rafailov 2023, §4, p. 5)
π^{SFT}	la política después del ajuste supervisado	Ouyang et al. (2022), §3.5, p. 8; Rafailov 2023, §3, p. 3

Símbolo	Significado	Nota
$r_{\varphi}(x, y)$	el modelo de recompensa aprendido, con parámetros φ	colisión resuelta: Ouyang ec. (1), p. 8 lo escribe r_{θ} ; en clase se usa r_{φ} (Rafailov ec. 2, p. 3) porque θ está reservado para los pesos del modelo desde la sesión 01. Si el deck proyecta la ecuación de Ouyang tal cual, anota el cambio; no se altera en silencio
y_w, y_l	respuesta elegida (<i>winner</i>) y rechazada (<i>loser</i>) para el mismo prompt x	Rafailov (2023), §3, p. 3
β	coeficiente de la restricción KL respecto de π_{ref}	Rafailov ec. (3), p. 3; en Ouyang ec. (2), p. 9 es el coeficiente de la penalización KL
$\sigma(\cdot)$	función logística	Rafailov (2023), §3, p. 3
$\mathcal{L}(\varphi)$	la pérdida del modelo de recompensa , escrita como función de los parámetros que se ajustan	cambio anotado: Rafailov ec. (2), p. 3 la escribe $L_R(r_{\varphi}, D)$ — función del modelo y del conjunto— y Ouyang ec. (1), p. 8 la escribe $\text{loss}(\theta)$. En clase se escribe $\mathcal{L}(\varphi)$ por coherencia con r_{φ} . Es el mismo caso que $r_{\theta} \rightarrow r_{\varphi}$: se anota, no se altera en silencio. Se introduce en 03
logits	vector de puntajes sin normalizar sobre el vocabulario, antes del softmax	no se escribe z , que está reservado para variable latente. Lo produce la capa de des-incrustación (Raschka 2024, §5.3.1, p. 153)
T	temperatura de muestreo	$T = 0$ es <i>greedy</i> , no “determinista”. Opera como $\text{softmax}(\text{logits} / T)$ con $T > 0$ (Raschka 2024, §5.3.1, p. 154)
k	colisión declarada. En la sesión 04, número de tokens conservados por top-k; en la 07, número de vecinos que devuelve un índice (<code>recall@10</code>); desde la 08 , número de fragmentos recuperados (top-k)	Se dice “top-k” y “ <code>Recall@k</code> ” completos, nunca k a secas (Raschka 2024, §5.3.2, p. 156). No confundir con <code>k_RRF</code> ni con <code>k1</code> de BM25
K	número de demostraciones en un prompt few-shot	mayúscula, y no es lo mismo que k . Brown et al. (2020), §2, p. 6: K entre 10 y 100, limitado por la ventana de contexto
p	masa de probabilidad acumulada que conserva el núcleo en top-p	sin fuente bibliográfica local: definición operativa en <code>curso/actividades/_fuentes/s1-mie.py</code> , líneas 70–77
n_ctx	ventana de contexto en tokens	$n_{\text{ctx}} = 2048$ en todos los modelos de Brown et al. (2020), §2.1, p. 8. Cifra histórica de GPT-3, no afirmación sobre el mercado actual
$\cos(u, v)$	similitud coseno	producto punto de vectores normalizados

Símbolo	Significado	Nota
u, v	los dos vectores de oración que se comparan	Reimers & Gurevych (2019), §3, p. 3: $(u, v, \sqrt{u \cdot v})$ en el objetivo de clasificación y $\text{cosine-sim}(u, v)$ en inferencia (Fig. 2)
q	vector de la consulta en búsqueda semántica	colisión declarada : no es el Q de la atención, que es una proyección de tokens dentro de una capa. Aquí q es un texto entero convertido en un vector. Se introduce en 06
s_i	vector del i -ésimo texto del corpus	se usa s y no d , porque d está reservado para la dimensión . Reimers & Gurevych (2019), §3, p. 3, usan s_a, s_p, s_n en la pérdida triplet
$\ v\ $	norma euclídea (L2) de v	
$\hat{v}$	$v/\ v\ $: el vector normalizado L2, con $\ \hat{v}\ = 1$	con $\ u\ = \ v\ = 1$, $\text{cos}(u, v) = u \cdot v$ exactamente , no aproximadamente
N	número de vectores indexados en la base	colisión declarada con n (longitud de secuencia en tokens): se escribe mayúscula y se dice una vez en voz alta. El costo del kNN exacto es $O(N \cdot d)$ — curso/actividades/semana-2/s2-mar-explicacion.html , línea 38 —, no $O(n)$ como escribe fuentes/notas-teoricas/s2-rag-y-vector-search.md §3.1
$nlist$	número de celdas de un índice IVF	no se escribe k , aunque fuentes/notas-teoricas/s2-rag-y-vector-search.md §3.3, línea 92, lo haga: k está reservado. $NLIST = 64$ en curso/actividades/_fuentes/s2-mar.py , línea 89
$nprobe$	celdas que se abren por consulta en IVF	$nprobe = nlist \Rightarrow$ búsqueda exacta (s2-mar-explicacion.html , línea 74). Perilla de consulta
M	conexiones por nodo en el grafo HNSW	colisión declarada con el M de la sesión 01 (orden de la cadena de Markov, $K^M(K-1)$). Se dice “conexiones por nodo”, nunca M a secas. Perilla de memoria y de construcción
<code>ef_construction</code>	tamaño del haz al construir el grafo HNSW	perilla de construcción : cambiarla exige reindexar
<code>ef_search</code>	tamaño del haz al consultar el grafo HNSW	perilla de consulta : “ajustable en tiempo de consulta, sin reconstruir el índice” (s2-mar-explicacion.html , línea 125)

Símbolo	Significado	Nota
k_{RRF}	constante de suavizado de Reciprocal Rank Fusion	Cuarta colisión con k. fuentes/notas-teoricas/s2-rag-y-vector-search.md §5.3, línea 184, lo escribe k y no es el top- k . $k_{\text{RRF}} = 60$ es “el valor estándar” según esa misma línea, sin fuente primaria en el repositorio . Controla cuánto vale una posición alta: con 60, entre el puesto 1 y el 10 hay un 13 % de diferencia; con 0, un factor 10
k_1, b	parámetros de BM25: saturación de la frecuencia y peso de la normalización por longitud	colisión declarada con k (notas-s2 §5.1, línea 163). Se nombran, no se ajustan: ninguna fuente del repositorio recomienda valores
avgdl	longitud media de documento del corpus, en BM25	notas-s2 §5.1, línea 163. Re-fragmentar cambia avgdl y con ello el puntaje BM25 de todos los documentos, incluidos los que no se tocaron
C, V	tamaño del fragmento y solapamiento, en la misma unidad	notación fijada por este curso para escribir la inflación del índice, $1/(1 - V/C)$, sin usar letras reservadas. Decir siempre la unidad: en el curso circulan caracteres, tokens y palabras (ver <i>Chunk size / overlap</i>)
$\Phi_0, \Delta\Phi$	los parámetros preentrenados y su incremento en el ajuste fino completo	Hu et al. (2021), §2, ec. 1, p. 3. En ajuste fino completo $\backslash \Delta\Phi\backslash = \backslash \Phi_0\backslash$: un juego entero de pesos por tarea
θ	el conjunto de parámetros que PEFT sí entrena , con $\Delta\Phi = \Delta\Phi(\theta)$ y $\backslash \theta\backslash \ll \backslash \Phi_0\backslash$	Hu et al. (2021), §2, ec. 2, p. 3: en GPT-3 175B, $\backslash \theta\backslash$ “ <i>puede ser tan pequeño como el 0,01 % de $\backslash \Phi_0\backslash$”.  No es θ, que en este curso son <i>todos</i> los pesos del modelo desde la sesión 01</i>
$W_0, \Delta W$	el peso congelado y su corrección aprendida, con $W_0 \in \mathbb{R}^{d \times k}$	Hu et al. (2021), §4.1, p. 4. W_0 no recibe gradiente
B, A	los dos factores de $\Delta W = B \cdot A$, con $B \in \mathbb{R}^{d \times r}$ y $A \in \mathbb{R}^{r \times k}$	Hu et al. (2021), §4.1, p. 4. A gaussiana, B inicializada en CERO , de modo que $\Delta W = 0$ al empezar.  Colisión declarada: fuentes/notas-teoricas/s4-llmops-y-finetuning.md §5.2, línea 227, invierte las letras ($\Delta W = A \cdot B$ con A de $d \times r$). Se usa la del paper, que es la del notebook (<code>_fuentes/s4-jue.py</code> , 108-109) y la de <code>s4-jue-explicacion.html</code> (46)
r	el rango de la adaptación	 Cuarta colisión con k/r del curso: no es el r de nada anterior. Hu et al. Tabla 6, p. 10: $r = 1$ basta para $\{W_q, W_v\}$ en WikiSQL y MultiNLI sobre GPT-3. Dettmers et al. §4, p. 6: “la dimensión de proyección r no afecta al desempeño ”
$\alpha, \alpha/r$	la escala que multiplica ΔWx	Hu et al. §4.1, p. 4: “fijamos α al primer r que probamos y no lo ajustamos ”.  El “ $\alpha = r$ o $2r$ ” de notas-s4 línea 234 tiene fuente solo en su primera mitad

Símbolo	Significado	Nota
$\hat{L}_{\text{LoRA}}$	número de matrices a las que se aplica LoRA	$\ \theta\ = 2 \cdot \hat{L}_{\text{LoRA}} \cdot d_{\text{model}} \cdot r$ (Hu et al., p. 6). Cifra derivada, verificada: GPT-3 175B con W_q, W_v en 96 capas $\rightarrow \hat{L} = 192$, y $r = 1$ da 4,7 M, $r = 4$ da 18 M, $r = 8$ da 37,7 M — las tres cifras de las Tablas 4 y 5

Términos

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Foundation model	modelo fundacional	modelo preentrenado a gran escala que sirve como base adaptable a muchas tareas, mediante prompting o ajuste posterior	01
Generative vs. discriminative	generativo vs. discriminativo	modelar $P(X)$ frente a modelar $P(Y X)$	01
Prior	prior (distribución a priori)	lo que se supone de una cantidad no observada antes de ver los datos: $P(\theta)$, o $P(Y)$ y π_k en el plano de la clase	01
Likelihood	verosimilitud	$P(X \theta)$ evaluada en los datos observados y leída como función de θ	01
Posterior	posterior (distribución a posteriori)	lo que se sabe después de observar los datos; siempre decir <i>de qué</i> es posterior: de θ , de la clase o del latente	01
Evidence	evidencia	$P(X)$, el denominador que normaliza en el teorema de Bayes	01
MLE	máxima verosimilitud (MLE)	elegir θ que maximiza $P(X \theta)$; equivale a minimizar la log-verosimilitud negativa	01
Latent variable	variable latente	variable que el modelo postula y nunca observa ; se infiere (EM en GMM y HMM)	01
Autoregressive model	modelo autorregresivo	modela $P(X)$ como $\prod_{t=1}^n P(x_t x_{<t})$ —el producto siempre con sus límites, ver la fila n de Notación—; incorpora sus salidas previas como entrada de la siguiente predicción	01
Ancestral sampling	muestreo ancestral	generar muestreando primero el latente y después la observación condicionada a él	01

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Naive Bayes / GMM / HMM / VAE	Naive Bayes, mezcla de gaussianas (GMM), modelo oculto de Markov (HMM) y autocodificador variacional (VAE)	cuatro formas de factorizar $P(X)$ antes del LLM; se usan como ancestros conceptuales, no como técnicas del curso. Las tres siglas se expanden en su primera aparición del deck y después se dicen sueltas	01
EM	esperanza-maximización (EM)	algoritmo que ajusta por máxima verosimilitud un modelo con variable latente, alternando dos pasos: el paso E calcula la posterior del latente con los parámetros fijos —las responsabilidades $\gamma(z_k)$, que son el teorema de Bayes aplicado al latente— y el paso M reestima los parámetros con esas responsabilidades fijas. No garantiza el máximo global (Bishop 2006, §9.2.2, p. 438)	01
ELBO	cota inferior variacional (ELBO)	$L = E[\log p(x \setminus z)] - KL[q(z \setminus x) \parallel p(z)]$; cota inferior de $\log P(X)$ que se maximiza cuando $P(X)$ es intratable. Kingma & Welling la llaman <i>variational lower bound</i>	02
LLM	modelo grande de lenguaje (LLM)	modelo de lenguaje entrenado a gran escala que factoriza $P(X)$ de forma autorregresiva. Se expande en su primera aparición de cada deck , como el resto de las siglas	01
KL divergence	divergencia de Kullback–Leibler (KL)	mide cuánto se aleja una distribución de otra; no es una distancia , porque no es simétrica. En el ELBO es el término que ata $q(z \setminus x)$ a la prior. No confundir con la penalización KL de RLHF y DPO, que es otra fila de esta tabla	02
RNN	red neuronal recurrente (RNN)	red que procesa la secuencia paso a paso arrastrando un estado oculto de tamaño fijo; su naturaleza secuencial « <i>impide la paralelización</i> » dentro del ejemplo (Vaswani 2017, §1), y ése es el cuello de botella que el transformer quita	02
Reparameterization trick	truco de reparametrización	escribir $z = \mu + \sigma \cdot \epsilon$ con $\epsilon \sim N(0, I)$ para que el muestreo sea diferenciable respecto de los parámetros	02

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Token	token	unidad del vocabulario del modelo; no es una palabra ni un carácter. El mismo texto da conteos distintos según el tokenizador (Raschka 2024, pp. 24 y 35)	02 (mención anticipada en 01)
Tokenization	tokenización	partir el texto en tokens y mapearlos a IDs enteros mediante un vocabulario	02
BPE	byte pair encoding (BPE)	tokenizador subpalabra que parte de caracteres y fusiona iterativamente pares frecuentes; descompone lo desconocido en subpalabras, sin token <\ unk\ >	02
Vocabulary	vocabulario	conjunto de tokens que el modelo puede leer y emitir (50 257 en GPT-2/GPT-3, Raschka p. 34)	02
Attention	atención	mecanismo que pondera tokens del contexto mediante Q, K, V ; la salida es una suma ponderada de los valores , no una decisión ni una intención	02
Self-attention	auto-atención	atención que relaciona posiciones dentro de una misma secuencia (Vaswani 2017, §2)	02
Scaled dot-product attention	atención de producto punto escalada	$\text{softmax}(QK^T/\sqrt{d_k}) \cdot V$ (Vaswani 2017, ec. 1)	02
Context vector	vector de contexto	salida de la atención para una posición: la suma ponderada de los valores. No se escribe z	02
Attention weights	pesos de atención	valores dinámicos , específicos de cada entrada; distintos de los parámetros de peso , que se aprenden y quedan fijos en inferencia (Raschka 2024, p. 66)	02
Causal mask	máscara causal	poner $-\infty$ en los scores de posiciones futuras antes del softmax, para preservar la propiedad autorregresiva	02
Multi-head attention	atención multi-cabeza	h atenciones en paralelo con proyecciones distintas, concatenadas y proyectadas; con $d_k = d_{\text{model}}/h$ el costo total es similar al de una sola cabeza	02

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Positional encoding	codificación posicional	señal de posición que el modelo inyecta porque la auto-atención es agnóstica al orden . ⚠️ No todas se suman: las absolutas – sinusoidal fija (Vaswani 2017, §3.5, p. 6) y aprendida (GPT)– sí se suman al vector del token y por eso comparten su <code>d_model</code> ; la rotatoria (RoPE) no se suma a la entrada, rota queries y keys dentro de la atención (Alammar & Grootendorst 2024, cap. 3, §«Positional Embeddings (RoPE)»). Decir «se suma» a secas describe solo una de las dos familias, y la sesión 02 proyecta las dos	02
Encoder / decoder / encoder-decoder	encoder, decoder, encoder-decoder	atención bidireccional (BERT), atención causal (GPT), y la combinación (T5). Lo que los separa es la máscara	02
Decoder-only	decoder-only	arquitectura de los LLM generativos del curso: auto-atención causal + feed-forward, sin pila de codificador	02
Context window	ventana de contexto	tokens que el modelo puede atender en una llamada ; es el tamaño de entrada soportado y lo que excede se trunca (Raschka 2024, p. 47). No es memoria persistente	02
Pretraining	preentrenamiento	aprendizaje auto-supervisado de next-token prediction sobre corpus sin etiquetas humanas; los objetivos son los mismos tokens desplazados una posición (Raschka 2024, cap. 1, pp. 5–7; §5.1.2)	03
Self-supervision	auto-supervisión	aprendizaje en el que la etiqueta se fabrica de la estructura de los propios datos; en un LLM, el siguiente token del corpus. No hay anotador humano (Raschka 2024, p. 6, recuadro NOTE, y p. 12)	03
Cross-entropy loss	entropía cruzada	la pérdida del preentrenamiento; equivale a la log-probabilidad promedio negativa de los tokens objetivo y es la forma operativa del MLE (Raschka 2024, p. 138)	03

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Perplexity	perplejidad	exp(pérdida) ; se lee como el tamaño efectivo de vocabulario sobre el que el modelo está indeciso en cada paso (Raschka 2024, pp. 139–140). No es una métrica de calidad de respuesta	03
Base model	modelo base	modelo después del preentrenamiento: completa texto según $P_{\theta}(x_{t+1} x_{<t})$, pero aún no fue ajustado para seguir instrucciones de forma fiable (Raschka 2024, §7.1; Ouyang et al. 2022, §1)	03
Emergent behavior	comportamiento emergente	capacidad de realizar tareas para las que el modelo no fue entrenado explícitamente; consecuencia de la exposición a datos, no evidencia de comprensión (Raschka 2024, p. 14)	03
Aligned model	modelo alineado	modelo post-entrenado para aproximar instrucciones, demostraciones o preferencias seleccionadas ; no implica verdad, seguridad ni valores universales	03
Alignment	alineamiento	post-entrenamiento que acerca la conducta del modelo a objetivos o preferencias seleccionados; siempre preguntar alineado a qué señal y de quién (Ouyang et al. 2022, §1)	03
HHH	útil, honesto e inofensivo (HHH)	el marco de tres propiedades con el que InstructGPT define “alineado”, con la advertencia de que la honestidad no se mide directamente y se sustituye por veracidad (Ouyang et al. 2022, §1, p. 2 y §3.6, p. 10)	03
Alignment tax	impuesto de alineamiento (<i>alignment tax</i>)	pérdida de desempeño en tareas de PLN públicas causada por el procedimiento de alineamiento; PPO-ptx es su mitigación conocida (Ouyang et al. 2022, §1, p. 3 y §5.1, p. 17). Traducción fijada por este curso; la industria usa el término en inglés	03
Preference pair	par de preferencias	tupla (x, y_w, y_l) : mismo prompt, respuesta elegida y respuesta rechazada; dato de entrada de RLHF y DPO	03

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Bradley-Terry model	modelo Bradley-Terry	modelo de preferencias que expresa $p(y_1 > y_2 \mid x)$ en función de la diferencia de recompensas; es lo que justifica la pérdida logística de RLHF y de DPO (Rafailov et al. 2023, ec. 1, p. 3)	03
Reward model / preference model (PM)	modelo de recompensa; en Constitutional AI, modelo de preferencias (PM) (Bai et al. 2022, §1.2, p. 5)	función escalar $r_\phi(x, y)$ aprendida de comparaciones; es un proxy de preferencias , no una función de verdad	03
Unembedding layer	capa de des-incrustación	la capa final que proyecta al vocabulario y produce los logits; es lo que se quita al modelo SFT para construir un modelo de recompensa escalar (Ouyang et al. 2022, §3.5, p. 8: “ <i>with the final unembedding layer removed</i> ”). Forma fijada por este curso ; es la única que se usa, y es coherente con traducir <i>embedding</i> como representación vectorial. Decir “la capa final” a secas es impreciso	03 (se reutiliza en 04)
Reference policy	política de referencia	política congelada respecto de la cual se limita el alejamiento en RLHF y se calculan los cocientes de DPO; suele ser el modelo SFT (Rafailov et al. 2023, §§3–4)	03
KL penalty	penalización KL	término que limita el alejamiento de π_θ respecto de π_{ref} ; en RLHF es explícito y en DPO queda dentro de la parametrización (Ouyang et al. 2022, ec. 2, p. 9; Rafailov et al. 2023, ec. 3, p. 3 y §4, p. 4)	03
SFT / instruction fine-tuning	ajuste supervisado (SFT); Raschka lo llama también <i>supervised instruction fine-tuning</i> (§7.1, p. 205)	ajuste de la política sobre demostraciones (instrucción, respuesta deseada) mediante aprendizaje supervisado	03
Prompt style / prompt template	plantilla de prompt (<i>prompt style</i>)	formato con el que se envuelve el par instrucción-respuesta para entrenar (Alpaca, Phi-3); es lo que convierte “seguir una instrucción” en “continuar un texto” (Raschka 2024, Fig. 7.4, p. 208)	03

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Preference tuning	ajuste por preferencias (<i>preference tuning</i>)	el tercero de los tres pasos que producen un LLM de calidad, después del preentrenamiento y del SFT: ajusta la salida del modelo a preferencias definidas por los datos que se le dan, «más alineada con la conducta esperada de seguridad de la IA o de preferencias humanas» (Alammar & Grootendorst 2024, cap. 12, §«The Three LLM Training Steps», pp. 355–357; el paso 3 se define en la p. 357). Es el paraguas, no un método: RLHF y DPO son dos formas de hacerlo, y el curso mete bajo él también Constitutional AI, que optimiza preferencias etiquetadas por IA. Traducción fijada por este curso. ⚠ No es sinónimo de <i>alineamiento</i> : el alineamiento es el objetivo y el ajuste por preferencias es el paso que lo persigue con datos de preferencia; decir «RLHF» donde va el paraguas es el error grave de la sesión 03	03
RLHF	RLHF	SFT → preferencias humanas → modelo de recompensa explícito → RL/PPO, con restricción respecto de una política de referencia (Ouyang et al. 2022, §1; Rafailov et al. 2023, §3)	03
PPO	PPO	el algoritmo de aprendizaje por refuerzo que InstructGPT usa en el paso 3. Se nombra, no se describe: su paper no está en fuentes/papers/ (Ouyang et al. 2022, §3.5, p. 9)	03
DPO	DPO	optimización directa de la política sobre pares de preferencias, sin modelo de recompensa separado ni bucle de RL; conserva recompensa implícita y política de referencia (Rafailov et al. 2023, §4)	03
Implicit reward	recompensa implícita	$\hat{r}_\theta(x, y) = \beta \cdot \log [\pi_\theta(y \setminus x) / \pi_{\text{ref}}(y \setminus x)]$; la función de recompensa que DPO no entrena por separado porque está definida por la propia política (Rafailov et al. 2023, §4, p. 5)	03

Término	Cómo se dice en clase	Definición operativa	Se introduce en
RLAIF	RLAIF	aprendizaje por refuerzo desde retroalimentación de IA; en Constitutional AI, la IA etiqueta preferencias de inocuidad (<i>harmlessness</i>) y el estudio conserva etiquetas humanas de utilidad (<i>helpfulness</i>)	03
Constitutional AI	Constitutional AI	principios escritos guían dos etapas: crítica/revisión + SFT, y comparaciones de IA + modelo de preferencias + RLAIF (Bai et al. 2022, §1.2)	03
Feedback model	modelo de retroalimentación (<i>feedback model</i>)	en Constitutional AI, el modelo independiente que etiqueta qué respuesta es menos dañina (Bai et al. 2022, §4.1, p. 10)	03
Red-teaming	red-teaming	generación deliberada de prompts que buscan provocar comportamiento dañino, para producir datos de entrenamiento o de evaluación (Bai et al. 2022, §3.1, p. 7)	03 (anticipo; se desarrolla en 18)
Inference	inferencia	la tercera etapa del ciclo de vida: usar el modelo ya entrenado. Nada de lo que se hace aquí modifica θ	04
Decoding strategy	estrategia de decodificación	la función que convierte la distribución sobre el vocabulario en un token elegido : greedy, temperatura, top-k, top-p. Raschka las llama <i>text generation strategies</i> o <i>decoding strategies</i> (2024, §5.3, p. 151)	04
Greedy decoding	decodificación greedy	tomar el argmax de la distribución en cada paso. Produce la misma salida en cada corrida sobre el mismo contexto de inicio (Raschka 2024, §5.3.1, p. 152). $T = 0$ es greedy; eso no equivale a reproducibilidad de extremo a extremo en una API , que depende de cosas que ninguna fuente del curso documenta	04
Temperature / top-p	temperatura / top-p	parámetros de muestreo; describen qué se le hace a la distribución , no “la creatividad”. $T > 1$ la aplana, $T < 1$ la afila, $T = 1$ no la toca (Raschka 2024, §5.3.1, p. 154)	04

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Top-k sampling	muestreo top-k	conservar los k tokens de mayor logit y enmascarar el resto con $-\infty$ antes del softmax; es la misma máscara de la atención causal, aplicada a otra cosa (Raschka 2024, §5.3.2, pp. 155–157). Corte de número fijo	04
Nucleus sampling (top-p)	muestreo top-p (<i>nucleus</i>)	conservar el prefijo más pequeño de tokens cuya probabilidad acumulada alcanza p, y renormalizar. Corte adaptativo : el mismo p deja más tokens cuanto más plana esté la distribución. ⚠️ No hay fuente bibliográfica en el repositorio (falta Holtzman et al. 2020); la definición operativa del curso es <code>curso/actividades/_fuentes/s1-mie.py</code> , líneas 70–77	04
Structured output	salida controlada	respuesta forzada a un esquema (JSON mode, structured outputs). Pedir un esquema es una instrucción; tenerlo es un hecho verificado : hay que validar sintaxis, esquema y dominio con código	04
In-context learning	aprendizaje en contexto	condicionar con ejemplos en el prompt; no actualiza pesos. Brown et al. (2020), §1, p. 5: “no involucran actualizaciones de gradiente ni ajuste fino, solo un número creciente de demostraciones dadas como condicionamiento”	04
Zero-shot / one-shot / few-shot	zero-shot, one-shot, few-shot	0, 1 o K demostraciones en el prompt, siempre sin actualizar pesos ; el ajuste fino es el cuarto punto del espectro y es el único que sí los actualiza (Brown et al. 2020, §2, pp. 6–7)	04
Chain-of-thought	cadena de razonamiento (CoT)	pedir pasos intermedios antes de la respuesta. En Wei et al. (2022) es una variante de few-shot : ejemplares con la forma <code>(entrada, cadena de pensamiento, salida)</code> (§1, p. 2). La variante zero-shot CoT (“piensa paso a paso”) es de otro paper que no está en fuentes/papers/	04

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Self-consistency	self-consistency	muestrear varias cadenas de razonamiento con $T > 0$ y quedarse con la respuesta final mayoritaria . Se nombra, no se describe : su paper (Wang et al. 2022a) no está en <code>fuentes/papers/</code> ; se conoce a través de Wei et al. (2022), §3.1, p. 4	04
Prompt	prompt	entrada completa al modelo: system, instrucciones, contexto y ejemplos	03 (uso operativo), 04 (se desarrolla)
Prompt injection	prompt injection	texto de un tercero que entra al prompt como dato y contiene instrucciones ; el modelo no distingue lo uno de lo otro por sí solo. Primera mitigación: delimitar el dato y ordenar explícitamente que no se obedezca su contenido	04 (anticipo; se desarrolla en 18)
Latency	latencia (de extremo a extremo)	tiempo de reloj de la llamada completa , del envío hasta la última porción de la respuesta. Es lo que mide <code>curso/labs/Lab-01-Foundation-Models/plantilla_lab01.py</code> , líneas 72-78 (<code>time.time()</code> alrededor de <code>create</code>). ⚠️ No es TTFT ni tokens por segundo : ninguna fuente del repositorio los define y la plantilla no los mide. Crece con los tokens de salida, así que para comparar modelos conviene reportar también <code>latencia / tokens_salida</code> . Tampoco es la latencia de consulta de un índice (ver sesión 07)	05
Cost per 1M tokens	costo por millón de tokens	la unidad en que la tabla semestral publica los precios (<code>fuentes/modelos/modelos-2026-1.json</code> , <code>"pricing_unit": "1M tokens"</code> , y <code>"embeddings_pricing_unit"</code> para la clave <code>embeddings</code>). Todo precio se cita con la fecha de verificación de su fila , que no es la misma para todas: 2026-07-10 en las filas de Anthropic, 2026-08-26 en <code>gpt-4o-mini</code> y 2026-08-27 en las filas de embeddings. Nunca se escribe a mano	05

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Blind evaluation	evaluación a ciegas	puntuar una respuesta sin saber qué modelo o qué variante la produjo (<code>curso/actividades/semana-1/s1-sab-taller.html</code>). Es el precursor humano del LLM como juez de la sesión 16 y comparte su motivo: sin ella, la puntuación mide la expectativa del anotador tanto como la respuesta	05
Reproducible baseline	línea base reproducible	<i>“código ejecutable, dependencias declaradas y resultados verificables”</i> (<code>curso/silabo/silabo.md</code> , categorías de evaluación). Es el criterio de reproducibilidad de los cuatro talleres; incluir un <code>requirements.txt</code> sin versiones fijadas cumple la letra y no el criterio	05
Embedding	representación vectorial (embedding)	vector denso donde la cercanía aproxima similitud semántica	02 (uso operativo), 06 (se desarrolla)
Semantic space	espacio semántico	espacio vectorial en el que <i>“oraciones semánticamente similares están cerca”</i> (Reimers & Gurevych 2019, §1, p. 1, nota al pie 2). Es una propiedad que se entrena, no una consecuencia de tener vectores	06
Sentence embedding	representación vectorial de oración	un vector de tamaño fijo por texto, obtenido por <i>pooling</i> sobre los vectores de salida del encoder. No es el embedding de token, que es una fila de la matriz de la capa de embedding (Raschka 2024, §2.7, p. 43). Solo el de oración se indexa	06
Pooling	<i>pooling</i> (agregación)	operación que reduce los <i>n</i> vectores de salida del encoder a uno : MEAN (por defecto), MAX o el vector del token CLS (Reimers & Gurevych 2019, §3, p. 3; ablación en Tabla 6, p. 7)	06

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Contrastive learning	entrenamiento contrastivo	acercar los vectores de pares que “van juntos” y alejar los de pares aleatorios. Es el nombre de la familia (fuentes/notas-teoricas/s2-rag-y-vector-search.md , §2.2); en Sentence-BERT la instancia literal es la pérdida triplet , y el resultado principal se obtuvo con un objetivo de clasificación sobre NLI (§3 y §3.1, p. 3). No colapsar los dos niveles en una sola frase	06
Siamese network	red siamesa	un modelo aplicado dos veces con pesos atados (<i>tied weights</i>), no dos modelos (Reimers & Gurevych 2019, Fig. 1, p. 3). Es lo que permite embeber cada documento por separado y una sola vez	06
Bi-encoder	bi-encoder	codificar consulta y documento por separado y comparar los vectores; permite precalcular todo el corpus. ⚠ El término no aparece en Reimers & Gurevych (2019) , que dice “ <i>siamese network structure</i> ”: es el nombre de la industria, adoptado por este curso para poder contrastarlo con <i>cross-encoder</i>	06
Cross-encoder	cross-encoder	pasar el par (consulta, documento) junto por la red y predecir un puntaje. Más preciso y no precalculable : comparar n textos entre sí exige $n(n-1)/2$ inferencias (Reimers & Gurevych 2019, §1, pp. 1-2)	06 (se desarrolla en 08, como reordenador)
Cosine similarity	similitud coseno	producto punto de vectores normalizados; sin normalizar es otra cosa	06
Dot product	producto punto	$u \cdot v$. Solo es una similitud coseno si ambos vectores están normalizados . Sin normalizar premia la magnitud y puede invertir el orden de los resultados	06

Término	Cómo se dice en clase	Definición operativa	Se introduce en
L2 normalization	normalización L2	dividir un vector por su norma euclídea para dejarlo de norma 1. Es lo que hace que producto punto y coseno sean el mismo número ; no ocurre sola: en el notebook del curso es un argumento explícito, <code>normalize_embeddings=True</code> (<code>curso/actividades/_fuentes/s2-lun.py</code> , línea 36), y la ficha del modelo dice si viene de fábrica (campo <code>normaliza_por_defecto</code> de <code>fuentes/modelos/modelos-2026-1.json</code> , clave <code>embeddings</code> , verificado 2026-08-27)	06
Embedding dimension	dimensión del embedding	número de componentes del vector, d . Se lee de fuentes/modelos/modelos-2026-1.json , clave embeddings , campo dimensions , con su fecha de verificación — nunca de memoria. Determina la memoria del índice: a igual número de fragmentos, 3072 guarda 8× más números que 384	06 (se cobra en 07)
Max sequence length	longitud máxima de secuencia	tokens que el modelo de embeddings procesa de una entrada ; lo que excede se descarta . Campo <code>max_seq_tokens</code> del JSON (verificado 2026-08-27: 128 en <code>all-MiniLM-L6-v2</code> , 8192 en <code>bge-m3</code> , <code>text-embedding-3-small</code> y <code>-3-large</code>). No es la ventana de contexto de un LLM ni el tamaño del fragmento: es su techo	06 (se cobra en 08)
Silent truncation	truncado silencioso	indexar un fragmento más largo que <code>max_seq_tokens</code> : el sistema no falla, no avisa y devuelve resultados , pero nunca podrá recuperar lo que quedó fuera. Con <code>chunk_size = 512</code> y <code>max_seq_tokens = 128</code> se indexa el primer cuarto de cada fragmento y se descartan 384 de cada 512 tokens. Con el andamiaje real del Lab 02 es peor: ver <i>Chunk size / overlap</i>	06 (se cobra en 08)

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Dense retrieval	recuperación densa	recuperar comparando vectores de la consulta y de los fragmentos, en vez de coincidencia de términos. Fuerte en sinónimos y paráfrasis; débil en identificadores exactos, códigos y nombres propios (<code>fuentes/notas-teoricas/s2-rag-y-vector-search.md</code> , §5.2)	06 (se contrasta con BM25 en 08)
Vector database	base de datos vectorial	motor que guarda vectores y los busca. Es más que su índice: una colección (que declara dimensión y métrica), puntos (vector + payload), un índice ANN y filtros de metadata . <i>El índice hace rápida la búsqueda; el payload la hace útil</i>	07
Exhaustive / brute-force kNN	kNN exacto	comparar la consulta contra los N vectores: $O(N \cdot d)$. Es la verdad de referencia contra la que se mide un índice aproximado, y con N pequeño sigue siendo la respuesta correcta (<code>s2-mar-explicacion.html</code> , línea 38; <code>curso/actividades/_fuentes/s2-mar.py</code> , líneas 50-52 y 185-187)	07
ANN	búsqueda aproximada de vecinos más cercanos (ANN)	renunciar a la exactitud garantizada a cambio de velocidad: “ <i>devuelven casi siempre los vecinos correctos</i> ” (<code>s2-mar-explicacion.html</code> , líneas 41-42). Aproximado no es impreciso: es una pérdida conocida y medible , y por eso se puede negociar	07
Index recall	recall del índice	fracción de los k vecinos que el kNN exacto habría devuelto y que el índice sí devolvió. Su verdad de referencia se calcula, no se anota (<code>s2-mar.py</code> , líneas 111 y 120). No es el Recall@k de la sesión 09	07

Término	Cómo se dice en clase	Definición operativa	Se introduce en
HNSW	HNSW	grafo de proximidad jerárquico : capas altas con saltos largos, capa base con todos los vectores; la búsqueda entra por arriba y baja refinando. Perillas <code>M</code> , <code>ef_construction</code> y <code>ef_search</code> (<code>fuentes/notas-teoricas/s2-rag-y-vector-search.md</code> §3.2; <code>s2-mar-explicacion.html</code> §2). ⚠ Su paper (Malkov & Yashunin) no está en <code>fuentes/papers/</code>: se describe a nivel intuitivo, con las notas del curso como fuente	07
IVF	IVF (índice de archivo invertido)	k-means agrupa los <code>N</code> vectores en <code>nlist</code> celdas; la consulta compara contra los centroides y busca exacto dentro de las <code>nprobe</code> más cercanas. El recall se pierde en las fronteras entre celdas , y <code>nprobe = nlist</code> es la búsqueda exacta (§3.3; <code>s2-mar-explicacion.html</code> §3)	07
Product quantization / IVF-PQ	cuantización de vectores (PQ)	comprimir los vectores del índice para que ocupen menos RAM; se combina con IVF para corpus grandes (§3.3, línea 95; <code>s2-mar-explicacion.html</code> , línea 77). Se nombra, no se describe : ninguna fuente del repositorio lo explica. No es la cuantización de pesos de QLoRA (sesión 19)	07
Collection / point / payload	colección, punto, payload	la colección declara dimensión y métrica ; un punto es vector + payload ; el payload lleva el texto y los metadatos que hacen falta para responder (<code>s2-mar.py</code> , líneas 153–157; <code>curso/labs/Lab-02-RAG-VectorSearch/rag_pipeline.py</code> , líneas 36–51)	07
Metadata filter	filtro de metadata	restringir la búsqueda vectorial a los puntos cuyo payload cumple una condición; no reemplaza la búsqueda por similitud, la acota (<code>s2-mar.py</code> , líneas 161–166)	07

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Embedded vs. server mode	modo embebido / modo servidor	QdrantClient(":memory:") no necesita infraestructura y no persiste ; QdrantClient(url=...) habla con un servicio —en el curso, docker run qdrant/qdrant— y persiste. El notebook de la sesión 07 usa el primero y el Taller 2 el segundo (s2-mar.py, línea 152; Lab-02-RAG-VectorSearch/README.md, línea 8)	07
RAG	recuperación aumentada con generación (RAG)	recuperar contexto y generar condicionado a él, sin modificar θ . Lo que el curso llama RAG es el Naive RAG de Gao et al. (2023), §II.A, p. 3: el marco “Retrieve-Read”. ⚠ El RAG de Lewis et al. (2020) no es eso : ajusta el <i>query encoder</i> y el generador de extremo a extremo y trata el documento como variable latente (§2.4, p. 4)	08
Naive / Advanced / Modular RAG	RAG ingenuo, avanzado y modular	los tres paradigmas de Gao et al. (2023), §II, pp. 3–5. <i>Advanced</i> añade pre-recuperación (reescritura de consulta) y post-recuperación (reordenar, comprimir); <i>Modular</i> recombina módulos. Los dos últimos se nombran, no se enseñan	08
Chunking	fragmentación (chunking)	partir documentos en unidades indexables. El fragmento es la unidad de todo el sistema : lo que se embebe (Lab-02/rag_pipeline.py, línea 35), lo que se indexa con su <code>chunk_id</code> (Lab-02/ingestion.py, línea 74), lo que se cita (rag_pipeline.py, línea 76) y lo que se anota como correcto en el golden set (Lab-02/evaluation.py, línea 29). Cambiar de estrategia cambia las cuatro cosas	08

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Chunk size / overlap	tamaño de fragmento y solapamiento	siempre con su unidad. En el curso circulan tres: 300 caracteres (<code>_fuentes/s2-mie.py</code> , línea 55), 500 y 512 tokens (<code>s2-mie-explicacion.html</code> , línea 77; <code>notas-s2 §4.2</code>) y 900 palabras (<code>Lab-02/ingestion.py</code> , líneas 50 y 53). El techo del modelo está en tokens , así que un <code>chunk_size</code> en otra unidad no es comparable con él: con 900 palabras (≥ 900 tokens) y <code>max_seq_tokens = 128</code> , se descarta al menos el 85,8 % de cada fragmento	08
Index inflation	inflación del índice por solapamiento	con fragmento <code>C</code> y solapamiento <code>V</code> se indexa $1/(1 - V/C)$ veces el texto original. Con los parámetros del Lab 02 (900/150) son +20 % exacto , dentro de la horquilla “~15–25 %” de <code>s2-mie-explicacion.html</code> , línea 121	08
Contextual chunking	fragmentación contextual	“el <i>chunk indexado</i> = <i>contexto</i> + <i>chunk original</i> ”, con el contexto generado por un LLM durante la ingesta (<code>notas-s2 §4.2</code> , líneas 138–142). ⚠ Su fuente de benchmarks no está registrada en <code>fuentes/web/fuentes-web.md</code> y es un post de proveedor: la afirmación de mejora NO es citable. Y alarga el fragmento , así que empeora el truncado	08
Retrieval	recuperación	traer los top-k fragmentos más relevantes para una consulta. k es perilla de consulta : se cambia sin reindexar. Subirlo es gratis para el índice y caro para el modelo (Gao et al. 2023, §IV.A.2, p. 10)	08
BM25	BM25	recuperación léxica por frecuencia de términos, con tres piezas: IDF (rareza), saturación de la frecuencia y normalización por longitud vía <code>\ d\ /avgd\ </code> (<code>notas-s2 §5.1</code> , línea 163). Fuerte en siglas, IDs y nombres propios; ciega a los sinónimos. Medido : gana en FEVER (75,1 vs. 74,5) y pierde por 12,2 puntos en Natural Questions (Lewis et al. 2020, Tabla 6, p. 8)	08

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Hybrid search	búsqueda híbrida	combinar recuperación léxica y densa porque “capture different relevance features” y “assist dense retrievers in handling queries containing rare entities” (Gao et al. 2023, §III.D.1, p. 9). ⚠️ Ninguna lectura del curso cuantifica la ganancia	08
Reciprocal Rank Fusion (RRF)	fusión por rango recíproco (RRF)	$1/(k_RRF + rank_1) + 1/(k_RRF + rank_2)$, con $k_RRF = 60$ (notas-s2 §5.3, línea 184). Combina posiciones, no puntajes —por eso puede mezclar un BM25 sin cota con un coseno en $[-1, 1]$ — y premia el acuerdo sobre el dominio : estar 2.º en las dos listas (0,0323) vale casi el doble que estar 1.º en una sola (0,0164). ⚠️ Su paper (Cormack et al. 2009) no está en fuentes/papers/	08
Reranking	reordenamiento (reranking)	segunda etapa: el bi-encoder trae top-20 y un cross-encoder los reordena a top-5 (notas-s2 §5.4). Cuesta 20 inferencias por consulta, independiente de N , frente a N si se cross-encodiera el corpus. Reordena; no recupera : lo que la primera etapa no trajo, el reordenador no lo puede ver. ⚠️ En Lewis et al. (2020), §4.1, p. 5, no hizo falta	08
Two-stage retrieval	recuperación en dos etapas	el patrón que hace viable el cross-encoder: recuperar barato y ancho, reordenar caro y estrecho . Es la resolución del compromiso bi-encoder/cross-encoder que la sesión 06 dejó abierta	08
Lost in the middle	“perdido en el medio”	“LLM tends to only focus on the beginning and end of long texts, while forgetting the middle portion” (Gao et al. 2023, §IV.A, p. 10). Es por qué el orden de los fragmentos en el prompt importa y por qué subir k puede empeorar la respuesta	08

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Negative rejection	rechazo negativo	“the model’s discernment in refraining from responding when the retrieved documents do not contain the necessary knowledge” (Gao et al. 2023, §VI.C.2, p. 12). Es la conducta ; su medición —la tasa de abstención del Taller 2— es de la sesión 09	08
Recall@k / MRR / Hit Rate	Recall@k, MRR, Hit Rate	métricas de recuperación , no de generación. Su verdad de referencia se anota (golden set), a diferencia del <i>recall del índice</i> de la sesión 07, que se calcula	09
Golden set	conjunto de referencia (golden set)	pares (pregunta → fragmentos o documentos que la responden) curados por un humano (s2-jue-html , 37–39). Es un artefacto con dueño, versión y caducidad , no un trámite: sus <code>expected_chunk_ids</code> apuntan a identificadores que el chunker inventó (<code>ingestion.py</code> , 74), así que re-fragmentar sin re-anotar produce un número que no significa nada y no lanza ningún error	09
Faithfulness	fidelidad al contexto	$F = \frac{ \mathcal{V} }{ \mathcal{V} + \mathcal{S} }$: fracción de las afirmaciones extraídas de la respuesta que se infieren del contexto (ragas §3, p. 3). Métrica de generación . Es la que mejor concuerda con humanos en el paper: 0,95 de exactitud por pares (Tabla 1, p. 5, WikiEval)	09 (se desarrolla en 16)
Hallucination	alucinación	afirmación fluida sin respaldo en el contexto ni en los hechos	09
GraphRAG	GraphRAG	grafo de entidades y relaciones extraído por un LLM, particionado en comunidades (Leiden) cuyos resúmenes se pre-generan ; la consulta es un map-reduce sobre esos resúmenes (graphrag §3.1). Existe porque el RAG vectorial “ <i>fails on global questions... inherently a query-focused summarization task, rather than an explicit retrieval task</i> ” (abstract, p. 1). Gana en cobertura y diversidad, pierde en concisión, y cuesta: 281 min de indexación por 1 M de tokens (§4.1.3, p. 9)	09

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Agent	agente	sistema que decide qué herramienta invocar y cuándo , en bucle, hacia un objetivo	11
Tool use / function calling	uso de herramientas	el modelo emite una llamada estructurada que ejecuta código externo	11
ReAct	ReAct	aumentar el espacio de acciones con acciones de lenguaje (<i>thoughts</i>) que no afectan al entorno y por tanto no producen observación: $\tilde{A} = A \cup L$ (Yao et al. 2023, §2, p. 3). El bucle pensamiento $\rightarrow$ acción $\rightarrow$ observación es la consecuencia, no la definición. Medido sobre PaLM-540B congelado con 6 y 3 ejemplos: gana en FEVER (60,9 vs. 56,3 de CoT) y pierde en HotpotQA (27,4 vs. 29,4), Tabla 1, p. 5	12
Plan-and-Execute	planificar y ejecutar	plan completo primero (1 llamada, modelo capaz), ejecución paso a paso después (n llamadas, posiblemente modelo barato); “ <i>sin re-decidir la estrategia en cada turno</i> ”. ⚠️ Sin paper en fuentes/papers/ : sus únicas fuentes son <code>fuentes/notas-teoricas/s3-agentes.md</code> §3.2 y <code>s3-mar-explicacion.html</code> §2. No se proyecta ninguna cifra	12
Reflexion	Reflexion	tres modelos —Actor, Evaluador y Auto-reflexión— más dos memorias , que convierten una señal escalar de fallo en texto dentro del contexto del intento siguiente (Shinn et al. 2023, §3, pp. 3–4). El Actor puede ser CoT o ReAct : no compite con ReAct, lo envuelve	12
MCP	Model Context Protocol (MCP)	estándar para conectar modelos con herramientas y datos	13
Supervisor pattern	patrón supervisor	un agente coordinador reparte trabajo entre agentes especializados	14
Hand-off	traspaso (hand-off)	ceder el control de la conversación a otro agente	14

Término	Cómo se dice en clase	Definición operativa	Se introduce en
LLM-as-judge	LLM como juez	usar un modelo para calificar salidas de otro. Tres variantes (zheng §3.1, p. 4): comparación por pares, puntuación de una sola respuesta y puntuación guiada por referencia. ⚠ De sus tres sesgos, el paper cuantifica dos y declara que no puede concluir sobre el tercero: posición (consistencia 65,0 % en GPT-4 y 23,8 % en Claude-v1, Tabla 2, p. 5) y verbosidad (tasa de fallo 91,3 % en Claude-v1 y GPT-3.5, 8,7 % en GPT-4, Tabla 3, p. 5), frente a autopreferencia: “our study <i>cannot determine whether the models exhibit a self-enhancement bias</i> ” (§3.3, p. 5). Se nombran los tres —la rúbrica lo exige— diciendo cuál está medido	16
RAGAS	RAGAS	marco de evaluación sin referencia para RAG, con tres métricas: <i>Faithfulness</i> , <i>Answer Relevance</i> y <i>Context Relevance</i> (ragas §3, pp. 3–4). ⚠ Context Precision y Context Recall NO existen en el paper , aunque los citen notas–s2 §6.2 y notas–s4 §2.3. ⚠ La librería no es proyectable: https://docs.ragas.io está registrada sin fecha de consulta (0.ar)	09 (métricas), 16 (aplicación)
Observability	observabilidad	poder reconstruir y atribuir una corrida a partir de lo que el sistema emitió: qué pasó, cuánto costó, cuánto tardó, con qué modelo y con qué versión del prompt. No es logging: el modo de fallo característico de un sistema con LLM —respuesta plausible y falsa, corrida seis veces más cara— devuelve HTTP 200 y no entra en ningún log de errores (s4–mar–explicacion.html , 37–42). Regla del curso: “si no está en la traza, no pasó”	17

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Trace / span	traza / span	traza = el registro de una corrida completa , con trace_id único; span = un paso dentro de ella —llamada al LLM, llamada a herramienta, etapa del pipeline— con input, output, duración, tokens, costo y error (notas-s4 §3.2, 111–114). Los spans se anidan vía un campo padre , como en el tracing distribuido clásico (s4-mar-explicacion.html, 55–58). El span es lo que se mide; la traza es lo que se audita : una traza sin spans dice cuánto costó la corrida y no dice dónde . ⚠ No es la traza del agente de la sesión 11 , que es una lista en memoria sin tiempos ni costo	17 (la traza del agente, en 11)
Prompt versioning	versionado de prompts	tratar el prompt como artefacto con id , versión y changelog , evaluado contra el golden set antes de desplegarse y con rollback disponible (notas-s4 §3.4, 152–158; s4-mie-explicacion.html §2, 56–64). Dos opciones: archivos en git (Opción A) o gestión en plataforma (Opción B). Su mitad observable es un campo de la traza : sin prompt_version en cada corrida, “ <i>el antes/después es imposible de reconstruir</i> ” (s4-mar-explicacion.html, 114–115). ⚠ curso/talleres/taller-04-LLmops.md no lo evalúa en ninguna parte	17 (el campo) · 18 (el ciclo completo, <code>_fuentes/s4-mie.py</code> 162–200)
Guardrail	guardrail	validación de entrada o salida que bloquea , corrige o deja pasar antes de continuar. Es código fuera del modelo , y por eso se ejecuta siempre, a diferencia de una instrucción del prompt. <code>curso/labs/Lab-04-LLMops/guardrails.py</code> implementa las tres salidas: bloquea (43, 49) y corrige (44). ⚠ No cambia θ : no es alineamiento (sesión 03)	18
Jailbreak	jailbreak	entrada diseñada para eludir las restricciones del modelo	18
PII	datos personales (PII)	información que identifica a una persona; se filtra antes de salir	18

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Prompt caching	prompt caching	reutilizar el prefijo ya procesado para bajar costo y latencia (fuentes/notas–teoricas/s4–llmops–y–finetuning.md §4.3, 191). ⚠ BLOQUEO DE VIGENCIA: fuentes/modelos/modelos–2026–1.json no tiene ningún campo de caché , y estimate_cost (plantilla_lab01.py, 48–54) solo conoce dos clases de token. No es un descuento: es otro modelo de facturación , y el curso no puede representarlo. Ningún porcentaje se proyecta	18
Semantic caching	caché semántico	responder desde caché cuando la consulta es semánticamente equivalente : “Si <i>embed(nueva_query) ≈ embed(query_previa)</i> , retornar <i>respuesta_previa</i> ” (notas–s4 §4.3, 206–211). Es un umbral fijo sobre embeddings , así que hereda la semana 2: sin normalizar los dos lados el umbral se rompe en silencio, y con max_seq_tokens = 128 (JSON, 2026-08-27) dos prompts que difieren tras el token 128 son el mismo vector . ⚠ Un acierto de caché es una respuesta que ninguna llamada generó : no tiene traza ni pasa por el guardrail de salida	18
PEFT	ajuste fino eficiente en parámetros (PEFT)	reparametrizar el cambio $\Delta\theta$ con un conjunto θ mucho menor y entrenar solo θ , con el modelo base congelado (Hu et al. 2021, §2, ec. 2, p. 3). Es una familia, no un método : adaptadores, prefix/prompt tuning, IA ³ , sesgos, máscaras de Fisher. ⚠ Este curso enseña uno solo , y Dettmers et al. (2023), §7, p. 14, declara que “ <i>deja a trabajo futuro explorar los compromisos de otros enfoques PEFT</i> ”	19

Término	Cómo se dice en clase	Definición operativa	Se introduce en
LoRA	adaptación de bajo rango (LoRA)	$h = W_0 x + B \cdot A \cdot x$, con W_0 congelado, $B \in \mathbb{R}^{d \times r}$ inicializada en cero y $A \in \mathbb{R}^{r \times k}$ gaussiana (Hu et al. 2021, §4.1, ec. 3, p. 4). Se puede fusionar ($W = W_0 + BA$) → “ninguna latencia adicional de inferencia, por construcción”. ⚠ Todas sus cifras son de 2021 y sobre RoBERTa, DeBERTa, GPT-2 y GPT-3 en GLUE, E2E NLG, WikiSQL, MultiNLI y SAMSum. ⚠ Solo adaptó pesos de atención; MLP, LayerNorm y sesgos quedaron “para trabajo futuro” (§4.2, p. 5)	19
QLoRA	QLoRA	LoRA sobre un base congelado y cuantizado a 4 bits , con almacenamiento en NF4 y cómputo en BFloat16 ; los gradientes se calculan solo para los parámetros LoRA (Dettmers et al. 2023, §3, ec. 5, p. 5). Medido: 65B de >780 GB a <48 GB. ⚠ Lo que NO demostró, literal: “no establecimos que QLoRA pueda igualar el ajuste fino completo de 16 bits a escalas de 33B y 65B” (§8, p. 15); la comparación contra ajuste fino completo llega solo hasta 3B (§4, p. 6)	19
Drift	deriva	degradación de calidad en producción respecto de la línea base medida	19
Hit Rate@k	Hit Rate@k	fracción de preguntas con al menos un fragmento relevante en el top-k. Es un booleano promediado : no le importa cuántos ni en qué posición (<code>_fuentes/s2-jue.py</code> , línea 95). Con un relevante por pregunta coincide numéricamente con Recall@k	09
Recall@k	Recall@k	$\frac{ \text{relevantes en top-}k }{ \text{relevantes} }$ (<code>s2-jue-html</code> , línea 51). Sólo se separa del Hit Rate cuando hay varios relevantes , y por eso el golden set necesita preguntas multi-documento. ⚠ evaluation.py del Lab 02 no lo calcula (líneas 42–43)	09

Término	Cómo se dice en clase	Definición operativa	Se introduce en
MRR	MRR (<i>mean reciprocal rank</i>)	promedio de 1/posición del primer acierto (<code>s2-jue.html</code> , línea 52; <code>s2-jue.py</code> , 102-111). ⚠ NO es la posición promedio , como escriben <code>taller-02</code> línea 65 y <code>notas-s2</code> §6.1: con aciertos en 1 y 5, la posición media es 3 y el MRR es 0,6 (equivalente a la posición 1,67)	09
Tipos de pregunta del golden set	simple, multi-chunk, negativa, adversarial	los cuatro valores del campo <code>tipo</code> de <code>golden_set_plantilla.json</code> . <code>evaluation.py</code> lee el campo (línea 36) y no segmenta ninguna métrica con él (42-43)	09
Pregunta negativa	pregunta negativa (sin respuesta en el corpus)	pregunta cuya respuesta correcta es abstenerse . <code>taller-02</code> , línea 61, exige ≥ 2 . ⚠ Con <code>expected_chunk_ids</code> vacío, <code>evaluation.py</code> la cuenta como fallo (líneas 29, 21-23, 37) y baja el Hit Rate : el sistema que hace lo correcto es penalizado	09
Tasa de abstención	tasa de abstención	“¿el sistema reconoce que el corpus no contiene la respuesta?” (<code>taller-02</code> , línea 66). Hacen falta dos : la correcta sobre las negativas y la indebida sobre las respondibles — porque un sistema que se abstiene siempre tiene la primera en 1,0 y es inútil. ⚠ No está implementada en el Lab 02, y no puede estarlo con <code>evaluate_retrieval</code> , que nunca genera respuestas	09
Golden set complaciente	golden set complaciente	“10 preguntas fáciles con las palabras exactas del documento dan Hit Rate 1.0 y cero información” (<code>s2-sab.html</code> , línea 67). El antídoto: ≥ 3 preguntas con vocabulario distinto al del documento (<code>s2-jue.html</code> , línea 42)	09
Resolución de la métrica	resolución de la métrica	el escalón mínimo observable: 1 / número de preguntas . Con 10 preguntas es 0,1 ; con las 8 del notebook, 0,125 . Una mejora menor que la resolución no se puede distinguir de ninguna mejora . Es por qué el notebook advierte que las métricas “necesitan volumen para discriminar” (<code>s2-jue.py</code> , 17-19)	09

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Reference-free evaluation	evaluación sin referencia	evaluar sin anotación humana previa , preguntándole a un LLM: “ <i>without having to rely on ground truth human annotations</i> ” (ragas , abstract, p. 1). Es el complemento exacto del golden set , no su sustituto	09
Answer relevance	relevancia de la respuesta	el LLM genera n preguntas desde la respuesta y se promedia el coseno con la original (ragas , ec. 1, p. 3). No mide veracidad : penaliza respuestas incompletas o redundantes	09
Context relevance	relevancia del contexto	CR = oraciones extraídas / oraciones totales del contexto (ragas , ec. 2, p. 4). Mide foco, no cobertura: NO es Recall@k . Es la más débil de las tres (0,70) y el paper explica por qué (§5, p. 5)	09
Vector RAG	RAG vectorial	“ <i>the family of conventional approaches</i> ” que “ <i>works well for queries that can be answered with information localized within a small set of records</i> ” (graphrag §2.1, p. 2). Es el nombre que un paper le da a lo que el curso construyó toda la semana	09
Sensemaking / global question	pregunta global	pregunta cuya respuesta no está en ningún fragmento sino distribuida en el corpus (“ <i>What are the main themes in the dataset?</i> ”). Hit Rate, Recall@k y MRR no están mal: no están definidos	09
Multimodal RAG	RAG multimodal	recuperar sobre texto, imágenes, tablas y ecuaciones tratadas como entidades de conocimiento , no como tipos de dato (raganything , abstract, p. 1). En RAG-Anything, doble grafo (cross-modal + textual) fusionado por alineación de entidades y recuperación híbrida estructural + densa (§2.2–2.3)	09

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Failure mode	modo de falla	el patrón de error que el baseline exhibe medido , no el que se supone: Hit Rate bajo en siglas, MRR bajo con Hit Rate alto, respuestas inventadas con métricas buenas. Es lo que elige la extensión — “según el modo de falla observado” (curso/actividades/semana-2/s2-sab-taller.html, líneas 39 y 60); la tabla de diagnóstico está en slides/sesion-09/contenido.md §9.2. Primero se mide, después se elige	10 (diagnóstico construido en 08 y 09)
Abstention marker	marcador de abstención	subcadena que se busca en la respuesta en minúsculas y sin exigir igualdad para decidir si el sistema se abstuvo: ["no contiene", "no tengo informacion", ...] (curso/labs/Lab-04-LLM0ps/evaluation.py, líneas 47-51). Existe porque la igualdad de cadena no funciona : en la semana 2 conviven cinco redacciones del «no sé» y las dos que importan difieren en una tilde y un punto (Lab-02/rag_pipeline.py, 80, frente a golden_set_plantilla.json, 60 y 69). ⚠ Es un detector por palabras clave : “el documento no contiene la fecha, pero...” cuenta como abstención, así que se reporta con una muestra revisada a mano	10
PEAS	PEAS	“Performance measure, Environment, Actuators, Sensors” — la taxonomía con la que la IA clásica describe un agente (notas-s3 §1.1, línea 14; Russell & Norvig 2021, cap. 2, sin copia local). ⚠ Ninguna fuente del curso mapea la E : ver slides/sesion-11/contenido.md §4.2, donde el mapeo del entorno está marcado [AGREGADO]	11

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Agent function	función de agente	el mapeo de percepciones a acciones (notas-s3 §1.1, línea 12). La diferencia que ordena el puente: en el agente clásico es código explícito ; en el agente LLM vive en los pesos del modelo y no se puede leer (notas-s3 §1.2, línea 34). No decir “razona” ni “comprende”: el glosario ya fija que lo emergente no es evidencia de comprensión	11
Goal-based agent	agente basado en objetivos	tercero de los cuatro tipos clásicos (reactivo simple, basado en modelos, basado en objetivos, basado en utilidad); “ <i>un agente LLM moderno es esencialmente un agente basado en objetivos</i> ” (notas-s3 §1.2, línea 24). Es lo que pregunta la reflexión 1 del Taller 3 (línea 100)	11
Tool schema	esquema de la herramienta	name, description e input_schema con properties y required (notas-s3 §2.1, 44-58; _fuentes/s3-lun.py, 60-85). La description es el prompt : es lo que el modelo lee para elegir, y debe decir cuándo usarla y cuándo no . ⚠ curso/labs/Lab-03-Agents/tools.py no tiene descripciones ni esquemas (líneas 91-95)	11
<code>tool_use</code> / <code>tool_result</code>	llamada y resultado de herramienta	las dos mitades del intercambio. Segunda invariante del bucle: cada <code>tool_use</code> recibe exactamente un <code>tool_result</code> (s3-lun.py, línea 20). Nombres de la estructura del material del curso , no firma de API vigente (§11.1)	11
Agent loop	bucle del agente	decidir → ejecutar → observar, repetido hasta respuesta final o hasta el límite de pasos . Primera invariante: el LLM nunca ejecuta (s3-lun-html, 64-66). No es lo mismo que la maquinaria de decisión: la maquinaria es tu código y no cambia entre un agente pequeño y uno grande (s3-lun.py, 293-295)	11

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Max steps / step budget	límite de pasos	tope de iteraciones del bucle; es la condición de parada, no una optimización . La rúbrica marca como grave “dibujar un bucle de agente sin condición de parada”. ⚠ Tres valores distintos en la misma semana: max_pasos=5 (s3-lun.py, 182), max_steps=8 (lab-03/agent.py, 47) y max_steps=10 (notas-s3, 201). No es lo mismo que el presupuesto de tokens o llamadas, que es de la sesión 12	11
Agent trace	traza del agente	la lista de eventos de una corrida: pregunta, cada llamada con su entrada, su resultado, su duración y si falló, y la respuesta final o el corte por límite de pasos (s3-lun.py, 184-215). Vale el 25 % del Taller 3 (línea 119) y es “el germen del Lab 04” (s3-lun.py, 21). Es el antecedente de traza / span de la sesión 17 , no un sinónimo: aquí es una estructura de datos en memoria	11 (se instrumenta en 17)
Toolformer	Toolformer	método de ajuste fino auto-supervisado que enseña a un LM a insertar llamadas a APIs en el texto, filtrando las candidatas por si reducen la pérdida sobre los tokens siguientes (toolformer §2, pp. 2-4). ⚠ No es un agente: como máximo una llamada por entrada (§4.2, p. 5), sin encadenar y sin interacción (§7, p. 11). Cambia 0 ; el function calling del curso no	11
Thought (ReAct)	pensamiento (<i>thought</i>)	acción en el espacio del lenguaje que no toca el entorno y no genera observación ; su único efecto es actualizar el contexto, $c_{t+1} = (c_t, \hat{a}_t)$ (Yao et al. 2023, §2, p. 3). Es una acción, no un comentario	12
Action space	espacio de acciones	el conjunto de operaciones que el agente puede ejecutar. Es una decisión de diseño y acota el techo del agente: ReAct usó tres — <code>search</code> , <code>lookup</code> , <code>finish</code> — “significativamente más débiles” que el estado del arte, a propósito (Yao et al. 2023, §3.1, p. 4)	12

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Observation	observación	lo que devuelve el entorno tras una acción. No la produce el modelo , y por eso ancla el razonamiento: en Yao et al. (2023), Tabla 2, p. 6, la alucinación es el 56 % de los fallos de CoT y el 0 % de los de ReAct	12
Trajectory / trace	trayectoria (traza)	la secuencia ($o_0, a_0, \dots, a_i, o_i$) de una corrida. En Reflexion es la memoria de corto plazo (Shinn et al. 2023, §3, p. 4); en el Taller 3 es el 25 % de la nota (taller-03, línea 119)	12 (se opera en 17)
Verbal reinforcement	refuerzo verbal	“reforzar agentes de lenguaje no actualizando pesos, sino mediante retroalimentación lingüística” (Shinn et al. 2023, abstract, p. 1). θ no cambia : la política se parametriza como “la memoria del agente emparejada con una elección de parámetros del LLM” (§1, p. 2)	12
Evaluator / verificador	evaluador (verificador)	el M_e que puntúa una trayectoria. Tres fuentes de señal: entorno binario , heurística escrita a mano o auto-evaluación (LLM o tests generados), Shinn et al. (2023), §1, p. 2. Es el techo del método : sin él, la auto-reflexión baja de 0,60 a 0,52 (Tabla 3, p. 8)	12
Self-reflection	auto-reflexión	el M_{sr} que convierte la señal del evaluador en texto accionable para el intento siguiente. No es reintentar : reintentar con $T = 0,7$ no resolvió ninguna tarea previamente fallada (Shinn et al. 2023, §4.2, p. 6)	12
Long-term memory (agente)	memoria de largo plazo del agente	el mem de auto-reflexiones que persiste entre intentos , acotado a $\Omega = 1-3$ experiencias “para respetar los límites de contexto del LLM” (Shinn et al. 2023, §3, p. 4; §4.1, p. 5). Es el ejemplar canónico de “ventana de contexto $\neq$ memoria del agente” , y trae su número	12

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Step budget / max_steps	presupuesto de pasos	el corte duro del bucle. Tiene justificación medida: con 7 y 5 pasos en HotpotQA y FEVER, “más pasos no mejoran el desempeño”, y solo el 0,84 % y el 1,33 % de las trayectorias correctas llegaron a consumirlos (Yao et al. 2023, §3.2, p. 5 y nota 3). En <code>lab-03/agent.py</code> , línea 47, <code>max_steps = 8</code>	12
Loop detector	detector de bucles	corte por repetición de acciones , no por número de pasos. Umbrales publicados para ALFWorld con GPT-3: “la misma acción y la misma respuesta durante más de 3 ciclos , o más de 30 acciones en el entorno” (Shinn et al. 2023, §4.1, p. 5). ⚠ El <code>ventana=6</code> del notebook (<code>_fuentes/s3-mar.py</code> , línea 92) no tiene fuente : es didáctico. No atrapa paráfrasis (línea 115)	12
Tool contract	contrato de la herramienta	nombre y descripción escritos para el modelo , esquema de entrada tipado, validación previa, error como valor de retorno , salida acotada por el sistema y efectos secundarios declarados. ⚠ Síntesis del curso: ninguna fuente lo reúne. En <code>lab-03</code> , el <code>SYSTEM_PROMPT</code> (<code>agent.py</code> 27–35) no describe ninguna tool y <code>_execute_action</code> (72) hace <code>tool(**args)</code> sin esquema	12
Error como valor vs. excepción	error devuelto vs. excepción lanzada	devolver <code>{"error": ...}</code> deja que el modelo lo lea y corrija ; lanzar mata la corrida y su traza . En <code>lab-03/tools.py</code> hay siete <code>return {"error": ...}</code> (23, 25, 29, 47, 53, 67, 71) y cuatro llamadas sin try (35–36, 48, 69, 76–82); <code>agent.py</code> escribe la traza solo en las dos salidas ordenadas (90 y 106)	12
Read-only en el papel	herramienta “de solo lectura”	promesa que hay que auditar contra la firma : <code>generate_chart</code> recibe <code>output_path</code> como parámetro (<code>tools.py</code> 63) y escribe donde el modelo diga (86), en un módulo cuyo docstring declara “solo lectura” (línea 4)	12

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Tool discovery	descubrimiento de herramientas	el cliente pregunta qué herramientas hay en vez de saberlo al escribir el código: “el cliente no sabe de antemano qué herramientas hay – esa es la diferencia con el lunes” (<code>_fuentes/s3-mie.py</code> , líneas 276–277). Es la propiedad que separa MCP del cableado y del function calling , no la sintaxis del protocolo	13
Tool catalog / manifiesto	catálogo de herramientas	la lista que el servidor publica: por cada herramienta, <code>name</code> , <code>description</code> y su esquema de entrada (<code>s3-mie.py</code> , 237–240). Es el esquema de la sesión 11 con otro dueño. ⚠️ Dos nombres en el material evaluable: <code>curso/talleres/taller-03-agentes.md</code> , línea 79, lo llama <i>manifiesto</i> y el notebook <i>catálogo</i> . ⚠️ Viaja como tokens de entrada en cada iteración: descubrir más herramientas sube el costo fijo del bucle (<code>s3-mie.py</code> , 368)	13
Host / cliente / servidor MCP	host, cliente y servidor	el host es la aplicación donde vive el LLM, el cliente el conector dentro del host, el servidor lo que expone las herramientas (<code>s3-mie.html</code> , 80–84). El host es la M de la cuenta y el servidor la N ; el cliente es lo que impide que la M se multiplique	13
M×N / M+N	la cuenta del estándar	M aplicaciones por N herramientas exige $M \cdot N$ integraciones ; con protocolo son $M + N$ piezas (<code>s3-mie.py</code> , 193–201). ⚠️ No son la misma unidad, y ⚠️ el protocolo solo gana si $(M-1)(N-1) > 1$: con $M = 1$ —el Lab 03— cuesta una pieza más . El argumento para un solo cliente es el costo marginal de la herramienta N+1 (<code>taller-03</code> , 77)	13

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Servidor MCP simulado	servidor simulado	clase Python en el mismo proceso que responde a las dos operaciones, sin instalar ni levantar nada (s3-mie.py , 229–252). Es el mismo recurso didáctico del LLMSimulado de la sesión 11: lo que se aprende es la forma de los mensajes, no la infraestructura. ⚠ No implica nada sobre el transporte real, que el curso declara fuera de alcance (s3-mie.py , 215)	13
Adaptador de nomenclatura	el adaptador vive en el cliente	cuando el contrato de la herramienta y el que espera la API del modelo no coinciden, la traducción se hace una vez, en el cliente , y el agente no se entera (s3-mie.py , 293–297). Es la razón mecánica por la que agregar un servidor no cambia una línea del agente (5.2, líneas 317–348)	13
Multi-agent system	sistema multi-agente	varios agentes con roles y capacidades distintas que se coordinan sobre una tarea. Es una decisión de topología, no un mecanismo nuevo. En el curso es extensión, no baseline (notas-s3 §4.1, línea 147; taller-03 , línea 65). ⚠ No está demostrado que gane a un agente único bien hecho: en ALFWorld dos agentes empatán con ReAct (54/54) y pierden en best of 3 (63 vs 66) — autogen Tabla 3, p. 25 —, y el propio paper deja la pregunta abierta (§B.2, p. 17)	14
Parallel execution	ejecución en paralelo	ejecutar varias ramas del flujo a la vez. Compra latencia; cuesta costo simultáneo y orden no garantizado; su protección es el presupuesto global , no el de cada rama (_fuentes/s3-mar.py , línea 274). ⚠ Ninguna fuente del curso mide su ganancia. ⚠ No es paralelismo de hardware ni batching (sesión 18)	14 (nombrado en 12)

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Conversable agent	agente conversable	en AutoGen, “an entity with a specific role that can pass messages to send and receive information to and from other conversable agents”, con capacidades combinables de LLM, humano y herramientas (autogen §2.1, p. 3). Se nombra citando el paper y su año (2023); no se proyecta ninguna firma de la librería	14
Termination condition	condición de terminación	lo que hace que el sistema pare. AutoGen la pone dos veces: en lenguaje natural (“instructing the agent to reply with «TERMINATE»”) y en código (“the max number of auto replies”), §2.2, p. 5. La segunda es la que vale , porque “LLMs do not follow all the instructions perfectly” (§C, p. 18). Es el mismo argumento que “el prompt es una instrucción, no un mecanismo” (s3-jue-html , 111)	14 (el límite de pasos se introdujo en 11)
Least privilege	mínimo privilegio	dar al agente solo las herramientas y los alcances que su tarea exige. Cuatro reglas operativas: solo lectura por defecto, alcance acotado por herramienta, identidad propia del agente e irreversible ⇒ confirmación humana (curso/actividades/semana-3/s3-jue-explicacion.html , 64-70). La demostración del curso: el mismo LLM engañado causa daño con la herramienta de exfiltración disponible y no puede causarlo sin ella — «el modelo cayó IGUAL... y no pasó nada, porque la capacidad no existía» (_fuentes/s3-jue.py , 141-158). ⚠ No es una propiedad del docstring: lab-03/tools.py promete «solo lectura» y no confina ninguna ruta. Se evalúa en la reflexión 3 (taller-03 , línea 104)	14 (se cobra en 15)

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Human-in-the-loop	humano en el bucle	exigir aprobación humana antes de ejecutar una acción, implementado en código y no pedido en el prompt : el decorador <code>tool_protegida</code> devuelve {"estado": "rechazado_por_humano"} sin llamar a la función (<code>_fuentes/s3-jue.py</code> , 88-96). El paper lo recomienda como punto de partida: “start with humans always in the loop... even if the target operation mode is more autonomous” (autogen §B.1, p. 16)	14
Indirect prompt injection	inyección indirecta	inyección cuyo payload viaja en el contenido que una herramienta trae —una web, un email, un PDF del corpus— en vez de en el chat (<code>s3-jue.html</code> , 48-50). Es peor que la directa por dos razones : no requiere acceso al chat, y el agente tiene herramientas , así que la inyección puede convertirse en acciones , no solo en texto (línea 108). Regla operativa: todo resultado de herramienta es dato no confiable (línea 43). Es el vector del corpus del Taller 2 dentro del agente del Taller 3	14 (anticipado en 04; los guardrails son de 18)
Autonomy proportional to risk	autonomía proporcional al riesgo	el grado de supervisión humana se decide por la matriz impacto × reversibilidad de cada acción: leer → autónomo; escribir borradores → autónomo con revisión posterior; enviar, borrar o pagar → confirmación previa; acciones legales o financieras graves → “quizá nunca autónomas” (<code>s3-jue.html</code> , 89 y 117). El diseño de tools codifica esa matriz . Respaldo en la lectura: “a high level of autonomy can also pose potential risks, especially in high-risk applications” (autogen §B.2, p. 17)	14

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Cascading failure	fallo en cascada	fallo de un agente que se propaga por la conversación a los demás. autogen §B.2, p. 17, lo nombra entre lo que hay que construir —“ <i>building fail-safes against cascading failures and exploitation</i> ”— y advierte del riesgo de “ <i>incomprehensible, unintelligible chatter among agents</i> ” cuando el sistema crece. Se nombra, no se mide: ninguna fuente del repositorio lo cuantifica	14
Tool registry	registro de herramientas	la estructura que el bucle consulta para resolver un nombre en una función ejecutable. ⚠ Un registro sin metadatos no sirve para elegir: curso/labs/Lab-03-Agents/tools.py, líneas 91-95, es nombre → función y el SYSTEM_PROMPT (agent.py, 27-35) no enumera nada, así que el modelo tiene que adivinar el nombre y los parámetros . El registro útil lleva name, description e input_schema y se inyecta en el prompt (_fuentes/s3-lun.py, 60-85). No es lo mismo que el esquema de la herramienta: el esquema describe una; el registro las reúne y decide cuáles ve el modelo	15 (el esquema, en 11)
Trace integrity	integridad de la traza	que la traza permita reconstruir la corrida: pregunta, cada acción con su entrada y su salida, tiempos , errores y respuesta final (curso/actividades/semana-3/s3-sab-taller.html, línea 66). Vale el 25 % del Taller 3 (taller-03, línea 119). ⚠ Se pierde por dos vías silenciosas: una excepción no capturada impide que se escriba el archivo (agent.py, 66-72 frente a 90 y 106), y un artefacto referenciado por ruta fija se sobrescribe entre corridas (tools.py, 63)	15

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Tool error as observation	el error como observación	convertir la excepción de una herramienta en el resultado que vuelve al modelo, en vez de dejarla propagar: <code>except Exception as e: resultado = f"ERROR: {e}"</code> (<code>_fuentes/s3-lun.py</code> , 201–205). Es lo que permite que un agente ReAct se recupere de un fallo y lo que conserva la traza. El andamiaje del Lab 03 no lo hace	15 (el bucle, en 11; ReAct, en 12)
Minimal span fields	los ocho campos mínimos de un span	“Identidad (<code>trace_id</code> , <code>span_id</code> , padre), tiempos (inicio, duración), modelo usado, tokens de entrada y salida, costo estimado, versión del prompt, y error si lo hubo” (<code>s4-mar-explicacion.html</code> , 109). Cuatro familias: identidad, tiempo, economía, cambio. ⚠️ TraceStep del Lab 03 (<code>agent.py</code> , 38–43) tiene cero de los ocho , y <code>curso/talleres/taller-04-llmops.md</code> líneas 23–26 los exige por escrito con un 30 % de peso	17
Instrumentación dentro vs. alrededor	instrumentar por dentro	emitir spans desde dentro de cada paso frente a cronometrar la llamada entera desde fuera. <code>Lab-04/instrumented_agent.py</code> hace lo segundo: mide una <code>latency_seconds</code> de extremo a extremo (línea 56) y no ve ninguna llamada al LLM ni ninguna herramienta . El Trazador del curso hace lo primero (<code>s4-mar.py</code> , 119–141). Es la diferencia entre “esta corrida tardó 1,1 s” y “la herramienta tardó 900 ms de esos 1,1 s”	17
p50 / p95	percentiles de latencia	el p50 es la corrida mediana; el p95, la que solo el 5 % supera. Medido sobre la corrida del propio curso (<code>_fuentes/traces.jsonl</code> , 10 trazas): p50 = 272 ms, media = 346 ms, p95 = 740 ms , con una anomalía de 1 112 ms. La media la diluye y el p50 no la ve . Por eso <code>notas-s4 §6.1</code> , línea 281, monitorea p95 y no el promedio. ⚠️ <code>curso/talleres/taller-04-llmops.md</code> línea 32 pide “latencia promedio”	17

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Traza como superficie de exposición	la traza también es un dato sensible	las trazas persisten prompts y respuestas, que pueden contener datos personales: “ Trazar no exime de proteger datos ” (s4-mar-explicacion.html , 117–118). Tres controles: redactar antes de persistir, controlar el acceso al sistema de trazas y definir retención . En Lab-04/instrumented_agent.py el orden es el correcto — validate_output (51) antes de write_local_trace (58)— y no es accidental: al revés, una clave detectada por SECRET_RE (guardrails.py , 23) ya estaría escrita en el archivo	17 (anticipo; los filtros son de 18)
Bloquear vs. redactar	bloqueo vs. redacción	bloquear devuelve False y la llamada no ocurre; redactar devuelve True con un texto distinto del que entró . ⚠ En guardrails.py el PII nunca bloquea : solo redacta (41–44), así que no puede producir la evidencia de bloqueo que s4-sab-taller.html línea 39 exige	18
Falso positivo de guardrail	falso positivo	entrada o salida legítima que el guardrail detiene o altera. Es la mitad que nadie mide , y el docstring del archivo asignado la nombra primero (guardrails.py , 4–5). Su versión medida está en Bai et al. (2022), §4.3, p. 12: sobre-entrenar produce Goodharting, respuestas “overly harsh” y lenguaje de plantilla	18
Evasividad	evasividad	degeneración del sistema que se protege bloqueando todo. “An AI assistant that answers all questions with «I don’t know» would be harmless, but of course it would also be completely useless” (Bai et al. 2022, p. 4). Es el techo de cualquier guardrail y la razón por la que la tasa de bloqueo sola no es una métrica	18

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Normalización antes de comparar	normalizar antes de comparar	minúsculas y sin tildes y con espacios colapsados, antes de buscar un patrón. 🚩 . lower() no quita tildes : guardrails.py línea 18 escribe <code>actua</code> y no atrapa <code>actúa</code> , mientras <code>_fuentes/s4-mie.py</code> línea 86 escribe <code>actúa</code> y no atrapa <code>actua</code> . Cuarto caso del mismo defecto en el curso, tras <code>0.x</code> , <code>evaluation.py</code> 47–51 y el " <code>drop</code> " del Lab 03 (<code>0.ag</code>)	18
Constitución implícita	constitución implícita	el conjunto de reglas que un sistema aplica, esté escrito o no: “ <i>we cannot avoid choosing some set of principles to govern it, even if they remain hidden or implicit</i> ” (Bai et al. 2022, §1, p. 2). INJECTION_PATTERNS es una constitución de cinco líneas. 🚩 Y el propio paper avisa de la suya: elegida “ <i>in a fairly ad hoc and iterative way</i> ” (nota 2, p. 3)	18
Red team (operativo)	red team	escribir a propósito las entradas que deben disparar un control. Bai et al. (2022) §3.2: 42 496 humanos + 140 335 generados = 182 831 prompts, y 491 142 adicionales en las corridas de RL (§4.2, p. 11). <code>s4-sab-taller.html</code> , 70: “Guardrail de adorno: activarlo sin demostrar un bloqueo real no cuenta. Diseña el input que lo dispara ”	18 (anticipado en 03 y 14)
Batching (API de lote)	batching	enviar trabajo no urgente a una cola que se procesa en horas, a cambio de precio (<code>s4-mie-explicacion.html</code> , 72). 🚩 No es la ejecución en paralelo de la sesión 14 —que “ <i>compra latencia; cuesta costo simultáneo</i> ”— ni el tamaño de lote del entrenamiento: el paralelismo gasta más para esperar menos; el batching espera más para gastar menos. 🚩 Su descuento no está en el JSON: no se proyecta ninguna cifra	18

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Streaming	streaming	recibir la respuesta por partes según se genera. “No baja el costo pero sí la latencia percibida” (<code>s4-mie-explicacion.html</code> , 75). ⚠ Mejora una latencia que este curso no mide: el glosario define latencia como la llamada completa y advierte que TTFT no lo define ninguna fuente del repositorio; el cronómetro de <code>plantilla_lab01.py</code> (72-78) se detendría antes con streaming y mostraría una mejora que el usuario no recibe	18
Prefijo estable	prefijo estable	la parte del prompt que se reenvía idéntica en cada llamada (system, ejemplos, instrucciones). Es lo único de esta familia que se puede cuantificar con la tabla vigente: con 2 000 tokens de prefijo, 100 de pregunta y 300 de respuesta, es el 55,6 % del costo por llamada en <code>claude-opus-4-8</code> y el 60,6 % en <code>gpt-4o-mini</code> (JSON, 2026-07-10 y 2026-08-26). Cuánto de eso devuelve el prompt caching, la tabla no lo dice	18
Techo del router	techo del enrutado	el ahorro de mandar parte del tráfico a un modelo barato está acotado por la fracción enrutada, no por la razón de precios: con 60 % a <code>claude-haiku-4-5</code> y 40 % a <code>claude-opus-4-8</code> el ahorro es 48 %, no 60 % ni 5× (JSON, 2026-07-10). ⚠ Corrige “5-25×” de <code>s4-mie-explicacion.html</code> , línea 70	18
Versión desplegada	versión desplegada	el puntero que dice qué versión atiende el tráfico ahora; es lo que un rollback cambia. ⚠ RegistroPrompts no lo tiene (<code>s4-mie.py</code> , 166-179): guarda, lista y recupera, pero no despliega, así que “volver a v7 es un cambio de configuración” (<code>s4-mie-html</code> , 63) no es implementable con esa clase. Y <code>obtener()</code> línea 175 usa <code>version or max(...)</code> , así que pedir la versión 0 devuelve la última sin avisar	18

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Changelog de prompt	changelog	la frase que dice qué cambió y por qué en una versión. El ejemplo del curso conecta las dos mitades del día: “v2: salida JSON estricta + delimitadores anti-inyección ” (s4-mie.py, 189). ⚠️ Un delimitador pedido en el prompt sigue siendo una instrucción, no un mecanismo: el versionado hace el cambio medible y reversible, no lo convierte en guardrail	18
Capa adaptadora	adaptador (<i>adapter layer</i>)	capa nueva insertada entre las existentes. Su límite está medido: +2,2 % de latencia con lote 32 y secuencia 512, pero +20,7 % y +30,3 % con lote 1 y secuencia 128 en GPT-2 medium sobre Quadro RTX8000 (Hu et al. 2021, Tabla 1, p. 4). Una penalización de latencia sin su tamaño de lote no significa nada	19
Hipótesis de rango intrínseco bajo	dimensión intrínseca baja	la conjetura de que el cambio útil de los pesos vive en pocas direcciones (Hu et al. 2021, §1, p. 2, siguiendo a Li et al. 2018a y Aghajanyan et al. 2020). Su evidencia son tres cosas medidas, ninguna es una SVD sintética: $r = 1$ rinde como $r = 64$ (Tabla 6, p. 10), los subespacios de $A_{\{r=8\}}$ y $A_{\{r=64\}}$ se solapan en las direcciones principales (Fig. 3, p. 11) y $\ \Delta W_q\ _F = 6,91$ frente a $\ W_q\ _F = 61,95$ (Tabla 7, p. 12). ⚠️ La Parte 1 del notebook la ilustra, no la demuestra: la matriz se fabrica de rango 8	19
Factor de amplificación	amplificación de direcciones	ΔW no repite las direcciones principales de W : “amplifica direcciones que no están enfatizadas en W ”, con factor $21,5 \approx 6,91/0,32$ para $r = 4$ en la capa 48 de GPT-3 (Hu et al. 2021, §7.3, Tabla 7, p. 12). Es el argumento de por qué el ajuste fino puede cambiar comportamiento sin reescribir el modelo	19

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Cuantización de pesos	cuantización de pesos	guardar los pesos con menos bits. Tercera acepción de la palabra en el curso. ⚠️ No es LoRA —cambia cómo se guarda lo que no se entrena, no qué se entrena— y ⚠️ no es la cuantización de vectores (PQ) de la sesión 07 , que comprime el índice. Confundir cualquiera de las tres es error grave de la rúbrica (línea 80)	19 (PQ en 07)
NF4	NormalFloat de 4 bits (NF4)	tipo de dato “ <i>óptimo desde teoría de la información para datos distribuidos normalmente</i> ”, construido con los cuantiles de una $N(0,1)$ normalizados a $[-1,1]$ (Dettmers et al. 2023, §3, ec. 4, p. 4). Medido: perplejidad media en Pile Common Crawl sobre OPT/BLOOM/LLaMA/Pythia de 125 M–13 B: Int4 34,34 · FP4 31,07/29,48 · NF4+DQ 27,41 (Tabla 2, p. 7)	19
Doble cuantización	doble cuantización (DQ)	cuantizar las constantes de cuantización . Medido: de 0,5 a 0,127 bits por parámetro, un ahorro de 0,373 bits/parámetro $\approx$ 3 GB en un modelo de 65B (Dettmers et al. 2023, §3, p. 5 y p. 2)	19
Optimizadores paginados	optimizadores paginados	desalojar los estados del optimizador a RAM con la memoria unificada de NVIDIA. ⚠️ No medido por el paper: “ <i>no damos mediciones duras... la paginación solo ocurre con minilotes de secuencias largas, lo cual es raro</i> ” (Dettmers et al. 2023, §4, p. 6)	19
Guanaco	Guanaco	la familia de modelos que QLoRA entrena sobre OASST1. 99,3 % del puntaje de ChatGPT en el benchmark Vicuna (80 prompts), juzgado por GPT-4, con intervalo de confianza del 95 % de $\pm 4,4$ (Dettmers et al. 2023, Tabla 6, p. 10). ⚠️ Es SFT con entropía cruzada, sin aprendizaje por refuerzo (§5.1, p. 8). ⚠️ Proyectar el 99,3 % sin su intervalo y sin su juez es el error que la rúbrica persigue	19

Término	Cómo se dice en clase	Definición operativa	Se introduce en
La calidad del dato manda	el dato es el ajuste fino	misma base de 65B, mismos 4 bits, mismos 41 GB, tres conjuntos: OASST1 (9 k) → 99,3 % · Alpaca → 70,7 % · FLAN v2 (450 k) → 48,4 % en el benchmark Vicuna (Dettmers et al. 2023, Tabla 6, p. 10). Es la respuesta con fuente a “qué datos necesitaria” del Taller 4, y desplaza la afirmación sin fuente de “100s–1000s de ejemplos” (s4-jue-explicacion.html , 74)	19
Ortogonalidad de los benchmarks	benchmarks parcialmente ortogonales	“un desempeño fuerte en MMLU no implica un desempeño fuerte en el benchmark de chatbot Vicuna, y viceversa” (Dettmers et al. 2023, p. 2 y §5.3, p. 10). El ejemplar: FLAN v2 es el mejor en MMLU (65B: 63,9) y el peor en Vicuna (48,4 %) . Se mide lo que se eligió medir	19
Regresión del ajuste fino	regresión medida	la capacidad que se pierde en lo que no se estaba optimizando. Ejemplar con cifra: Guanaco 65B obtiene 62,2 de MMLU 5-shot frente a 63,4 del LLaMA 65B sin ajustar (Dettmers et al. 2023, Tabla 5, p. 8). Es el impuesto de alineamiento del glosario, medido en otro método. ⚠ Sustituye a <i>catastrophic forgetting</i> , que s4-jue-explicacion.html línea 39 nombra sin ninguna fuente en el repositorio	19
Deriva	deriva (drift)	degradación de calidad en producción respecto de una línea base medida. ⚠ Sin línea base no hay deriva , hay una impresión: la línea base es el golden set de las sesiones 09 y 16. Son tres cosas distintas (fuentes/notas-teoricas/s4-llmops-y-finetuning.md §6.2, 289–292): cambia el modelo (“el proveedor lo actualiza... sin aviso”, §1, línea 14), cambia el corpus , o cambia la distribución de consultas . Solo la tercera es el <i>concept drift</i> clásico	19

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Señal de monitoreo	señal y su umbral	las cinco de notas-s4 §6.1 (279-285): latencia p95 (>3×), costo por consulta (>2×), fidelidad RAGAS (<0,7), tasa de rechazo por guardrails (pico súbito) y satisfacción. ⚠️ Los cinco umbrales son convención del curso, sin fuente. ⚠️ Y el Lab 04 solo puede producir dos de las cinco señales (slides/sesion-19/contenido.md §9.2): no hay tokens (0.an), no hay RAGAS, no hay 👍/👎	19
Umbral por debajo de la resolución	alerta inobservable	un umbral de alerta menor que el escalón mínimo de la métrica. Ejemplar aritmético del curso: notas-s4 línea 294 alerta a la “caída de más del 5 %” y taller-04 línea 41 pide 15 casos → resolución $1/15 = 6,67\% > 5\%$: la alerta no puede dispararse por un 5 % . Hacen falta ≥ 20 casos, que es el mínimo que las propias notas exigen (línea 41) y el taller contradice (0.bd)	19 (la resolución, en 09)
Evaluation harness	arnés de evaluación	el código que une el sistema bajo prueba con el evaluador: corre cada caso del golden set, guarda la respuesta junto al id del caso y se la entrega al evaluador. ⚠️ En el Lab 04 no existe y su ausencia es silenciosa: instrumented_agent.py escribe reports/traces.jsonl (línea 66) sin id de caso, evaluation.py lee reports/answers.json (71) y nada escribe ese archivo ; el reporte sale entero a cero sin lanzar ninguna excepción (0.bc). No es un renombrado: casar traza y caso exige que la corrida sepa qué caso está corriendo	20

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Bloqueo demostrado	bloqueo demostrado	evidencia de que un guardrail se disparó: la entrada que lo provoca, la traza de la corrida y la salida bloqueada . “Activarlo sin demostrar un bloqueo real (con su traza) no cuenta. Diseña el input que lo dispara ” (curso/actividades/semana-4/s4-sab-taller.html , línea 70). ⚠ No todo guardrail puede producirlo: en Lab-04/guardrails.py el PII redacta y devuelve True (41-44), así que solo la inyección (43) y la fuga de secretos en salida (49) generan la evidencia que la rúbrica del día pide	20 (el guardrail, en 18)
Cobertura declarada del guardrail	qué NO cubre	la lista explícita de lo que un control deja pasar y de lo que rompe por error , escrita por quien lo implementó. Es una sección exigida del informe: “ Cuáles activaste, un bloqueo demostrado con traza, y qué NO cubren (honestidad) ” (s4-sab-taller.html , línea 60). Convierte los siete huecos de guardrails.py en material calificable en vez de en un fallo del estudiante	20
Redacción destructiva	redacción destructiva	redacción que altera el significado de la entrada y deja al sistema respondiendo otra cosa, sin fallar ni avisar. ⚠ Ejemplar verificado y ejecutado: PHONE_RE (Lab-04/guardrails.py , línea 22) incluye el espacio en su clase de caracteres, así que <code>redact_pii("ventas de las tiendas 101 102 103")</code> devuelve <code>"ventas de las tiendas [TELEFONO_REDACTADO]"</code> (0.bf). Misma familia que el truncado silencioso (semana 2) y el cero fabricado (semana 1): el sistema sigue funcionando y devuelve otra cosa	20 (el guardrail, en 18)

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Mejora derivada de la medición	mejora derivada	cambio del sistema cuya justificación es un número del reporte , no una intuición: “Al menos 1 mejora concreta implementada después del análisis (ajuste de prompt, nuevo guardrail, etc.)” (curso/talleres/taller-04-llmops.md , línea 54). Es lo que distingue medir de decorar , y por eso el informe pide para cada peor caso “la traza, el diagnóstico y la mitigación” (s4-sab-taller.html , 59)	20
Latencia por tramo	latencia por tramo	descomponer el tiempo de una corrida en guardrail de entrada, cada llamada al LLM, cada herramienta y guardrail de salida , en vez de reportar un solo número. ⚠ El andamiaje mide un tramo y arranca tarde : instrumented_agent.py fija started en la línea 45 , después de validate_input (44) y antes de construir el cliente (49), así que no mide el guardrail de entrada y sí el arranque (0.az). El Taller 4 pide los tres niveles (líneas 24, 25 y 32)	20 (la latencia, en 05; el span, en 17)
Golden set v2	golden set v2	conjunto de referencia sobre la respuesta final , no sobre la recuperación: pregunta , respuesta_esperada , criterio_exito y tipo ∈ { feliz , ambiguo , negativo , adversarial }(Lab-04/golden_set_v2_plantilla.json). No tiene expected_chunk_ids , así que no hereda el techo de 0,70 de 0.u. ⚠ El Taller 4 pide 15 casos y notas-s4 línea 41 llama anti-patrón a menos de 20	16
Score promedio sobre tipos heterogéneos	el promedio que esconde	promediar una métrica sobre tipos de caso a los que no se aplica. ⚠ abstention_score de Lab-04/evaluation.py (línea 48) devuelve 0 tanto para «falló» como para «no aplica» : su promedio sobre 15 casos tiene un techo de 0,067-0,133 y el reporte de un agente perfecto muestra 0,00 en tres de sus cuatro filas. “«4.2/5 de promedio» esconde que TODOS los casos trampa fallaron” (s4-sab-html , 68)	16

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Position bias	sesgo de posición	propensión del juez a favorecer una posición en una comparación por pares (zheng §3.3, p. 4). Se mide con la consistencia : fracción de casos en que el veredicto no cambia al intercambiar el orden. ⚠ Es un sesgo de la comparación: evaluar de a una lo hace inaplicable. ⚠ Y depende de cuánto se parezcan los candidatos : 67,5 % de consistencia entre dos modelos parecidos frente a 98,8 % entre dos muy distintos (Tabla 11, p. 25). Aparece justo donde uno quiere medir	16
Verbosity bias	sesgo de verbosidad	el juez prefiere respuestas largas “ <i>even if they are not as clear, high-quality, or accurate as shorter alternatives</i> ” (zheng §3.3, p. 5). Medido con un ataque construido —reinsertar la misma lista parafraseada al principio, sobre 23 respuestas—: 91,3 % de fallo en Claude-v1 y GPT-3.5, 8,7 % en GPT-4 (Tabla 3, p. 5, jueves de 2023)	16
Self-enhancement bias	sesgo de autopreferencia	que el juez favorezca respuestas de su propia familia. ⚠ NO está demostrado en la lectura del curso : zheng §3.3, p. 5, observa +10 % de tasa de victoria de GPT-4 sobre sí mismo y +25 % de Claude-v1, señala que GPT-3.5 no se favorece , y concluye que “ <i>our study cannot determine</i> ” si el sesgo existe. La mitigación — juez de otra familia— se recomienda por su costo cero, no por una cifra	16
Consistencia del juez	consistencia	fracción de casos en que el juez da el mismo veredicto al intercambiar el orden de las dos respuestas (zheng Tabla 2, p. 5). ⚠ NO es acuerdo ni corrección : los ejemplos few-shot suben la consistencia de GPT-4 de 65,0 % a 77,5 % y su acuerdo con humanos no se mueve (zheng D.2, p. 26)	16

Término	Cómo se dice en clase	Definición operativa	Se introduce en
Agreement (juez–humano)	acuerdo	“the probability of randomly selected individuals (but not identical) of each type agreeing on a randomly selected question” (zheng §4.1, p. 7). Se cita siempre con su setup: S2 descarta empates y su azar es 50 % (GPT-4 vs. humano: 85 %); S1 los incluye y su azar es 33 % (66 %). ⚠ El «85 % > 81 % humano–humano» está advertido por los autores: el estimador subestima el acuerdo humano (D.3, p. 26), y la cota superior real – humano vs. mayoría humana– es 90 %	16
Calibración del juez	calibrar el juez	medir el acuerdo del juez con etiquetas humanas decididas antes de correr el sistema. ⚠ Dos cifras en la misma semana: ≥ 20 casos y umbral “~85–90 %” (s4–lun.py , 213–215, sin fuente externa) frente a 5 etiquetas (s4–sab–html , 38 y 49) – con 5, la resolución del acuerdo es 0,20 y el umbral no es alcanzable. “Un juez sin calibrar es una opinión cara”	16
Evaluable exacto	evaluable exacto	comparar la respuesta con la esperada mediante igualdad normalizada (minúsculas, espacios, puntuación). Es gratis, no tiene sesgos y solo sirve para respuestas cerradas. ⚠ La normalización es una decisión de evaluación que hay que escribir: evaluar_exacto("Técnico.", "tecnico") es False (_fuentes/s4–lun.py , 53) – quinta aparición del patrón de la tilde (0.x)	16
Anclas de la rúbrica	anclas	la descripción explícita de qué es un 5 y qué es un 1 en cada dimensión (s4–lun–html , 74; _fuentes/s4–lun.py , 91). Es lo que separa una rúbrica de una opinión, y es la misma idea que hace funcionar a RAGAS frente a GPT Ranking (0,54, casi el azar): descomponer la tarea en algo verificable en vez de pedir una impresión global	16

Distinciones que la rúbrica vigila

Confundir cualquiera de estos pares es un hallazgo grave, no un matiz de redacción:

- $P(X)$ vs. $P(Y|X)$ — generativo vs. discriminativo.
- Token vs. palabra vs. carácter.
- `d_model` vs. ventana de contexto — dimensión del modelo vs. tokens que caben en la entrada.
- Pesos de atención vs. parámetros de peso — dinámicos por entrada vs. aprendidos y fijos.
- Codificador del VAE vs. encoder del transformer — latente continuo vs. pila de capas sobre tokens.
- Ventana de contexto vs. memoria del agente.
- Recuperación (Recall@k, MRR) vs. generación (fidelidad, corrección).
- RAG vs. ajuste fino: RAG aporta **contexto**; el ajuste fino cambia **comportamiento**.
- LoRA vs. cuantización: QLoRA usa ambas y no son lo mismo.
- SFT vs. RLHF vs. DPO — tres métodos distintos de alineamiento.
- Agente vs. chatbot vs. pipeline de prompts encadenados.
- Temperatura como parámetro de muestreo vs. “creatividad”.
- Similitud coseno vs. producto punto sin normalizar.
- Modelo base vs. modelo alineado — qué señal optimizó cada uno; no es tamaño ni arquitectura.
- Alineado vs. correcto vs. seguro — alineado es *a una señal seleccionada*; no implica ninguna de las otras dos (Ouyang et al. 2022, §5.3, p. 19).
- Veracidad vs. honestidad — lo primero se mide con proxies declarados; lo segundo, según la propia fuente, no se puede medir en un modelo generativo (Ouyang et al. 2022, §3.6, p. 10).
- Recompensa absoluta vs. diferencia de recompensas — solo la diferencia significa algo, tanto en el modelo de recompensa como en los puntajes Elo.
- **Top-k vs. top-p** — corte de número **fijo** vs. corte **adaptativo** por masa acumulada. Sobre los mismos logits, $p = 0,9$ deja 2 tokens con $T = 1$ y 7 con $T = 5$.
- **Few-shot vs. ajuste fino** — condicionar el prefijo vs. actualizar θ . Es la versión de semana 1 de la distinción RAG vs. ajuste fino: **few-shot no entrena nada**.
- **Tokens de entrada vs. tokens de salida** — no cuestan lo mismo, y por eso few-shot (paga en entrada) y chain-of-thought (paga en salida) no cuestan lo mismo. En `fuentes/modelos/modelos-2026-1.json` la salida cuesta 5× la entrada en las tres filas de Anthropic (verificadas el 2026-07-10) y 4× en `gpt-4o-mini` (verificada el 2026-08-26); la relación es una propiedad **de cada fila**, no una ley del mercado. **En embeddings no aplica**: hay un solo precio por modelo, porque embeber es una sola dirección.
- **Greedy vs. determinista** — $T = 0$ toma el `argmax` en cada paso; eso no es una promesa de reproducibilidad bit a bit en una API de producción.
- **Una corrida vs. una medición** — con $T > 0$ una salida es una **muestra**. El Taller 1 exige correr cada configuración ≥ 3 veces y reportar **promedio y rango**, no una cifra suelta.
- **Cero real vs. dato ausente disfrazado de cero** — `open_weight_local` cuesta 0 porque su precio es 0: se ejecuta localmente y no hay precio por token. Distinto es un `null` que una función convierte en 0.0 sin avisar: `estimate_cost` de `curso/labs/Lab-01-Foundation-Models/plantilla_lab01.py`, líneas 52-53, **sigue haciéndolo**. (Hasta el 2026-08-26 la fila *propietario_economico* lo disparaba; su precio ya está verificado y hoy ninguna fila lo hace, pero el mecanismo sigue en el código.) En una tabla de costos, un cero **medido** y un cero **fabricado por un dato que falta** no significan lo mismo.
- **“X veces más caro” sin decir en qué** — la razón entre dos modelos puede no conservarse entre entrada y salida. `claude-opus-4-8` cuesta 33× lo que `gpt-4o-mini` en entrada y 41,7× en salida, así que la razón total depende de la mezcla de tokens de la tarea. Solo cuando el factor coincide en los dos términos — `opus` frente a `claude-haiku-4-5`, 5× en ambos — la comparación se puede decir con un solo número.

- **Embedding de token vs. embedding de oración** — una fila de la matriz de la capa de embedding, **estática por ID** (Raschka 2024, §2.7–2.8, pp. 43–45), frente a **un** vector por texto obtenido por pooling sobre la **salida** del encoder (Reimers & Gurevych 2019, §3, p. 3). Solo el segundo se indexa, y solo el segundo es contextual.
- **Bi-encoder vs. cross-encoder** — precalculable frente a no precalculable. El segundo es más preciso (≈ 7 puntos de Spearman en la evaluación entre temas de AFS, Tabla 3, p. 6) y **no escala**: comparar $n = 10\ 000$ oraciones entre sí son 49 995 000 inferencias, unas 65 horas en una V100 (Reimers & Gurevych 2019, §1, pp. 1–2).
- **Normalizar los documentos vs. normalizar los dos lados** — con solo los documentos normalizados, $q \cdot s = \|q\| \cdot \cos(q, s)$, así que **el ranking de una consulta no cambia**; pero el puntaje deja de estar en $[-1, 1]$ y **deja de ser comparable entre consultas**, y cualquier umbral fijo —el de abstención, por ejemplo— queda roto sin que nada falle ruidosamente.
- **“El coseno es más robusto que la euclidiana”** — con vectores **normalizados** las tres medidas producen **el mismo ranking**; Reimers & Gurevych (2019), §4, p. 4, midieron Manhattan y euclídea negativas obteniendo resultados “*roughly the same*”; y la documentación oficial de OpenAI, vía la fila `embed_api_economico` de `fuentes/modelos/modelos-2026-1.json` (verificada 2026-08-27), normaliza a longitud 1 precisamente “*de modo que coseno y distancia euclídea producen el mismo orden*”. El argumento de concentración de distancias es sobre vectores **sin normalizar**. ⚠️ **Divergencia abierta** con `fuentes/notas-teoricas/s2-rag-y-vector-search.md`, §2.3: pendiente de decisión del profesor.
- **La maldición de la dimensionalidad, en sus dos papeles** — “los árboles espaciales exactos degeneran a fuerza bruta en dimensión alta” (sesión 07; sostenido por `curso/actividades/semana-2/s2-mar-explicacion.html`, líneas 39–40 y 121–122) **no es** “la coseno es más robusta que la euclídea” (sesión 06, **vetado** mientras siga abierta la discrepancia 0.g). Mismo fenómeno, dos preguntas distintas; **solo la primera es proyectable**.
- **Longitud máxima de secuencia vs. tamaño del fragmento** — la primera es del **modelo** y la fija su ficha; el segundo lo elige quien fragmenta. **El fragmento no puede ser mayor que el techo del modelo sin perder texto en silencio**. Con `all-MiniLM-L6-v2` (`max_seq_tokens: 128`, JSON verificado 2026-08-27) y el `chunk_size = 512` que proponen las notas del curso (§4.2), se descartan **384 de cada 512 tokens** sin un solo aviso.
- **Techo del modelo vs. tamaño del fragmento vs. ventana de contexto** — tres límites distintos: `max_seq_tokens` del modelo de embeddings, el `chunk_size` que elige quien fragmenta, y la ventana del LLM que genera. **Solo el primero trunca en silencio**. Y con el andamiaje real del Lab 02 —900 palabras (`ingestion.py`, línea 50) contra 128 tokens (`rag_pipeline.py`, línea 25)— la fracción descartada no es el 75 % de la sesión 06 sino **al menos el 85,8 %**.
- **Cifra verificada vs. juicio de calidad** — que `fuentes/modelos/modelos-2026-1.json` haya verificado dimensiones, precios, idioma y límites de secuencia **no valida** ningún “*el mejor de su clase*”. Una tabla de vigencia fija hechos comprobables, no rankings de calidad.
- **null vs. false en la ficha de un modelo** — `normaliza_por_defecto: null` (`bge-m3`) es **dato ausente**, no “no normaliza”. Se **mide $\|v\|$** sobre una salida real antes de decidir. Es la misma trampa que el `estimate_cost` que convierte un precio ausente en **0.0**.
- **Recall del índice vs. Recall@k de recuperación** — fidelidad al **kNN exacto** frente a fracción de los fragmentos **anotados como correctos**. La verdad de referencia del primero se **calcula** (`curso/actividades/_fuentes/s2-mar.py`, línea 111); la del segundo se **anota** en el golden set (`curso/labs/Lab-02-RAG-VectorSearch/evaluation.py`, línea 29). **Un índice con recall 1.0 puede alimentar un RAG con Hit Rate 0.3**. Es un nivel **por debajo** de la distinción recuperación vs. generación, no un sinónimo suyo.
- **Cuantización de vectores (PQ) vs. cuantización de pesos (QLoRA)** — comprimir el **índice** frente a comprimir el **modelo**. Es una tercera acepción de la misma palabra, en la semana 2, y confundirla con la de la semana 4 es el mismo error que confundir LoRA con cuantización.
- **Latencia de consulta del índice vs. latencia de extremo a extremo** — la primera es el tiempo de una búsqueda ANN (`s2-mar-explicacion.html`, línea 48: “*p50/p99*”); la segunda es la del glosario desde la sesión 05, y en un RAG completo **la primera es solo uno de sus sumandos, y casi siempre el más pequeño**.
- **Perilla de construcción vs. perilla de consulta** — `M`, `ef_construction` y `nlist` exigen **reindexar**; `ef_search` y `nprobe` se cambian **en caliente, por consulta** (`s2-mar-explicacion.html`, línea 125). Prometer un ajuste de recall sin decir cuál de los dos es se parece a prometerlo gratis.
- **Índice ANN vs. base de datos vectorial** — el índice es **una** de las cuatro piezas del motor; las otras tres son la colección, el punto con su payload y el filtro de metadata. Decir “base vectorial” cuando se quiere decir “índice” oculta justo lo que hay que operar el sábado.
- **Aproximado vs. impreciso** — un índice ANN tiene una pérdida **conocida y medible**, y por eso se puede negociar contra latencia y memoria. `nprobe = nlist` es el kNN exacto: la aproximación es un dial, no otro algoritmo.
- **Fragmentación vs. recuperación** — cómo se corta el texto frente a cómo se elige qué traer. Son dos etapas y fallan por cosas distintas, pero **la primera acota a la segunda**: ninguna forma de buscar encuentra lo que el corte destruyó.

- **BM25 vs. densa: no hay una mejor, hay una mejor para la tarea** — medido en Lewis et al. (2020), Tabla 6, p. 8: BM25 gana en FEVER (75,1 vs. 74,5) y pierde por **12,2 puntos** en Natural Questions. Decir “*la densa es mejor*” sin decir en qué tarea es la versión de la semana 2 del “*X veces más caro sin decir en qué*” de la semana 1.
- **RRF combina rangos, no puntajes** — y es lo que le permite fusionar un BM25 sin cota superior con un coseno en `[-1, 1]`. Promediar los puntajes crudos **no es búsqueda híbrida**: es sumar magnitudes incomparables.
- **Reranking reordena, no recupera** — el cross-encoder solo ve los candidatos que la primera etapa le pasó. Un reranker que no mejora puede estar diciendo que **el problema está antes**.
- **RAG de Lewis (2020) vs. RAG del curso** — el paper fundacional **ajusta el query encoder y el generador** y trata el documento como variable latente (§2.4, p. 4); lo que el curso y el Taller 2 llaman RAG es el **Naive RAG** de Gao et al. (2023), §II.A: recuperar y pegar al prompt, con todo congelado. La sigla es la misma y el sistema no.
- **RAG reduce las alucinaciones; no las elimina** — en la evaluación humana de Lewis et al. (2020), Tabla 4, p. 8, **en el 17,7 % de los casos las dos respuestas fueron pobres**. La rúbrica ya vigila esta confusión; ahora tiene cifra.
- **Más contexto vs. mejor contexto** — “*a common misconception in the RAG process is the belief that retrieving as many relevant documents as possible... is beneficial*” (Gao et al. 2023, §IV.A.2, p. 10). Subir `k` es **gratis para el índice y caro para el modelo**.
- **El golden set es función del chunking** — sus `expected_chunk_ids` apuntan a identificadores que el chunker inventó (`Lab-02/ingestion.py`, línea 74). Re-fragmentar sin re-anotar produce **un número que no significa nada y no lanza ningún error**. Es el mismo patrón que el `estimate_cost` que devuelve `0.0` y que el truncado silencioso.
- **Verdad de referencia calculada vs. anotada** — el recall del índice **se calcula** contra el kNN exacto; el `Recall@k` **se anota** en un golden set. El primero nunca caduca; el segundo caduca cada vez que cambia la fragmentación.
- **MRR vs. posición promedio** — MRR es el promedio de **1/posición**, no de la posición. Con aciertos en 1 y 5, la posición media es 3 y el MRR es 0,6. `taller-02`, línea 65, y `notas-s2` §6.1 lo escriben mal.
- **Hit Rate vs. Recall@k** — con **un** relevante por pregunta son el mismo número; con varios, no. Reportarlos como distintos sobre un golden set de un solo relevante es reportar dos veces lo mismo.
- **Anotar por chunk_id vs. por documento** — precisión máxima y caducidad garantizada frente a precisión media y robustez ante el re-chunking. **Hay que elegir a sabiendas**; el notebook de la 09 elige documento y lo declara (`s2-jue.py`, 67-68).
- **Pregunta negativa vs. pregunta fallida** — abstenerse ante una negativa es un **acierto**. Con `evaluation.py` tal como está, produce `hit=False` y baja el Hit Rate: **el sistema correcto es penalizado**.
- **Tasa de abstención correcta vs. indebida** — hacen falta las dos, porque abstenerse siempre da 1,0 en la primera. Es la simétrica de “*un RAG que siempre responde algo es un generador de alucinaciones con citas decorativas*”.
- **Context Relevance de RAGAS vs. Recall@k** — foco del contexto recuperado frente a si llegó lo que hacía falta. Un sistema con un fragmento perfecto y otro con ese mismo más cuatro de relleno tienen **el mismo Hit Rate y Context Relevance muy distinta**.
- **Evaluación con referencia vs. sin referencia** — Hit Rate, MRR y Recall@k necesitan anotación humana; las tres métricas de RAGAS existen para cuando no la hay. **No son sustitutas**.
- **Pregunta local vs. pregunta global** — para “*¿cuáles son los temas del corpus?*” no hay fragmento que anotar: las métricas de la 09 **no están definidas**, y por eso GraphRAG se evalúa por comparación con un LLM juez y no con un golden set.
- **Promedio global vs. desempeño por tipo de pregunta** — en `raganything` Tabla 2, p. 8, el sistema con mejor exactitud global (63,4) es el **peor** en preguntas incontestables (46,0). **El promedio esconde exactamente lo que el Taller 2 obliga a medir**.
- **Ganancia medida vs. ganancia transferible** — que quitar el reordenador cueste 1,0 punto en DocBench (`raganything` Tabla 4, p. 9) **no dice cuánto vale un reranker en el corpus de nadie más**. Es la versión de la semana 2 del “*X veces más caro sin decir en qué*”.
- **Resolución de la métrica vs. mejora real** — con 10 preguntas, el escalón mínimo del Hit Rate es 0,1: una mejora menor **no es indistinguible de cero por casualidad, sino por construcción**.
- **Lo que se indexa vs. lo que se paga en el prompt** — con la cadena real del Lab 02, **128 tokens llegan al índice y ≥900 llegan al prompt en cada consulta** (`rag_pipeline.py`, líneas 68 y 76). La parte descartada **no es recuperable y sí es facturable**. Es un nivel **por debajo** del *truncado silencioso*, no un sinónimo suyo: el truncado explica por qué no se encuentra; esto explica por qué se paga igual.

- **Extracción vacía vs. documento sin contenido** — `page.extract_text()` or `""` (Lab-02/ingestion.py, línea 31) convierte un PDF escaneado en un fragmento hecho **solo de marcadores** `[page=N]`, que se normaliza, se fragmenta, se embebe y se indexa. **El sistema no falla, devuelve resultados, y el documento entero no está.** Sexto ejemplar del patrón del “cero silencioso” del curso, junto a `estimate_cost` devolviendo `0.0`, el truncado a 128, el golden set caducado, la tilde de la abstención y el `null` de `normaliza_por_defecto`.
- **Agente vs. pipeline vs. chatbot** — *(ya está en la lista; se propone sustituirla por esta
- **El modelo decide vs. el modelo ejecuta** — el LLM **emite** una estructura; **tu código**
- **Aprender a llamar vs. decidir en bucle** — Toolformer aprende lo primero **en los pesos**
- **Límite de pasos vs. presupuesto** — el primero acota **iteraciones** y es la condición de
- **Descripción de la herramienta vs. contrato de la herramienta** — la descripción es ****para el**
- **ReAct vs. chain-of-thought** — razonar **dentro** de una llamada, sin tocar el entorno, frente a
- **ReAct vs. Reflexion** — **dentro del intento vs. entre intentos.** No compiten: en Shinn et al.
- **Reintentar vs. reflexionar** — con `T = 0,7`, ninguna tarea fallada se resolvió reintentando
- **Auto-evaluación con verificador vs. sin él** — Shinn et al. (2023), Tabla 3, p. 8: con tests
- **Ganancia del patrón vs. ganancia en una tarea** — ReAct gana en FEVER y pierde en HotpotQA con
- **Prompting vs. ajuste fino, para un patrón de agente** — con PaLM-8B/62B, ReAct ****por prompting**
- **Límite de pasos vs. detector de repetición** — el primero corta **siempre** y no diagnostica; el
- **Límite del sistema vs. límite en el esquema de la tool** — `row_limit` viaja como parámetro
- **Traza escrita vs. traza perdida** — `lab-03/agent.py` escribe la traza en `completed` y en
- **Function calling vs. MCP** — cómo el modelo PIDE vs. cómo la herramienta se **PUBLICA.** No
- **Descubrir una herramienta vs. tener permiso para invocarla** — el catálogo dice **qué existe,**
- **Integraciones vs. piezas** — $M \times N$ cuenta pares que alguien escribe y mantiene; $M+N$ cuenta
- **Estándar abierto vs. estándar de la industria** — lo primero es una propiedad de la
- **Multi-agente vs. agente único bien hecho** — **no está demostrado que el primero gane.** En
- **Ganancia de multi-agente vs. capacidad del modelo base** — la misma ablación de OptiGuide da
- **Límite de pasos vs. presupuesto vs. detector de repetición** — ****tres frenos** que no se
- **Presupuesto estimado vs. costo medido** — `costo_usd=0.005` y `costo_por_paso=0.002` son
- **El prompt es una instrucción; el mecanismo es código** — ****«Le puse al system prompt que nunca**
- **Validación que crees que te protege vs. lo que realmente te protege** — el `guard` de
- **Límite de pasos vs. presupuesto** — *(ya propuesta por `slides/sesion-11/contenido.md` §18.3;
- **Validar la cadena vs. validar la capacidad** — la lista negra de `tools.py`, líneas 21-25,
- **Descripción ausente vs. modelo torpe** — cuando un agente llama a una herramienta que no
- **La traza como registro vs. la traza como evidencia** — guardar los pasos no es lo mismo que
- **Bloquear vs. redactar vs. dejar pasar** — tres salidas distintas de un guardrail; solo la
- **Guardrail vs. alineamiento** — inferencia frente a entrenamiento; θ no cambia frente a θ

- **Batching vs. paralelismo** — esperar más para gastar menos frente a gastar más para esperar
- **Descuento vs. otro modelo de facturación** — el prompt caching no es un porcentaje sobre las
- **Historial vs. versión desplegada** — guardar todas las versiones (git, `RegistroPrompts`) no
- **θ cambia vs. θ no cambia** — es la partición que ordena el curso entero: prompting,
- **LoRA vs. cuantización vs. cuantización de vectores** — qué se entrena, cómo se guarda el
- **r como perilla de capacidad vs. r como perilla de memoria** — los papers miden que r
- **Qué matrices se adaptan vs. con qué rango** — Dettmers §4, p. 6: “el hiperparámetro más
- **Fusionar vs. intercambiar adaptadores** — cero latencia extra o lote mixto de tareas, no
- **Reducción de checkpoint vs. reducción de despliegue** — los 10 000× de LoRA son de
- **Mejorar una métrica vs. no romper las demás** — Guanaco 65B: 99,3 % en Vicuna y r -1,2 puntos
- **Ilustrar una hipótesis vs. medirla** — aproximar con SVD una matriz fabricada de rango 8 no
- **Umbral de alerta vs. resolución de la métrica** — un umbral por debajo del escalón mínimo no
- **Guardrail que existe vs. guardrail activado vs. guardrail demostrado** — estar en el archivo,
- **Bloquear vs. redactar, en términos de evidencia** — r (complementa la distinción ya propuesta
- **Métrica que no aplica vs. métrica que falló** — un θ puede significar las dos cosas y
- **Consistencia vs. acuerdo vs. corrección (del juez)** — que repita el mismo veredicto al
- **Métricas de recuperación vs. de fidelidad al contexto vs. de calidad de la respuesta** —