

Taller 1 — Comparación de modelos fundacionales


MMIA 6013 — IA Generativa y Agentes · Sesión 05 · sábado 19 de septiembre de 2026

230 minutos de laboratorio evaluado · 25 % de la nota final · entrega 19 de septiembre

Daniel Andrés Riofrío Almeida

La API es el instrumento; la decisión es el entregable

- El mismo problema con tres modelos: costo, latencia, calidad y decisión de arquitectura
- Objetivo literal: desarrollar criterio para elegir el modelo correcto para un problema dado
- Costo, latencia y calidad no deciden solas: el propietario ve tus datos; el local exige tu hardware
- Tres preguntas filtran el problema: ¿es real? ¿tiene 10 casos con respuesta verificable automáticamente? ¿sabes qué separa un acierto de un fallo?
- Escribe un haiku no discrimina modelos, y esta vez tampoco se puede puntuar: las Partes 2 y 4 miden exactitud a lo largo de un barrido
- Que la calidad no siga al costo es la hipótesis de hoy, no un resultado



Fuente: curso/talleres/taller-01-foundation-models.md (revisión b del 2026-09-18), §Parte 1, «Objetivo» e «Instrucciones» (líneas 171-191) y §Contexto, «Requisito de la tarea» (líneas 35-40: problema del área propia y los 10 casos verificables); curso/silabo/silabo.md, líneas 181-182 (cronograma Sáb 19); curso/actividades/semana-1/s1-sab-taller.html, líneas 14-15 (defendible con números), línea 37 (las dos preguntas de validación) y línea 70 (problema de juguete); Alammar & Grootendorst (2024), cap. 1, §«Proprietary, Private Models» p. 30 y §«Open Models» p. 31 (qué separa propietario de abierto, más allá de las tres columnas que hoy se miden)

Qué llega enseñado, y las dos cosas que se enseñan hoy


- Costo, tokens y las cuatro variantes de prompt → sesión 04: llegan aprendidas y hoy se aplican
- Temperatura, top-k y top-p → sesión 04 y el notebook del miércoles; hoy **por primera vez se califican**: la Parte 0 sobre la distribución en local y la Parte 2 contra la API
- Tokens de razonamiento y niveles de esfuerzo → sesión 04, palanca 5; la Parte 4 los mide
- Qué hace la atención → sesión 02; base frente a alineado → sesión 03
- Lo que ninguna sesión enseñó y hoy se califica: el **verificador de 10 casos** y el protocolo de latencia
- Los dos se construyen en el segundo bloque, antes de tocar el laboratorio. Reproducibilidad (10 %) se pierde en casa

Qué se entrega y cómo se califica

05

Seis partes: la rampa de la Parte 0 y cinco barridos sobre el mismo problema

- Un problema, un verificador de 10 casos, una función de llamada y el mismo prompt exacto: las Partes 1 a 4 son barridos sobre eso. La Parte 5 (10 %) y la reproducibilidad (10 %) no llaman a ningún modelo
- Parte 0 (10 %) — la rampa, y no usa ninguna de las tres: GPT-2 en tu máquina, sin clave, sin red y sin costo; la distribución que las demás partes solo infieren
- Parte 1 (10 %) — qué modelo: exactitud sobre los 10 casos, latencia, costo con su fecha
- Parte 2 (20 %) — qué dial: verificar **parametros_expuestos** contra la API (8 %) y barrer temperatura × top-p (12 %)
- Parte 3 (15 %) — qué técnica: cuatro variantes, sus tokens y una conclusión de 200–300 palabras
- Parte 4 (25 %) — cuánto pensar: tres niveles de esfuerzo, tokens de razonamiento contados, dos gráficas



Fuente: curso/talleres/taller-01-foundation-models.md (revisión b del 2026-09-18): los seis encabezados de parte con su peso (líneas 81, 169, 215, 317, 353 y 490) y la tabla de §Criterios de evaluación (líneas 536–546), que esta vez **coinciden**; §Contexto, líneas 25–33 (un problema, un verificador, una función de llamada, y la Parte 0 que no usa ninguno de los tres); §Con qué modelo corre cada parte, líneas 50–57 (qué fila corre cada parte, con la clave del curso y sin ella); §Parte 0, líneas 81–165; §Parte 1, líneas 169–197; §Parte 2.a, líneas 222–277; §Parte 2.b, líneas 279–313; §Parte 3, líneas 317–349; §Parte 4, líneas 353–439; §Parte 5, líneas 490–513; curso/actividades/semana-1/s1-sab-taller.html, línea 68 (≥3 corridas, promedio y rango)

Esta vez los encabezados y la tabla dicen lo mismo

- Parte 0, la distribución graficada y medida, las tres palancas comprobadas sobre ella y el límite del modelo base: 10 %
- Parte 1, tres modelos con calidad, latencia y costo medidos y fechados: 10 %
- Parte 2.a, matriz de exposición verificada con sus mensajes literales: 8 % · Parte 2.b, el barrido: 12 %
- Parte 3, las cuatro variantes de prompting: 15 %
- Parte 4.a, barrido de esfuerzo con los tokens contados y las dos gráficas: 15 % · Parte 4.b, los casos contaminados: 10 %
- Parte 5, reflexión teórica: 10 % · Reproducibilidad, repositorio y CSV crudo: 10 %

Fuente: curso/talleres/taller-01-foundation-models.md (revisión b del 2026-09-18), §Criterios de evaluación, líneas 536–546: los nueve criterios y sus pesos son literales, y suman 100. Que coincidan con los encabezados de parte (líneas 81, 169, 215, 317, 353 y 490) se comprobó sumando: $10 + 10 + (8+12) + 15 + (15+10) + 10 + 10$. La contradicción 40/40/20 frente a 25/25/25/15/10 que traía el enunciado de septiembre quedó cerrada en la revisión a del 2026-09-18, y la revisión b abrió la Parte 0 rebajando las Partes 1 y 5 de 15 % a 10 % (§Qué cambió el 2026-09-18 b, líneas 558–564)

Terminado no es «los tres modelos corrieron»

- Las gráficas de la distribución de la Parte 0.a y la salida cruda de GPT-2 de la 0.c, **sin editar**
- Los 10 casos verificables con sus respuestas esperadas, y los tres modelos con el mismo prompt exacto; cada precio con su archivo y la fecha de su fila
- La matriz de exposición con **dos columnas** —lo que declara la tabla y lo que observaste— y los mensajes de error literales
- El barrido de decodificación con exactitud y estabilidad; las dos gráficas del barrido de esfuerzo
- Las cuatro variantes con sus tokens y su conclusión, y las cinco respuestas de la Parte 5
- Informe en PDF, repositorio, **resultados.csv crudo** con las corridas locales incluidas a costo cero, ninguna clave, README con el uso de IA

Catorce exigencias: las dos primeras corren sin clave
— las dos primeras: sin clave, sin red, sin costo

está terminado si...	de dónde sale
Distribución graficada, entropía y núcleo 0,9	enunciado, Parte 0.a
Salida cruda de gpt2 ante tu instrucción	enunciado, Parte 0.c
10 casos con su respuesta esperada	enunciado, Contexto
3 modelos, mismo prompt exacto	enunciado, Parte 1
Precios con archivo y fecha por fila	tabla semestral
Matriz de 2 columnas y mensajes literales	enunciado, Parte 2.a
Barrido con exactitud y estabilidad	enunciado, Parte 2.b
4 variantes, mismo modelo, tokens	enunciado, Parte 3
Conclusión de 200–300 palabras	enunciado, Parte 3
Tokens de razonamiento contados por nivel	enunciado, Parte 4.a
Las dos gráficas: exactitud y costo	enunciado, Parte 4.a
5 preguntas de 100–150 palabras	enunciado, Parte 5
Informe, repositorio y resultados.csv crudo	enunciado, Entregables
Ninguna clave; README declara el uso de IA	política y sílabo

se pierde en casa

[AGREGADO] la forma de lista; cada fila es una exigencia de su fuente

Fuente: curso/talleres/taller-01-foundation-models.md (revisión b del 2026-09-18), §Parte 0.a líneas 105–120 y §Parte 0.c líneas 142–151 (las gráficas y la salida cruda pegada sin editar), §Contexto líneas 35–40, §Parte 1 líneas 175–197, §Parte 2.a líneas 222–252, §Parte 2.b líneas 279–313, §Parte 3 líneas 323–335, §Parte 4.a líneas 372–399, §Parte 5 líneas 490–513 y §Entregables líneas 519–528 (informe, repositorio y el CSV crudo, con las corridas locales de la Parte 0 a costo cero); curso/actividades/semana-1/s1-sab-taller.html, líneas 53–63 (rúbrica propia), 68 (tres corridas), 69 (mismo prompt) y 71 (precio con fuente y fecha); curso/silabo/silabo.md, líneas 150–151 (declarar el uso de asistentes de IA generativa) y curso/politica-credenciales.md. La FORMA de lista de comprobación es [AGREGADO - no está en las fuentes]; cada línea es una exigencia literal de una de esas fuentes

Cómo se mide: calidad, latencia y costo

05

El verificador de 10 casos es un entregable, no un adjetivo

- 10 casos con respuesta verificable **automáticamente**: una cifra, una clase, un campo de un JSON
- La exactitud se cuenta, no se estima. Es lo que hace puntuables las Partes 2 y 4: 15 celdas × 5 corridas no se puntúan a ojo
- Ejemplo, extracción de cláusulas de contratos: el caso trae el contrato y **la lista esperada**, y el verificador compara
- Se escribe **antes** de llamar a ningún modelo: después es ajustar el instrumento al resultado
- Lo cualitativo no desaparece, cambia de sitio: ¿alucina? ¿respeta el formato? ¿es verboso? se anotan al leer
- Y se anotan **a ciegas**: puntuar sabiendo qué modelo respondió mide la expectativa tanto como la respuesta

*Fuente: curso/talleres/taller-01-foundation-models.md (revisión b del 2026-09-18), §Contexto, «Requisito de la tarea», líneas 35–40 (los 10 casos verificables y por qué las Partes 2 y 4 los exigen), §Parte 1, líneas 183–188 (exactitud medida, y las observaciones cualitativas) y §Parte 0, líneas 90–97 (los 10 casos **no** entran en esa parte: ahí se mide la distribución y no el acierto); curso/actividades/semana-1/s1-sab-taller.html, líneas 57–62 (el ejemplo de contratos, material del profesor) y 64 (evaluación a ciegas); curso/labs/Lab-01-Foundation-Models/plantilla_lab01.py, línea 28 (quality_score se llena a mano; el verificador es código del estudiante y la plantilla todavía no lo trae). Escribirlo antes de llamar a ningún modelo es [AGREGADO - no está en las fuentes]*

Qué mide exactamente el cronómetro

- Latencia de extremo a extremo: tiempo de reloj de la llamada completa
- No es tiempo hasta el primer token ni tokens por segundo: el curso no los define
- Un modelo verboso parece lento: reporten también latencia / tokens de salida
- El local mide su máquina; los de API incluyen red y proveedor. Digan en qué equipo corrió
- La plantilla llama una vez y su tabla no imprime calidad: las tres corridas las añaden ustedes

```
# plantilla_lab01.py, líneas 72-81
start = time.time()
message = client.messages.create(...) # la llamada completa
latency = time.time() - start

# los tokens no se cuentan: se leen de la respuesta
tokens_in  = message.usage.input_tokens
tokens_out = message.usage.output_tokens
```

Fuente: [curso/labs/Lab-01-Foundation-Models/plantilla_lab01.py](#), líneas 72-78 (el cronómetro alrededor de la llamada), 80-81 y 107-108 (los campos de usage), 20-28 (output_tokens y quality_score en el mismo resultado), 159-166 (la tabla que imprime, sin la columna de calidad) y 205-208 (una llamada por modelo); [curso/talleres/taller-01-foundation-models.md](#) (revisión b del 2026-09-18), §Parte 1, líneas 185 y 188 (latencia declarando qué se mide, y observaciones cualitativas); [curso/actividades/semana-1/s1-sab-taller.html](#), línea 68 (tres corridas, promedio y rango); [proceso/contexto/glosario.md](#), fila latencia (de extremo a extremo). Las tres consecuencias operativas —normalizar por tokens de salida, el local no compite en la misma pista y declarar la máquina— son [AGREGADO - no está en las fuentes], derivadas de ese código

El costo se estima antes de gastarlo

- $\text{costo} = (\text{tokens_entrada} / 1\text{M}) \times \text{precio_entrada} + (\text{tokens_salida} / 1\text{M}) \times \text{precio_salida}$
- La unidad la fija el catálogo: los precios están publicados por millón de tokens
- Estimar el costo total ANTES de correrlo. Presupuesto orientativo: **menos de 1 USD por grupo**
- Supuesto declarado —1 000 de entrada, 600 de salida visible, y 1 500 / 3 000 / 7 000 totales en los tres niveles de esfuerzo—
- Unas 900 llamadas, y **no se reparten como el trabajo**: la Parte 2.b son 750 y cuesta 0,38 USD; la Parte 4 son 36 y cuesta diez veces más por llamada. La Parte 0 no llama a nadie: corre entera en tu máquina
- La Parte 4 cuesta **0,18 USD** en la fila de razonamiento de OpenAI y **2,10** en la balanceada: la diferencia la explica el precio de la fila, no el dial. Aritmética sobre precios de 2026-07-10, 2026-08-26 y 2026-09-18: si cambian, se rehace

Fuente: `curso/labs/Lab-01-Foundation-Models/plantilla_lab01.py`, líneas 48–54 (la fórmula) y `curso/actividades/_fuentes/s1-jue.py`, líneas 45–50 (la misma fórmula, notebook del jueves); `fuentes/modelos/modelos-2026-1.json`, línea 5 (`pricing_unit = 1M tokens`) y precios de cada fila con su fecha; `curso/talleres/taller-01-foundation-models.md` (revisión b del 2026-09-18), §Presupuesto, líneas 443–486: la tabla por partes (líneas 455–465), el «menos de 1 USD por grupo» (línea 467), la frase de que la diferencia entre 2,10 y 0,18 la explica el precio de la fila y no el dial (líneas 473–476) y las tres reglas de estimación (líneas 478–486) son literales del enunciado. Los «menos de 2 USD por grupo» de `curso/actividades/semana-1/s1-sab-taller.html`, línea 50, son de la versión anterior del taller y quedaron **superados**: manda el enunciado, y el material del sábado está pendiente de actualizar. Las cifras por parte son aritmética sobre el JSON con conteos de tokens supuestos y declarados

La tabla ya no tiene una sola fecha

- Tres fechas, no una: Anthropic el 2026-07-10; gpt-4o-mini el 2026-08-26; gpt-5.6-luna el 2026-09-18
- El 0 de llama3.1:8b es cero **por token**, no gratis: ese modelo lo paga tu máquina, en VRAM
- La segunda ranura admite propietario o económico: claude-sonnet-4-6 también cabe
- Salida = 5× entrada en las tres de Anthropic, 4× en gpt-4o-mini y 6× en gpt-5.6-luna: el mismo proveedor tiene dos razones
- claude-opus-4-8 frente a gpt-4o-mini: 33× en entrada y 41,7× en salida
- La razón no se conserva: X veces más caro necesita decir en qué

La fecha de verificación es una columna, no un pie
fuentes/modelos/modelos-2026-1.json · versión 2026-1

la banda marca el trío por defecto de la plantilla

identificador	modelo	entrada USD/1M	salida USD/1M	verificado
propietario _grande	claude-opus-4-8	5,0	25,0	2026-07-10
propietario _balanceado	claude-sonnet-4-6	3,0	15,0	2026-07-10
propietario _economico	gpt-4o-mini	0,15	0,60	2026-08-26
openai _razonamiento	gpt-5.6-luna	0,2	1,2	2026-09-18
juez _economico	claude-haiku-4-5	1,0	5,0	2026-07-10
open_weight _local	llama3.1:8b	0	0	cero real, local

«verificado» no es una sola fecha: 70 días de diferencia
3 filas locales, sin precio ni fecha, no se proyectan

Fuente: fuentes/modelos/modelos-2026-1.json, releído el 2026-09-18 (nueve filas desde esa fecha; el diagrama proyecta las seis que llevan precio y fecha, más la local del trío por defecto de la plantilla; las otras tres corren en local y su cero no es un precio por verificar). Campo verified_at global: 2026-07-10 (Anthropic); 2026-08-26 (OpenAI gpt-4o-mini, pagina oficial, precio reconfirmado el 2026-09-18); 2026-09-18 (OpenAI gpt-5.6-luna, pagina oficial de precios). Las filas propietario_economico y openai_razonamiento traen además su propio verified_at y su campo source con la URL de la página oficial de precios. Ranuras: curso/talleres/taller-01-foundation-models.md (revisión b del 2026-09-18), §Parte 1, líneas 177–181, y §Con qué modelo corre cada parte, líneas 50–57; trío por defecto: curso/labs/Lab-01-Foundation-Models/plantilla_lab01.py, líneas 179–189. Las razones derivadas (5×, 4× y 6×; 33× y 41,7×) son [CÁLCULO DERIVADO del JSON, con la fecha de cada fila]; Alammar & Grootendorst (2024), cap. 1, §«Limited Resources Are All You Need», pp. 28–29 (la VRAM como recurso limitante del modelo local) y §«Open Models», p. 31 (hace falta hardware potente para ejecutarlo)

Uno de estos dos zeros no era un precio. ¿Qué debió hacer la función?

- A. Devolver 0.0, como hace hoy: un costo desconocido no se puede sumar al total
- B. Devolver 0.0 y escribir el aviso en la salida, junto a la fila afectada
- C. Lanzar un error y no imprimir la tabla hasta que el precio esté verificado

informe del estudiante · tabla comparativa (Parte 1)			
modelo	calidad (1-5)	latencia (s)	costo (USD)
claude-opus-4-8	4	3,1	0,004120
gpt-4o-mini	3	1,4	0,000000
llama3.1:8b	3	6,8	0,000000

informe de ejemplo, con la tabla semestral anterior al 2026-08-26; calidad y latencia son ilustrativas

Fuente: fuentes/modelos/modelos-2026-1.json, estado de la fila propietario_economico anterior al 2026-08-26, registrado en curso/planificacion/plan.md, sección Discrepancias, Cerradas, punto 3; curso/labs/Lab-01-Foundation-Models/plantilla_lab01.py, líneas 52-53 (retorno de 0.0 sin aviso ante un precio ausente), 57-64 (validate_model_name vigila el nombre, no el precio) y 182 (el trío por defecto incluía esa fila); curso/actividades/_fuentes/s1-jue.py, líneas 46-50 (el notebook del jueves lanza ante el mismo dato ausente); proceso/contexto/glosario.md, distinción cero real frente a dato ausente disfrazado de cero


Ninguna clave, y una línea base reproducible

- `.env.example` se versiona con los nombres y sin valores. Tu `.env` es local y no se entrega
- El código nunca ve la clave: los SDK la leen del entorno, sin argumento de clave
- La clave del curso va al entorno y nunca al código: una llamada de prueba **por proveedor** antes de la Parte 1. La Parte 0 no necesita ninguna
- El repositorio del taller nace vacío: `.gitignore` con `.env` en el primer commit
- Si una clave se expone, primero se rota. Borrar el archivo no la saca del historial
- Línea base reproducible: código ejecutable, dependencias declaradas, resultados verificables

Fuente: `curso/politica-credenciales.md` (cómo configurar credenciales y qué hacer si una clave se expone); `curso/labs/Lab-01-Foundation-Models/.env.example` (dos líneas, ambas sin valor) y `plantilla_lab01.py`, líneas 13–18, 71 y 98 (los SDK leen del entorno, sin argumento de clave); `curso/actividades/semana-1/s1-sab-taller.html`, línea 47; `curso/talleres/taller-01-foundation-models.md` (revisión b del 2026-09-18), §Con qué modelo corre cada parte, líneas 46–48 (el curso reparte una clave de OpenAI), §Parte 0, «Preparación», líneas 101–103 (cero llamadas a una API, cero dólares, ninguna credencial) y §Entregables, líneas 522 (repositorio con `requirements.txt`) y 530–532 (ninguna clave en el informe, el notebook, una captura ni el repositorio: hallazgo bloqueante); `curso/silabo/silabo.md`, líneas 87–89 (definición de línea base reproducible) y 150–151. El `.gitignore` en el primer commit y las versiones fijadas son [AGREGADO - no está en las fuentes] y requieren validación del profesor si van a pesar en el 10 %

230 minutos, y cierran

- Veinte minutos de encuadre; el resto es laboratorio. La Parte 0 corre mientras reparto la clave y ustedes instalan dependencias
- Minuto 50: GPT-2 respondiendo en local y una respuesta de prueba por proveedor, o el problema es de entorno
- Minuto 75: problema validado y verificador de 10 casos corriendo. Es el hito que más se atrasa
- Minuto 150: la estimación de costo de la Parte 4 hecha, antes de lanzar el barrido de esfuerzo
- Los bloques de parte pagan 80 %. El resto no tiene bloque: Parte 5, 10 %, se escribe fuera; reproducibilidad, 10 %, se pierde en casa
- Mini-plenaria: tres grupos, una frase cada uno — decisión y hallazgo inesperado



Fuente: curso/planificacion/plan.md (sábado 08:00–11:50, 230 min); curso/talleres/taller-01-foundation-models.md (revisión b del 2026-09-18), §Criterios de evaluación, líneas 536–546 (los cinco pesos escritos bajo los bloques) y §Presupuesto, líneas 443–486 (la Parte 4 es la más cara por llamada y se abarata bajando de fila en vez de recortarse); §Qué cambió el 2026-09-18 a, «Dos advertencias operativas para el sábado», línea 691 (la Parte 0 son unos 30 minutos, no comparte tarea ni función de llamada y conviene arrancarla mientras se reparte la clave y se instalan dependencias); curso/actividades/semana-1/s1-sab-taller.html, líneas 44–51 (checklist previa, incluida la llamada de prueba por proveedor). El reparto de los ocho bloques lo fijó el profesor el 2026-09-18, sobre la revisión b del enunciado, y sustituye a la agenda de tres bloques del 2026-08-26, que era de la versión anterior del taller y no cubría las seis partes: ya no requiere validación