

Taller 2 — Sistema RAG sobre base vectorial


MMIA 6013 — IA Generativa y Agentes · Sesión 10 · sábado 26 de septiembre de 2026

230 minutos de laboratorio evaluado · 25 % de la nota final · entrega hoy, 26 de septiembre
Grupos de 2 a 3 · repositorio y resultados.csv al cierre, 11:50 · informe en PDF hasta las 23:59

Daniel Andrés Riofrío Almeida

Baseline → medir → extender → medir

- Orden estricto. Sin métricas del baseline no se puede demostrar que la extensión mejore nada
- Antes de tocar su corpus, la Parte 0: tres fallas reproducidas sobre ejemplos/, sin clave y sin Docker
- Hoy no se entrega un sistema que funcione: uno que se pueda medir, y un número discutible
- El baseline y su medición son el 65 % de los criterios; la extensión, el 10 %
- index() borra la colección antes de crearla: dos nombres de colección, y las dos medibles a las 11:50
- Corpus propio: 5 documentos, 50 páginas, un idioma declarado y con capa de texto; solo .pdf, .txt y .md



Fuente: curso/talleres/taller-02-rag-vector-search.md, §«Contexto» (la regla de oro y «por eso hay una Parte 0 antes de tocar tu corpus»), §«Requisito del corpus» y §«Criterios de evaluación» (Revisión 2026-09-19); curso/actividades/semana-2/s2-sab-taller.html, §«Errores frecuentes», tarjeta «Extensión antes que baseline», y §«Los tres puntos de no retorno»; curso/silabo/silabo.md, 80–82 (línea base obligatoria más extensión elegida); Lab-02-RAG-VectorSearch/rag_pipeline.py, RagPipeline.index(); ingestion.py, load_corpus(). Las dos colecciones y el 65 % son [AGREGADO]: aritmética sobre los pesos literales

Las cinco partes, tal como las pide el enunciado

- Parte 0 — tres fallas que no fallan, reproducidas sobre ejemplos/ sin clave y sin Docker: 10 %
- Parte 1 — baseline: ingesta, fragmentación en tokens justificada, índice, top-5, generación: 35 %
- Parte 2 — golden set de 10 (10 %), métricas a $k=3$ y $k=5$ (10 %), tres peores casos con evidencia (10 %)
- Parte 3 — UNA extensión: A otra fragmentación · B híbrida BM25+RRF · C reranking · D RAGAS: 10 %
- Parte 4 — dos preguntas: qué medía aquel 0,70, y una pregunta global sobre su corpus: 5 %
- Reproducibilidad — repositorio, versiones, resultados.csv crudo y ninguna clave: 10 %

Fuente: [curso/talleres/taller-02-rag-vector-search.md](#) (Revisión 2026-09-19), §«Parte 0 — Tres fallas que no fallan», §«Parte 1 — Baseline RAG funcional», §«Parte 2 — Evaluación con golden set», §«Parte 3 — Extensión elegida por el modo de falla», §«Parte 4 — Reflexión» y §«Criterios de evaluación», de donde salen los ocho pesos literales; §«Fecha de entrega» (repositorio al cierre, informe hasta las 23:59); [curso/actividades/semana-2/s2-sab-taller.html](#), §«Agenda de los 230 minutos» y el párrafo que le sigue; [curso/planificacion/plan.md](#), «Cerradas», 11 (0.t, 0.w y 0.y CERRADAS) y «Abiertas», 0.br

Los 65 puntos están en medir, no en extender

- Parte 0 — las tres fallas reproducidas, con la salida cruda y qué las detecta: 10 %
- Parte 1 — baseline, fragmentación en tokens justificada y fila de embeddings con su fecha: 35 %
- Parte 2 — golden set 10 % · métricas sobre responsables 10 % · tres peores casos 10 %
- Parte 3 — extensión elegida por el modo de falla medido, medida y explicada: 10 %
- Parte 4 — reflexión: 5 %. Reproducibilidad —CSV crudo, versiones, ninguna clave—: 10 %
- Desde el 19 los encabezados y la tabla dicen lo mismo, y los ocho pesos suman 100

Fuente: curso/talleres/taller-02-rag-vector-search.md (Revisión 2026-09-19), §«Criterios de evaluación»: los ocho criterios y sus pesos son literales, y los encabezados de parte llevan los mismos números; §«Qué cambió el 2026-09-19», fila de los pesos; curso/silabo/silabo.md, 76 (el 25 % global del taller); curso/planificacion/plan.md, «Cerradas», 11 (discrepancia 0.t, CERRADA). El 65 % y la lectura de las dos últimas viñetas son [AGREGADO]: aritmética sobre esos mismos pesos

Terminado no es «el retrieval anda»

- Al cierre, 11:50: repositorio con el código, golden_set.json, requirements con versiones y el resultados.csv crudo
- Hasta las 23:59: el informe en PDF, con las tres salidas de la Parte 0, la tabla de métricas y los tres peores casos
- Del sílabo, que el enunciado no repite: README reproducible, y costo y latencia observados
- Y la declaración de qué herramientas de IA generativa usaron y para qué parte del trabajo
- Ningún archivo entregado contiene una clave. Qué corpus suben también es una decisión
- A la derecha, las once condiciones con su fuente: es la diapositiva que conviene fotografiar

Once condiciones, y dónde lo dice cada una		
está terminado si...	sección	
Las 3 salidas crudas de la Parte 0	P0	se estrena hoy
Capa de texto, y qué rechazó la ingesta	P1	
chunk_tokens y overlap_tokens contra el tope	P0.b y P1	
Fila de embeddings con id y verified_at	P1	
Qdrant responde 3 preguntas con top-5	P1	
Una respuesta generada y su generador	P1	se estrena hoy
10 preguntas: 2 negativas, por documento y frase	P2.a	
Hit Rate y MRR sobre respondibles a k=3 y k=5, y las dos tasas	P2.b	
Los 3 peores casos con evidencia	P2.c	se pierde en casa: 10 %
resultados.csv crudo, fila por consulta	Entregables	
requirements con versiones, README con uso de IAG, costo y latencia, ninguna clave	sílabo y política	
[AGREGADO] la forma de lista; cada fila es una exigencia de su fuente · P0 a P2.c y Entregables son secciones del enunciado del taller		

Fuente: curso/talleres/taller-02-rag-vector-search.md (Revisión 2026-09-19), §«Entregables» (los tres contenedores y las diez exigencias del informe), §«Parte 0», §«Parte 1», §«Parte 2.b», §«Parte 2.c» y §«Parte 3», Opción D (costo, número de llamadas y límites del juez); curso/actividades/semana-2/s2-sab-taller.html, §«Qué se entrega»; curso/silabo/silabo.md, 80 (README reproducible), 87-89 (línea base reproducible, costo y latencia) y 150-151 (declarar el uso de IAG); curso/politica-credenciales.md. La FORMA de lista de once condiciones es [AGREGADO]; cada fila es una exigencia literal con su fuente

Tres fallas que no fallan — y hoy valen el 10 %

10

Los primeros 45 minutos: la Parte 0 mientras Qdrant arranca

- Parte 0 y depuración: QDRANT_URL=":memory:" corre sin Docker; el baseline se indexa en el contenedor
- docker run -p 6333:6333 qdrant/qdrant, respondiendo en localhost:6333, es lo único del día que no practicamos
- pip install -r requirements.txt: desde el 19 fija versiones, porque la API de Qdrant cambió de search a query_points
- El directorio corpus/ no existe: créenlo donde vayan a ejecutar, porque la ruta es relativa
- golden_set_plantilla.json → golden_set.json; id y pregunta se leen sin get, y las filas con REEMPLAZAR se saltan
- El .env con la clave que reparto hoy, y .gitignore con .env en el primer commit: el lab no lo trae

Fuente: [curso/actividades/semana-2/s2-sab-taller.html](#), §«Antes de escribir código» y §«Los tres puntos de no retorno»; [Lab-02-RAG-VectorSearch/README.md](#), §«Setup» y §«Las tres fallas que no fallan»; [requirements.txt](#), cabecera del 2026-09-19 y sus 8 dependencias con versión mínima; [.env.example](#); [rag_pipeline.py](#), QDRANT_URL y el constructor de RagPipeline; [evaluation.py](#), [load_golden_set\(\)](#), [evaluate_retrieval\(\)](#) y el argumento `--golden`; glosario, modo embebido / modo servidor. Los añadidos operativos son [AGREGADO]. Discrepancia 0.k, CERRADA el 2026-09-19 (plan, «Cerradas», 10 y 12)

0.a — El PDF que se indexaba vacío, y lo que hoy lo detiene

- ejemplos/instructivo_escaneado.pdf no tiene capa de texto: `extract_text` devuelve cadena vacía
- Hasta el 18, el or y el marcador de página producían un fragmento sin una sola palabra, indexado sin excepción
- Hoy `caracteres_utiles` descuenta los marcadores y `load_corpus` avisa y no lo indexa: 200 caracteres es el umbral
- 0.a pide la salida cruda de la ingesta y dos frases sobre qué producía la versión anterior: 3 %

```
# ingestion.py - caracteres_utiles() y Documento.parece_escaneado
MIN_CARACTERES_UTILES = 200    # por documento


def caracteres_utiles(text: str) -> int:
    # letras y digitos, sin los [page=N] que anade read_pdf()
    return sum(ch.isalnum()
               for ch in MARCADOR_PAGINA.sub("", text))

# load_corpus(): si parece_escaneado -> AVISO y continue
#   "instructivo_escaneado.pdf: 0 caracteres utiles en
#   2 pagina(s). ¿Escaneado o fotografiado? NO se indexa"
```

Fuente: Lab-02-RAG-VectorSearch/ingestion.py (revisión del 2026-09-19), `MIN_CARACTERES_UTILES`, `caracteres_utiles()`, `Documento.parece_escaneado`, `read_pdf()` y `load_corpus()` — recortado a 11 líneas y 65 columnas, acentos retirados salvo en el mensaje citado, sin cambiar identificadores—; Lab-02-RAG-VectorSearch/README.md, §«Las tres fallas que no fallan»; curso/talleres/taller-02-rag-vector-search.md, §«0.a — El PDF que se indexa vacío»; curso/actividades/semana-2/s2-sab-taller.html, §«Errores frecuentes», tarjeta «El PDF que se indexa vacío»; curso/planificacion/plan.md, «Cerradas», 10 (discrepancia 0.z, CERRADA)

0.b — El fragmento que se cortaba a 128, y el coseno que lo prueba

- Hasta el 18, ingestion.py fragmentaba en 900 palabras y el modelo cableado admite 128 tokens (modelos-2026-1.json, fila verificada 2026-08-27)
- Una palabra da ≥ 1 token: al índice llegaba $\leq 14,2$ % del fragmento, sin un solo aviso
- Hoy fixed_size_chunks_tokens usa el tokenizador del mismo modelo, y load_corpus lee el tope: chunk_tokens por defecto es el tope menos 2
- Pedir más produce un AVISO con la cifra, no una excepción: puede ser una decisión que hay que justificar
- 0.b: pidan chunk_tokens=900, peguen el aviso y comparen el texto entero con el recortado:
 $\cos(v_{\text{entero}}, v_{\text{cortado}}) \approx 1$
- Lo que no cupo nunca llegó al índice, y sí llega al prompt en cada consulta: se paga igual



Fuente: Lab-02-RAG-VectorSearch/ingestion.py (revisión del 2026-09-19), fixed_size_chunks_tokens(), load_corpus() —el aviso y el valor por defecto chunk_tokens = max_seq_tokens - 2— y fixed_size_chunks(), que conserva las 900 palabras como historia; rag_pipeline.py, EMBEDDING_MODEL, RagPipeline.ingest() y max_seq_length leído del modelo; fuentes/modelos/modelos-2026-1.json, fila embed_notebook_s2: max_seq_tokens 128, verified_at 2026-08-27; curso/talleres/taller-02-rag-vector-search.md, §«0.b — El fragmento que se corta a 128» y §«Parte 1», punto 2; curso/actividades/_fuentes/s2-lun.py, ejercicio 5.1 (1106 tokens y coseno 1,0000 sobre el modelo real); proceso/contexto/glosario.md, «truncado silencioso». La fracción $\leq 14,2$ % es [AGREGADO - CÁLCULO DERIVADO]. Discrepancia 0.p, CERRADA el 2026-09-19


Las dos consultas devuelven vecinos sanos. ¿Qué número las separa?

Sobre ejemplos/: una pregunta cuya respuesta no está en el corpus, y otra cuya respuesta está en el PDF que la ingesta rechazó

Las dos devuelven sus vecinos con puntajes del mismo orden, y ninguna excepción

- A. El puntaje del mejor vecino: por debajo de un umbral, se declara que no está
- B. El Hit Rate: la segunda es responsable y va a fallar; la primera es negativa y no entra
- C. Ninguno de los dos: lo que las separa no lo mide el índice

¿Y cómo están anotadas las dos en el golden set de ejemplos/?



¿qué número de los que van a medir hoy separa estos dos casos?

las dos consultas son literales del enunciado, §«0.c»; los puntajes no se dibujan porque ninguna fuente los mide

Fuente: curso/talleres/taller-02-rag-vector-search.md, §«0.c – El índice que no se queja» (las dos consultas son literales de ahí) y §«Parte 2.a»; Lab-02-RAG-VectorSearch/golden_ejemplo.json, items 5 y 6 –los dos de tipo negativo, y el criterio de éxito del 6 dice que su respuesta sí está en el PDF que no se pudo indexar–; Lab-02-RAG-VectorSearch/README.md, §«Las tres fallas que no fallan»; rag_pipeline.py, RagPipeline.retrieve(); evaluation.py, es_respondible() y evaluate_retrieval(); proceso/contexto/glosario.md, «umbral máximo de distancia; sobre un coseno, umbral de abstención» y «pregunta negativa». Ninguna cifra de puntaje se proyecta: ninguna fuente del repositorio los mide. Se leen después de recoger las manos

Una sola frase de abstención, comparada normalizada

- Hasta el 18 convivían tres redacciones del «no sé» en tres archivos: dos diferían en una tilde y un punto
- Ningún detector por igualdad de cadena disparaba: tasa 0,0 con un sistema que se abstiene siempre
- Hoy la frase es una, ABSTENCION, y es la misma en el prompt, en el golden set y en el detector
- Se compara normalizada: minúsculas, sin tildes y sin puntuación. Si la cambian, la cambian en los tres sitios
- La Parte 2.b pide dos tasas: correcta sobre las negativas, indebida sobre las responsables
- Hit Rate y MRR miden la recuperación. Ninguno dice si la respuesta que salió es correcta

```
# rag_pipeline.py - ABSTENCION, _normalizar_texto() y se_abstuvo()
ABSTENCION = "El corpus no contiene información suficiente."

def _normalizar_texto(t: str) -> str:    # minúsculas, sin
    t = unicodedata.normalize("NFKD", t.casefold())
    t = "".join(c for c in t if not unicodedata.combining(c))
    return " ".join("".join(c if c.isalnum() or c.isspace()
                             else " " for c in t).split())

def se_abstuvo(respuesta: str) -> bool:  # tildes ni puntos
    return (_normalizar_texto(ABSTENCION)
            in _normalizar_texto(respuesta or ""))
```


Fuente: Lab-02-RAG-VectorSearch/rag_pipeline.py (revisión del 2026-09-19), ABSTENCION, _normalizar_texto(), se_abstuvo(), RagPipeline.build_prompt() y RagPipeline.answer() —el bloque va tal cual, con los dos comentarios de margen partidos para caber en 72 columnas—; evaluation.py, las claves abstencion_correcta y abstencion_indebida de evaluate_retrieval(); golden_set_plantilla.json, ítems 7 y 8, campo respuesta_esperada; curso/talleres/taller-02-rag-vector-search.md, §«Parte 1», punto 5, y §«Parte 2.b»; proceso/contexto/glosario.md, «marcador de abstención» y «tasa de abstención»; Alammar & Grootendorst (2024), cap. 8, §«RAG Evaluation», pp. 257–258. Discrepancias 0.x y 0.ab, CERRADAS el 2026-09-19

Elegir la extensión, cuidar las claves y cerrar el día

10

La extensión se elige por el modo de falla medido

- Hit Rate alto y MRR alto: la recuperación va bien, falta medir la generación → D, RAGAS
- Hit Rate alto y MRR bajo: el relevante llega, pero llega tarde → C, reranking; y la fila multilingüe no publica cifras
- Hit Rate bajo en siglas, códigos y números: es vocabulario → B, híbrida BM25 + RRF
- Los dos bajos: el fragmento no está indexado como creen, o no está → A, otra fragmentación
- MRR alto con Hit Rate bajo no existe: hay acierto cuando el primero cae dentro del top-k, y entonces el recíproco vale como mucho 1, así que $MRR@k \leq Hit Rate@k$
- Con 8 respondibles el escalón del Hit Rate es $1/8 = 0,125$; el verbo del enunciado es «mide y explica», no «mejora»



Fuente: curso/actividades/semana-2/s2-sab-taller.html, §«El golden set es el verificador...», fila «Extensión» de la tabla (elegida por el modo de falla medido, con el par y las tasas que la justificaron); curso/talleres/taller-02-rag-vector-search.md, §«Parte 3 – Extensión elegida por el modo de falla» («el verbo es mide y explica, no mejora») y §«Con qué modelo corre cada parte», punto 4; fuentes/modelos/modelos-2026-1.json, clave rerankers, filas rerank_local_ingles y rerank_local_multilingue, verificadas 2026-09-19 (la segunda con benchmark_model_card nulo); slides_v2/sesion-09/contenido-base.md §9.2 y §8; proceso/contexto/glosario.md, «modo de falla»; Lab-02-RAG-VectorSearch/evaluation.py, evaluate_retrieval() y posicion_del_primer_acierto(); Alammam & Grootendorst (2024), cap. 8, §«RAG Evaluation», pp. 257–258 (faithfulness y answer relevance miden la respuesta generada, no la recuperación). La región imposible y el escalón de $1/8$ son [AGREGADO - CÁLCULO DERIVADO]. Discrepancia 0.q, CERRADA por redacción el 2026-09-19


El código correcto no tiene nada que ocultar

- `.env.example` se versiona con los nombres de variable y sin valores; el `.env` es local
- El código nunca ve la clave: `load_dotenv` y `os.getenv`, y no hay dónde pegarla
- El lab declara las dos claves vacías y elige la ruta de generación por la que encuentre
- `.gitignore` con `.env` en el primer commit: el directorio del lab no lo trae
- Si una clave se expone, primero se rota. Borrar el archivo no la saca del historial
- Y decidan qué corpus suben: un documento interno en un repositorio público también es una fuga

Fuente: `curso/politica-credenciales.md` (flujo de configuración y qué hacer si una clave se expone); `Lab-02-RAG-VectorSearch/.env.example` (revisión del 2026-09-19: las dos claves declaradas y sin valor, y la colección `mmia6013_rag`); `rag_pipeline.py`, `load_dotenv()` y `RagPipeline.generate()`; `requirements.txt`, dependencias de OpenAI y Anthropic; `curso/talleres/taller-02-rag-vector-search.md`, §«Entregables», recuadro de credenciales; `curso/silabo/silabo.md`, 139–141. El `.gitignore` en el primer commit y el aviso sobre el corpus son [AGREGADO]

230 minutos, y cierran

- Veinte minutos de encuadre; los otros 210 son laboratorio y yo circulo
- Minuto 45: Qdrant respondiendo y un documento de su corpus ingestado con caracteres útiles
- Minuto 105: el baseline genera — top-5 y una respuesta, o el prompt en modo inspección declarado
- Minuto 150: golden_set.json con sus dos negativas y el resultados.csv del baseline, antes de elegir extensión
- Si falta tiempo se recorta en la Parte 3: es la única que no es prerequisite de nada
- Mini-plenaria de 15 minutos: tres grupos, su peor caso y qué extensión eligieron por él



Fuente: [curso/actividades/semana-2/s2-sab-taller.html](#) (reescrita el 2026-09-19), §«Agenda de los 230 minutos» —los siete bloques: 20, 25, 60, 45, 20, 45 y 15— y §«Los tres puntos de no retorno» (minutos 45, 105 y 150, y qué se recorta si falta tiempo); [curso/talleres/taller-02-rag-vector-search.md](#), §«Criterios de evaluación»; [curso/planificacion/plan.md](#), fila 10 (sábado 08:00–11:50, 230 min) y «Cerradas», 11. El reparto de 65 % sobre tres bloques es [AGREGADO]: aritmética sobre los pesos literales

El lunes: se hereda el método, no el corpus

- El sílabo dice que los talleres 02, 03 y 04 son incrementales sobre un mismo sistema
- Pero el Taller 3 no pide este corpus: pide un dataset —SQLite, CSV o API— y tres herramientas
- Lo que sí se heredan por escrito son el golden set y el CSV: el Taller 4 pide extenderlo a 15 casos
- Semana 3: qué es un agente, patrones y toolset, MCP, y multi-agente con sus riesgos
- Un pipeline RAG no es un agente: no decide qué herramienta invocar ni cuándo
- Taller 3 — Agente con uso de herramientas, sábado 3 de octubre, 25 %

Fuente: curso/silabo/silabo.md, 77 (Taller 03, 25 %, 3 de octubre) y 81 (incrementales sobre un mismo sistema); curso/talleres/taller-03-agentes.md, 27-30 (dominio y dataset) y 32-38 (las tres herramientas mínimas) — el enunciado no menciona corpus, y su única mención de RAG (87) está en la extensión opcional de memoria; curso/talleres/taller-04-llmops.md, 41 (extender el golden set del Taller 02) y 48 (RAGAS «si tu agente usa RAG internamente»); curso/actividades/semana-2/s2-sab-taller.html, §«Lo que se lleva a casa»; curso/planificacion/plan.md, 25, filas 11-15; proceso/contexto/rubrica_calidad.md, 92. La contradicción entre el sílabo y el enunciado del Taller 3 requiere entrada nueva en el plan: [POR CONFIRMAR]