

M06 · MATEMÁTICAS Y PROGRAMACIÓN PARA IA

Guía del estudiante

Comparación estadística de modelos

Explicación y aplicación, diapositiva por diapositiva

Material de estudio para comprender cómo una diferencia observada entre modelos se convierte en una conclusión estadística limitada por la unidad, la métrica, la dependencia, la referencia nula y el alcance del diseño.

37 diapositivas

6 puntos de control

1 experimento

El argumento completo del módulo

Comparar modelos no consiste en escoger el promedio mayor o el p-value menor. La conclusión depende de una cadena completa: población y unidad, correspondencia entre mediciones, métrica y dirección, estimando, efecto observado, incertidumbre, referencia nula y límite de generalización.

Cadena conceptual: diseño -> diferencias pareadas -> magnitud -> dispersión -> incertidumbre -> referencia nula -> conclusión proporcional.

Dos casos numéricos complementarios

Caso	Unidad y propósito	Resultado que se construye
Diapositivas	Diez diferencias de log-loss usadas para hacer visibles el efecto, la prueba t y la referencia exacta por cambios de signo.	Media 0.019, intervalo t y dos p-values obtenidos bajo contratos distintos.
Notebook	Treinta flores de test evaluadas por Regresión Logística y Random Forest sobre la misma partición de Iris.	Pérdidas por observación, métricas agregadas, incertidumbre, sensibilidad y dependencia entre folds.

Caso experimental: Regresión Logística frente a Random Forest

La tarea binaria usa versicolor y virginica, las variables sepalLength y sepalWidth, una partición estratificada 70/30 y semilla 42. La Regresión Logística funciona como referencia probabilística lineal con escalado. Random Forest aporta una alternativa no lineal basada en un ensamble de 300 árboles.

Log-loss como métrica primaria

Log-loss evalúa la probabilidad asignada a la clase verdadera. Premia probabilidades bien calibradas y penaliza con fuerza los errores seguros. A diferencia de accuracy, no reduce cada predicción a una etiqueta antes de compararla. Accuracy, recall y F1 se mantienen como descripciones secundarias dependientes de un umbral.

Convención del notebook: $d_i = \text{log-loss}_{\text{LR}}(i) - \text{log-loss}_{\text{RF}}(i)$. Como menor log-loss es mejor, $d_i > 0$ favorece a Random Forest y $d_i < 0$ favorece a Regresión Logística.

Comparación estadística de modelos

Una comparación estadística es un argumento trazable, no una función de biblioteca.

La cuestión central

Comenzar directamente con fórmulas elimina la pregunta organizadora y hace que diseño, incertidumbre y decisión parezcan temas separados.

Explicación conceptual

La comparación pasa de una diferencia observada a una conclusión defendible. La ruta no comienza con una prueba, sino con diseño; después aparecen incertidumbre y decisión. La unidad narrativa es un argumento: primero se define qué comparación sería válida; luego se cuantifica lo observado y su incertidumbre; al final se decide qué lenguaje es proporcional a la evidencia. La presentación completa vuelve varias veces sobre esta cadena.

Aplicación en machine learning

Ejemplo de apertura: dos clasificadores se evalúan en los mismos pacientes y B obtiene menor pérdida promedio. La pregunta útil no es todavía cuál gana, sino qué población representan esos pacientes, qué variabilidad queda fuera y qué conclusión permitiría el diseño.

Correspondencia con el experimento

Notebook. El caso longitudinal compara Regresión Logística y Random Forest sobre Iris. La secuencia completa separa diseño, efecto, incertidumbre y conclusión.

Límite de interpretación

No adelante que el objetivo es decidir qué modelo gana. El objetivo es aprender qué puede concluirse, bajo qué contrato y con qué límites. No convierta la portada en un índice detallado ni anticipe un ganador. Su función es instalar una pregunta y un criterio de éxito.

Dos promedios no bastan para afirmar que un modelo es mejor

Un resultado agregado describe; el diseño autoriza o impide la comparación.

La cuestión central

Dos métricas agregadas borran la correspondencia entre casos, la dispersión y las unidades que sostienen la diferencia. El salto de 0.02 a 'B es mejor' confunde descripción con inferencia.

Explicación conceptual

Los promedios 0.84 y 0.86 y su diferencia 0.02 describen el resultado observado, pero no identifican su procedencia ni su estabilidad. Todavía faltan los casos utilizados, la unidad, la variabilidad representada y la población de interés. El promedio responde qué ocurrió en la muestra agregada; no responde por qué ocurrió, cuán estable es ni a qué población se pretende generalizar. La procedencia de cada observación determina qué variabilidad está representada.

Aplicación en machine learning

Suponga que A obtiene accuracy 0.84 y B 0.86. Ese resumen es compatible con una mejora uniforme en casi todos los casos o con una mejora concentrada en una subpoblación pequeña. El agregado no distingue ambos escenarios y puede ocultar daño en una clase crítica.

Correspondencia con el experimento

Notebook. Punto de control 1 (diapositivas 2-3): quedan fijados la pregunta, la población, la unidad, la métrica primaria, el emparejamiento y el estimando.

Límite de interpretación

El valor 0.02 no puede clasificarse como pequeño o grande sin una escala de relevancia y tampoco autoriza inferencia sin resultados por unidad. No clasifique 0.02 como grande o pequeño sin una escala de relevancia definida. El número de decimales tampoco constituye una señal de precisión inferencial.

La comparación se diseña antes de calcular el p-value

Primero se diseña el argumento; después se calcula dentro de ese contrato.

La cuestión central

Un análisis que comienza con el resultado favorece decisiones post hoc: cambiar métrica, alternativa o procedimiento hasta obtener una historia conveniente.

Explicación conceptual

La secuencia contiene pregunta, unidad y métrica, estimando, resultado observado, referencia nula, incertidumbre y conclusión limitada. Cada pieza restringe la siguiente; calcular primero y justificar después rompe la trazabilidad. La cadena del slide impone dependencias lógicas. La pregunta determina la población; la población y el proceso determinan la unidad; unidad y métrica definen el estimando; solo entonces tiene sentido elegir una referencia nula y un procedimiento.

Aplicación en machine learning

En un proyecto se calculan accuracy, F1 y AUROC, y después se escoge la métrica con menor p-value. Aunque cada cálculo sea correcto, el argumento queda condicionado por una elección posterior. El plan previo debe indicar qué métrica responde a la pregunta principal y cuáles serán sensibilidad.

Correspondencia con el experimento

Notebook. Punto de control 1 (diapositivas 2-3): quedan fijados la pregunta, la población, la unidad, la métrica primaria, el emparejamiento y el estimando.

Límite de interpretación

El p-value no repara una unidad equivocada, un emparejamiento falso ni una métrica elegida después de mirar los datos. El orden no exige ignorar los datos, sino distinguir decisiones previas de análisis exploratorios posteriores. Si algo cambia después, debe registrarse.

La resta A - B conserva quién mejora porque menor log-loss es mejor

La dirección de un efecto depende de la métrica y del orden de la resta.

La cuestión central

La palabra 'mejor' no tiene signo universal. En log-loss un valor menor es preferible; en accuracy ocurre lo contrario. Una resta sin convención explícita puede invertir la conclusión.

Explicación conceptual

En log-loss, valores menores son mejores. Defina $d_i = \text{loss_A}(i) - \text{loss_B}(i)$: $d_i > 0$ favorece a B, $d_i < 0$ favorece a A y $d_i = 0$ es empate. La dirección debe declararse antes de calcular. Definir $d_i = \text{loss_A}(i) - \text{loss_B}(i)$ convierte dos resultados en un objeto interpretable. Un valor positivo significa que A pierde más y, por tanto, B mejora; un valor negativo favorece a A.

Aplicación en machine learning

La convención depende de la métrica. Para log-loss, A - B positivo favorece a B porque menor es mejor. Para accuracy, la misma resta positiva favorece a A porque mayor es mejor. No existe una regla de signo independiente del significado de la métrica.

Correspondencia con el experimento

Notebook. Punto de control 2 (diapositivas 4-9): ambos modelos producen una probabilidad para cada una de las mismas 30 flores de test; de allí nacen pérdidas y diferencias pareadas.

Límite de interpretación

Cambiar A - B por B - A no cambia la evidencia, pero sí el signo y el lenguaje. Mezclar convenciones produce conclusiones invertidas. La misma convención debe mantenerse en tablas, código, intervalos y conclusión. La dirección de la métrica debe quedar declarada antes de observar los resultados.

Los diez pares revelan siete ventajas para B, dos para A y un empate

Mirar diferencias individuales revela patrones que el promedio no puede mostrar.

La cuestión central

El promedio 0.019 oculta cuántas unidades favorecen a cada modelo, la presencia de empates y si una sola observación domina el resumen.

Explicación conceptual

La tabla contiene siete diferencias positivas, dos negativas y una cero. La variación entre unidades y el máximo 0.06 muestran información que los promedios agregados ocultaban. La tabla conserva la evidencia elemental: siete diferencias positivas, dos negativas y una cero. Esa estructura permite revisar consistencia, dispersión y casos influyentes antes de resumir.

Aplicación en machine learning

En detección de fraude, B podría mejorar siete clientes, empeorar dos y empatar uno. Antes de celebrar el conteo, conviene revisar si una de las dos pérdidas corresponde a un cliente de alto costo o si la mejora máxima domina el promedio.

Correspondencia con el experimento

Notebook. Punto de control 2 (diapositivas 4-9): ambos modelos producen una probabilidad para cada una de las mismas 30 flores de test; de allí nacen pérdidas y diferencias pareadas.

Límite de interpretación

Siete de diez no es una probabilidad de superioridad futura. Es un resumen descriptivo de estas diez unidades. No interprete siete de diez como 70% de probabilidad de superioridad futura ni como una prueba de signos ya realizada. Es descripción de estas unidades.

La unidad es el caso de prueba, no una fila numerada

La unidad se define por el proceso de muestreo, no por la geometría de la tabla.

La cuestión central

Nombrar 'fila' como unidad crea pseudorreplicación: la forma del archivo sustituye al proceso que produjo los datos.

Explicación conceptual

Cada caso de prueba produce dos pérdidas comparables y una diferencia. La heterogeneidad representada es entre casos; no incluye nuevas semillas, nuevas muestras de entrenamiento, otros datasets o cambio de dominio. La unidad es el caso de prueba porque representa una observación relevante del proceso objetivo. Cada unidad contiene dos mediciones comparables y una diferencia. Aquí la variabilidad es entre casos, no entre entrenamientos o dominios.

Aplicación en machine learning

Diez imágenes de prueba representan variación entre imágenes. Diez semillas representan variación de optimización. Aunque ambas tablas tengan diez filas, la primera permite hablar de casos futuros bajo condiciones similares y la segunda de nuevas corridas del entrenamiento.

Correspondencia con el experimento

Notebook. Punto de control 2 (diapositivas 4-9): ambos modelos producen una probabilidad para cada una de las mismas 30 flores de test; de allí nacen pérdidas y diferencias pareadas.

Límite de interpretación

Una fila es solo una forma de almacenar datos. La unidad se define por el proceso que generó la observación. La declaración completa incluye población, unidad y fuente de variabilidad. La conclusión queda limitada a lo efectivamente representado por la muestra.

El emparejamiento depende de la procedencia, no de la forma de la tabla

El emparejamiento lo autoriza la procedencia compartida, no la apariencia tabular.

La cuestión central

Dos columnas con igual longitud parecen pareadas, pero la coincidencia de posición no garantiza que las observaciones correspondan a la misma entidad.

Explicación conceptual

Un par válido exige la misma identidad: el mismo caso evaluado por A y B. Dos filas en la misma posición, pero correspondientes a imágenes distintas, no crean un par y no autorizan d_i . El emparejamiento es una afirmación de identidad o correspondencia científica. Evaluar A y B sobre la misma imagen crea un par; evaluar imágenes distintas en la misma fila no lo crea.

Aplicación en machine learning

Si la columna A contiene image_001, image_002, image_003 y la columna B fue ordenada de otra manera, restar por posición compara entidades distintas. Una clave estable de caso debe demostrar la correspondencia antes de construir las diferencias.

Correspondencia con el experimento

Notebook. Punto de control 2 (diapositivas 4-9): ambos modelos producen una probabilidad para cada una de las mismas 30 flores de test; de allí nacen pérdidas y diferencias pareadas.

Límite de interpretación

No fabrique pares para poder usar una prueba pareada. Si los casos son distintos, el diseño y el procedimiento deben reflejarlo. Los identificadores y la procedencia deben verificarse antes de usar `ttest_rel`. Sin pares reales corresponde un diseño independiente o estructurado coherente; la posición en una tabla no crea pares.

El estimando es $\Delta = E(\text{loss}_A - \text{loss}_B)$; 0.019 es solo su estimación

El estimando formula la pregunta; la estimación es una respuesta provisional de la muestra.

La cuestión central

Es frecuente llamar 'efecto' tanto al parámetro como al número observado. Eso borra la incertidumbre de muestreo.

Explicación conceptual

Δ es la diferencia media que se desea conocer en la población o proceso objetivo. La barra $d = 0.019$ es la estimación calculada con estas diez unidades. Un valor positivo favorece a B por la convención adoptada. El estimando $\Delta = E(\text{loss}_A - \text{loss}_B)$ pertenece a la población o proceso objetivo y es desconocido. La media muestral $\bar{d} = 0.019$ es una estimación obtenida de diez unidades.

Aplicación en machine learning

Para un servicio de predicción, Δ podría ser la diferencia media de log-loss en futuras solicitudes del mismo proceso operativo. Las diez observaciones actuales estiman esa cantidad, pero no representan automáticamente nuevos países, nuevas versiones del modelo o cambio de dominio.

Correspondencia con el experimento

Notebook. Punto de control 2 (diapositivas 4-9): ambos modelos producen una probabilidad para cada una de las mismas 30 flores de test; de allí nacen pérdidas y diferencias pareadas.

Límite de interpretación

El valor 0.019 no es el 'efecto verdadero': es una estimación que cambiaría con otra muestra. Las expresiones correctas son 'la diferencia media observada' o 'la estimación de Δ '. El alcance permanece condicionado a la población declarada.

Restar dentro del par no garantiza independencia entre unidades

Pareado describe la comparación dentro de unidad; independencia describe la relación entre unidades.

La cuestión central

La palabra 'pareado' puede dar una falsa sensación de haber resuelto toda dependencia. Solo organiza la relación A-B dentro de cada unidad.

Explicación conceptual

La resta controla la comparación dentro de cada unidad, pero las diferencias $d_1, \dots, d_n$ aún pueden depender entre sí. Pacientes del mismo hospital, usuarios del mismo hogar o datos con estructura temporal pueden compartir influencias. La resta elimina parte de la variación compartida dentro del par, pero la inferencia se aplica a $d_1, \dots, d_n$. Estas diferencias todavía pueden estar correlacionadas por hospital, usuario, tiempo o cualquier estructura común.

Aplicación en machine learning

En visión médica, varias imágenes del mismo paciente pueden formar pares válidos A-B y, al mismo tiempo, ser dependientes entre sí. El paciente o el centro puede inducir correlación entre las diferencias, reduciendo la cantidad efectiva de información independiente.

Correspondencia con el experimento

Notebook. Punto de control 2 (diapositivas 4-9): ambos modelos producen una probabilidad para cada una de las mismas 30 flores de test; de allí nacen pérdidas y diferencias pareadas.

Límite de interpretación

Pareado no significa independiente. La prueba se aplica a las diferencias y necesita justificar su estructura entre unidades. Evalúe independencia sobre las diferencias, no sobre las pérdidas A y B por separado. Si hay grupos o repetición, el modelo debe representarlos.

La diferencia observada es 0.019 puntos de log-loss a favor de B

El efecto observado debe entenderse en su escala antes de estandarizarlo o probarlo.

La cuestión central

Pasar directamente al p-value deja sin interpretar cuánto cambió la métrica y en qué dirección.

Explicación conceptual

La suma de las diez diferencias es 0.19 y su media es 0.019. Al ser positiva, favorece a B: en estas unidades, B reduce el log-loss promedio en 0.019 puntos frente a A. La media $d_{\text{bar}} = 0.019$ se obtiene sumando 0.19 y dividiendo para diez. Como el signo es positivo y menor log-loss es mejor, B reduce la pérdida promedio en 0.019 puntos en estas unidades.

Aplicación en machine learning

Una reducción de 0.019 en log-loss puede ser valiosa si mejora probabilidades bien calibradas en una decisión de alto costo, o irrelevante si queda por debajo del cambio mínimo operativo. La estadística describe magnitud e incertidumbre; el dominio define utilidad.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

No confunda dirección con relevancia práctica. El dominio, los costos y un umbral previamente definido determinan si 0.019 importa. La significancia estadística no se interpreta antes de describir escala natural, dirección y población observada. Convertir 0.019 en porcentaje tampoco es válido sin una definición explícita.

La misma media pierde precisión cuando aumenta la dispersión

Magnitud y precisión son ejes distintos de la evidencia.

La cuestión central

Una misma media puede provenir de observaciones muy consistentes o muy dispersas. Tratar ambos casos igual confunde magnitud con precisión.

Explicación conceptual

Dos muestras pueden compartir media 0.019 y producir evidencia diferente. Con mayor dispersión, el error estándar crece y el intervalo suele ensancharse; la estimación central no cambia, pero su precisión sí. La dispersión de d_i determina cuánta información aporta la media sobre Delta. Al aumentar la variación manteniendo el centro, crece el error estándar y normalmente se ensancha el intervalo.

Aplicación en machine learning

Dos modelos pueden tener la misma mejora media en diez datasets. En el primer caso las mejoras son cercanas a 0.019 en todos; en el segundo hay grandes ganancias y pérdidas que se cancelan. La segunda comparación ofrece una estimación menos precisa del efecto medio.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

No deduzca precisión a partir de la media. La variabilidad de las diferencias es información indispensable. Una distribución estrecha no implica un efecto más grande cuando el centro es idéntico. La precisión tampoco implica causalidad.

Desviación y error estándar describen objetos distintos

La desviación describe datos; el error estándar describe precisión del estimador.

La cuestión central

Desviación estándar y error estándar comparten unidades y suelen intercambiarse, aunque responden preguntas diferentes.

Explicación conceptual

La desviación $s_d = 0.0260128174$ describe cuánto varían las diferencias individuales. El error estándar $SE(d_{\text{bar}}) = s_d/\sqrt{10} = 0.0082259751$ cuantifica la precisión de la media estimada bajo el modelo de muestreo. $s_d = 0.0260128174$ resume la variabilidad entre las diez diferencias. $SE(d_{\text{bar}}) = s_d/\sqrt{n} = 0.0082259751$ describe la variación esperada de la media estimada bajo el modelo de muestreo.

Aplicación en machine learning

Si se mantienen dispersión e independencia y se pasa de 10 a 40 unidades, el error estándar se reduce aproximadamente por un factor de dos. Esto no hace más homogéneos los casos: solo mejora la precisión con la que se estima su media.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

El error estándar no describe casos individuales y no es una medida de importancia del efecto. Más observaciones no reducen la heterogeneidad real de los casos; reducen la incertidumbre de la media. El error estándar no describe casos individuales.

H0,t: Delta = 0 fija la ausencia de diferencia media

Una hipótesis útil nombra el estimando y el tipo exacto de ausencia que se contrasta.

La cuestión central

'Los modelos son iguales' es una nulidad demasiado amplia: podría referirse a parámetros, predicciones, errores o algoritmos completos.

Explicación conceptual

Reemplace la frase vaga 'los modelos son iguales' por $H_{0,t}: \Delta = 0$. La alternativa bilateral es $H_{1,t}: \Delta \neq 0$. Ambas afirmaciones se refieren a la diferencia media en la población o proceso declarado. $H_{0,t}: \Delta = 0$ declara ausencia de diferencia media en el estimando elegido. $H_{1,t}: \Delta \neq 0$ es bilateral y plantea que la media difiere en alguna dirección.

Aplicación en machine learning

En este módulo H_0 no dice que A y B producen las mismas probabilidades. Solo declara que la diferencia media de log-loss, definida sobre la población objetivo, es cero. Pueden existir diferencias caso a caso aun cuando la media poblacional sea cero.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

H_0 no afirma igualdad de predicciones, errores o algoritmos. Solo fija ausencia de diferencia media en el estimando elegido. No atribuya a H_0 igualdad caso a caso ni equivalencia práctica. Una hipótesis nula es una afirmación sobre un parámetro y un modelo, no una descripción total de los algoritmos.

Cambiar la alternativa después de ver el signo altera el análisis

La alternativa se decide por la pregunta, no por el signo que resultó conveniente.

La cuestión central

Después de observar $d_{\text{bar}} > 0$ aparece la tentación de elegir una prueba unilateral que favorezca B. Ese cambio usa los datos dos veces.

Explicación conceptual

La pregunta bilateral se fija antes de ver los datos. Observar $d_{\text{bar}} > 0$ no autoriza reemplazarla por una alternativa unilateral para reducir el p-value. El contrato debe mantenerse o el cambio debe declararse como análisis posterior. La alternativa es parte del contrato previo. Una pregunta bilateral reconoce ambas direcciones; una unilateral requiere justificación científica previa y consecuencias coherentes si aparece el efecto contrario.

Aplicación en machine learning

Un equipo planea una comparación bilateral, observa que B mejora y cambia a $H1: \Delta > 0$. La dirección ya fue sugerida por los datos. Si el objetivo era confirmar superioridad de B, la justificación unilateral debía existir antes y contemplar qué hacer ante un efecto contrario.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

Una prueba unilateral requiere una dirección científicamente justificada de antemano, no solo un signo favorable observado. Métrica, dirección y alternativa deben quedar preespecificadas. Toda modificación posterior cambia el análisis de confirmatorio a exploratorio y requiere una justificación explícita.

T compara la media de d con su error estándar

El estadístico ordena la evidencia bajo un modelo; no reemplaza la magnitud del efecto.

La cuestión central

La fórmula t puede convertirse en un ritual algebraico sin interpretación: reemplazar números y esperar una etiqueta.

Explicación conceptual

El estadístico es $T = d_{\text{bar}}/SE(d_{\text{bar}}) = 0.019/0.0082259751 = 2.30975656$. Indica que la media observada está a unas 2.31 unidades de error estándar de cero. $T = d_{\text{bar}}/SE(d_{\text{bar}})$ compara señal con incertidumbre. El valor 2.30975656 indica que la media observada está a 2.31 errores estándar de cero bajo la escala del procedimiento.

Aplicación en machine learning

Un efecto de 0.019 con SE 0.0082 y otro de 0.19 con SE 0.082 producen aproximadamente el mismo T. El estadístico comunica distancia relativa a la incertidumbre, pero los dos efectos tienen magnitudes muy distintas en su escala aplicada.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

T no mide relevancia práctica. Un efecto pequeño puede producir un T grande con mucha precisión y viceversa. Estandarizar permite usar una referencia, pero oculta la escala aplicada. T se interpreta junto con el efecto original y su incertidumbre.

Con diez unidades, los supuestos condicionan la prueba t

Los supuestos pertenecen al objeto analizado y al diseño, no solo a la función usada.

La cuestión central

Con $n = 10$, una sola diferencia atípica o dependencia no reconocida puede alterar fuertemente la referencia t.

Explicación conceptual

La t pareada trabaja con $d_1, \dots, d_{10}$. Exige pares correctos, independencia defendible entre diferencias y una forma de distribución razonable, sin valores influyentes que dominen una muestra tan pequeña. La prueba pareada es una prueba de una muestra aplicada a las diferencias. Requiere pares correctos, independencia entre d_i y una forma de distribución razonable para que la media estandarizada se compare con $t_{.9}$.

Aplicación en machine learning

Una diferencia extrema puede deberse a un caso mal etiquetado, un error de preprocesamiento o un subgrupo real. La acción correcta no es borrarla automáticamente: primero se verifica procedencia, luego se informa sensibilidad y se decide si el proceso objetivo incluye ese tipo de caso.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

Diez observaciones no vuelven robusto cualquier análisis. Si el diseño falla, cambiar de función no lo repara. El diagnóstico no se reduce a una prueba automática de normalidad con poca potencia. Incluye forma, valores influyentes y procedencia; un fallo de diseño no se corrige mediante una transformación cosmética.

La prueba t produce $t(9) = 2.30975656$ y $p = 0.0462549274$

El software calcula números; el diseño y el lenguaje determinan qué significan.

La cuestión central

La salida de software invita a mirar únicamente p y emitir una decisión. Así se pierden la magnitud, el intervalo y los supuestos.

Explicación conceptual

La ejecución reproducible entrega estadístico, p-value bilateral e intervalo t. El p-value queda cerca del umbral convencional 0.05, pero la salida debe leerse junto con efecto, intervalo y supuestos. El procedimiento produce $t(9) = 2.30975656$, p bilateral = 0.0462549274 y un IC t. Son tres vistas del mismo modelo: distancia estandarizada, extremidad bajo H_0 y rango de efectos compatibles.

Aplicación en machine learning

`scipy.stats.ttest_rel` puede devolver el mismo t y p aunque el usuario haya emparejado filas incorrectamente. La biblioteca no conoce la identidad de los casos ni la población objetivo; por eso la validación del diseño ocurre fuera de la función.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

No resuma este slide como 'significativo'. El número 0.05 no explica magnitud, precisión, validez ni alcance. Redondear p a 0.05 antes de interpretar o informar únicamente 'se rechaza' elimina información. El cálculo conserva cifras suficientes y el reporte utiliza un redondeo comunicable.

El p-value mide extremidad bajo H_0 ; no mide la probabilidad de H_0

El p-value es una probabilidad de resultados bajo un modelo, no una probabilidad del modelo.

La cuestión central

La confusión central es invertir $P(\text{datos extremos} \mid H_0)$ y $P(H_0 \mid \text{datos})$. Son probabilidades diferentes y una no se obtiene de la otra sin un modelo adicional.

Explicación conceptual

Bajo H_0 , el diseño y los supuestos, $p = P(|T| \geq |T_{\text{obs}}|)$ cuantifica cuán frecuente sería observar un estadístico al menos tan extremo como el obtenido. Compara T_{obs} con una distribución de referencia. El p-value considera un mundo de referencia donde H_0 , el diseño y los supuestos se mantienen. Allí pregunta con qué frecuencia aparecería un $|T|$ al menos tan extremo como $|T_{\text{obs}}|$.

Aplicación en machine learning

Imagine repetir muchas veces el muestreo bajo una situación donde $\Delta = 0$ y recalculando T en cada muestra. El p-value es la proporción teórica de esas repeticiones con $|T|$ al menos tan grande como el observado, siempre bajo el mismo diseño y supuestos.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t , p-value y sensibilidad por caso.

Límite de interpretación

El p-value no es $P(H_0 \mid \text{datos})$, no es la probabilidad de replicación y no mide el tamaño del efecto. No lo describa como probabilidad de error, de replicación o de que la mejora sea real. La frase debe conservar explícitamente el condicionamiento.

p = 0.046 no asigna 4.6% a la nulidad ni 95.4% a la mejora

Corregir la gramática del condicional corrige gran parte de la interpretación estadística.

La cuestión central

Frases como 'H0 tiene 4.6% de probabilidad' parecen intuitivas porque convierten p en confianza directa, pero cambian el objeto condicionado.

Explicación conceptual

Reescriba toda interpretación empezando: 'Bajo H0, el diseño y los supuestos...'. Luego describa la probabilidad de obtener |T| al menos tan extremo. Ese lenguaje conserva el condicionamiento que las frases tachadas omiten. La lectura válida comienza con 'Bajo H0, el diseño y los supuestos...' y termina con la frecuencia de estadísticas al menos tan extremas. No asigna probabilidad posterior a H0 ni a la superioridad.

Aplicación en machine learning

En un reporte de modelos, 'p = 0.046, por tanto hay 95.4% de probabilidad de que B sea mejor' mezcla una probabilidad de resultados con una probabilidad de hipótesis. Para obtener una probabilidad posterior se necesitarían un modelo bayesiano y supuestos adicionales.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

No complete 100% - p para obtener confianza en la alternativa. Ese cálculo no tiene esa interpretación. Reformulaciones como 'hay 95.4% de confianza en B' son incorrectas. La lectura válida contiene el mundo nulo, el estadístico y el criterio de extremidad.

El IC t admite mejoras desde casi cero hasta 0.0376 puntos de log-loss

El intervalo devuelve la inferencia a la escala del problema y hace visible su precisión.

La cuestión central

Un p-value cercano a un umbral no muestra si los efectos compatibles son triviales, importantes o muy inciertos.

Explicación conceptual

El IC t del 95% es [0.00039155, 0.03760845]. Bajo el mismo modelo t, abarca desde una mejora casi nula hasta 0.0376 puntos a favor de B; hace visible la incertidumbre que un p-value no expresa en escala de log-loss. El IC t [0.00039155, 0.03760845] conserva la escala de log-loss. Bajo el procedimiento t, los datos son compatibles con una mejora casi cero y también con una mejora cercana a 0.0376.

Aplicación en machine learning

Dos estudios pueden producir p cercanos y tener intervalos muy diferentes. Uno podría admitir efectos desde casi cero hasta una mejora relevante; otro, un rango estrecho de efectos pequeños. El intervalo permite discutir decisiones que el umbral no resuelve.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t, p-value y sensibilidad por caso.

Límite de interpretación

El intervalo observado no asigna 95% de probabilidad a Delta; en la interpretación frecuentista el parámetro se trata como fijo. El procedimiento produce intervalos con cobertura de largo plazo bajo sus supuestos; no asigna 95% de probabilidad a Delta dentro del intervalo ya calculado.

Una conclusión defendible integra efecto, precisión y límites

Un buen reporte conserva toda la cadena y limita su conclusión al contrato que la sostiene.

La cuestión central

Un reporte puede ser numéricamente correcto y aun así inducir una conclusión excesiva si omite unidad, dirección o alcance.

Explicación conceptual

Construya tres frases: se compararon diez unidades pareadas con $d = \text{loss_A} - \text{loss_B}$; B redujo el log-loss promedio en 0.019; el IC y el p-value t describen incertidumbre bajo supuestos, sin demostrar superioridad general. Una conclusión defendible integra cuatro anclas: diseño y resta; efecto en escala natural; incertidumbre y evidencia condicionada; límite de generalización. Ninguna ancla sustituye a otra.

Aplicación en machine learning

Ejemplo de reporte parcial: 'En diez casos pareados, B redujo el log-loss medio en 0.019 puntos frente a A. El IC t del 95% fue [0.0004, 0.0376] y $p_t = 0.046$ bajo los supuestos de la prueba. El resultado no establece superioridad fuera de estas unidades'.

Correspondencia con el experimento

Notebook. Punto de control 3 (diapositivas 10-21): las diferencias de log-loss se resumen mediante magnitud, dispersión, intervalo, estadístico t , p-value y sensibilidad por caso.

Límite de interpretación

Los términos 'demostrado', 'equivalentes' y 'mejor en general' exceden la evidencia. Un umbral no sustituye el argumento. Los criterios observables incluyen: diez unidades pareadas, definición A-B, magnitud 0.019, intervalo t , p condicionado y ausencia de 'mejor en general'.

Una unidad o un par mal declarados invalidan la inferencia

La validez del diseño precede a cualquier cambio de procedimiento.

La cuestión central

Después de una pausa o cambio de sesión, recordar fórmulas no garantiza recuperar el razonamiento. Es más útil reactivar los puntos donde la cadena puede romperse.

Explicación conceptual

Cuatro fallos rompen piezas distintas del diseño: unidad mal rotulada, par falso, fold tratado como réplica y métrica elegida después de observar resultados. Todos invalidan el cálculo posterior. Las cuatro alertas corresponden a errores distintos: unidad mal rotulada, par falso, dependencia ignorada y plan modificado después de mirar resultados. Cualquiera invalida interpretaciones posteriores.

Aplicación en machine learning

Antes de reutilizar el análisis en otra cohorte, se verifica la conservación de los identificadores, las exclusiones realizadas, la métrica empleada y la posible procedencia común de varias filas.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

Cambiar de prueba no corrige una pregunta o procedencia mal definidas. La frase 'usar otra prueba' no resuelve el problema. Primero se corrige o delimita la estructura de datos; después se selecciona un procedimiento compatible.

Pareado, independiente y estructurado son contratos distintos

El contrato estadístico se identifica por procedencia y dependencia, no por formato.

La cuestión central

La misma tabla de dos columnas puede representar casos pareados, grupos independientes o folds dependientes. Elegir por apariencia conduce a restas y errores estándar inválidos.

Explicación conceptual

Mismos casos permiten diferencias pareadas; casos distintos no autorizan fabricar pares; folds solapados forman una estructura dependiente. Diez filas pueden corresponder a contratos inferenciales incompatibles. En el diseño pareado existe correspondencia por unidad; en el independiente las observaciones proceden de casos distintos; en el estructurado hay vínculos adicionales que deben modelarse.

Aplicación en machine learning

Tres tablas de dos columnas: predicciones de A y B sobre los mismos clientes; scores obtenidos en clientes distintos; scores de folds solapados. Solo la primera autoriza diferencias caso a caso con independencia todavía por justificar.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

La dimensión de una tabla no identifica la unidad ni selecciona la prueba. No fabrique pares en el caso independiente. No trate los folds como observaciones independientes. La procedencia manda sobre el número de filas.

La referencia nula conserva $|d_i|$ y permite invertir signos

Toda aleatorización debe declarar qué conserva, qué cambia y qué nulidad representa.

La cuestión central

'Hacer una permutación' es una instrucción incompleta: diferentes reordenamientos representan nulidades diferentes y algunos destruyen el diseño.

Explicación conceptual

La referencia mantiene magnitudes y pares observados, asigna signos +1 o -1 y recalcula $|media(d)|$. La validez exige que esas inversiones sean defendibles bajo la nulidad de invariancia elegida. El cambio de signo conserva $|d_i|$ y la identidad de cada par; solo invierte qué modelo recibe la ventaja dentro de la unidad. El estadístico es $|media(d)|$ para un contraste bilateral.

Aplicación en machine learning

En una unidad donde $d_i = 0.04$, el cambio de signo permite +0.04 o -0.04 sin alterar su magnitud. La referencia pregunta qué medias surgirían si la asignación de dirección dentro de cada par fuese intercambiable bajo la nulidad.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

El procedimiento no permuta casos entre pares ni elimina su procedencia. 'Permutación' no autoriza cualquier reordenamiento. No intercambie observaciones entre unidades ni confunda esta referencia con reentrenar modelos. La invariancia de signos es una condición de la nulidad.

Tres diferencias generan ocho configuraciones nulas

Construir la referencia con las manos vuelve observable el significado de 'bajo H_0 '.

La cuestión central

La regla de cambios de signo sigue siendo abstracta mientras no se enumeren resultados concretos.

Explicación conceptual

Con tres magnitudes existen $2^3 = 8$ combinaciones de signos. Cada combinación genera una media que se coloca en la misma recta; el conjunto de ocho medias es la distribución de referencia. Con tres magnitudes hay ocho vectores de signos. Cada vector produce una media; el conjunto de esas medias constituye la referencia nula exacta para este ejemplo reducido.

Aplicación en machine learning

Con magnitudes 0.04, 0.01 y 0.03, la configuración (+,+, -) produce media $(0.04 + 0.01 - 0.03)/3$. Repetir el cálculo para las ocho configuraciones transforma una regla abstracta en una distribución visible.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

La exactitud aquí significa enumerar todas las configuraciones permitidas, no garantizar que la nulidad sea apropiada. Aclare que varias configuraciones pueden producir la misma media; lo que se enumera son asignaciones permitidas. No confunda simetría de la referencia con simetría garantizada de cualquier población.

Diez pares producen exactamente 1024 asignaciones de signo

La enumeración exacta elimina error Monte Carlo, no crea información muestral nueva.

La cuestión central

El código puede ocultar que el procedimiento es la repetición sistemática de una operación simple.

Explicación conceptual

Con diez diferencias hay $2^{10} = 1024$ vectores de signos. Para cada uno se multiplica, promedia y compara el valor absoluto con 0.019. La enumeración completa no necesita semilla. `product((-1,1), repeat=10)` genera los 1024 vectores de signos. Cada uno multiplica las diferencias observadas, calcula una media y compara su valor absoluto con 0.019.

Aplicación en machine learning

Una iteración del código puede usar signos (1,-1,1,...), multiplicarlos por el vector d y obtener una media nula. El motor repite exactamente la misma operación; lo único que cambia es el vector de signos.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

No confunda 1024 transformaciones de la misma muestra con 1024 muestras o experimentos independientes. Las 1024 filas computadas no son nuevas observaciones ni aumentan n . Son estados de la referencia condicionada a los diez valores observados.

Sesenta y ocho de 1024 configuraciones dan $p = 0.06640625$

El p-value exacto depende tanto del conteo como de la nulidad que define las configuraciones.

La cuestión central

Contar configuraciones sin definir 'tan extremo' puede producir un p-value unilateral o bilateral distinto sin advertirlo.

Explicación conceptual

Se cuentan 68 configuraciones con $|media_nula| \geq 0.019$. Por tanto, $p = 68/1024 = 0.06640625$. Las dos colas pertenecen a un solo conjunto bilateral de resultados extremos. Para el estadístico $|media(d)|$, una configuración entra en la cola si $|media_nula| \geq 0.019$. Se cuentan 68 de 1024 y el cociente es 0.06640625.

Aplicación en machine learning

Una configuración con media nula -0.022 es extrema porque su valor absoluto supera 0.019. Una media 0.018 no entra en la cola. La bilateralidad se implementa con valores absolutos, no sumando dos p-values calculados de manera improvisada.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

Este p-value es una proporción bajo la referencia declarada; no es probabilidad de que B sea mejor. No interprete 68 como número de muestras ni 0.066 como probabilidad de igualdad. Es una proporción dentro de la referencia declarada.

Exacto no significa libre de supuestos

La exactitud computacional es una propiedad del algoritmo; la validez es una propiedad del argumento completo.

La cuestión central

La palabra 'exacto' suele confundirse con 'verdadero' o 'sin supuestos'. Eso mezcla precisión computacional con validez científica.

Explicación conceptual

El cálculo recorre sin huecos las 1024 transformaciones permitidas. Aun así, debe defenderse la invariancia de signos bajo H_0 y el alcance del diseño hacia la población objetivo. Hay tres puertas: exhaustividad del cálculo, validez de la invariancia de signos y alcance del diseño. Cumplir la primera no garantiza las otras dos.

Aplicación en machine learning

Si las diferencias solo pueden ser positivas por una restricción estructural de la métrica o del proceso, invertir signos podría no representar un estado plausible bajo H_0 . Enumerar todas las inversiones seguiría siendo exacto como cálculo, pero no necesariamente válido como modelo.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

Exacto describe el cálculo condicional a una referencia; no significa universalmente válido ni libre de decisiones científicas. La expresión precisa es 'exacto respecto de esta referencia'. El método no constituye un refugio automático cuando la normalidad resulta dudosa.

La t contrasta media cero; los signos exigen una invariancia más fuerte

P-values distintos pueden ser coherentes cuando responden preguntas condicionales distintas.

La cuestión central

Al obtener dos p-values, es tentador tratarlos como competidores que deberían coincidir o escoger el más favorable.

Explicación conceptual

La t usa $H_0: t: E(d) = 0$ y estandariza la media con su error estándar. Los cambios de signo conservan magnitudes y requieren invariancia conjunta frente a las inversiones permitidas. Son contratos diferentes. La t contrasta media cero mediante una referencia para la media estandarizada. Los signos requieren invariancia conjunta ante inversiones y ordenan $|media(d)|$. Sus nulidades y referencias no son idénticas.

Aplicación en machine learning

La t puede ser el análisis principal si el estimando es la media y sus supuestos son defendibles; los signos pueden servir como sensibilidad a otra invariancia. La jerarquía debe decidirse por pregunta y diseño, no por cuál entrega p menor.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

No elija el procedimiento por el menor p-value. El diseño y la pregunta fijan el contrato antes del resultado. Ningún procedimiento confirma al otro y el menor p-value no adquiere prioridad por ser menor. Uno puede ser principal y otro sensibilidad si esa jerarquía fue declarada.

El efecto favorece a B, pero la fuerza de evidencia depende del contrato

La evidencia puede favorecer una dirección y al mismo tiempo ser frágil respecto del modelo inferencial.

La cuestión central

El umbral puede hacer parecer que $p_t = 0.046$ y $p_{\text{signos}} = 0.066$ cuentan historias opuestas, aunque parten del mismo efecto observado.

Explicación conceptual

La dirección y la media 0.019 no cambian. El IC t es [0.00039155, 0.03760845], $p_t = 0.0462549274$ y $p_{\text{signos}} = 0.06640625$. La calificación inferencial es sensible al modelo y a una muestra pequeña. La dirección, 0.019 y el IC t permanecen. Lo que cambia es la fuerza de evidencia bajo cada contrato. La muestra pequeña hace visible esa sensibilidad.

Aplicación en machine learning

En una revisión ejecutiva, afirmar 'la prueba t ganó y la de signos perdió' es incorrecto. Ambas usan los mismos datos, pero expresan compatibilidad con contratos distintos. El mensaje honesto es que la dirección favorece B y la fuerza inferencial es sensible.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

La discrepancia no invalida uno de los métodos. Revela dependencia respecto del contrato inferencial. No concluya que un procedimiento es correcto porque cruza 0.05. La sensibilidad al modelo es un resultado que debe comunicarse.

Ni $p < 0.05$ demuestra superioridad ni $p > 0.05$ demuestra igualdad

Un umbral puede apoyar una regla de decisión previa; no sustituye la interpretación científica.

La cuestión central

Las reglas binarias borran la diferencia entre ausencia de evidencia, evidencia de ausencia e importancia práctica.

Explicación conceptual

Con p_t por debajo de 0.05 y p_{signos} por encima, usar un semáforo produciría relatos opuestos. Ninguno demuestra superioridad general ni igualdad. Faltan magnitud, precisión, supuestos, alcance y, para equivalencia, una pregunta formal. $p < 0.05$ bajo un contrato no demuestra superioridad general; $p > 0.05$ bajo otro no demuestra igualdad. La equivalencia necesita márgenes y una pregunta formal distinta.

Aplicación en machine learning

Para demostrar equivalencia se necesitaría definir un margen práctico, por ejemplo que diferencias dentro de un rango sean suficientemente pequeñas, y aplicar un procedimiento diseñado para esa pregunta. Un $p > 0.05$ en superioridad no proporciona esa evidencia.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

No significativo significa evidencia insuficiente bajo ese análisis; no evidencia de equivalencia. 'Aceptar H_0 ' no es sinónimo de modelos iguales. La formulación correcta indica que los datos no muestran suficiente incompatibilidad con H_0 bajo ese procedimiento.

B favorece estas unidades; no demuestra superioridad general

La conclusión final debe retener tanto lo observado como las condiciones que limitan su alcance.

La cuestión central

Una conclusión incompleta puede seleccionar solo el p-value conveniente u omitir que el alcance se limita a diez unidades.

Explicación conceptual

Incluya unidades, dirección, magnitud, intervalo, dos referencias y límite. Formulación modelo: en estas diez unidades, B redujo el log-loss promedio en 0.019; el IC t y los dos p-values muestran evidencia sensible al procedimiento y no prueban superioridad general. Las seis piezas son: unidades, dirección, magnitud, intervalo, dos referencias y límite. Juntas producen una afirmación proporcional: B favorece estas unidades, pero la evidencia no demuestra superioridad general.

Aplicación en machine learning

Un informe puede presentar la conclusión en dos niveles: primero el resultado local en las diez unidades; después el límite explícito sobre nuevos casos, semillas o datasets. Esa separación evita que el lector confunda observación con generalización.

Correspondencia con el experimento

Notebook. Punto de control 4 (diapositivas 22-32): los cambios de signo construyen una segunda referencia nula y permiten comparar conclusiones dependientes de contratos distintos.

Límite de interpretación

No omita el resultado que cruza el umbral menos favorable. La sensibilidad es parte de la conclusión, no un inconveniente que se oculta. Incluya ambos p-values y la sensibilidad. No esconda el análisis menos favorable ni convierta el intervalo en garantía de relevancia.

Caso, corrida, dataset y fold generalizan de forma distinta

La etiqueta de la unidad define la variabilidad representada y la frontera de generalización.

La cuestión central

En ML, el mismo término 'comparar modelos' puede referirse a casos, entrenamientos, tareas o particiones. Mezclarlos produce generalizaciones falsas.

Explicación conceptual

Casos representan heterogeneidad entre observaciones; corridas, variación de optimización; datasets, heterogeneidad entre problemas; folds, una partición dependiente del mismo dataset. Cada unidad sostiene un alcance diferente. Cada unidad representa una fuente de variabilidad: casos futuros, optimización entre corridas, heterogeneidad entre datasets o dependencia de particiones. La población objetivo cambia con la unidad.

Aplicación en machine learning

Caso: dos modelos fijos sobre nuevos pacientes. Corrida: dos algoritmos reentrenados con nuevas semillas. Dataset: dos procedimientos aplicados a nuevas tareas. Fold: particiones vinculadas del mismo dataset. Cada escenario cambia qué significa una réplica.

Correspondencia con el experimento

Notebook. Punto de control 5 (diapositivas 33-36): la validación cruzada muestra variación entre folds y, al mismo tiempo, dependencia debida al solapamiento de los conjuntos de entrenamiento.

Límite de interpretación

Compartir diez filas no crea el mismo proceso de muestreo ni la misma población objetivo. Antes de elegir una prueba, la pregunta relevante es '¿qué varía entre filas?'. Un score repetido no es automáticamente una réplica.

Cambiar la unidad cambia el estimando

Cambiar la unidad no es renombrar columnas; cambia la pregunta estadística.

La cuestión central

Tablas idénticas pueden ocultar preguntas poblacionales distintas, por lo que reutilizar el mismo análisis por comodidad es metodológicamente débil.

Explicación conceptual

En casos se estima la diferencia media para casos futuros; en corridas, la diferencia media entre nuevas ejecuciones del entrenamiento; en datasets, el comportamiento medio entre nuevos problemas. La misma forma de tabla es engañosa. Para casos, Delta se refiere a pérdidas en nuevas observaciones; para corridas, a nuevas ejecuciones del entrenamiento; para datasets, a nuevos problemas. Cada estimando integra sobre otra fuente de variación.

Aplicación en machine learning

Si una fila es una corrida, Delta integra variación de inicialización y entrenamiento. Si es un dataset, Delta integra heterogeneidad entre problemas. El mismo valor 0.019 no responde a la misma pregunta en ambos escenarios.

Correspondencia con el experimento

Notebook. Punto de control 5 (diapositivas 33-36): la validación cruzada muestra variación entre folds y, al mismo tiempo, dependencia debida al solapamiento de los conjuntos de entrenamiento.

Límite de interpretación

No traslade automáticamente procedimiento, supuestos o conclusión entre estos niveles. No transfiera automáticamente supuestos o procedimiento entre niveles. Un resultado sobre casos fijos no establece estabilidad entre semillas ni generalidad entre datasets.

Diez filas no hacen equivalentes casos, semillas, datasets y folds

La forma de los datos no determina el tamaño efectivo de la evidencia.

La cuestión central

El número de filas es una señal visual fuerte y engañosa: diez casos, diez semillas, diez datasets y diez folds parecen ofrecer el mismo n .

Explicación conceptual

Las cuatro tablas se distinguen mediante unidad $\rightarrow$ fuente de variabilidad $\rightarrow$ alcance. La procedencia, no las dimensiones, determina la estructura; los folds deben considerarse dependientes. n solo tiene significado junto con la unidad y el proceso generador. Casos, corridas y datasets pueden representar muestras de poblaciones distintas; folds reutilizan el mismo dataset y tienen dependencia adicional.

Aplicación en machine learning

Diez seeds obtenidas sobre un único dataset no equivalen a diez datasets. Pueden demostrar estabilidad de optimización en ese problema, pero no rendimiento relativo en nuevas tareas. La cantidad de filas no amplía por sí sola el dominio de generalización.

Correspondencia con el experimento

Notebook. Punto de control 5 (diapositivas 33-36): la validación cruzada muestra variación entre folds y, al mismo tiempo, dependencia debida al solapamiento de los conjuntos de entrenamiento.

Límite de interpretación

Los folds no son estudios y las semillas no representan casos futuros. Cada fila responde a otra pregunta; una cantidad aparentemente suficiente de filas no garantiza validez, que depende de independencia, muestreo y estimando.

Los folds reutilizan datos y no constituyen réplicas independientes

La reutilización de datos reduce la independencia aparente entre scores de folds.

La cuestión central

Los folds suelen analizarse como si fueran estudios independientes, lo que puede producir errores estándar demasiado optimistas.

Explicación conceptual

Los conjuntos de entrenamiento se solapan y el mismo dataset se reutiliza en todos los folds. Por ello, los scores quedan vinculados; una *t* pareada ingenua sobre folds puede subestimar la incertidumbre. En validación cruzada, los conjuntos de entrenamiento se solapan y todas las particiones provienen del mismo dataset. Los scores están correlacionados y no representan diez nuevas muestras independientes del problema.

Aplicación en machine learning

En 5-fold CV, cada observación aparece en test una vez y en entrenamiento cuatro veces; los modelos de cada fold comparten gran parte de los datos. Esta superposición vincula los scores incluso cuando cada fold produce un número separado.

Correspondencia con el experimento

Notebook. Punto de control 5 (diapositivas 33-36): la validación cruzada muestra variación entre folds y, al mismo tiempo, dependencia debida al solapamiento de los conjuntos de entrenamiento.

Límite de interpretación

Repetir particiones no convierte automáticamente scores correlacionados en observaciones independientes. Este slide marca una frontera metodológica, no prescribe una receta universal. Este slide marca una frontera, no prescribe una prueba universal. El procedimiento depende del objetivo, esquema de remuestreo y literatura metodológica pertinente.

Reproducir exige conservar decisiones y análisis realizados

Reproducir un cálculo es necesario; la trazabilidad del razonamiento exige conservar también las decisiones.

La cuestión central

Guardar el notebook permite repetir cálculos, pero no revela qué análisis se planearon, cuáles se intentaron ni por qué se reportó uno.

Explicación conceptual

Antes: pregunta, población, unidad, métrica, pares y secundarios previstos. Durante: diferencias, efecto, supuestos y decisiones inesperadas. Después: magnitud, límites, versiones y todos los análisis realizados. La reproducibilidad completa conserva decisiones antes, durante y después. También registra multiplicidad: tres métricas por dos procedimientos representan seis análisis, aunque solo uno aparezca en la tabla final.

Aplicación en machine learning

Si se probaron tres métricas y dos procedimientos, el registro debe mostrar seis análisis. Elegir después el único $p < 0.05$ sin declarar los otros cinco crea selección silenciosa y hace que la evidencia parezca más fuerte.

Correspondencia con el experimento

Notebook. Punto de control 6 (diapositiva 37): el resultado final conserva configuración, métrica, unidad, efecto, incertidumbre, supuestos y límites de generalización.

Límite de interpretación

Guardar código no basta si se ocultan decisiones posteriores o se reporta solo el menor p-value. Reproducibilidad y determinismo no son sinónimos. Un resultado puede repetirse perfectamente y seguir basado en un diseño inválido o en selección silenciosa.