

Comparación estadística de modelos

De una diferencia observada a una conclusión defendible.

DISEÑO

INCERTIDUMBRE

DECISIÓN

Dos promedios no bastan para afirmar que un modelo es mejor

DOS RESULTADOS AGREGADOS



CUATRO PREGUNTAS QUE FALTAN


- 1 ¿Mismos casos?** La procedencia decide si hay pares.
- 2 ¿Cuál es la unidad?** Caso, fold o corrida cambian la pregunta.
- 3 ¿Qué variabilidad?** ¿Es consistente entre unidades?
- 4 ¿Qué población o proceso?** ¿Qué representa el test?



El número no autoriza la conclusión sin contrato.

Primero fijamos unidad, procedencia, diseño y variabilidad; después interpretamos.

La comparación se diseña antes de calcular el p -value



TU ACCIÓN Ordena los siete pasos y señala cuáles deben fijarse antes de observar el resultado.

La resta $A - B$ conserva quién mejora porque menor log-loss es mejor

1 PÉRDIDA POR UNIDAD

$$\ell(y, q) = -[y \log(q) + (1 - y) \log(1 - q)]$$

La métrica ya fija qué dirección significa mejorar.

2 SENTIDO DE MEJORA

log-loss ↓

MEJOR


La mejora apunta hacia pérdidas más pequeñas.

RESTA DECLARADA

$$d_i = \text{loss}_A(i) - \text{loss}_B(i)$$

$$d = \text{loss_A} - \text{loss_B}$$

EL SIGNO CONSERVA QUIÉN MEJORA



La dirección solo se interpreta después de fijar la métrica y el orden de la resta.

Los diez pares revelan siete ventajas para B, dos para A y un empate

EVIDENCIA POR UNIDAD

Unidad	A ■	mismo caso	● B	$d = A - B$	lectura
1	0.42	■ → ●	0.38	+0.04	+ favorece B
2	0.37	■ → ●	0.36	+0.01	+ favorece B
3	0.51	■ → ●	0.48	+0.03	+ favorece B
4	0.46	■ ← ●	0.48	-0.02	- favorece A
5	0.40	■ → ●	0.35	+0.05	+ favorece B
6	0.55	■ = ●	0.55	0.00	0 empate
7	0.48	■ → ●	0.46	+0.02	+ favorece B
8	0.44	■ → ●	0.38	+0.06	+ B · máxima
9	0.39	■ → ●	0.38	+0.01	+ favorece B
10	0.52	■ ← ●	0.53	-0.01	- favorece A

LECTURA DEL CASO

- 7

+ favorecen a B

menor log-loss
- 2

- favorecen a A

la ventaja no es uniforme
- 1

0 empate

unidad 6

Máxima: unidad 8 · d = 0.06


MICRODEMOSTRACIÓN

Marca +, - o 0 en cada fila.
¿Qué borrarían dos promedios?

⋮ Los pares conservan dirección, dispersión y concentración; los promedios las ocultan.

La unidad es el caso de prueba, no una fila numerada

UNA UNIDAD • DOS MEDICIONES COMPARABLES • UNA DIFERENCIA



✓ VARIABILIDAD INCLUIDA

heterogeneidad entre casos

Cada caso puede favorecer de forma distinta a A o a B.

+ CONDICIONADO EN

modelos A y B ya entrenados


La inferencia no vuelve a entrenar los modelos.

✗ FUERA DEL ALCANCE


- otra muestra de entrenamiento
- semilla o inicialización
- otros datasets o dominios
- dependencia de cross-validation

El emparejamiento depende de la procedencia, no de la forma de la tabla

1 PAR VÁLIDO · misma identidad



2 RESTA BLOQUEADA · identidades distintas



Misma imagen → existe d_i . Imágenes distintas → la resta se detiene.

El estimando es $\Delta = \mathbb{E}[\text{loss}_A - \text{loss}_B]$
0.019 será solo su estimación

+ ESTIMANDO

PROCESO O POBLACIÓN OBJETIVO




$$\Delta = \mathbb{E}[\text{loss}_A - \text{loss}_B]$$

DESCONOCIDO

Parámetro del proceso:
no se observa directamente.

MUESTREO



UNA MUESTRA
una realización observable

✓ ESTIMACIÓN

DIEZ UNIDADES OBSERVADAS



$$\hat{\Delta} = \frac{1}{n} \sum_{i=1}^n d_i = 0.019$$

CALCULADA

Resumen de esta muestra:
puede cambiar con otra.

LECTURA DEL SIGNO


$\Delta > 0 \Rightarrow$ favorece a B

porque menor pérdida
significa mejor desempeño

≡ ACTIVIDAD

Clasifica cada objeto como estimando o estimación.
Luego explica por qué un signo positivo favorece a B.

Restar dentro del par no garantiza independencia entre unidades



PAREADO $\neq$ INDEPENDIENTE ENTRE UNIDADES

La prueba trabaja sobre diferencias.
El diseño debe sostener su independencia.

La diferencia observada es 0.019 puntos de log-loss a favor de B

DIEZ DIFERENCIAS EN LA ESCALA DE LOG-LOSS

menor pérdida = mejor

1	2	3	4	5	6	7	8	9	10
+0.04	+0.01	+0.03	-0.02	+0.05	0.00	+0.02	+0.06	+0.01	-0.01

$d = [0.04, 0.01, 0.03, -0.02, 0.05, 0.00, 0.02, 0.06, 0.01, -0.01]$

● 7 positivas ● 2 negativas ● 1 cero $n = 10$

CALCULAR EN LA ESCALA NATURAL

$$\bar{d} = \frac{1}{10} \sum_{i=1}^{10} d_i = 0.019$$

media de las diez diferencias observadas



EFECTO OBSERVADO

0.019

puntos de log-loss


El signo positivo favorece a B.

! Sin etiqueta universal: la relevancia depende del dominio, los costos y el umbral sustantivo.

La misma media pierde precisión cuando aumenta la dispersión

MISMA ESCALA · MISMO CENTRO


1 Concentrada



Menor dispersión

menor EE
más precisión

2 Dispersa



Mayor dispersión

mayor EE
menos precisión


PERMANECE media/efecto = 0.019

CAMBIA dispersión · EE · precisión · ancho del intervalo

Desviación y error estándar describen objetos distintos

1 DIFERENCIAS INDIVIDUALES


Diez casos ocupan posiciones distintas.



$$s_d = 0.0260128174$$

dispersión entre los casos


PREGUNTA ¿Cuánto varían los casos?



reduce la incertidumbre de la media

2 MEDIA ESTIMADA

Su distribución es más estrecha.



$$se(\bar{d}) = \frac{s_d}{\sqrt{10}} = 0.0082259751$$

precisión de la media

PREGUNTA ¿Con qué precisión se estima la media?




no es la dispersión de los casos.

NO INTERCAMBIAR OBJETOS

casos individuales y media estimada

$H_{0,t} : \Delta = 0$ fija la ausencia de diferencia media

DEL LENGUAJE VAGO AL CONTRATO ESTADÍSTICO



ALCANCE VÁLIDO DE LA NULIDAD

Ausencia de diferencia media en el estimando declarado.

NO AFIRMA

igualdad total de predicciones, errores, calibración o comportamiento por subgrupos.

ACTIVIDAD Reescribe “los modelos son iguales” como dos hipótesis sobre el estimando.

Cambiar la alternativa después de ver el signo altera el análisis

LA DIRECCIÓN DEL CONTRASTE PERTENECE AL PLAN

ANTES DE VER LOS DATOS

$H_{1,t} : \Delta \neq 0$
pregunta bilateral preespecificada

Permite evidencia en
ambas direcciones.

DESPUÉS: SIGNO OBSERVADO

$\hat{\Delta} = 0.019 > 0$
el dato informa; no reescribe el plan

Resultado compatible con
la pregunta ya fijada.

MANTENER EL CONTRATO

$H_{1,t} : \Delta \neq 0$
interpretación bilateral

DESVÍO POST HOC

$H_{1,t} : \Delta > 0$

Cambiar a una cola porque el signo "conviene"
introduce flexibilidad no declarada.

Regla: observar el signo no autoriza cambiar la pregunta.

Una cola puede ser válida:
si se justifica y fija antes.

T compara la media de $\bar{d}$ con su error estándar

UNA RAZÓN · DOS OBJETOS



NUMERADOR · DIFERENCIA MEDIA

señal observada frente a cero

$$\bar{d} - 0 = 0.019$$

ESTADÍSTICO OBSERVADO

$$T_{\text{obs}} = \frac{\bar{d} - 0}{\text{se}(\bar{d})}$$

$$\frac{0.019}{0.0082259751} = 2.30975656$$



DENOMINADOR · ERROR ESTÁNDAR

incertidumbre de la media

$$\text{se}(\bar{d}) = 0.0082259751$$

ESCALA DE ERRORES ESTÁNDAR DESDE CERO

DISTANCIA ESTANDARIZADA

¿Cuántas unidades de incertidumbre separan la media observada de cero?

$$T_{\text{obs}} = 2.30975656$$



LECTURA CORRECTA

La media observada queda a esta distancia estandarizada de la referencia nula.



T no mide relevancia práctica.

ESTANDARIZAR NO RESPONDE

si el cambio importa en la escala natural del problema.

Con diez unidades, los supuestos condicionan la prueba t

UNA PRUEBA DE UNA MUESTRA SOBRE LAS DIFERENCIAS



✓ Los cuatro controles condicionan juntos la distribución de referencia.

✓ Evalúa los supuestos sobre las diferencias, no sobre las pérdidas A y B por separado.

La prueba t produce $t(9) = 2.30975656$ y $p = 0.0462549274$

CÁLCULO REPRODUCIBLE

```
stats.ttest_rel(
    loss_a,
    loss_b
)
```

SALIDA EXACTA DEL PROCEDIMIENTO

ESTADÍSTICO	$t(9) = 2.30975656$
RESULTADO BILATERAL	$p_{\text{bilateral}} = 0.0462549274$
INTERVALO	$IC_{t,95\%} = [0.00039155, 0.03760845]$

CERCA DE UN UMBRAL CONVENCIONAL; TODAVÍA NO CONCLUYE

Léelo junto con:



SIGUIENTE PREGUNTA

¿Qué probabilidad representa realmente este p -value ?

El *p-value* mide extremidad bajo H_0 ; no mide la probabilidad de H_0

LA PREGUNTA QUE RESPONDE

$$p = P(|T| \geq |T_{obs}| \mid H_0, \text{ diseño y supuestos})$$

? Bajo H_0 , el diseño y los supuestos:
¿qué tan extremo es $|T_{obs}|$ frente a lo que H_0 produciría?

1 Qué se supone

H_0 , diseño y supuestos fijan la distribución de referencia: qué valores podría tomar T bajo H_0 .

2 Qué se calcula

Se compara $|T_{obs}|$ con esa referencia. p mide la proporción con $|T| \geq |T_{obs}|$. Bilateral: importan ambos extremos.

3 Qué no calcula LECTURAS INVÁLIDAS

- × ~~$P(H_0 \mid \text{datos})$~~
- × ~~$P(B \text{ es mejor} \mid \text{datos})$~~
- × ~~probabilidad de repetir el signo~~

∴ *p-value* = extremidad bajo H_0 , no probabilidad posterior.

$p = 0.046$ **no asigna** 4.6 % **a la nulidad ni** 95.4 % **a la mejora**

TRES INVERSIONES DEL CONDICIONAL

1 **× INVÁLIDA**
~~4.6 % de probabilidad de que no exista diferencia.~~

2 **× INVÁLIDA**
~~95.4 % de probabilidad de que la mejora sea real.~~

3 **× INVÁLIDA**
~~95.4 % de probabilidad de repetir el mismo signo.~~



REESCRITURA VÁLIDA

Bajo H_0 , el diseño y los supuestos:

$p = 0.046$ describe la probabilidad de obtener

$|T| \geq |T_{\text{obs}}|$ bajo esa referencia nula.

No asigna probabilidad a la verdad de H_0
ni a que la mejora sea real.

Extremidad condicionada ~~de~~ **probabilidad posterior.**


TU ACCIÓN Corrige las tres frases empezando: "Bajo H_0 , el diseño y los supuestos..."

El IC_t admite mejoras desde casi cero hasta 0.0376 puntos de log-loss

INTERVALO EXACTO EN LA ESCALA DEL EFECTO

puntos de log-loss · resta declarada · valores positivos favorecen a B

$$IC_{t,95\%} = [0.00039155, 0.03760845]$$



LECTURA FRECUENTISTA VÁLIDA

Valores compatibles con los datos bajo el procedimiento paramétrico y sus supuestos.



LECTURA PROBABILÍSTICA INVÁLIDA

"Hay 95% de probabilidad de que el parámetro fijo esté dentro."

IDEA CLAVE

El intervalo cuantifica compatibilidad y precisión; no vuelve aleatorio al parámetro.

Una conclusión defendible integra efecto, precisión y límites

CUATRO ANCLAS



UNIDAD Y RESTA

Diez unidades



EFECTO

Dirección y magnitud




PRECISIÓN

Intervalo y evidencia



LÍMITE

Alcance del diseño



BORRADOR PROVISIONAL EN TRES FRASES

1

Se compararon diez unidades pareadas con pérdida $A - B$
La procedencia autoriza la resta dentro de cada unidad.

2

La diferencia media observada fue $\hat{\Delta} = 0.019$
El intervalo exacto aparece debajo y muestra la precisión del efecto.
 $IC_{t,95\%} = [0.00039155, 0.03760845]$


3

$p_{\text{bilateral}} = 0.0462549274$ es condicional al modelo y a sus supuestos.
Estas diez unidades no demuestran superioridad general.
Hace falta evidencia adicional para ampliar el alcance.

ACTIVIDAD • COMPLETA LAS TRES FRASES SIN USAR
"demostrado" • "equivalentes" • "mejor en general"

UN UMBRAL NO ES UN VEREDICTO

Una unidad o un par mal declarados invalidan la inferencia



Pareado, independiente y estructurado son contratos distintos



✗ 10 filas $\neq$ mismo contrato

La referencia nula conserva $|d_i|$ y permite invertir signos

MÁQUINA DE REFERENCIA NULA



COMPUERTA DE VALIDEZ

¿La inversión de signos es defendible bajo H_0 ?

CONDICIÓN BAJO LA NULIDAD

La regla debe representar una invariancia defendible.

Tres diferencias generan ocho configuraciones nulas


MAGNITUDES FIJAS

$|d_1| = 0.04$

$|d_2| = 0.01$

$|d_3| = 0.03$

Se conserva $|d|$; cambian los signos.




MICRODEMOSTRACIÓN

Elige una configuración, calcula su media y ubícala en la recta común.

Diez pares producen exactamente 1024 asignaciones de signo

MOTOR DE ENUMERACIÓN EXACTA


– **ENUMERACIÓN EXHAUSTIVA:**
NO USA SEMILLA



Sesenta y ocho de 1024 configuraciones dan $p = 0.06640625$

DISTRIBUCIÓN NULA EXACTA DE LAS MEDIAS

enumeración completa



CONFIGURACIONES EXTREMAS EN TOTAL

68

de todas las

1024

MEDIAS NULAS

conteo exhaustivo

$$p = \frac{68}{1024} = 0.06640625$$



Proporción bajo la referencia nula declarada; no es un veredicto sobre los modelos.

Exacto no significa libre de supuestos

1 • EXHAUSTIVIDAD COMPUTACIONAL



2 • VALIDEZ DEL MODELO NULO

3 • GENERALIZACIÓN EXTERNA

INVARIANCIA DE SIGNOS

$$\mathcal{L}(d \mid H_0) \\ = \mathcal{L}(s \odot d \mid H_0)$$

¿La inversión es defendible
bajo H_0 ?

ALCANCE DEL DISEÑO

muestra · tareas
población objetivo

¿Hasta dónde puede
generalizar el diseño?



exacto $\nRightarrow$ validez universal

DOS PREGUNTAS SIGUEN ABIERTAS

validez de la nulidad
y generalización externa

La t contrasta media cero; los signos exigen una invariancia más fuerte

MISMO VECTOR OBSERVADO

d

1 CONTRATO t

NULIDAD $H_{0,t} : \mathbb{E}(d) = 0$

REFERENCIA Modelo para las diferencias.

ESTADÍSTICO $T = \frac{\bar{d}}{s_d / \sqrt{n}}$

QUÉ ORDENA

La media de d en unidades de su error estándar.

2 CONTRATO DE SIGNOS

SE CONSERVA Magnitudes y pares fijos: $|d|$

NULIDAD Distribución conjunta invariante ante las inversiones de signo permitidas.

REGLA $d \mapsto s \odot |d|, \quad s_i \in \{-1, +1\}$

ESTADÍSTICO

$|\bar{d}|$ sobre otra referencia.

≠ Referencias distintas: el diseño fija el contrato; no se elige por el menor

p -value.

El efecto favorece a B, pero la fuerza de evidencia depende del contrato

DIRECCIÓN, MAGNITUD E INCERTIDUMBRE


MUESTRA $n = 10$

DIFERENCIA POR UNIDAD $d = \text{loss}_A - \text{loss}_B$

MEDIA OBSERVADA $\bar{d} = 0.019$

INTERVALO DEL PROCEDIMIENTO

$IC_{t,95\%} = [0.00039155, 0.03760845]$



casi cero
El intervalo y el contraste comparten una única referencia inferencial.
No son confirmaciones independientes.

FUERZA DE EVIDENCIA

CONTRATO t

Modelo para las diferencias

$p_t = 0.0462549274$

CONTRATO DE SIGNOS

Referencia por inversiones permitidas

$p_{\text{signos}} = 0.06640625$
Las referencias nulas son distintas;
por eso cambia la lectura de extremidad.



Dirección observada: favorece a B.

La fuerza de evidencia depende del contrato y de una muestra pequeña.


LÍMITE DEL RESULTADO

No prueba superioridad general
ni relevancia práctica.

Ni $p < 0.05$ demuestra superioridad ni $p > 0.05$ demuestra igualdad

UN MISMO UMBRAL · DOS CONTRATOS DISTINTOS

resultado limítrofe $\neq$ veredicto



REGLA COMÚN

clasifica $\neq$ decide

El umbral clasifica un resultado bajo su contrato;

no decide superioridad práctica ni igualdad.

no significativo $\neq$ evidencia de equivalencia

B favorece estas unidades; no demuestra superioridad general

SEIS PIEZAS • UNA SOLA REDACCIÓN



CONCLUSIÓN PROPORCIONAL

En estas diez unidades pareadas, B redujo la log-loss en promedio 0.019 puntos frente a A.

El intervalo informado fue $IC_{t,95\%} = [0.0004, 0.0376]$

Prueba pareada: $p_t = 0.0463$ · cambios de signo: $p_{\text{signos}} = 0.0664$


La evidencia cambia con el modelo de referencia y la muestra es pequeña.



Motiva más evidencia; no prueba superioridad general ni relevancia práctica.

EL UMBRAL NO ES EL VEREDICTO




Caso, corrida, dataset y fold generalizan de forma distinta



COMPARTIR DIEZ FILAS NO CREA EL MISMO PROCESO DE MUESTREO





la unidad fija el alcance

Cambiar la unidad cambia el estimando

UNIDAD	MISMA FORMA	¿QUÉ MIDE CADA FILA?	POBLACIÓN OBJETIVO → ESTIMANDO
1 CASOS	 10 FILAS	Pérdida por observación $\ell_A - \ell_B$ modelos ya entrenados	 Diferencia media en casos futuros
2 CORRIDAS	 10 FILAS	Desempeño por entrenamiento $m_A - m_B$ optimización y entrenamiento	 Diferencia media entre nuevas corridas
3 DATASETS	 10 FILAS	Desempeño relativo por tarea $r_A - r_B$ una fila = un problema	 Comportamiento medio en nuevos problemas

❌ La misma forma de tabla no autoriza trasladar estimando, supuestos ni procedimiento.

Diez filas no hacen equivalentes casos, semillas, datasets y folds

MISMA SILUETA	UNIDAD	FUENTE DE VARIABILIDAD		ALCANCE	
CASOS 	caso de prueba MODELOS YA FIJADOS	→	heterogeneidad entre casos	→	casos futuros con modelos fijos
SEMILLAS 	corrida completa UNA SEMILLA POR PIPELINE	→	optimización y entrenamiento test compartido = estructura	→	nuevas corridas ≠ NUEVOS CASOS
DATASETS 	dataset o tarea UNA FILA POR PROBLEMA	→	heterogeneidad entre problemas	→	comparación entre tareas o datasets
FOLDS  MISMO DATASET	fold del mismo dataset NO ES UN ESTUDIO NUEVO	→	entrenamiento solapado dataset reutilizado	→	NO SON DIEZ ESTUDIOS detener t ingenua



Completa unidad → fuente de variabilidad → alcance para las cuatro tablas
y marca dónde no usarías una t ingenua.

Los folds reutilizan datos y no constituyen réplicas independientes

UN ÚNICO DATASET
Las observaciones se reutilizan al entrenar.

D

F_1



F_2

F_3

F_4

F_5

EL TEST ROTA; EL TRAIN SE SOLAPA



SOLAPAMIENTO RECONSTRUIBLE
Cualquier par de entrenamientos comparte 3 de 5 bloques

→

NO SON CINCO ESTUDIOS
5 scores del mismo $D \neq 5$ estudios

!

El solapamiento de entrenamiento y la reutilización del dataset pueden subestimar la incertidumbre
Detecta la dependencia y detén la inferencia automática: aquí no existe una receta universal.

Reproducir exige conservar decisiones y análisis realizados

UNA SOLA TRAYECTORIA AUDITABLE

ANTES

- Pregunta y población
- Unidad, métrica y pares
- Contraste primario
- Secundarios previstos

El diseño se fija antes de mirar el resultado.

DURANTE

- Diferencias por unidad
- Efecto e incertidumbre
- Supuestos y dependencia
- Decisiones inesperadas

DESPUÉS

- Dirección, magnitud y límites
- Análisis adicionales
- Datos, código y versiones
- Semilla o enumeración exacta

AUDITORÍA DE MULTIPLICIDAD

Tres métricas y dos procedimientos: registra seis análisis y cuál era el primario.