

Guía de estudio para el estudiante

Slides 1 al 17: de la pregunta de datos a la SVD

Matemáticas aplicadas a Machine Learning · clase de 110 minutos

Mensaje central

Propósito. Esta guía desarrolla las mismas ideas y expresiones matemáticas de los slides 1–17 de `module_05.pdf`. Cada slide incluye una lectura verbal de la expresión principal, el significado de los símbolos, el desarrollo matemático, una interpretación conceptual y preguntas de autoevaluación. El objetivo es que la notación no oculte la idea matemática.



Plan de los 110 minutos

Slide	Objetivo de aprendizaje	Tiempo
1	Fijar el propósito: estructura, error e interpretación	4 min
2	Leer la matriz de datos y formular una hipótesis de redundancia	5 min
3	Entender el orden lógico del módulo antes de calcular	5 min
4	Reactivar producto interno, norma y ortogonalidad	7 min
5	Entender qué significa exactamente $Av = \lambda v$	7 min
6	Dominar el microejemplo simétrico y $A = Q\Lambda Q^T$	8 min
7	Entender por qué la simetría hace limpio el problema espectral	6 min
8	Ver por qué $Av = \lambda v$ falla para matrices rectangulares	6 min
9	Construir $A^T A$ y AA^T y justificar sus propiedades	9 min
10	Identificar V en la entrada y U en la salida	9 min
11	Pasar de autovalores a valores singulares	7 min
12	Leer $A = U\Sigma V^T$ como transformación geométrica	7 min
13	Distinguir SVD completa, reducida y compacta	6 min
14	Seguir la SVD compacta sobre un vector x	9 min
15	Conectar SVD con $A^T A$ y AA^T	6 min
16	Entender la no unicidad literal de los vectores singulares	4 min
17	Verificar la SVD con NumPy y residuales	5 min
Total		110 min

Cómo usar esta guía. Para cada slide conviene seguir siempre la misma secuencia: (1) leer la expresión en palabras, (2) identificar qué representa cada símbolo, (3) comprobar las dimensiones, (4) interpretar geoméricamente la idea y (5) revisar el desarrollo algebraico.

Slide 1 · De direcciones propias a estructura latente

Tiempo sugerido: 4 min

Mensaje central

La clase persigue tres preguntas: qué estructura conserva una matriz, qué error introduce truncarla y qué interpretación es defendible. El recorrido conecta espectro, SVD y aproximación de rango bajo.

Cómo se lee la expresión principal: en este slide no hay una ecuación principal que calcular; es un mapa de preguntas. La sigla SVD se lee “descomposición en valores singulares”.

Símbolos y contexto: a lo largo del módulo, A o X representarán una matriz de datos o una transformación lineal. “Rango bajo” significará representar esa matriz usando menos direcciones activas.

Desarrollo de la expresión matemática

Aunque todavía no calculamos, el mapa matemático completo que aparecerá durante la clase es

$$X \xrightarrow{\text{SVD}} U\Sigma V^T \xrightarrow{\text{truncar}} X_k = U_k \Sigma_k V_k^T \xrightarrow{\text{medir}} \frac{\|X - X_k\|_F}{\|X\|_F}.$$

El primer paso es una descomposición exacta: si conservamos todos los componentes,

$$X = U\Sigma V^T.$$

El segundo paso introduce una aproximación: X_k conserva solo k componentes. El tercero cuantifica la pérdida mediante una norma. La distinción inicial es

$$\underbrace{X = U\Sigma V^T}_{\text{igualdad exacta}} \quad \text{frente a} \quad \underbrace{X \approx X_k}_{\text{aproximación controlada}}.$$

Todavía no necesitamos saber cómo se construyen U , Σ y V ; el objetivo es reconocer hacia dónde conduce el módulo.

Interpretación

Una matriz puede tener muchas columnas, pero parte de la información puede ser redundante. La SVD permite separar direcciones dominantes de direcciones débiles y cuantificar qué se pierde si se descartan estas últimas.

Autoevaluación y conexión

Si dos columnas contienen casi la misma información, ¿es necesario conservar ambas para representar los datos? El slide 2 de `module_05.pdf` muestra una matriz concreta para formular esa hipótesis antes de ejecutar ningún algoritmo.

Slide 2 · Una matriz de datos puede tener más columnas que estructura útil

Tiempo sugerido: 5 min

Mensaje central

La matriz del caso conductor contiene 5 documentos y 4 rasgos:

$$X = \begin{bmatrix} 4 & 5 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ 0 & 1 & 5 & 4 \\ 0 & 1 & 4 & 3 \\ 5 & 6 & 0 & 0 \end{bmatrix}.$$

Cómo se lee: “ X es una matriz de cinco filas por cuatro columnas”. Cada fila representa un documento y cada columna un rasgo.

Símbolos: X es la matriz de datos; una entrada x_{ij} es el valor del rasgo j para el documento i . Aquí $m = 5$ filas y $n = 4$ columnas.

Interpretación

Antes de calcular, observa el patrón. Las columnas 1 y 2 se activan en documentos parecidos; lo mismo ocurre con las columnas 3 y 4. Esto sugiere que cuatro rasgos pueden contener menos de cuatro patrones dominantes. Es una hipótesis visual, no una conclusión todavía. Aquí una **dirección** significa una orientación vectorial en el espacio de características; varias direcciones dominantes pueden generar un subespacio de menor dimensión efectiva.

Autoevaluación y conexión

¿Cuántos vectores columna tiene X ? Cuatro. ¿Eso implica cuatro direcciones independientes? No necesariamente. Antes de comprimir debemos ordenar el razonamiento matemático.

Desarrollo de la expresión matemática

Es útil mirar la matriz como un conjunto de columnas:

$$X = [x_1 \ x_2 \ x_3 \ x_4],$$

con

$$x_1 = \begin{bmatrix} 4 \\ 3 \\ 0 \\ 0 \\ 5 \end{bmatrix}, \quad x_2 = \begin{bmatrix} 5 \\ 4 \\ 1 \\ 1 \\ 6 \end{bmatrix}, \quad x_3 = \begin{bmatrix} 0 \\ 0 \\ 5 \\ 4 \\ 0 \end{bmatrix}, \quad x_4 = \begin{bmatrix} 0 \\ 0 \\ 4 \\ 3 \\ 0 \end{bmatrix}.$$

Una matriz de 5×4 puede tener como máximo rango 4:

$$\text{rank}(X) \leq \min(5, 4) = 4.$$

Pero el número de columnas no obliga a que existan cuatro direcciones realmente independientes. Si una columna fuese combinación lineal exacta de otras, por ejemplo

$$x_4 = \alpha_1 x_1 + \alpha_2 x_2 + \alpha_3 x_3,$$

el rango disminuiría. En este caso no afirmamos todavía dependencia exacta: visualmente observamos patrones parecidos entre (x_1, x_2) y entre (x_3, x_4) .

Más adelante la SVD convertirá esta intuición en una afirmación cuantitativa: direcciones casi redundantes suelen manifestarse mediante valores singulares pequeños. Por ahora, la conclusión correcta es solo una hipótesis de estructura efectiva menor que el número de columnas.

Slide 3 · La narrativa correcta no empieza con el comando svd

Tiempo sugerido: 5 min

Mensaje central

El orden del módulo es: formular el problema, estudiar el espectro, justificar la necesidad de SVD, aplicar la SVD, truncar, medir el error, interpretar y validar.

Cómo se lee la expresión principal: este slide no tiene una ecuación central; tiene una secuencia lógica. “Aplicar SVD” no es el primer paso, sino una consecuencia de haber entendido qué problema matemático tenemos.

Símbolos y términos: espectro = conjunto de autovalores de una matriz cuadrada; SVD = descomposición en valores singulares; truncar = conservar solo las primeras direcciones singulares.

Desarrollo de la expresión matemática

La secuencia puede escribirse como una cadena matemática. Partimos de

$$X \in \mathbb{R}^{m \times n}.$$

Primero recuperaremos un problema espectral cuadrado mediante

$$X^T X v_i = \lambda_i v_i,$$

y, como $X^T X$ es semidefinida positiva, sus autovalores relevantes satisfacen $\lambda_i \geq 0$. De ellos aparecerán las escalas singulares

$$\sigma_i = \sqrt{\lambda_i}.$$

Después construiremos la SVD exacta

$$X = U \Sigma V^T.$$

Solo entonces introduciremos el truncamiento:

$$X_k = U_k \Sigma_k V_k^T = \sum_{i=1}^k \sigma_i u_i v_i^T,$$

y mediremos el error, por ejemplo con

$$\|X - X_k\|_F \quad \text{o} \quad \frac{\|X - X_k\|_F}{\|X\|_F}.$$

Este slide distingue tres etapas que suelen confundirse: descomponer X , aproximar mediante X_k y evaluar cuánto se perdió.

Interpretación

Los autovalores funcionan naturalmente para matrices cuadradas; la SVD extiende esa intuición a matrices rectangulares. Luego, el truncamiento convierte la descomposición exacta en una herramienta de compresión.

Autoevaluación y conexión

¿Qué conocimientos mínimos necesitamos antes de hablar de autovectores y SVD? Producto interno, norma y ortogonalidad. Eso es lo que reactiva el slide 4.

Slide 4 · Norma, producto interno y ortogonalidad

Tiempo sugerido: 7 min

Mensaje central

Los conceptos geométricos que reaparecerán son

$$\langle x, y \rangle = x^T y, \quad \|x\|_2 = \sqrt{x^T x}, \quad x \perp y \iff x^T y = 0, \quad Q^T Q = I.$$

Cómo se lee: “el producto interno de x e y es x transpuesta por y ”; “la norma dos de x es la raíz cuadrada de x transpuesta por x ”; “ x es ortogonal a y si y solo si x transpuesta por y es cero”; “ Q transpuesta por Q es igual a la identidad”.

Símbolos: x, y son vectores; T significa transpuesta; $\langle x, y \rangle$ es producto interno; $\|x\|_2$ es longitud euclídea; $\perp$ significa ortogonalidad; Q es una matriz con columnas ortonormales; I es la identidad.

Desarrollo de la expresión matemática

El producto interno permite obtener coordenadas sobre una dirección. Si q_i es unitario, entonces

$$q_i^T x$$

es la coordenada de x en la dirección q_i . Si reunimos una base ortonormal en

$$Q = [q_1 \ q_2 \ \cdots \ q_n],$$

entonces

$$Q^T x = \begin{bmatrix} q_1^T x \\ q_2^T x \\ \vdots \\ q_n^T x \end{bmatrix}$$

recoge todas esas coordenadas de una sola vez.

Ahora desarrollemos la condición de ortonormalidad:

$$Q^T Q = \begin{bmatrix} q_1^T q_1 & \cdots & q_1^T q_n \\ \vdots & \ddots & \vdots \\ q_n^T q_1 & \cdots & q_n^T q_n \end{bmatrix} = I.$$

Por tanto,

$$q_i^T q_i = 1, \quad q_i^T q_j = 0 \quad (i \neq j).$$

Es decir, cada columna tiene norma 1 y columnas distintas son ortogonales.

Además, una matriz ortogonal conserva la norma euclídea:

$$\|Qx\|_2^2 = (Qx)^T (Qx) = x^T Q^T Q x = x^T I x = x^T x = \|x\|_2^2.$$

Luego

$$\|Qx\|_2 = \|x\|_2.$$

Esta propiedad explica por qué Q , y más adelante U y V , pueden reinterpretar coordenadas sin introducir por sí mismas estiramiento; el escalamiento aparecerá en una matriz diagonal.

Autoevaluación y conexión

Si una matriz tiene direcciones especiales que no cambian de dirección al transformarlas, necesitamos un concepto nuevo: el autovector.

Slide 5 · $Av = \lambda v$ fija una dirección propia

Tiempo sugerido: 7 min

Mensaje central

Un autovector $v \neq 0$ de una matriz cuadrada A satisface

$$Av = \lambda v.$$

La matriz puede estirar, comprimir o invertir el vector, pero no lo saca de su misma recta.

Cómo se lee: “ A por v es igual a λ por v ”.

Símbolos: $A \in \mathbb{R}^{n \times n}$ es una matriz cuadrada; $v \in \mathbb{R}^n$ es un autovector no nulo; $\lambda \in \mathbb{R}$ (en el caso simétrico real que veremos) es el autovalor y representa el factor de escala asociado a esa dirección.

Desarrollo de la expresión matemática

Partimos de la definición

$$Av = \lambda v, \quad v \neq 0.$$

Llevamos todo al mismo lado:

$$Av - \lambda v = 0.$$

Como $v = Iv$, podemos factorizar:

$$Av - \lambda Iv = (A - \lambda I)v = 0.$$

Queremos una solución no nula. Si $A - \lambda I$ fuese invertible, multiplicar por $(A - \lambda I)^{-1}$ obligaría a $v = 0$. Por tanto, para que exista un autovector no nulo, $A - \lambda I$ debe ser singular:

$$\det(A - \lambda I) = 0.$$

Esta es la ecuación característica.

Para una matriz general 2×2 ,

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}, \quad A - \lambda I = \begin{bmatrix} a - \lambda & b \\ c & d - \lambda \end{bmatrix},$$

y

$$\det(A - \lambda I) = (a - \lambda)(d - \lambda) - bc = 0.$$

Las raíces de esta ecuación son los autovalores. Después, para cada raíz λ_i , resolvemos

$$(A - \lambda_i I)v = 0$$

para obtener la dirección propia correspondiente. El slide 6 realiza exactamente estos pasos con números concretos.

Interpretación

“Autovector” describe una dirección. Si v es autovector, cualquier múltiplo no nulo cv representa la misma dirección y también es autovector del mismo autovalor.

Autoevaluación y conexión

El slide 6 de `module_05.pdf` usa una matriz 2×2 simétrica para ver todo el mecanismo completo con números concretos.

Slide 6 · La simetría revela direcciones propias ortogonales

Tiempo sugerido: 8 min

Mensaje central

El microejemplo usa

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad A = Q\Lambda Q^T.$$

Sus direcciones propias ortonormales son

$$u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad u_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

con autovalores 3 y 1.

Cómo se lee: “ A es igual a Q por Λ por Q transpuesta”. Se aplica de derecha a izquierda sobre un vector: primero Q^T , luego Λ , finalmente Q .

Símbolos: A es la transformación; $Q = [u_1 \ u_2]$ contiene autovectores ortonormales; $\Lambda = \text{diag}(3, 1)$ contiene autovalores; Q^T es la transpuesta de Q .

Desarrollo de la expresión matemática

Trabajamos con

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

1. Autovalores. Calculamos

$$A - \lambda I = \begin{bmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix}$$

y exigimos

$$\det(A - \lambda I) = 0.$$

Para una matriz 2×2 , el determinante es producto de la diagonal principal menos producto de la diagonal secundaria:

$$(2 - \lambda)(2 - \lambda) - (1)(1) = 0.$$

Entonces

$$(2 - \lambda)^2 - 1 = 0 \implies \lambda^2 - 4\lambda + 3 = 0 \implies (\lambda - 3)(\lambda - 1) = 0,$$

de donde

$$\lambda_1 = 3, \quad \lambda_2 = 1.$$

2. Autovector asociado a $\lambda_1 = 3$. Sustituimos:

$$(A - 3I)v = 0 \implies \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = 0.$$

La primera ecuación da

$$-v_1 + v_2 = 0 \implies v_2 = v_1.$$

Podemos elegir como representante de esa dirección

$$\tilde{u}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Su norma es

$$\|\tilde{u}_1\|_2 = \sqrt{1^2 + 1^2} = \sqrt{2},$$

por lo que el autovector normalizado es

$$u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

3. Autovector asociado a $\lambda_2 = 1$. Ahora

$$(A - I)v = 0 \implies \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = 0,$$

de modo que

$$v_1 + v_2 = 0 \implies v_2 = -v_1.$$

Elegimos

$$\tilde{u}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad \|\tilde{u}_2\|_2 = \sqrt{2},$$

y normalizamos:

$$u_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

4. Construcción de Q y Λ . Colocamos los autovectores normalizados como columnas, respetando el mismo orden de sus autovalores:

$$Q = [u_1 \ u_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

Los ceros de Λ expresan que, en esta base, las dos direcciones propias no se mezclan: una coordenada se escala por 3 y la otra por 1.

Como u_1 y u_2 son ortonormales,

$$Q^T Q = I \quad \text{y por tanto} \quad Q^{-1} = Q^T.$$

La diagonalización queda

$$A = Q \Lambda Q^T.$$

Leída sobre un vector x :

$$x \xrightarrow{Q^T} Q^T x \xrightarrow{\Lambda} \Lambda Q^T x \xrightarrow{Q} Q \Lambda Q^T x = Ax.$$

Así se explica también la figura círculo $\rightarrow$ elipse: en la dirección u_1 la longitud se multiplica por 3, mientras que en la dirección u_2 se multiplica por 1.

Autoevaluación y conexión

Este ejemplo funciona de forma especialmente limpia porque $A = A^T$. El slide 7 explica qué se gana exactamente con la simetría.

Slide 7 · Por qué la simetría importa

Tiempo sugerido: 6 min

Mensaje central

Para una matriz real simétrica, $A = A^T$, los autovalores son reales y existe una base ortonormal de autovectores. Por eso puede escribirse

$$A = Q\Lambda Q^T,$$

con $Q^T Q = I$ y Λ diagonal.

Cómo se lee: “ A es igual a Q por Λ por Q transpuesta”; “ Q transpuesta por Q es igual a la identidad”.

Símbolos: A es la matriz simétrica; Q contiene autovectores ortonormales; Λ contiene los autovalores en su diagonal; I es la identidad; T indica transposición.

Interpretación

La matriz no necesita mezclar arbitrariamente las direcciones: podemos elegir ejes perpendiculares especiales y, en esos ejes, la transformación se reduce a escalar cada coordenada. La acción de A se entiende como obtener coordenadas, escalar y regresar al sistema original.

Desarrollo de la expresión matemática

Si las columnas de Q son autovectores ortonormales $q_1, \dots, q_n$, entonces

$$Aq_i = \lambda_i q_i.$$

Agrupando todos los autovectores:

$$Q = [q_1 \ q_2 \ \cdots \ q_n], \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n).$$

La diagonalización ortogonal es

$$A = Q\Lambda Q^T.$$

Al actuar sobre un vector x :

$$x \xrightarrow{Q^T} Q^T x \xrightarrow{\Lambda} \Lambda Q^T x \xrightarrow{Q} Q\Lambda Q^T x = Ax.$$

Aquí $Q^T x$ obtiene las coordenadas de x en la base de autovectores; Λ multiplica cada coordenada por su autovalor; Q reconstruye el vector en el sistema original.

Autoevaluación y conexión

Si $Q^T Q = I$, ¿qué propiedad tienen las columnas de Q ? Son ortonormales. Todo esto funciona porque A es cuadrada. ¿Qué ocurre cuando una matriz de datos tiene $m \neq n$?

Slide 8 · El lenguaje de autovalores falla en matrices rectangulares

Tiempo sugerido: 6 min

Mensaje central

Si

$$A \in \mathbb{R}^{m \times n}, \quad A: \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad m \neq n,$$

la ecuación $Av = \lambda v$ no está bien tipada: sus dos lados viven en espacios distintos.

Cómo se lee: “ A pertenece a las matrices reales de m por n y transforma vectores de $\mathbb{R}^n$ en vectores de $\mathbb{R}^m$ ”. “ m distinto de n ” indica que la matriz es rectangular.

Símbolos: m = dimensión de salida/número de filas; n = dimensión de entrada/número de columnas; $v \in \mathbb{R}^n$ = vector de entrada; $Av \in \mathbb{R}^m$ = vector de salida; λ = escalar.

Interpretación

Un autovector exige que el vector de salida pueda compararse con el vector de entrada porque debe quedar sobre la misma dirección. En una matriz rectangular, A lleva vectores de $\mathbb{R}^n$ a $\mathbb{R}^m$; por tanto, no podemos pedir en general que Av sea un múltiplo escalar de v .

Desarrollo de la expresión matemática

Sea

$$v \in \mathbb{R}^n.$$

Entonces

$$Av \in \mathbb{R}^m.$$

En cambio,

$$\lambda v \in \mathbb{R}^n.$$

Por tanto, si $m \neq n$,

$$Av \in \mathbb{R}^m \quad \text{y} \quad \lambda v \in \mathbb{R}^n$$

y la igualdad

$$Av = \lambda v$$

no puede plantearse en el sentido usual. No significa que la matriz rectangular “no tenga estructura”; significa que el problema espectral debe reformularse.

Autoevaluación y conexión

Si A es 5×4 y $v \in \mathbb{R}^4$, entonces $Av \in \mathbb{R}^5$. ¿Dónde vive λv ? En $\mathbb{R}^4$. Por ello necesitamos construir matrices cuadradas que conserven información sobre la entrada y la salida.

Slide 9 · $A^T A$ y AA^T recuperan problemas simétricos

Tiempo sugerido: 9 min

Mensaje central

A partir de $A \in \mathbb{R}^{m \times n}$ construimos

$$A^T A \in \mathbb{R}^{n \times n}, \quad AA^T \in \mathbb{R}^{m \times m}.$$

Ambas matrices son cuadradas, simétricas y semidefinidas positivas.

Cómo se lee: “ A transpuesta por A ” y “ A por A transpuesta”. La primera actúa en el espacio de entrada; la segunda, en el espacio de salida.

Símbolos: A = matriz original; A^T = transpuesta; m, n = dimensiones de salida y entrada; x = vector de prueba; $\|Ax\|_2$ = longitud de Ax .

Interpretación

$A^T A$ vuelve al espacio de entrada: primero aplicamos A y después A^T . Por eso actúa sobre vectores de $\mathbb{R}^n$. En cambio, AA^T actúa en el espacio de salida $\mathbb{R}^m$. Esta construcción permite reutilizar las propiedades de las matrices simétricas vistas en el slide 7.

Desarrollo de la expresión matemática

1. **Simetría.** Usamos $(BC)^T = C^T B^T$:

$$(A^T A)^T = A^T (A^T)^T = A^T A,$$

$$(AA^T)^T = (A^T)^T A^T = AA^T.$$

Por tanto, ambas son simétricas.

2. **Semidefinición positiva.** Para cualquier $x \in \mathbb{R}^n$,

$$x^T A^T A x = (Ax)^T (Ax) = \|Ax\|_2^2 \geq 0.$$

Análogamente, para cualquier $y \in \mathbb{R}^m$,

$$y^T AA^T y = \|A^T y\|_2^2 \geq 0.$$

Por esto sus autovalores son reales y no negativos.

Precisión importante. “Semidefinida positiva” no significa que todos los autovalores sean estrictamente positivos. Puede haber autovalores iguales a cero; eso ocurrirá cuando existan direcciones que A anula.

Autoevaluación y conexión

¿Por qué es importante que los autovalores sean no negativos? Porque podremos definir una escala real

$$\sigma_i = \sqrt{\lambda_i}.$$

El siguiente paso es identificar qué direcciones obtiene $A^T A$ y qué direcciones obtiene AA^T .

Slide 10 · $A^T A \rightarrow V$ y $AA^T \rightarrow U$

Tiempo sugerido: 9 min

Mensaje central

Los autovectores de $A^T A$ forman las direcciones singulares de entrada v_i ; los de AA^T forman las direcciones singulares de salida u_i :

$$A^T A v_i = \sigma_i^2 v_i, \quad AA^T u_i = \sigma_i^2 u_i.$$

Cómo se lee: “ A transpuesta por A por v sub i es igual a sigma sub i al cuadrado por v sub i ”; análogamente para u_i .

Símbolos: $v_i \in \mathbb{R}^n$ = vector singular derecho/entrada; $u_i \in \mathbb{R}^m$ = vector singular izquierdo/salida; $\sigma_i \geq 0$ = valor singular; $V = [v_1 \ v_2 \ \dots]$ y $U = [u_1 \ u_2 \ \dots]$ agrupan esas direcciones.

Desarrollo de la expresión matemática

Para cada dirección activa v_i :

$$A^T A v_i = \sigma_i^2 v_i.$$

Como $A^T A \in \mathbb{R}^{n \times n}$, tenemos $v_i \in \mathbb{R}^n$. Agrupamos estas direcciones en

$$V = [v_1 \ v_2 \ \dots].$$

En el espacio de salida:

$$AA^T u_i = \sigma_i^2 u_i,$$

con $u_i \in \mathbb{R}^m$, y

$$U = [u_1 \ u_2 \ \dots].$$

Los autovalores no nulos de $A^T A$ y AA^T coinciden:

$$\lambda_i(A^T A) = \lambda_i(AA^T) = \sigma_i^2 \quad (\sigma_i > 0).$$

Interpretación

V organiza direcciones de entrada; U organiza direcciones de salida; σ_i conecta cuánto se escala una dirección de entrada para convertirse en una dirección de salida. Para $\sigma_i > 0$ se puede definir

$$u_i = \frac{A v_i}{\sigma_i}.$$

Así, si conocemos v_i y σ_i , obtenemos automáticamente la dirección correspondiente u_i .

Autoevaluación y conexión

¿Por qué v_i tiene dimensión n y u_i dimensión m ? Porque pertenecen, respectivamente, al dominio y codominio de A . Falta convertir σ_i^2 en una escala σ_i y reunir U , Σ y V en una sola factorización.

Slide 11 · De autovalores a valores singulares

Tiempo sugerido: 7 min

Mensaje central

Si

$$\lambda_i = \sigma_i^2,$$

entonces

$$\sigma_i = \sqrt{\lambda_i} \geq 0, \quad Av_i = \sigma_i u_i.$$

Cómo se lee: “lambda sub i es igual a sigma sub i al cuadrado; por tanto sigma sub i es la raíz de lambda sub i y es no negativa”. “ A por v_i es igual a sigma i por u_i ”.

Símbolos: λ_i = autovalor de $A^T A$ o AA^T ; σ_i = valor singular; v_i = dirección de entrada; u_i = dirección de salida; $\Sigma = \text{diag}(\sigma_i)$ = matriz diagonal de escalas.

Desarrollo de la expresión matemática

De

$$A^T Av_i = \sigma_i^2 v_i$$

definimos, para $\sigma_i > 0$,

$$u_i = \frac{Av_i}{\sigma_i}.$$

Multiplicando por σ_i :

$$Av_i = \sigma_i u_i.$$

Esta igualdad es la pieza esencial de la SVD: si entra exactamente la dirección v_i , A la envía a la dirección u_i y cambia su longitud por el factor σ_i .

Reuniendo todas las direcciones:

$$V = [v_1 \ v_2 \ \cdots], \quad U = [u_1 \ u_2 \ \cdots], \\ \Sigma = \text{diag}(\sigma_1, \sigma_2, \dots),$$

obtenemos

$$A = U\Sigma V^T.$$

Interpretación

La SVD separa la transformación en tres funciones: V^T obtiene coordenadas en las direcciones de entrada, Σ escala esas coordenadas y U expresa el resultado en direcciones del espacio de salida.

Autoevaluación y conexión

Si $\sigma_i = 0$, ¿qué ocurre con esa dirección? A la envía al vector cero; es una dirección sin contribución activa a la salida. El siguiente slide interpreta la factorización completa como una transformación geométrica.

Slide 12 · SVD: la descomposición que corresponde al problema real

Tiempo sugerido: 7 min

Mensaje central

Para cualquier matriz real $A \in \mathbb{R}^{m \times n}$ existe

$$A = U\Sigma V^T.$$

U y V contienen direcciones ortonormales y Σ contiene valores singulares no negativos.

Cómo se lee: “ A es igual a U por Sigma por V transpuesta”. Al aplicarla a x , se lee de derecha a izquierda: primero $V^T x$, luego Σ , finalmente U .

Símbolos: A = transformación; V = direcciones de entrada; V^T = obtiene coordenadas; Σ = escalas singulares; U = direcciones de salida; x = vector de entrada; Ax = salida.

Interpretación

La multiplicación se entiende actuando sobre un vector x y leyendo de derecha a izquierda:

$$Ax = U\Sigma V^T x.$$

Cada factor tiene una función concreta y distinta.

Desarrollo de la expresión matemática

$$x \xrightarrow{V^T} z = V^T x \xrightarrow{\Sigma} w = \Sigma z \xrightarrow{U} y = Uw = Ax.$$

$V^T x$: obtiene las coordenadas de x respecto de las direcciones singulares de entrada.

Σz : multiplica cada coordenada por su valor singular; no mezcla coordenadas porque Σ es diagonal.

Uw : reconstruye el resultado en el espacio de salida.

Si V y U son ortogonales (en la forma completa), preservan normas y ángulos; el cambio de magnitud ocurre en Σ .

Precisión importante. No conviene interpretar V^T y U únicamente como “rotaciones”. Una matriz ortogonal puede incluir reflexiones. La afirmación segura es: preservan producto interno, normas y ángulos.

Autoevaluación y conexión

La fórmula $A = U\Sigma V^T$ puede escribirse con diferentes tamaños. El slide 13 distingue la forma completa, reducida y compacta.

Slide 13 · SVD completa, reducida y compacta

Tiempo sugerido: 6 min

Mensaje central

Sea $A \in \mathbb{R}^{m \times n}$, $q = \min(m, n)$ y $r = \text{rank}(A)$. Las formas completa, reducida y compacta representan la misma matriz, pero mantienen distinto número de direcciones.

Cómo se lee: por ejemplo, $U \in \mathbb{R}^{m \times m}$ se lee “ U es una matriz real de m filas por m columnas”. $q = \min(m, n)$ se lee “ q es el menor entre m y n ”.

Símbolos: m = filas/salida; n = columnas/entrada; q = menor dimensión; r = rango de A , número de valores singulares positivos; subíndices q y r indican cuántas columnas/direcciones se conservan.

Desarrollo de la expresión matemática

SVD completa

$$A = U \Sigma V^T, \quad U \in \mathbb{R}^{m \times m}, \quad \Sigma \in \mathbb{R}^{m \times n}, \quad V^T \in \mathbb{R}^{n \times n}.$$

SVD reducida (economy/thin)

$$A = U_q \Sigma_q V_q^T, \quad U_q \in \mathbb{R}^{m \times q}, \quad \Sigma_q \in \mathbb{R}^{q \times q}, \quad V_q^T \in \mathbb{R}^{q \times n}.$$

SVD compacta

$$A = U_r \Sigma_r V_r^T, \quad U_r \in \mathbb{R}^{m \times r}, \quad \Sigma_r \in \mathbb{R}^{r \times r}, \quad V_r^T \in \mathbb{R}^{r \times n}.$$

La forma compacta conserva únicamente los valores singulares positivos y las direcciones asociadas.

Interpretación

Ejemplo: si A es 5×4 y tiene rango $r = 2$, entonces $q = 4$. La forma reducida usa $U_q \in \mathbb{R}^{5 \times 4}$, mientras que la compacta usa solo $U_r \in \mathbb{R}^{5 \times 2}$. La compacta elimina explícitamente las direcciones correspondientes a valores singulares cero.

Autoevaluación y conexión

¿Qué forma es la más natural si queremos hablar solo de las direcciones realmente activas? La compacta. El slide 14 sigue exactamente qué le ocurre a un vector usando esa forma.

Slide 14 · SVD compacta: coordenadas activas, escala y reconstrucción

Tiempo sugerido: 9 min

Mensaje central

Con

$$A = U_r \Sigma_r V_r^T,$$

un vector $x \in \mathbb{R}^n$ pasa por

$$z = V_r^T x, \quad w = \Sigma_r z, \quad y = U_r w = Ax.$$

Cómo se lee: “ z es V sub r transpuesta por x ”; “ w es Sigma sub r por z ”; “ y es U sub r por w , igual a A por x ”.

Símbolos: r = rango de A ; x = entrada; $z \in \mathbb{R}^r$ = coordenadas activas; $w \in \mathbb{R}^r$ = coordenadas escaladas; $y \in \mathbb{R}^m$ = salida; V_r, U_r = bases activas; Σ_r = valores singulares positivos.

Desarrollo de la expresión matemática

Sea $x \in \mathbb{R}^n$.

Paso 1: coordenadas activas

$$z = V_r^T x \in \mathbb{R}^r.$$

Cada componente es un producto interno:

$$z_i = v_i^T x.$$

Por tanto, z_i mide cuánto de x está alineado con la dirección singular v_i .

Paso 2: escala diagonal

$$w = \Sigma_r z \in \mathbb{R}^r.$$

Como $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$,

$$w_i = \sigma_i z_i.$$

No se mezclan coordenadas: cada eje se escala de manera independiente.

Paso 3: reconstrucción en salida

$$y = U_r w = U_r \Sigma_r V_r^T x = Ax \in \mathbb{R}^m.$$

Interpretación

V_r describe el subespacio activo de entrada, que coincide con $\ker(A)^\perp$ (el espacio fila). Por eso cualquier componente de x que esté en $\ker(A)$ no contribuye a $V_r^T x$ ni a la salida. U_r coloca el resultado en el subespacio activo de salida, es decir, en la imagen de A .

Autoevaluación y conexión

Auditoría dimensional:

$$\mathbb{R}^n \xrightarrow{V_r^T} \mathbb{R}^r \xrightarrow{\Sigma_r} \mathbb{R}^r \xrightarrow{U_r} \mathbb{R}^m.$$

Esta cadena debe cerrar siempre. El slide 15 demuestra algebraicamente por qué v_i y u_i están enlazados por los mismos σ_i^2 .

Slide 15 · $A^T A$ y AA^T conectan la SVD con problemas espectrales

Tiempo sugerido: 6 min

Mensaje central

Las relaciones

$$Av_i = \sigma_i u_i, \quad A^T u_i = \sigma_i v_i$$

conectan los espacios de entrada y salida y generan

$$A^T A v_i = \sigma_i^2 v_i, \quad AA^T u_i = \sigma_i^2 u_i.$$

Cómo se lee: “ A por v_i es sigma i por u_i ” y “ A transpuesta por u_i es sigma i por v_i ”. Al aplicar otra vez A o A^T , la escala aparece al cuadrado.

Símbolos: v_i = dirección singular de entrada; u_i = dirección singular de salida; σ_i = escala singular; $A^T A$ = operador cuadrado en entrada; AA^T = operador cuadrado en salida.

Desarrollo de la expresión matemática

Partimos de

$$Av_i = \sigma_i u_i.$$

Multiplicamos por A^T a la izquierda:

$$A^T Av_i = A^T(\sigma_i u_i) = \sigma_i A^T u_i.$$

Como

$$A^T u_i = \sigma_i v_i,$$

obtenemos

$$A^T Av_i = \sigma_i^2 v_i.$$

Análogamente, partimos de

$$A^T u_i = \sigma_i v_i$$

y multiplicamos por A :

$$AA^T u_i = A(\sigma_i v_i) = \sigma_i Av_i = \sigma_i^2 u_i.$$

Por tanto,

$$AA^T u_i = \sigma_i^2 u_i.$$

Interpretación

Esta es la razón exacta por la cual $A^T A$ y AA^T comparten los mismos autovalores no nulos: ambos describen la misma escala σ_i , pero desde dos espacios diferentes. v_i vive en la entrada; u_i vive en la salida.

Autoevaluación y conexión

¿Los autovalores de A son necesariamente σ_i ? No. En general, los valores singulares se obtienen a partir de los autovalores de $A^T A$ (o AA^T), no de A .

Slide 16 · Cambio de signo y multiplicidades repetidas rompen la unicidad literal

Tiempo sugerido: 4 min

Mensaje central

La expansión singular es

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

El producto A puede permanecer igual aunque cambien los signos de pares singulares o la base elegida dentro de un subespacio asociado a un valor singular repetido.

Cómo se lee: “ A es la suma, desde $i = 1$ hasta r , de sigma i por u_i por v_i transpuesta”.

Símbolos: r = rango; σ_i = valor singular; u_i = dirección de salida; v_i = dirección de entrada; v_i^T = vector fila transpuesto; cada término $\sigma_i u_i v_i^T$ tiene rango uno.

Desarrollo de la expresión matemática

La expansión singular puede escribirse como

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Si cambiamos simultáneamente

$$u_i \mapsto -u_i, \quad v_i \mapsto -v_i,$$

el término correspondiente no cambia:

$$\sigma_i (-u_i) (-v_i)^T = \sigma_i (-u_i) (-v_i^T) = \sigma_i u_i v_i^T.$$

Por tanto, el signo de un par singular no es identificable de manera absoluta.

Interpretación

Si un valor singular está repetido, por ejemplo $\sigma_i = \sigma_j$, las direcciones dentro de ese subespacio pueden rotarse mediante una transformación ortogonal y la matriz A sigue siendo la misma. Lo estable es el subespacio asociado y el producto final, no una orientación particular de cada vector dentro de ese subespacio.

Autoevaluación y conexión

Dos librerías o dos ejecuciones pueden devolver signos diferentes en U y V sin que ninguna esté equivocada. Para comparar SVDs, no se deben comparar vectores signo a signo sin considerar esta ambigüedad. El slide 17 muestra cómo verificar reconstrucción y residuales numéricamente.

Slide 17 · NumPy comprueba la SVD; no sustituye su argumento matemático

Tiempo sugerido: 5 min

Mensaje central

En código se calcula una SVD y se reconstruye

$$\hat{X} = U\Sigma V^T, \quad \|X - \hat{X}\| \approx 0.$$

Cómo se lee: “ X sombrero es igual a U por Sigma por V transpuesta”; “la norma de X menos X sombrero es aproximadamente cero”.

Símbolos: X = matriz original; U = vectores singulares izquierdos; s = vector de valores singulares devuelto por NumPy; $\Sigma = \text{diag}(s)$; $V^T = \text{Vt}$; $\hat{X}$ = reconstrucción; residual = tamaño del error numérico.

```
U, s, Vt = np.linalg.svd(X, full_matrices=False)
X_hat = U @ np.diag(s) @ Vt
residual = np.linalg.norm(X - X_hat)
assert np.allclose(X, X_hat)
```

Desarrollo de la expresión matemática

Si $X \in \mathbb{R}^{m \times n}$ y usamos `full_matrices=False`, con $q = \min(m, n)$:

$$U \in \mathbb{R}^{m \times q}, \quad s \in \mathbb{R}^q, \quad V^T \in \mathbb{R}^{q \times n}.$$

La línea

`np.diag(s)`

construye $\Sigma \in \mathbb{R}^{q \times q}$. Entonces

$$\hat{X} = U\Sigma V^T$$

debe tener dimensión $m \times n$, igual que X .

El residual absoluto es

$$\|X - \hat{X}\|,$$

y debería ser muy pequeño salvo errores de redondeo. Para comparar matrices con escalas distintas suele ser más interpretable usar también

$$\frac{\|X - \hat{X}\|_F}{\|X\|_F}.$$


Interpretación

`np.allclose` no demuestra la SVD; comprueba que, dentro de una tolerancia numérica, la reconstrucción coincide con la matriz original. El argumento matemático sigue siendo $X = U\Sigma V^T$ con las propiedades de ortonormalidad y no negatividad ya establecidas.

Autoevaluación y conexión

Antes de ejecutar, verifica: (1) dimensiones esperadas, (2) identidad que se comprobará, (3) norma y tolerancia, y (4) interpretación del residual en relación con la escala de X . El siguiente paso natural del módulo es usar la SVD para truncar y controlar el error.

Mapa conceptual de cierre



Mensaje central

Síntesis. La SVD no aparece como una fórmula aislada. Nace al llevar la intuición de autovectores y matrices simétricas a una matriz rectangular: $A^T A$ y AA^T producen direcciones ortonormales de entrada y salida, sus autovalores no negativos producen las escalas σ_i , y todo se reúne en

$$A = U\Sigma V^T.$$