

Mapa de la clase: de la intuición al espacio latente

SVD, autovalores/autovectores, embeddings y reducción de rango

1

¿De dónde partimos?

- Matrices de datos: documento-término, usuario-item, activaciones, embeddings
- Mucha dimensión, redundancia y estructura no evidente
- Pregunta central: qué geometría conviene conservar y cuánto error aceptar

1	0	2	0
0	1	0	2
2	0	1	0
0	2	0	1

Matriz de datos



Nube de puntos de alta dimensión

2

¿Qué queremos lograr?

- Entender cuándo usar autovalores/autovectores
- Entender qué añade la SVD en matrices rectangulares
- Reducir rango sin exagerar el significado de los ejes latentes




3

Herramientas conceptuales

1 Producto interno:

$$\langle x, y \rangle = x^T y$$




2 Norma 2:

$$\|x\|_2 = \sqrt{x^T x}$$



3 Ortogonalidad:

$$x^T y = 0$$



4 Base ortonormal:

$$Q^T Q = I$$



Sirven para proyectar, medir error y cambiar de coordenadas.

4

Camino de la clase


Autovalores/
autovectores



Matrices
simétricas



Matrices
rectangulares



SVD


$$A = U \Sigma V^T$$



Aproximación
de rango bajo



Embeddings
y PCA



Caso conductor

Matriz documento-característica 5x4

	t_1	t_2	t_3	t_4
d_1	3	2	0	0
d_2	4	1	0	1
d_3	0	0	2	3
d_4	1	0	3	4
d_5	0	1	2	2



Dos bloques dominantes: (t_1, t_2) y (t_3, t_4)



Resultado esperado

- ✓ Explicar $A = U \Sigma V^T$ con sentido geométrico
- ✓ Justificar una elección de k usando error y compresión
- ✓ Distinguir afirmaciones algebraicas de interpretaciones semánticas

HERRAMIENTAS



Álgebra
lineal



Geometría
lineal



Optimización
y error



Datos de alta
dimensión



Juicio
crítico



Idea fuerza

La SVD organiza geometría lineal; el significado del dominio debe validarse fuera de la descomposición.

Producto interno, norma y proyección

Los prerequisites geométricos que reaparecen en la SVD

1 Conceptos clave



Producto interno

$$\langle x, y \rangle = x^T y$$

Mide alineación entre vectores



Norma 2

$$\|x\|_2 = \sqrt{x^T x}$$

Mide longitud



Ortogonalidad

$$x \perp y \Leftrightarrow x^T y = 0$$

Ángulo de 90°



Base ortonormal

$$Q^T Q = I$$

Conserva producto interno y norma

2 Ejemplo guiado: proyectar z sobre e_1

$$z = \begin{pmatrix} 3 \\ 2 \end{pmatrix}$$

$$e_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

1 Coordenada en la dirección e_1 :


$$e_1^T z = 3$$

2 Proyección:

$$\begin{aligned} \text{proj}_{e_1}(z) &= (e_1^T z) e_1 \\ &= 3e_1 = \begin{pmatrix} 3 \\ 0 \end{pmatrix} \end{aligned}$$

3 Residuo:

$$z - \text{proj}_{e_1}(z) = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$



El residuo queda ortogonal a e_1

$$e_1^T \begin{pmatrix} 0 \\ 2 \end{pmatrix} = 0$$

3 ¿Qué reaparece después?

$$V^T x = \begin{bmatrix} v_1^T x \\ v_2^T x \\ \vdots \\ v_n^T x \end{bmatrix}$$



Cada entrada es un producto interno



Cada entrada mide cuánto de x va en la dirección v_i



$V^T x$ obtiene las coordenadas de x en la base ortonormal dada por V



Idea clave

Proyectar = obtener coordenadas mediante productos internos. Esa es la intuición operativa detrás de $V^T x$.

Autovalores y autovectores

Qué significan y por qué importan en matrices simétricas


1

Definición

$$Av = \lambda v$$

- v : dirección especial
- λ : factor de escala

La dirección de v no cambia; solo cambia su magnitud y, si $\lambda < 0$, también su orientación.



2

Cuándo tiene sentido



Matrices cuadradas

A pertenece a $\mathbb{R}^{n \times n}$

$$A: \mathbb{R}^n \rightarrow \mathbb{R}^n$$



El problema $Av = \lambda v$ está bien definido.



Matrices rectangulares

A pertenece a $\mathbb{R}^{m \times n}$

$$A: \mathbb{R}^n \rightarrow \mathbb{R}^m$$



Si $m \neq n$, Av y λv viven en espacios distintos.



Por eso los autovectores no son la herramienta general para matrices rectangulares.

3

Caso especialmente útil: matrices simétricas

- Sus autovalores son reales
- Tiene una base ortonormal de autovectores
- Puede escribirse como

$$A = Q\Lambda Q^T$$

$$A = Q\Lambda Q^T$$

Q : autovectores ortonormales

Λ : autovalores en la diagonal

$$Q = \begin{bmatrix} \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet \\ \bullet & \bullet & \bullet & \bullet \end{bmatrix}$$

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

4

Lectura geométrica

Cambio de coordenadas

$$Q^T x$$



Escalamiento por Λ

$$\Lambda(Q^T x)$$



Regreso

$$Q(\Lambda(Q^T x))$$



En matrices simétricas, los autovectores diagonalizan la transformación.



Idea clave:

Los autovectores resuelven elegantemente el caso cuadrado y simétrico; la SVD extiende esta intuición al caso rectangular.

¿Por qué necesitamos la SVD?

La respuesta cuando la matriz es rectangular

1 Planteamiento del problema

A pertenece a $\mathbb{R}^{m \times n}$

$$A : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

Espacio
de entrada
 $\mathbb{R}^n$



A



Espacio
de salida
 $\mathbb{R}^m$

Autovectores: $Av = \lambda v$

SVD: $A = U\Sigma V^T$



Exigen comparar
vectores del
mismo espacio




Funciona para
matrices
rectangulares

2 Qué significan U , Σ y V

V o V^T

Define direcciones
ortonormales del
espacio de entrada



vectores singulares
derechos

Σ


Escala cada dirección
por un valor singular σ_i

$$\begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_r \\ 0 & 0 & \cdots & 0 \end{bmatrix}$$

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$$

U

Expresa el resultado en
direcciones ortonormales
del espacio de salida



vectores singulares
izquierdos

3 Lectura operativa

x

(entrada en $\mathbb{R}^n$)



$V^T x$

(coordenadas
en la base V)



$\Sigma V^T x$

(escalado por los
valores singulares)



$U\Sigma V^T x = Ax$

(resultado en $\mathbb{R}^m$)

cambiar
coordenadas

estirar/comprimir

reorientar en
la salida

4 Relaciones fundamentales

$$A^T A v_i = \sigma_i^2 v_i$$

$$A A^T u_i = \sigma_i^2 u_i$$

$$A v_i = \sigma_i u_i$$



Los valores singulares son las raíces cuadradas de los autovalores de $A^T A$.



Idea clave:

La SVD separa orientación y escala: V organiza la entrada, Σ cambia magnitudes y U organiza la salida.

Aproximación de rango bajo

Compresión, error y estructura dominante

1

Concepto principal

$$A_k = U_k \Sigma_k V_k^T$$



Se conservan solo las k direcciones más importantes



Los valores singulares se ordenan:
 $\sigma_1 \geq \sigma_2 \geq \dots$



Si los últimos σ_i son pequeños, su contribución es débil

2

Qué gana uno al truncar



Compresión

Menos parámetros /
Dimensión reducida.



Desruido

Se eliminan componentes débiles.



Interpretabilidad estructural

Revela patrones dominantes, pero con cautela.

3

Cómo se mide el error

$$\text{Error de reconstrucción} = \|A - A_k\|_F$$

$$\text{Error relativo} = \frac{\|A - A_k\|_F}{\|A\|_F}$$



La norma de Frobenius agrega la energía total del residuo.



4

Caso conductor

- Matriz documento-característica 5x4
- Valores singulares aprox.:
11.38, 8.09, 0.25, 0.11
- Con $k = 2$, el error relativo de Frobenius es $\sim 1.94\%$
- Interpretación: dos componentes capturan casi toda la estructura

Matriz original A
(5x4)



Aproximación A_2
(rango 2)



Residuo $A - A_2$
(error)



5

Advertencia



Bajo error algebraico no implica interpretación semántica perfecta.
La validez depende del dominio.



Idea clave:

Elegir k es un equilibrio entre compresión y fidelidad.

Embeddings, espacio latente y PCA

Cómo interpretar las coordenadas reducidas sin sobreinterpretarlas

1 Embeddings como coordenadas

Coordenadas latentes por SVD truncada:


$$Z = U_k \Sigma_k$$



También puede verse la información de columnas mediante V_k



Cada fila de Z es una representación de baja dimensión.




2 Qué sí podemos decir

- ✓ Puntos cercanos tienden a compartir estructura lineal similar
- ✓ La reducción puede revelar bloques, temas o patrones dominantes
- ✓ La distancia y la orientación dependen de la geometría elegida



3 Qué no debemos exagerar

- ⚠ Un eje latente no trae significado semántico automático
- ⚠ Una rotación ortogonal puede cambiar las coordenadas sin cambiar la estructura
- ⚠ La interpretación final requiere contexto del dominio



4 PCA y su relación con SVD


PCA

- Trabaja con datos centrados
- Busca direcciones de máxima varianza
- Puede calcularse a partir de la SVD de la matriz centrada

VS

Truncated SVD

- No centra los datos
- Útil cuando la matriz es grande o dispersa
- Muy usado en texto y matrices documento-término



5 Lectura final



Espacio latente = coordenadas útiles para resumir estructura, no una verdad semántica garantizada.



Álgebra lineal



Geometría lineal



Optimización y error



Datos de alta dimensión



Juicio crítico



Idea clave:

La geometría reducida ayuda a pensar y comprimir; la interpretación fuerte exige evidencia externa.