

De direcciones propias a estructura latente

M05 une espectro, SVD y rango bajo para analizar matrices de datos sin atribuir un significado que los resultados no permiten justificar.

¿Qué estructura conserva una matriz?

¿Qué error introduce truncarla?

¿Qué interpretación es defendible?

Una matriz de datos puede tener mas columnas que estructura útil

La compresión razonable exige decidir que estructura conservar y como medir la pérdida.

X: documentos × 4 rasgos

$$X = \begin{bmatrix} 4 & 5 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ 0 & 1 & 5 & 4 \\ 0 & 1 & 4 & 3 \\ 5 & 6 & 0 & 0 \end{bmatrix}$$

PREGUNTA DE APERTURA

Observa la matriz: ¿que columnas parecen redundantes y que pérdida aceptarías al comprimirla?

Sin calcular todavía: formula una hipótesis que luego contrastaremos con la SVD.

¿En que orden conviene construir la respuesta?

La narrativa correcta no empieza con el comando svd

Primero se fija el problema espectral, luego la necesidad de SVD y después se trunca.

ORDENA EL PROCESO

Ordena: formular el problema, estudiar el espectro, aplicar SVD, truncar, medir el error, interpretar y validar.

¿Que prerequisites debemos reactivar?

Norma, producto interno y ortogonalidad solo hasta donde hacen falta

Sin ortogonalidad ni norma, U , V y el error de reconstrucción quedan sin interpretación.

AUDITORIA RÁPIDA

Define con tus palabras producto interno, norma 2, vectores ortogonales y matriz ortogonal; corrige las imprecisiones.

¿Que significa exactamente un autovector?

$Av = \lambda v$ fija una dirección propia, no cualquier vector


IDEA QUE DEBE QUEDAR

Un autovector es no nulo y preserva dirección bajo una matriz cuadrada.

EVIDENCIA VISIBLE

Predicción sobre qué vectores conservan dirección y exigencia explícita de un vector no nulo.

Direcciones ortogonales estables




¿Que ejemplo pequeño conviene dominar?

La simetría revela direcciones propias ortogonales

$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ organiza su acción con una base ortonormal y escalas reales.

Direcciones ortogonales estables



$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

$$A = Q\Lambda Q^T$$

$$u_1 = \frac{1}{\sqrt{2}}(1, 1), \quad Au_1 = 3u_1$$

$$u_2 = \frac{1}{\sqrt{2}}(1, -1), \quad Au_2 = u_2$$

$$u_1^T u_2 = 0, \quad \lambda_1 = 3, \quad \lambda_2 = 1$$

En una matriz simétrica real, las direcciones propias pueden elegirse ortonormales.

No toda matriz real es diagonalizable ni tiene autovectores ortogonales

IDEA QUE DEBE QUEDAR

El caso simétrico limpia el problema; fuera de él, varias propiedades fallan.

EVIDENCIA VISIBLE

Lista de inferencias inválidas y su condición faltante.

Matriz no simétrica

$$B = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

$$B^2 = 0, \quad \lambda(B) = (0, 0)$$

Problema espectral correcto

$$B^T B = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\text{eig}(B^T B) = (1, 0),$$

$$\sigma(B) = (1, 0)$$

¿Basta un contraejemplo para separar autovalores y valores singulares?

Autovalores y valores singulares no son intercambiables

El contraejemplo nilpotente B separa ambos conceptos sin ambigüedad.

Matriz no simétrica

$$B = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

$$B^2 = 0, \quad \lambda(B) = (0, 0)$$

**Problema espectral
correcto**

$$B^T B = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\text{eig}(B^T B) = (1, 0),$$

$$\sigma(B) = (1, 0)$$

Conclusión

$$\lambda_i(A) \neq \sigma_i(A),$$

$$\sigma_i^2 = \text{eig}_i(A^T A)$$

**salvo relaciones
especiales, no se
intercambian**

B tiene autovalores (0,0), pero valores singulares (1,0).

La simetría entrega espectro real y base ortonormal

IDEA QUE DEBE QUEDAR

$$A = Q\Lambda Q^T$$

convierte el problema en un cambio de base estable.

EVIDENCIA VISIBLE

Simetría $\rightarrow$ espectro real $\rightarrow$ base ortonormal.

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

$$A = Q\Lambda Q^T$$

¿Por qué esto ya no basta para una matriz rectangular?

Una matriz 5×4 no admite el mismo lenguaje de autovalores

IDEA QUE DEBE QUEDAR

La ecuación de autovalores deja de estar bien tipada cuando dominio y codominio difieren.

EVIDENCIA VISIBLE

Chequeo dimensional sobre la matriz del caso conductor.

X: documentos $\times$ 4 rasgos

$$X = \begin{bmatrix} 4 & 5 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ 0 & 1 & 5 & 4 \\ 0 & 1 & 4 & 3 \\ 5 & 6 & 0 & 0 \end{bmatrix}$$

¿Qué objetos cuadrados conviene construir entonces?


$A^T A$ y $A A^T$ recuperan un problema espectral defendible

IDEA QUE DEBE QUEDAR

Los espectros de $A^T A$ y $A A^T$ organizan la escala singular de A .

EVIDENCIA VISIBLE

Dimensiones, espacio de entrada y espacio de salida.



¿Cómo aparece ahora la SVD completa?


SVD: la descomposicion que corresponde al problema real

IDEA QUE DEBE QUEDAR

La SVD factoriza cualquier matriz rectangular o cuadrada en ejes ortogonales y escalas no negativas.

EVIDENCIA VISIBLE

$$A = U\Sigma V^T$$



¿Que dimensiones tiene cada factor?

SVD completa, reducida y compacta no son la misma cosa

IDEA QUE DEBE QUEDAR

La forma completa, la reducida por $\min(m,n)$ y la compacta por rango responden a contratos distintos.

EVIDENCIA VISIBLE

Tabla completada por el estudiante para $m \times n$, $\min(m,n)$ y $r = \text{rank}(A)$.

Completa

$$U \in \mathbb{R}^{m \times m} \quad \Sigma \in \mathbb{R}^{m \times n} \quad V^T \in \mathbb{R}^{n \times n}$$

Reducida

$$q = \min(m, n) \quad U \in \mathbb{R}^{m \times q} \quad \Sigma \in \mathbb{R}^{q \times q} \quad V^T \in \mathbb{R}^{q \times n}$$

Compacta


$$r = \text{rank}(A) \quad U_r \in \mathbb{R}^{m \times r} \quad \Sigma_r \in \mathbb{R}^{r \times r} \quad V_r^T \in \mathbb{R}^{r \times n}$$

¿Cómo se interpreta geoméricamente la multiplicación?

SVD compacta: coordenadas activas, escala y reconstrucción

$$A = U_r \Sigma_r V_r^T$$

Ejemplo exacto ($r=2$): $V_r=R(35^\circ)$, $\Sigma_r=\text{diag}(1.6, 0.7)$, $U_r=R(30^\circ)$, $x=(0.30, 0.90)$




Auditoría
dimensional

$$\mathbb{R}^n \xrightarrow{V_r^T} \mathbb{R}^r \xrightarrow{\Sigma_r} \mathbb{R}^r \xrightarrow{U_r} \mathbb{R}^m$$

V_r^T anula la componente de x en $\ker(A)$;
 Σ_r reescala las coordenadas activas y U_r
reconstruye la salida.

$A^T A$ y $A A^T$ conectan la SVD con problemas espectrales

Los dos operadores cuadrados comparten los autovalores no nulos σ_i^2 .



v_i vive en la entrada, u_i en la salida y σ_i^2 enlaza ambos problemas espectrales.

Cambio de signo y multiplicidades repetidas rompen la unicidad literal

La descomposición es estable como producto, pero sus vectores pueden cambiar de signo o base dentro de subespacios repetidos.

COMPARA DOS SVD

Cambia simultáneamente el signo del par singular correspondiente; explica por qué el producto A no cambia.

¿Que herramienta nueva habilita esta descomposición?

NumPy comprueba la SVD; no sustituye su argumento matematico

```
U, s, Vt = np.linalg.svd(X, full_matrices=False)
X_hat = U @ np.diag(s) @ Vt
residual = np.linalg.norm(X - X_hat)
assert np.allclose(X, X_hat)
```

Antes de ejecutar

1. Declarar shapes
2. Formular la identidad
3. Elegir norma y tolerancia
4. Interpretar el residual

Shapes, residuales y reconstruccion permiten auditar numericamente una SVD ya formulada.

IDEA QUE DEBE QUEDAR

La utilidad aplicada de la SVD aparece al convertirla en aproximación de rango bajo.

EVIDENCIA VISIBLE

$$A = \sum_i \sigma_i u_i v_i^T$$

$$\sigma_1 u_1 v_1^T$$

rango 1

CONSERVAR

$$\sigma_2 u_2 v_2^T$$

rango 1

CONSERVAR

¿Cómo se construye la aproximación truncada?

Truncar conserva los primeros componentes de rango uno

A_k retiene k términos de la expansión singular y descarta el resto.

$$A = \sum_i \sigma_i u_i v_i^T$$



truncar después de $k=2$

$$A_2 = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T, \quad \text{rank}(A_2) \leq 2$$

Eckart–Young–Mirsky: A_k es óptima entre matrices de rango $\leq k$ bajo las normas declaradas.

Eckart-Young-Mirsky justifica la mejor aproximación de rango a lo sumo k

IDEA QUE DEBE QUEDAR

Entre todas las matrices de rango a lo sumo k , A_k minimiza el error en normas espectral y de Frobenius.

EVIDENCIA VISIBLE

Enunciado operativo del teorema.

A_k retiene k términos de la expansión singular y descarta el resto.

$$A = \sum_i \sigma_i u_i v_i^T$$




$$A_2 = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T, \quad \text{rank}(A_2) \leq 2$$

¿Cómo se mide exactamente la pérdida?

Elegir k exige declarar qué error importa

El caso conductor separa peor dirección residual y pérdida acumulada.



Peor dirección residual

$$\|X - X_2\|_2 = \sigma_3 \approx 0.2492$$

Pérdida acumulada

$$\frac{\|X - X_2\|_F}{\|X\|_F} \approx 0.01941$$

Decisión defendible

k=2 conserva $\approx 99.962\%$

k=2 es defendible para compresión con $\approx 1.94\%$ de error relativo; no es una regla universal.


Energía algebraica no es automáticamente varianza explicada

IDEA QUE DEBE QUEDAR

Los cuadrados de los valores singulares solo admiten una lectura estadística bajo condiciones adicionales.

EVIDENCIA VISIBLE

Contraste entre uso algebraico y uso estadístico.



¿Como se ve esto en la matriz del caso conductor?

Antes de ejecutar SVD conviene predecir redundancias estructurales

IDEA QUE DEBE QUEDAR

El patrón de columnas sugiere un rango efectivo pequeño antes de cualquier cálculo.

EVIDENCIA VISIBLE

Matriz original y lectura previa de bloques.

X: documentos × 4 rasgos

$$X = \begin{bmatrix} 4 & 5 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ 0 & 1 & 5 & 4 \\ 0 & 1 & 4 & 3 \\ 5 & 6 & 0 & 0 \end{bmatrix}$$


¿Qué representa cada factor de la SVD?

Cada factor responde una pregunta distinta sobre los datos

V organiza patrones, Σ sus escalas y $U\Sigma$ ubica observaciones en coordenadas latentes.

X: documentos × 4 rasgos


$$X = \begin{bmatrix} 4 & 5 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ 0 & 1 & 5 & 4 \\ 0 & 1 & 4 & 3 \\ 5 & 6 & 0 & 0 \end{bmatrix}$$



V

patrones
 t_1, t_2 juntos
 t_3, t_4 juntos


direcciones de
características



Σ

escalas

11.38
8.09
0.25, 0.11



$U\Sigma$

coordenadas
latentes

ubica cada
documento

X centrada: PCA

X sin centrar: TruncatedSVD

La SVD demuestra estructura algebraica; cualquier significado semántico requiere validación externa.

Predecir, descomponer, truncar, medir y solo después interpretar

IDEA QUE DEBE QUEDAR

La interpretación llega al final porque depende de error, escala, finalidad y contexto.

EVIDENCIA VISIBLE

Se propone un k para compresión y se explica que validación downstream faltaría para usarlo en ML.

Peor dirección residual

$$\|X - X_2\|_2 = \sigma_3 \approx 0.2492$$

Pérdida acumulada

$$\frac{\|X - X_2\|_F}{\|X\|_F} \approx 0.01941$$

Decisión defendible

$k=2$ conserva $\approx 99.962\%$

¿Qué ocurre cuando la matriz ya es de embeddings?

La SVD también ordena embeddings, pero no certifica semántica

IDEA QUE DEBE QUEDAR

Las direcciones latentes de un embedding son algebraicamente útiles pero semanticamente condicionales.

EVIDENCIA VISIBLE

Transición desde documento-característica a embedding matrix.



¿Que afirmaciones son legítimas y cuales son excesivas?

Una coordenada latente dominante no equivale a un concepto demostrado

IDEA QUE DEBE QUEDAR

La SVD organiza geometría lineal;
el significado requiere validación
externa.

EVIDENCIA VISIBLE

Se separa una conclusion
algebraica defendible de una
conclusion semántica excesiva.

V

patrones
 t_1, t_2 juntos
 t_3, t_4 juntos

direcciones de
características

¿Cuando aparece PCA de forma correcta?

PCA aparece cuando la matriz se centra antes de la SVD


IDEA QUE DEBE QUEDAR

En datos centrados, V contiene las direcciones principales.

$$\lambda_i(\text{Cov}(X)) = \frac{\sigma_i^2}{n_{\text{samples}} - 1}$$

EVIDENCIA VISIBLE

Secuencia: centrar los datos, aplicar la SVD y leer las direcciones principales.



X centrada $\rightarrow$ PCA

X sin centrar $\neq$ PCA automática

¿Por que TruncatedSVD no equivale siempre a PCA?

TruncatedSVD y PCA se separan cuando no hay centrado

IDEA QUE DEBE QUEDAR

La ausencia de centrado cambia la interpretación estadística aunque la algebra siga siendo útil.

EVIDENCIA VISIBLE

Contraste entre datos centrados y matriz dispersa sin centrar.

 X_c

centrada

PCA

≠

 X

sin centrar

TruncatedSVD

La diferencia clave es el centrado y su interpretación estadística.

¿Que rutina computacional corresponde a cada problema?

eig, eigh, svd, matrix_rank y norm no responden la misma pregunta

```
np.linalg.eig(A)           # matriz cuadrada general
np.linalg.eigh(S)          # matriz simétrica
np.linalg.svd(X)           # matriz rectangular
np.linalg.matrix_rank(X)   # rango numérico
np.linalg.norm(R, ord='fro')
```

Antes de ejecutar

1. Declarar shapes
2. Formular la identidad
3. Elegir norma y tolerancia
4. Interpretar el residual

La elección de la rutina depende de estructura, dimensiones y tipo de afirmación matemática.

Primero se declara la afirmación, luego se ejecuta el cálculo

Dimensiones, criterio de error y tolerancia deben declararse antes de ejecutar NumPy.

DECISIÓN NUMÉRICA

Calcula el residual, compáralo con la tolerancia declarada y decide: ¿redondeo o afirmación falsa?

¿Que errores deben bloquearse en cierre?

Las confusiones clave se eliminan cuando se separan dimensiones, espectro, truncar e interpretación.

DETECTA EL ERROR

Clasifica cada afirmación como válida o inválida y nombra la condición que falta.

¿Que deberíamos poder hacer hasta ahora?

La prueba final: defender una SVD de forma correcta

Se debe conectar espectro, SVD, rango bajo y espacio latente con criterios explícitos de error y alcance.

RETO DE SALIDA

Defiende un valor de k : cita el error, explica que conservas y limita la interpretación semántica.