

Modelo relacional y SQL analítico

Organizar experimentos para comparar resultados y defender la conclusión.

RELACIONES

qué representa cada fila

CONSULTAS

cómo se construye la comparación

AUDITORÍA

qué permite defender el resultado


Un ranking ordenado puede ser falso aunque SQL no produzca errores

El motor ejecuta la relación escrita; la tabla final no demuestra por sí sola que la decisión sea válida.



Antes de aceptar el resultado hay que preguntar qué representa cada fila


Cinco preguntas transforman una sospecha general en evidencia que puede verificarse o refutarse.



Actividad: convierte dos dudas en preguntas que puedan comprobarse con filas, claves o conteos.
La ficha no registra opiniones: registra condiciones de validez.

Dataset, configuración, ejecución y métrica no son la misma clase de fila

Separar relaciones obliga a declarar qué entidad o hecho representa cada fila antes de escribir un JOIN.



Separar no fragmenta el caso: fija qué significa cada fila.
Solo después pueden declararse claves, relaciones y cardinalidades.

La clave responde quién es la fila; la granularidad responde qué significa

Identidad y significado deben declararse juntos, pero no cumplen la misma función.

1

GRANULARIDAD • SIGNIFICADO

¿Qué representa exactamente una fila?

2

CLAVE • IDENTIDAD

¿Qué valores distinguen esa fila?

RELACIÓN	UNA FILA REPRESENTA...	CLAVE PROPUESTA
datasets	una versión identificable de un dataset	dataset_id PK
configs	una configuración de entrenamiento	config_id PK
runs	una ejecución sobre versión, config y semilla	run_id PK
metrics	una métrica, split y ejecución	PK COMPUESTA (run_id, split, metric_name)


RESTRICCIÓN ADICIONAL DE runs

UNIQUE(dataset_id, config_id, seed)

Impide repetir la unidad experimental; no reemplaza la PK de runs.

Una ejecución referencia un dataset y una configuración, y produce métricas


Las claves expresan tres relaciones uno-a-muchos; ninguna combinación queda autorizada solo por proximidad.



La geometría del esquema fija qué filas pueden combinarse antes de escribir el JOIN.

Primero se eligen las ejecuciones completadas; después se buscan sus métricas

FROM y WHERE construyen la población inicial; ORDER BY solo estabiliza su presentación.



Un atributo NULL y una fila de métrica inexistente son problemas diferentes

NULL vive dentro de una fila existente; una métrica faltante exige conservar el run y observar que no hubo pareja.



LEFT JOIN conserva el run para volver visible la ausencia de pareja.
Cero, cadena vacía y celda blanca no sustituyen ninguno de los dos casos.

LEFT JOIN conserva la ejecución y vuelve observable la métrica ausente

Las condiciones de la métrica viven en ON; WHERE identifica las ejecuciones que no encontraron pareja.

COPIA DIDÁCTICA QA • MÉTRICA OBJETIVO

validation / accuracy

runs.run_id	status	ON run_id	metrics	split / metric
run_1	completed	→	run_1	validation/accuracy
run_2	completed	→	run_2	validation/accuracy
run_3	completed	- - - - -	Ø FILA AUSENTE	
run_4	completed	→	run_4	validation/accuracy

RESULTADO DE AUDITORÍA

run_3 FILA AUSENTE

sin NULL, cero ni valor ficticio

m.run_id IS NULL

CONSULTA DE AUDITORÍA

copia QA

```
SELECT r.run_id,
r.dataset_id,
r.config_id,
r.seed
FROM runs AS r
LEFT JOIN metrics AS m
ON m.run_id = r.run_id
AND m.split = 'validation'
AND m.metric_name = 'accuracy'

WHERE r.status = 'completed'
AND m.run_id IS NULL;
```

La ausencia se detecta por la clave derecha.


ON decide qué pareja buscar.

WHERE decide qué ausencia reportar.

La ausencia es una relación faltante; no una métrica nula.

JOIN construye pares de filas; no pega tablas de manera neutral

Cada condición ON determina qué pares existen y cuántas filas produce la consulta.



Una fila de salida representa `run + split + metric`


Filtrar validation no sustituye la condición que une cada métrica con su run

El filtro limita métricas; la igualdad de claves establece la identidad del par.

RELACIÓN ROTA

IDENTIDAD AUSENTE

```
JOIN metrics AS m
ON m.split = 'validation'
filtra métricas, pero no nombra el run
```



PRODUCTO ACCIDENTAL


CONTEO DEL EJEMPLO SIMBÓLICO

$2 \text{ runs} \times 2 \text{ métricas} = 4 \text{ pares accidentales}$

RELACIÓN CORRECTA

IDENTIDAD PRESENTE

```
JOIN metrics AS m
ON m.run_id = r.run_id
AND m.split = 'validation'
```



PARES AUTORIZADOS

CONTEO DEL MISMO EJEMPLO

$2 \text{ identidades} = 2 \text{ pares autorizados}$

Filtrar split $\neq$ relacionar por run_id


Tres métricas producen tres filas por run sin duplicar la entidad equivocada

La repetición es válida cuando la salida declara la granularidad del lado muchos.

EJECUCIONES

LADO MUCHOS: FILAS DE MÉTRICAS

SALIDA OBJETIVO




4 runs $\times$ 3 métricas por run = 12 filas

validation/accuracy $\Rightarrow$ 4 filas esperadas

DISTINCT puede ocultar el síntoma, pero no demuestra que el JOIN sea correcto

Reducir filas visibles no recupera la identidad ni valida las asociaciones conservadas.



Menos filas visibles ≠ relación correcta

La comparación exige el mismo dataset, la misma métrica y las mismas semillas


La población elegible es la intersección de criterios declarados antes de calcular cualquier media.



Población elegible = versión $\cap$ estado $\cap$ métrica $\cap$ semillas esperadas

GROUP BY cambia la granularidad: de semilla a configuración

AVG resume valores; las columnas agrupadas determinan qué representa la fila resultante.



(dataset_version, config_id, seed, accuracy) → (dataset_version, config_id, mean_validation_accuracy, observed_seed_count)

La media solo es comparable cuando el conteo de semillas coincide con el diseño

HAVING audita cada grupo después de GROUP BY y excluye coberturas incompletas.

```
HAVING COUNT(DISTINCT seed) =  
(SELECT COUNT(*) FROM expected_seeds)
```

GRUPO COMPLETO

expected_seed_count = 2

SEMILLAS OBSERVADAS

:seed_1

:seed_2

$\text{COUNT}(\text{DISTINCT seed}) = 2$

INCLUIR EN LA COMPARACIÓN

cobertura observada = cobertura esperada

$2 = 2 \implies \text{incluir}$

GRUPO INCOMPLETO

expected_seed_count = 2

SEMILLAS OBSERVADAS

:seed_1

SEMILLA AUSENTE

$\text{COUNT}(\text{DISTINCT seed}) = 1$

EXCLUIR E INVESTIGAR


cobertura incompleta · media no comparable

$1 \neq 2 \implies \text{excluir}$

GROUP BY forma grupos $\longrightarrow$ HAVING audita cobertura

Cada CTE responde una pregunta y declara una granularidad

El valor didáctico está en poder inspeccionar cada transformación, no en prometer mejor rendimiento.



UNA CTE NOMBRA UNA RESPONSABILIDAD Y EXPONE SU SALIDA

Puede auditarse por separado · no implica automáticamente una mejora de rendimiento

eligible_runs conserva una fila por versión, configuración y semilla

Los JOIN construyen la población válida; todavía no existe reducción ni ranking.

SQL • CINCO ENTRADAS • SIN GROUP BY

```
eligible_runs AS (  
  SELECT d.version AS dataset_version,  
         c.config_id, r.run_id, r.seed,  
         m.metric_value AS validation_accuracy  
  FROM datasets AS d  
  JOIN runs AS r ON r.dataset_id = d.dataset_id  
  JOIN configs AS c ON c.config_id = r.config_id  
  JOIN expected_seeds AS es ON es.seed = r.seed  
  JOIN metrics AS m ON m.run_id = r.run_id  
  AND m.split = 'validation'  
  AND m.metric_name = 'accuracy'  
  WHERE r.status = 'completed'  
)
```

datasets • configs • runs • expected_seeds • metrics

CUATRO CONTROLES ANTES DE ACEPTAR UNA FILA

01 IDENTIDAD

datasets ↔ runs
configs ↔ runs

02 ESTADO

runs.status
= 'completed'

03 MÉTRICA OBJETIVO

validation
/ accuracy

04 DISEÑO

runs.seed ∈
expected_seeds

GRANULARIDAD DE SALIDA • SIN AGREGACIÓN

dataset_version • config_id • seed

UNA FILA ELEGIBLE POR UNIDAD EXPERIMENTAL

run_id = TRAZABILIDAD

identifica esa misma fila
NO AÑADE OTRA DIMENSIÓN

config_summary calcula la media y conserva el conteo que la hace comparable

GROUP BY cambia la unidad; HAVING exige que la cobertura observada coincida con el diseño.




LA MEDIA SIN CONTEO NO DEMUESTRA QUE LOS GRUPOS SEAN COMPARABLES

salida = versión + configuración + medida simbólica + evidencia de cobertura

RANK compara dentro de cada versión y deja iguales a las medias iguales

La ventana define el mérito; el orden final puede estabilizar la presentación sin alterar el empate.



DENTRO DE OVER • DEFINE DESEMPEÑO

```
PARTITION BY dataset_version  
ORDER BY mean_validation_accuracy DESC
```

FUERA DE OVER • ESTABILIZA LA PRESENTACIÓN

```
ORDER BY dataset_version, performance_rank, config_id
```

mismo valor $\implies$ mismo puesto

El ranking se entrega junto con checks de unicidad, ausencia, rango y cobertura

Cada consulta debe poder revelar una falla concreta o activar una investigación.

RIESGO	QUERY DISTINTIVA	RESULTADO ESPERADO	SIGNIFICADO DEL HALLAZGO
01 DUPLICACIÓN	GROUP BY dataset_id, config_id, seed HAVING COUNT(*) > 1	ESPERADO 0 filas	SI APARECE UNA FILA unidad experimental duplicada
02 MÉTRICA AUSENTE	LEFT JOIN metrics ... WHERE m.run_id IS NULL	CANÓNICO 0 filas	SI APARECE UNA FILA falta validation / accuracy
03 RANGO ACCURACY	WHERE metric_value < 0 OR metric_value > 1	ESPERADO 0 filas	SI APARECE UNA FILA valor fuera de proporción
04 COBERTURA	HAVING observed_seed_count <> expected_seed_count	ESPERADO 0 grupos	SI APARECE UN GRUPO excluir del ranking
05 CARDINALIDAD	completed_run_count vs joined_target_metric_count	CONDICIÓN conteos iguales	SI DIFIEREN explicar pérdida o multiplicación

REGISTRAR: QUERY • RESULTADO • SIGNIFICADO • DECISIÓN

Cero filas apoya un check específico; no demuestra corrección universal

Una decisión defendible conecta pregunta, claves, granularidad y límites

La tabla final no contiene por sí sola el razonamiento que autoriza interpretarla.



DEFENDER = EXPLICAR LA CADENA Y REPARAR EL ESLABÓN DÉBIL
La tabla final es evidencia de salida; no sustituye la justificación

Una consulta es correcta cuando explica qué comparó y cómo intentó refutarse

El cierre conserva una afirmación delimitada, no una impresión vaga de que “los datos están bien”.

