

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

MATEMÁTICAS Y PROGRAMACIÓN PARA IA

Evaluación multiusuario de la detección de suplantación mediante dinámica de mouse

Análisis general de diez cuentas y estudio de caso de detección temprana

Resumen

Los controles de acceso tradicionales verifican credenciales en un instante, pero no garantizan que la persona que continúa operando una sesión sea quien se autenticó. Este trabajo estudia la dinámica de mouse como una biometría conductual para detectar cambios de operador mientras la sesión permanece activa. Se construyen perfiles independientes para las diez cuentas del conjunto Balabit y se evalúan 816 sesiones públicas: 411 legítimas y 405 impostoras. Cada sesión se resume mediante 17 características temporales, espaciales y cinemáticas. Un baseline RMS-z y un *Isolation Forest* se entrenan solo con sesiones legítimas y usan un umbral propio por cuenta. En el promedio general de las diez cuentas, RMS-z obtuvo $AUC = 0.627$ e *Isolation Forest* $AUC = 0.611$; este último alcanzó $FAR = 34.2\%$ y $FRR = 61.0\%$, lo que revela separación modesta e inestabilidad entre usuarios. Como análisis específico, **user12** se estudia con prefijos de 25 a 150 eventos. Su mejor AUC apareció con 100 eventos ($AUC = 0.692$, $FAR = 69.4\%$ y $FRR = 3.6\%$), pero ningún tamaño satisfizo el criterio operativo previo. Los resultados muestran una señal conductual medible, aunque insuficiente para un autenticador autónomo.

Palabras clave: autenticación continua, biometría conductual, dinámica de mouse, detección de anomalías, suplantación de identidad.

1. Introducción y contexto

La autenticación mediante contraseña, código de un solo uso o biometría física suele concentrarse en el ingreso al sistema. Una credencial correcta demuestra que alguien superó ese control, pero no que el mismo operador permanezca frente al equipo durante toda la sesión. Una cuenta puede quedar abierta, ser cedida o pasar a manos de otra persona después del acceso. También puede ser controlada por un programa o por un agente de inteligencia artificial capaz de interactuar con la interfaz. El problema de este trabajo no es volver a comprobar una credencial, sino buscar evidencia temprana de que cambió la forma de operar.

Este enfoque es diferente al de un CAPTCHA el cual plantea un reto puntual para estimar si quien responde parece ser humano. La autenticación continua, en cambio, compara una secuencia de comportamiento con el perfil previamente registrado de una persona concreta. La dinámica del mouse puede utilizarse para detectar desviaciones respecto al patrón de comportamiento habitual de un usuario legítimo, independientemente de que estas provengan de otro ser humano o de un sistema automatizado. Sin embargo, la detección de una anomalía no permite determinar directamente su causa ni demostrar, por sí sola, la existencia de una intención maliciosa o la intervención de una inteligencia artificial. Por esta razón, en una aplicación real, una anomalía debería considerarse una señal de riesgo que active mecanismos adicionales de verificación, en lugar de generar automáticamente una alerta.

El trabajo combina una evaluación general con un estudio de caso. Primero, el protocolo de perfilado se aplica de forma independiente a las diez cuentas para describir el desempeño promedio y su variación entre usuarios. Después, **user12** se analiza con mayor detalle para examinar cuántos eventos deben observarse antes de decidir, qué características aportan mayor discriminación y cuánto varía el comportamiento legítimo entre sesiones. Este caso complementa la evaluación general, pero no representa por sí solo al conjunto ni fue seleccionado por tener el mejor resultado.

Para decidir si una sesión se parece al perfil legítimo se comparan dos detectores de una clase. RMS-z es un baseline simple e interpretable: calcula qué tan lejos están, en promedio, las características de una sesión respecto del perfil estandarizado del usuario; un valor alto indica una sesión más inusual. *Isolation Forest*, en cambio, construye particiones aleatorias de los datos mediante varios árboles. Las

observaciones anómalas suelen quedar aisladas con menos particiones que las legítimas, por lo que reciben un puntaje de anomalía mayor. Ambos métodos se entrenan únicamente con sesiones legítimas y permiten detectar desviaciones sin necesitar ejemplos de todos los tipos posibles de impostor.

1.1. Base científica del comportamiento humano

Cuando una persona mueve el mouse, el computador solo guarda una secuencia de datos: en qué momento ocurrió cada evento, dónde estaba el puntero y si hubo un clic. Sin embargo, detrás de esos datos existe una acción humana. La persona mira la pantalla, decide hacia dónde ir y coordina la mano y el brazo para llegar al objetivo. En ese proceso toma muchas decisiones inconscientemente: iniciar rápido o despacio, seguir una línea recta o una curva, corregir la dirección, hacer una pausa y presionar el botón. Esas decisiones no se repiten de manera idéntica, pero tampoco son totalmente aleatorias.

Una comparación sencilla es la escritura a mano. Dos firmas de la misma persona nunca son exactamente iguales, aunque suelen compartir rasgos de velocidad, tamaño, inclinación y presión. Con el mouse ocurre algo parecido. El proyecto no busca una trayectoria idéntica que funcione como contraseña. Busca tendencias que aparecen muchas veces y que, juntas, pueden describir la forma habitual de interactuar de un usuario.

La cinemática es la parte de la física que describe cómo cambia un movimiento con el tiempo. No intenta explicar qué músculo produjo el movimiento ni qué fuerza se aplicó, sino lo que puede observarse en el recorrido. En el caso del mouse, la posición indica dónde está el puntero mediante las coordenadas (x, y) y la trayectoria reúne todas esas posiciones para mostrar el camino completo. Ese camino puede ser recto, curvo o incluir pequeñas correcciones cuando la persona se desvía y vuelve a apuntar hacia su objetivo.

La velocidad indica cuánta distancia recorre el puntero durante un intervalo de tiempo. Si una persona mueve el mouse una distancia grande en poco tiempo, la velocidad es alta; si recorre poca distancia en el mismo tiempo, la velocidad es baja. La aceleración indica cómo cambia esa velocidad. Aparece cuando el usuario comienza a moverse, gana rapidez, reduce la marcha o se detiene antes de llegar a un botón. También se observa cuánto gira el recorrido entre un tramo y el siguiente. Las pausas, los clics y estos cambios de dirección ayudan a describir el ritmo con el que la persona observa la pantalla, decide y actúa.

Flash y Hogan [1] estudiaron movimientos del brazo entre dos puntos y observaron que una persona no suele mover la mano a velocidad constante. Normalmente comienza despacio, acelera, alcanza una velocidad máxima y vuelve a reducirla al acercarse al destino. Cuando la velocidad se representa a lo largo del tiempo, el resultado suele parecer una campana. También observaron que la mano tiende a reducir la velocidad en las partes más curvas del recorrido.

Para explicar ese comportamiento propusieron el modelo de mínimo *jerk*¹. La idea del modelo es que muchos movimientos voluntarios pueden aproximarse como una búsqueda de suavidad. Esto ayuda a entender por qué la forma del camino, la velocidad y la aceleración no son números arbitrarios: reflejan cómo se organiza el movimiento.

El estudio de Flash y Hogan no demostró que cada persona tenga una firma de mouse única. Además, sus experimentos analizaron movimientos del brazo en condiciones controladas, no sesiones de computadora.

¹El *jerk* es la rapidez con la que cambia la aceleración; un valor alto indica un cambio brusco y uno bajo, un movimiento más suave.

El proyecto se basa en principios de este tipo para elegir variables con significado físico, como la media y la variación de la aceleración.

Dhawale, Smith y Ölveczky [2] explican que ninguna persona repite un movimiento de forma idéntica. Una parte de la variación proviene de pequeños cambios inevitables en el sistema nervioso y en los músculos. Otra parte puede aparecer porque la persona aprende, se adapta o prueba una forma diferente de alcanzar el mismo objetivo. En el uso de una computadora también pueden influir la tarea, la fatiga, el estado de ánimo, la superficie, la sensibilidad del mouse o el dispositivo utilizado.

Las diferencias que aparecen entre movimientos de una misma persona reciben el nombre de variación intrausuario. Las diferencias entre personas se conocen como variación interusuario. La autenticación solo puede funcionar bien cuando las diferencias entre el propietario y los impostores son mayores que los cambios normales del propio usuario. Si el modelo espera que el propietario se mueva siempre de la misma manera, generará alarmas cada vez que este cambie de ritmo. Por eso el perfil debe representar varios comportamientos legítimos y no una única trayectoria ideal.

La relación entre estas ideas y la seguridad informática aparece en el estudio de Antal y Egyed-Zsigmond [3]. Los autores estudiaron la dinámica de mouse con el mismo conjunto Balabit utilizado en este proyecto. Los datos se recogieron durante el uso general de una computadora y no mediante una sola tarea de laboratorio. El movimiento se dividió en acciones, como mover, apuntar y hacer clic, o arrastrar un objeto. Después se calcularon medidas de tiempo, distancia, velocidad, aceleración, dirección y suavidad.

Su resultado principal para este trabajo es que una sola acción contiene poca evidencia. En la parte más difícil de su evaluación, el AUC pasó de aproximadamente 0.79 con una acción a 0.90 al combinar 20 acciones. Al utilizar sesiones completas alcanzaron un AUC de 0.92. También observaron que varias medidas de aceleración y suavidad aportaban más información que algunas medidas simples de velocidad. Esto respalda la idea de acumular interacción antes de decidir.

Una acción del estudio de Antal y Egyed-Zsigmond reúne varios registros consecutivos; no equivale a un evento o fila individual del conjunto de datos utilizado en este proyecto. Además, ellos utilizaron clasificadores con ejemplos de ambas clases, mientras que este proyecto entrena solo con datos legítimos. Por esas diferencias, sus cifras sirven como antecedente y no como un resultado que el presente experimento deba reproducir exactamente.

Los registros de mouse no contienen el texto escrito por el usuario, pero sí pueden revelar hábitos personales. Por eso son menos sensibles al contenido que las pulsaciones del teclado, aunque deben protegerse como datos biométricos conductuales.

El proyecto se basa en este tipo de medidas y transforma cada ventana de eventos en 15 resúmenes numéricos. La duración, la frecuencia de eventos y las pausas describen el ritmo. Los movimientos y los eventos de botón muestran cómo se distribuyen las acciones. La distancia, el desplazamiento y la eficiencia describen el camino seguido. La velocidad, la aceleración y los cambios angulares cómo se ejecutó el movimiento. Finalmente, la fracción de segmentos con tiempo válido permite controlar la calidad del registro antes de entregarlo al modelo.

El modelo no sabe qué tarea realizaba la persona, qué intención tenía ni por qué se movió de cierta manera. Solo aprende qué combinaciones de esas medidas son habituales en las sesiones legítimas. Una combinación poco habitual recibe un puntaje de anomalía mayor.

1.2. Qué datos se usan para entrenar

En este trabajo, **entrenar** significa construir un perfil numérico del propietario a partir de interacciones conocidas como legítimas. No se enseña al modelo una lista de ataques ni se incluyen ejemplos de impostores durante el ajuste. Por eso se trata de aprendizaje de una clase: el sistema aprende qué es habitual para el usuario y considera anómalo aquello que se aleja de ese patrón.

El conjunto de datos contiene 65 sesiones legítimas de entrenamiento pertenecientes a diez usuarios. Para cada usuario, sus sesiones se ordenan de manera fija y luego se dividen en dos grupos. Aproximadamente el 75 % se utiliza para construir el perfil de comportamiento normal del usuario, proceso denominado enrolamiento, mientras que el 25 % restante se reserva para validación.

De esta forma, cada usuario cuenta normalmente con cuatro o cinco sesiones para construir su perfil y con una o dos sesiones adicionales para comprobar si el modelo reconoce correctamente nuevas sesiones legítimas del mismo usuario.

Por otra parte, las 816 sesiones públicas de prueba se mantienen completamente separadas durante el entrenamiento y la validación, y solo se utilizan en la evaluación final. Las sesiones privadas que no poseen una etiqueta conocida no se incluyen en el cálculo de las métricas.

No se construye un único perfil mezclando personas. Para cada usuario se ajustan un escalador, los modelos y un umbral propios usando solo sus datos legítimos. Las sesiones impostoras intervienen exclusivamente al medir el desempeño. La Tabla 1 muestra la composición exacta del experimento.

Usuario	Enrolamiento	Validación	Prueba	Legítimas	Impostoras
user7	5	2	73	36	37
user9	5	2	66	23	43
user12	5	2	105	56	49
user15	4	2	115	45	70
user16	4	2	106	68	38
user20	5	2	50	30	20
user21	5	2	59	37	22
user23	4	2	71	38	33
user29	5	2	63	43	20
user35	4	1	108	35	73
Total	46	19	816	411	405

Tabla 1: Partición por cuenta y composición de la prueba pública.

Dentro de esta cohorte, **user12** conserva un papel analítico específico. Sus cinco sesiones de enrolamiento, dos de validación y 105 de prueba permiten estudiar prefijos tempranos y variación intrausuario. Se presenta como un caso descriptivo fijado de antemano, no como evidencia de que sus resultados representen a las diez cuentas.

1.3. Qué miden las métricas

Cada puntaje se compara con el umbral y genera una de dos decisiones: aceptar la sesión o activar una alarma. Como la clase positiva es el impostor, TP es un impostor detectado, FN es un impostor aceptado, FP es un usuario legítimo enviado a alarma y TN es un usuario legítimo aceptado. A partir de esos cuatro conteos se calculan:

- **Detección de impostores o *recall*:** $R = TP/(TP + FN)$. Indica qué proporción de las suplantaciones produce una alarma; cuanto mayor, mejor.
- **Tasa de falsa aceptación (FAR):** $FAR = FN/(TP + FN) = 1 - R$. Mide qué proporción de impostores consigue permanecer en la sesión; cuanto menor, mayor seguridad.
- **Tasa de falso rechazo (FRR):** $FRR = FP/(TN + FP)$. Mide qué proporción de sesiones legítimas genera una falsa alarma; cuanto menor, mejor experiencia para el propietario.
- **Precisión de las alarmas:** $P = TP/(TP + FP)$. Responde qué proporción de las alarmas emitidas corresponde realmente a un impostor.
- **F1 de la clase impostora:** $F_1 = 2PR/(P + R)$. Es la media armónica entre precisión y detección. Resume ambas, pero no muestra por sí sola cuántos legítimos fueron aceptados correctamente.
- **Área bajo la curva ROC (AUC):** $AUC = \int_0^1 TPR(u) du$, donde la curva se obtiene variando todos los umbrales posibles y u es la tasa de falsos positivos, $FP/(FP + TN)$, que aquí coincide con la FRR. Evalúa la separación de los puntajes sin depender del umbral elegido. El área se estima con `roc_auc_score`; 0.5 equivale al azar y 1 representa separación perfecta.
- **Cobertura:** es el número de sesiones evaluables dividido entre el total de sesiones públicas. Una cobertura de 1 significa que ningún archivo quedó excluido por ser más corto que la ventana solicitada.
- **Pérdida balanceada:** $L = (FAR + FRR)/2$. Penaliza por igual aceptar impostores y rechazar legítimos; cuanto menor, mejor compromiso.

El desempeño del sistema se evalúa considerando tanto su capacidad para detectar sesiones impostoras como su capacidad para reconocer las variaciones naturales del comportamiento del usuario legítimo. Para ello se emplean métricas como la tasa de falsa aceptación (FAR), la tasa de falso rechazo (FRR), el área bajo la curva ROC (AUC) y el puntaje F_1 . Los resultados se analizan tanto de forma global como por usuario, con el objetivo de evitar que diferencias en el número de sesiones de cada cuenta distorsionen la evaluación general.

Además, los criterios utilizados para determinar si el comportamiento del modelo puede considerarse confiable se establecen antes de analizar el conjunto de prueba, evitando seleccionar retrospectivamente condiciones que favorezcan los resultados obtenidos.

2. Investigación

Pregunta principal. ¿Qué tan bien las características temporales y cinemáticas del mouse permiten distinguir sesiones legítimas e impostoras en diez usuarios, y qué muestra el caso de `user12` sobre la posibilidad de detectar una suplantación de manera temprana?

La pregunta principal se descompone en cuatro preguntas específicas:

1. ¿Cuál es el desempeño promedio de los modelos en las diez cuentas?
2. ¿Cuánto varían la separabilidad, la FAR y la FRR entre usuarios?
3. En `user12`, ¿cómo cambia la detección al observar entre 25 y 150 eventos y existe un mínimo que satisfaga el criterio operativo?

4. En ese caso, ¿qué características discriminan mejor y qué tan estable es el comportamiento legítimo entre sesiones?

2.1. Objetivo general

Evaluar el comportamiento general de perfiles individuales de dinámica de mouse, entrenados exclusivamente con datos legítimos de diez usuarios, y profundizar mediante **user12** en la detección temprana y la variación intrausuario.

2.2. Objetivos específicos

1. Construir variables temporales, espaciales y cinemáticas a partir de eventos de mouse.
2. Ajustar modelos y umbrales independientes por cuenta, sin mezclar identidades ni utilizar impostores durante el entrenamiento.
3. Comparar un baseline RMS-z y un *Isolation Forest* mediante promedios generales y resultados por usuario.
4. Medir en **user12** el efecto de observar distintas cantidades de eventos antes de emitir una decisión.
5. Identificar, en el estudio de caso, las variables con mayor discriminación y cuantificar el cambio del puntaje legítimo entre sesiones.

3. Metodología

3.1. Diseño y unidad de análisis

Se adopta un diseño cuantitativo y reproducible con dos niveles. El nivel principal evalúa las diez cuentas del Balabit Mouse Dynamics Challenge Dataset [5]; la unidad de evaluación es una sesión completa y se entrena un perfil independiente por persona. El segundo nivel profundiza en **user12**; allí se emplean ventanas y prefijos para estudiar detección temprana. Una **interacción** es una fila con marca temporal, coordenadas (x, y) , botón y estado, mientras que una **sesión** es la secuencia completa contenida en un archivo. La clase positiva es el impostor y una predicción positiva representa una alarma.

Cada evento contiene dos marcas de tiempo. **client timestamp** indica el instante registrado por el cliente desde el que se produjo el movimiento, mientras que **record timestamp** corresponde al instante con el que el registro recibió o almacenó ese evento. Para ordenar los eventos y calcular las medidas temporales se utiliza **client timestamp**, porque conserva mejor la separación temporal entre movimientos consecutivos. En una sesión inspeccionada, solo 6.9 % de los intervalos fueron repetidos con este reloj, frente a 71.4 % con **record timestamp**.

Un intervalo repetido significa que dos eventos distintos tienen la misma marca de tiempo: $\Delta t = 0$. En ese caso no es posible calcular una velocidad fiable, pues la fórmula $v = d/\Delta t$ exigiría dividir la distancia recorrida entre cero. Por esta razón, cuando $\Delta t \leq 0$, el segmento se conserva para describir la trayectoria y su distancia espacial, pero se excluye de los cálculos de velocidad y aceleración. Así se aprovecha la información sobre por dónde se movió el puntero sin crear velocidades indefinidas o artificialmente grandes.

3.2. Evaluación general de las diez cuentas

Cada sesión completa se transforma en 17 características: conteos de eventos, movimientos, interacciones de botón y pausas; duración y frecuencia; longitud, desplazamiento y eficiencia de trayectoria; media, desviación y máximo de velocidad; media y desviación de aceleración absoluta; cambio angular medio; fracción de pausas y fracción de segmentos temporales válidos. La posición absoluta no se usa y se verificó que trasladar una trayectoria no modifica el vector resultante.

Para cada cuenta, primero se separan sus sesiones que se conocen como legítimas. Aproximadamente 75 % se usa para **construir el perfil del usuario**; esta etapa se denomina **enrolamiento**. Por ejemplo, si una persona aporta cinco sesiones de enrolamiento, el sistema aprende con ellas qué valores de velocidad, pausas y aceleración son habituales para esa persona. El modelo no recibe sesiones impostoras durante este aprendizaje.

El 25 % restante se reserva para **validación** y no participa en la construcción del perfil. Estas sesiones también son legítimas, pero se usan después para comprobar qué puntajes recibe un usuario real y para fijar el umbral de alarma. Así, la validación permite decidir cuánto puede alejarse una sesión del perfil antes de considerarla anómala, sin consultar las etiquetas de la prueba pública. La división concreta de cada cuenta se presenta en la Tabla 1.

El **StandardScaler** estima la media y la desviación estándar de cada característica exclusivamente a partir de las sesiones de enrolamiento. Estos parámetros se conservan sin cambios para transformar las sesiones de validación y prueba. Así, el perfil del usuario se construye sin incorporar información de las sesiones destinadas a evaluarlo.

Se comparan dos detectores de una clase. El primero es un baseline interpretable, denominado RMS-z, que mide la distancia de una sesión respecto del perfil estandarizado. Para un vector estandarizado $\mathbf{z}$ de 17 características, su puntaje se define como:

$$s_{\text{RMS}}(\mathbf{z}) = \sqrt{\frac{1}{17} \sum_{j=1}^{17} z_j^2}, \quad (1)$$

El segundo detector es un *Isolation Forest* de 200 árboles, **contamination=auto** y una semilla fija², con valor 7. En ambos detectores, un puntaje mayor indica una mayor anomalía. Para cada usuario, el umbral de decisión se fija en el percentil 95 de los puntajes de sus sesiones legítimas de validación. Las etiquetas públicas se consultan únicamente después de congelar la transformación, el modelo y el umbral. Las métricas se reportan por usuario y como promedio general de las diez cuentas.

El valor 7 se eligió únicamente como una constante fija de reproducibilidad. No tiene un significado matemático especial ni existe una razón teórica para esperar que produzca mejores resultados que otro entero. Se conserva el mismo valor en los modelos de las diez cuentas y en el estudio de caso para que todos utilicen el mismo punto de partida aleatorio. Esto no hace que los perfiles aprendidos sean iguales, porque cada modelo recibe sesiones de entrenamiento diferentes. Evaluar una sola semilla tampoco demuestra que los resultados sean estables frente a la aleatoriedad; para comprobarlo sería necesario repetir el protocolo con varias semillas y reportar la variación de las métricas, sin escoger la

²La semilla es el número que inicializa el generador de números pseudoaleatorios del algoritmo; en el código se configura mediante **random_state=7**. *Isolation Forest* usa aleatoriedad para seleccionar muestras y construir las particiones de sus árboles. Al fijar la semilla, esas elecciones se pueden repetir al ejecutar el experimento con los mismos datos, orden, parámetros y entorno de software.

que mejor funcione en el test.

3.3. Estudio de caso: user12 y decisión temprana

La división se realiza a nivel de sesión, antes de formar las ventanas. De las cinco sesiones de enrolamiento y las dos de validación se extraen ventanas no superpuestas. Se conservan como máximo 300 ventanas por sesión, de modo que una sesión extensa no tenga más peso que las demás durante el ajuste.

Para cada una de las 105 sesiones públicas de prueba se utiliza únicamente el prefijo formado por sus primeros $N \in \{25, 50, 75, 100, 125, 150\}$ eventos. Se entrena y calibra un *Isolation Forest* independiente para cada valor de N . Por tanto, cada combinación de sesión y tamaño de prefijo produce una sola decisión. Las ventanas procedentes de una misma sesión no se consideran sesiones independientes.

3.4. Construcción de características

Los eventos se ordenan de forma estable por tiempo. Para dos registros consecutivos se calculan

$$\Delta t_i = t_i - t_{i-1}, \quad d_i = \sqrt{(x_i - x_{i-1})^2 + (y_i - y_{i-1})^2}, \quad v_i = \frac{d_i}{\Delta t_i}, \quad (2)$$

donde v_i solo se define para $\Delta t_i > 0$. Entre velocidades válidas sucesivas se obtiene la aceleración absoluta, $a_j = |v_j - v_{j-1}|/(\tau_j - \tau_{j-1})$, siempre que el nuevo intervalo sea positivo. El cambio angular se calcula como la diferencia absoluta entre direcciones consecutivas, envuelta al intervalo $[-\pi, \pi]$.

En el estudio de caso, cada ventana se resume en las 15 características de la Tabla 2. A diferencia del análisis de sesión completa, se usan proporciones en lugar de conteos absolutos para que el tamaño N no actúe como predictor. Los valores inexistentes se representan con cero y se verifica que el vector final sea finito.

Grupo	Características
Temporales	Duración, frecuencia de eventos, fracción de pausas de al menos 0.5 s y fracción de segmentos con tiempo creciente.
Eventos	Fracción de movimientos y fracción de eventos de botón.
Espaciales	Longitud de trayectoria, desplazamiento neto y eficiencia, definida como desplazamiento dividido entre la longitud de trayectoria.
Cinemáticas	Media, desviación y máximo de velocidad; media y desviación de aceleración absoluta; cambio angular absoluto medio.

Tabla 2: Características extraídas de cada ventana del estudio de caso.

3.5. Modelo y umbral del estudio de caso

Las características se estandarizan mediante **StandardScaler**, ajustado solo con ventanas de enrolamiento. Sobre esas ventanas legítimas se entrena un *Isolation Forest* [4] de 200 árboles, con `contamination=auto` y semilla 7. El método aísla observaciones mediante particiones aleatorias y permite formar un perfil sin necesitar ejemplos de cada posible tipo de impostor.

El puntaje se orienta para que un valor mayor represente más anomalía:

$$s(\mathbf{x}) = -\text{score_samples}(\text{StandardScaler}(\mathbf{x})). \quad (3)$$

El umbral γ del caso es el percentil 90 de los puntajes de validación legítima. Se usa el método **higher**, que selecciona un valor observado. La regla queda $\hat{y} = 1$ si $s(\mathbf{x}) > \gamma$ y $\hat{y} = 0$ en otro caso. El percentil coincide con el máximo tolerado de 10 % de rechazo legítimo en validación. Este umbral difiere del percentil 95 del experimento general porque el caso temprano usa el criterio operativo previamente declarado; por tanto, sus tasas no se comparan de forma directa con las de sesión completa.

3.6. Métricas y criterio operativo

Se aplican las definiciones de la Sección 1.3. En el nivel general, se calcula cada métrica para todas las cuentas y luego se obtiene su promedio para describir el comportamiento general. En el caso, para cada N los conteos se calculan sobre una sola decisión por sesión pública. Las unidades de evaluación son sesiones, no las ventanas legítimas usadas para ajustar el modelo.

Antes de revisar la prueba se declara confiable una ventana únicamente si cumple, de forma simultánea,

$$\text{AUC} \geq 0.80, \quad \text{FAR} \leq 0.10, \quad \text{FRR} \leq 0.10, \quad \text{cobertura} = 1.00. \quad (4)$$

En **user12**, el AUC individual orientado de cada característica a 100 eventos, $\max(\text{AUC}_k, 1 - \text{AUC}_k)$, se usa solo como diagnóstico y no para reajustar el bosque. Las seis longitudes se comparan buscando la primera que cumpla el criterio. Por último, el modelo de 100 eventos puntúa por separado todas las ventanas legítimas de cada sesión para comparar mediana, percentil 95 y tasa de alarma.

4. Resultados

4.1. Desempeño general en las diez cuentas

La Tabla 3 resume el comportamiento promedio de las diez cuentas. RMS-z obtuvo el mayor AUC promedio (0.627 frente a 0.611), mientras que *Isolation Forest* alcanzó mayor exactitud promedio (0.591 frente a 0.487). Ninguno resolvió simultáneamente los dos tipos de error: el baseline aceptó menos impostores, pero rechazó más sesiones legítimas; el bosque redujo la FRR media a costa de elevar la FAR media.

Modelo	AUC	F1	Exactitud	FAR	FRR
RMS-z	0.627	0.516	0.487	25.0 %	71.2 %
<i>Isolation Forest</i>	0.611	0.505	0.591	34.2 %	61.0 %

Tabla 3: Resultados generales: promedio de las métricas de las diez cuentas.

4.2. Variabilidad entre cuentas y transferencia del umbral

La Tabla 4 muestra el desempeño de *Isolation Forest* por cuenta. El AUC indica qué tan bien el modelo ordena las sesiones impostoras por encima de las legítimas, sin depender de un único umbral; la FAR y la FRR, en cambio, cuantifican los errores al aplicar el umbral individual obtenido en validación. Por esta razón, una cuenta puede mostrar un AUC aceptable y, aun así, tener un comportamiento operativo deficiente. Por ejemplo, **user7** logró el mayor AUC (0.861), pero rechazó 63.9 % de las sesiones legítimas; en **user9** y **user35**, la FAR fue 0 %, a costa de una FRR de 100 %. En el extremo opuesto, **user20** y **user21** no rechazaron sesiones legítimas (FRR de 0 %), pero aceptaron 95 % y 100 %

Usuario	AUC	F1	FAR	FRR
user7	0.861	0.763	0.0 %	63.9 %
user9	0.755	0.789	0.0 %	100.0 %
user12	0.552	0.635	4.1 %	92.9 %
user15	0.678	0.750	5.7 %	88.9 %
user16	0.497	0.483	26.3 %	73.5 %
user20	0.650	0.095	95.0 %	0.0 %
user21	0.611	0.000	100.0 %	0.0 %
user23	0.421	0.571	21.2 %	84.2 %
user29	0.576	0.160	90.0 %	7.0 %
user35	0.507	0.807	0.0 %	100.0 %

Tabla 4: Desempeño de *Isolation Forest* por cuenta en sesiones completas.

de los impostores, respectivamente.




Figura 1: Resultados de *Isolation Forest* por cuenta.

La Figura 1 en el panel superior, el AUC varía entre 0.421 para **user23** y 0.861 para **user7**: ocho de las diez cuentas superan el nivel de azar (0.50), pero solo **user7** alcanza la referencia de 0.80. El panel inferior muestra que ninguna cuenta queda simultáneamente por debajo del límite de 10 % en FAR y

FRR. Por tanto, aunque el modelo encuentra cierta señal discriminante en varias cuentas, los umbrales estimados con las sesiones de validación disponibles no se transfieren de manera estable a las sesiones públicas de prueba.

4.3. Estudio de caso user12: efecto del tamaño de observación

La Tabla 5 resume la evaluación. Todas las ventanas alcanzaron cobertura total. Aumentar la cantidad de eventos no produjo una mejora monótona: el AUC pasó de 0.632 con 25 eventos a un máximo de 0.692 con 100, descendió a 0.665 con 125 y terminó en 0.673 con 150. La FRR se mantuvo por debajo de 10 %, pero la FAR fue elevada en todos los tamaños.

Eventos	Tiempo (s)	AUC	Detección	FAR	FRR	F1	Cumple
25	3.9	0.632	18.4 %	81.6 %	7.1 %	0.290	No
50	9.7	0.652	24.5 %	75.5 %	5.4 %	0.375	No
75	16.9	0.651	28.6 %	71.4 %	8.9 %	0.412	No
100	23.1	0.692	30.6 %	69.4 %	3.6 %	0.455	No
125	31.1	0.665	32.7 %	67.3 %	7.1 %	0.464	No
150	37.2	0.673	24.5 %	75.5 %	5.4 %	0.375	No

Tabla 5: Desempeño por número de eventos observados.

El menor valor de la pérdida balanceada apareció con 100 eventos. Esa observación tomó una mediana de 23.1 segundos. No debe interpretarse como un mínimo confiable: ninguna ventana alcanzó a la vez AUC de 0.80, FAR y FRR de 10 % o menos y cobertura total.




Figura 2: Evolución del AUC, la FAR y la FRR al aumentar la cantidad de eventos observados.

La Figura 2 permite ver que el mejor AUC no coincide con una reducción suficiente de la FAR. Aunque la FRR permanece cerca o debajo del límite, la mayoría de los impostores continuó siendo aceptada.

4.4. Estudio de caso user12: características con mayor discriminación

A 100 eventos, las señales individuales más discriminantes fueron la variación de aceleración, la aceleración media absoluta y la velocidad máxima. En las tres, la mediana fue mayor para las sesiones impostoras. La Tabla 6 presenta las cinco primeras variables.

Característica	AUC orientado	Mediana legítima	Mediana impostora
Variación de aceleración	0.769	4433.022	9707.450
Aceleración media absoluta	0.743	2844.057	4809.817
Velocidad máxima	0.665	3273.308	5095.940
Variación de velocidad	0.657	639.502	866.590
Fracción de movimientos	0.626	0.890	0.860

Tabla 6: Principales características individuales a 100 eventos.

El ranking coincide en dirección general con el antecedente de Antal y Egyed-Zsigmond [3], que encontró información relevante en aceleración y *jerk*. No obstante, los valores presentes son diagnósticos univariados de un solo usuario y no prueban que esas variables sean universales.




Figura 3: AUC individual orientado de las características con mayor discriminación a 100 eventos.

La Figura 3 ordena las cinco variables principales. Las barras comienzan en 0.5, valor que representa una separación equivalente al azar, para destacar la señal adicional que aporta cada característica.

4.5. Estudio de caso user12: estabilidad entre sesiones

En las siete sesiones legítimas, la tasa de alarma varió entre 6.3% y 18.0%. En las dos sesiones reservadas para validación estuvo entre 7.3% y 12.5%. La sesión con mayor tasa pertenecía al propio enrolamiento, lo cual indica que el perfil legítimo conserva heterogeneidad aun dentro de los datos disponibles.

Sesión	Rol	Ventanas	Mediana	Tasa de alarma
2144641057	Enrolamiento	300	0.397	9.0 %
5265929106	Enrolamiento	300	0.399	12.3 %
5815391283	Enrolamiento	300	0.394	6.3 %
7409188284	Enrolamiento	300	0.429	18.0 %
8872593360	Enrolamiento	300	0.393	8.3 %
9031593624	Validación	300	0.392	7.3 %
9838420452	Validación	297	0.400	12.5 %

Tabla 7: Puntajes legítimos por sesión con ventanas de 100 eventos.




Figura 4: Tasa de alarma por sesión legítima con ventanas de 100 eventos. El color y el tramado distinguen las sesiones de enrolamiento de las reservadas para validación.

La Figura 4 muestra que la tasa de alarma cambia incluso entre sesiones legítimas. Una sesión de enrolamiento llegó al 18.0 %, mientras otras permanecieron por debajo del límite del 10 %.

5. Discusión, limitaciones e implicaciones

En conjunto, los resultados muestran que la dinámica de mouse contiene una señal útil, pero todavía insuficiente para funcionar como un autenticador autónomo. El desempeño cambia entre usuarios y depende de la representación, el umbral y las pocas sesiones disponibles para calibrarlo. A continuación se resumen los principales hallazgos, limitaciones e implicaciones para un uso responsable del método.

- **Resultado general.** Los AUC promedio de RMS-z (0.627) e *Isolation Forest* (0.611) muestran una separación modesta. El bosque obtuvo mayor exactitud promedio, pero su FAR de 34.2 % y FRR de 61.0 % no permiten utilizarlo como autenticador autónomo.
- **Variación entre cuentas.** El AUC del bosque osciló entre 0.421 y 0.861. Incluso *user7*, con el mayor AUC, rechazó 63.9 % de sus sesiones legítimas. Esto sugiere que una o dos sesiones de validación no bastan para fijar de forma estable el umbral individual.

- **Caso user12.** La evaluación por ventanas a 100 eventos mejoró el AUC a 0.692, pero mantuvo una FAR de 69.4 %. Sus resultados no se comparan directamente con los de sesión completa, porque emplean ventanas y un percentil distintos. Ningún tamaño de ventana cumplió el criterio operativo.
- **Alcance de los datos.** Las diez cuentas describen solo la variación interna de Balabit. Las suplantaciones provienen de otras personas, no de agentes de IA ni de automatizaciones; evaluar esos escenarios requeriría datos específicos con distintos dispositivos, velocidades y estrategias de imitación.
- **Otras limitaciones.** El análisis usa pocas sesiones para enrolamiento y validación, y la partición sigue el orden de los archivos, que no asegura una cronología real. Además, cambios de dispositivo, tarea o contexto pueden modificar el comportamiento legítimo, y el análisis temprano todavía no se repitió en las otras nueve cuentas.
- **Uso responsable.** La dinámica de mouse es un dato biométrico conductual. Una aplicación real debe contar con consentimiento, minimización y protección de datos, límites de retención, auditorías y mecanismos de recuperación. El modelo debe servir como señal de riesgo para autenticación escalonada, nunca como decisión irrevocable sobre identidad o culpabilidad.

6. Conclusiones y trabajo futuro

La dinámica de mouse contiene una señal medible, pero su utilidad no es uniforme entre personas. En las diez cuentas, RMS-z logró el mayor AUC promedio (0.627) y *Isolation Forest* la mayor exactitud promedio (0.591); ninguno produjo un punto operativo aceptable por sus elevadas FAR o FRR y por la fuerte variación entre usuarios. Por tanto, la evidencia no valida un autenticador autónomo general, aunque sí justifica investigar perfiles personalizados y mejores métodos de calibración.

Este proyecto explica parte de esa dificultad. En **user12**, la aceleración aportó la señal individual más clara y 100 eventos ofrecieron el mejor AUC del rango, pero la FAR de 69.4 % impidió satisfacer el criterio operativo. Su función dentro del trabajo es mostrar con detalle el compromiso entre rapidez, detección y falsas alarmas, no generalizar desde una sola persona.

El siguiente paso consiste en recolectar datos conductuales propios durante sesiones prolongadas y representativas del uso cotidiano del computador. Con estos datos será posible repetir las comparaciones en condiciones más realistas y superar las principales limitaciones del conjunto Balabit: el número reducido de sesiones, la escasa diversidad de dispositivos y contextos, y la naturaleza simulada de las suplantaciones. Además, los agentes de IA capaces de controlar un computador permitirían recolectar interacciones automatizadas y evaluar de forma explícita si el método distingue entre el uso humano legítimo y una suplantación realizada por IA.

Referencias

- [1] T. Flash y N. Hogan, *The coordination of arm movements: An experimentally confirmed mathematical model*, *The Journal of Neuroscience*, vol. 5, núm. 7, pp. 1688–1703, 1985.
- [2] A. K. Dhawale, M. A. Smith y B. P. Ölveczky, *The role of variability in motor learning*, *Annual Review of Neuroscience*, vol. 40, pp. 479–498, 2017. doi: 10.1146/annurev-neuro-072116-031548.

- [3] M. Antal y E. Egyed-Zsigmond, *Intrusion detection using mouse dynamics*, *IET Biometrics*, vol. 8, núm. 5, pp. 285–294, 2019. doi: 10.1049/iet-bmt.2018.5126.
- [4] F. T. Liu, K. M. Ting y Z.-H. Zhou, *Isolation Forest*, en *Proceedings of the 8th IEEE International Conference on Data Mining*, pp. 413–422, 2008.
- [5] Balabit, *Mouse Dynamics Challenge Dataset*, 2016. Repositorio `balabit/Mouse-Dynamics-Challenge` en GitHub.