

1. Tema

Detección de suplantación de identidad frente a variaciones naturales del comportamiento mediante biometría conductual, Feature Engineering y Machine Learning

2. Descripción de la Propuesta

2.1. Descripción Funcional

Los sistemas tradicionales de autenticación estática (contraseñas, tokens) verifican la identidad únicamente al inicio de la sesión. Frente a esta limitación, la **autenticación continua** mediante **biometría conductual** evalúa en segundo plano los patrones neuromotores de interacción del usuario (dinámica de tecleo y movimientos del cursor) de forma transparente y sin fricción.

Problema central: El comportamiento de una persona no es constante en el tiempo; experimenta **variaciones naturales intra-usuario** (*behavioral drift*) ocasionadas por fatiga, estrés o cambios de contexto. Si el sistema no reconoce esta variabilidad inherente, genera altos índices de falsas alarmas (*False Rejection Rate*).

Pregunta Central de Investigación

¿Qué características espaciotemporales extraídas mediante Feature Engineering permiten discriminar con robustez entre la deriva natural del usuario legítimo y una suplantación real de identidad, minimizando los falsos rechazos?

El sistema analizará y diferenciará entre tres estados operativos:

1. **Comportamiento habitual:** Patrón de interacción recurrente del usuario legítimo.
2. **Variaciones naturales:** Desviaciones legítimas de velocidad y pausas del mismo usuario entre distintas sesiones.
3. **Suplantación de identidad:** Patrón anómalo correspondiente a un atacante o usuario no autorizado.

Datasets Públicos y Gratuitos de Libre Descarga:

- **Balabit Mouse Dynamics Challenge Dataset:** Benchmark público internacional con sesiones continuas de interacción de múltiples usuarios en entornos reales, capturando coordenadas (x, y, t) , clics y trayectorias.
Enlace de descarga: <https://github.com/balabit/Mouse-Dynamics-Challenge>
- **Keystroke and Mouse Dynamics for UEBA Dataset (Mendeley Data):** Repositorio multi-sesión abierto con más de 140 000 registros integrados de pulsaciones de teclado (*Hold Time*, *Flight Time*) y métricas de cursor.
Enlace de descarga: <https://data.mendeley.com/datasets/f78jsh6zp9/2>
- **CMU Keystroke Dynamics Benchmark Dataset:** Dataset de referencia histórica de dinámica de tecleo multi-sesión.
Enlace de descarga: <https://www.cs.cmu.edu/~keystroke/>

Estructuración de Clases y Escenario de Clasificación:

- **Clasificación Binaria Supervisada: Clase 0 (Legítimo)**, agrupando sesiones base y sesiones con variación natural del usuario; frente a **Clase 1 (Impostor)**, con sesiones de terceros.
- **Detección de Anomalías (One-Class):** Perfilado no supervisado entrenado exclusivamente con el comportamiento del usuario legítimo para evaluar umbrales dinámicos frente a ataques.

2.2. Descripción Técnica

El proyecto se implementará en **Python**, empleando las siguientes librerías especializadas:

- **Procesamiento Numérico y Datos:** *pandas*, *numpy*, *scipy* (álgebra lineal, transformaciones estadísticas y series temporales).
- **Machine Learning & Validación:** *scikit-learn* (clasificadores supervisados, reducción dimensional y métricas).
- **Interpretabilidad y Visualización:** *matplotlib*, *seaborn* y *SHAP* (valores de Shapley para análisis de atribución).

Pipeline y Arquitectura de la Solución:

1. **Ingesta y Preprocesamiento:** Limpieza de valores nulos, filtrado de eventos espurios y segmentación en ventanas temporales móviles por usuario y sesión.
2. **Feature Engineering de Alto Nivel:** Extracción de descriptores conductuales especializados:
 - *Teclado:* Tiempos de pulsación (*Hold Time*), tiempos de vuelo entre dígrafos (*Flight Time*), velocidad de tipeo (WPM), variabilidad del ritmo, frecuencia de borrado (*Backspace*) y duración de pausas cognitivas.
 - *Mouse:* Velocidad tangencial media, aceleración instantánea, curvatura y rectitud de trayectorias (distancia euclidiana vs. real), tasa de cambio de dirección angular (*jitter*), frecuencia de clics y ratio de tiempo inactivo.
3. **Análisis Estadístico y Selección de Atributos:** Cálculo de varianza intra-sesión vs. inter-usuario para seleccionar variables con alta estabilidad temporal individual y alto poder discriminativo frente a terceros.
4. **Entrenamiento y Comparación de Modelos:** Se contrastarán dos configuraciones experimentales:
 - *Modelo Baseline:* Entrenado únicamente con variables crudas o estadísticas elementales directas.
 - *Modelo con Feature Engineering:* Entrenado con el conjunto optimizado de descriptores espaciotemporales.Modelos evaluados: **Logistic Regression**, **Random Forest**, **Support Vector Machines (SVM RBF)** e **Isolation Forest**.
5. **Validación Estratificada por Sesión (Out-of-Session Split):** Partición estricta basada en sesiones temporales independientes (las primeras sesiones entrenan y sesiones posteriores evalúan), garantizando que el modelo generalice ante la deriva natural sin memorizar una única sesión (*data leakage*).
6. **Evaluación e Interpretabilidad:** Medición mediante *Precision*, *Recall*, *F1-Score*, *ROC-AUC*, *EER* (Equal Error Rate) y análisis de importancia de variables con *SHAP*.

Tema de Investigación Complementario (Fuera del Temario del Curso):

Se investigarán los fundamentos teóricos de la **Biometría Conductual Continua** y el fenómeno de **Behavioral Drift** (deriva temporal del patrón de conducta), analizando técnicas de actualización adaptativa de perfiles y ajuste dinámico de umbrales para mantener la seguridad sin generar fricción al usuario legítimo.

3. Objetivos

3.1. Objetivo General

Desarrollar y evaluar un sistema de Machine Learning fundamentado en Feature Engineering para la autenticación continua mediante biometría conductual de teclado y mouse, capaz de discriminar de forma robusta entre variaciones naturales del comportamiento de un usuario legítimo y eventos de suplantación de identidad.

3.2. Objetivos Específicos

1. **Adquirir y estructurar** datasets públicos de biometría conductual (teclado y mouse) con sesiones independientes multi-usuario.
2. **Implementar un pipeline de Feature Engineering** que extraiga descriptores cinemáticos, estadísticos y temporales.
3. **Evaluar estadísticamente** la estabilidad temporal intra-usuario y el poder discriminativo inter-usuario de las variables.
4. **Entrenar y comparar** múltiples modelos de Machine Learning bajo las modalidades *Baseline* y con *Feature Engineering*.
5. **Validar la robustez del sistema** ante variaciones naturales aplicando evaluación por sesiones desacopladas (*out-of-session*).
6. **Interpretar el rendimiento** mediante métricas de clasificación (*Precision*, *Recall*, *F1*, *ROC-AUC*, *EER*) y análisis *SHAP*.
7. **Investigar y sintetizar** los conceptos teóricos de biometría conductual, autenticación continua y *behavioral drift*.