

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

MATEMÁTICAS Y PROGRAMACIÓN PARA IA

Detección temprana de suplantación durante una sesión activa mediante dinámica de mouse

Estudio de caso con autenticación continua y detección de anomalías

Resumen

Los controles de acceso tradicionales verifican credenciales en un instante, pero no garantizan que la persona que continúa operando una sesión sea quien se autenticó. Este trabajo estudia la dinámica de mouse como una biometría conductual para detectar cambios de operador mientras la sesión permanece activa. La propuesta se fundamenta en tres ideas: el movimiento voluntario presenta regularidades cinemáticas, cada persona conserva a la vez variación motora natural y la interacción con el mouse permite construir perfiles no intrusivos. Se realiza un estudio de caso con `user12` del conjunto Balabit. Un *Isolation Forest* se ajusta solo con ventanas legítimas; el umbral se fija con validación legítima y la prueba usa los primeros 25, 50, 75, 100, 125 o 150 eventos de cada sesión. El mejor compromiso se observó con 100 eventos, con $AUC = 0.692$, $FAR = 69.4\%$ y $FRR = 3.6\%$. Ningún tamaño satisfizo simultáneamente el criterio previo de $AUC \geq 0.80$, $FAR \leq 10\%$, $FRR \leq 10\%$ y cobertura total. Por tanto, el experimento identifica señales útiles, especialmente relacionadas con la aceleración, pero no valida todavía un autenticador operativo.

Palabras clave: autenticación continua, biometría conductual, dinámica de mouse, detección de anomalías, suplantación de identidad.

1. Introducción y contexto

La autenticación mediante contraseña, código de un solo uso o biometría física suele concentrarse en el ingreso al sistema. Una credencial correcta demuestra que alguien superó ese control, pero no que el mismo operador permanezca frente al equipo durante toda la sesión. Una cuenta puede quedar abierta, ser cedida o pasar a manos de otra persona después del acceso. También puede ser controlada por un programa o por un agente de inteligencia artificial capaz de interactuar con la interfaz. El problema de este trabajo no es volver a comprobar una credencial, sino buscar evidencia temprana de que cambió la forma de operar.

Este objetivo es distinto del de un CAPTCHA. Un CAPTCHA plantea un reto puntual para estimar si quien responde parece ser humano. La autenticación continua, en cambio, compara una secuencia de comportamiento con el perfil previamente registrado de una persona concreta. La dinámica de mouse puede, por ello, señalar tanto a otro ser humano como a un sistema automatizado cuando su patrón se aparta del perfil legítimo. Sin embargo, una anomalía no identifica su causa: no demuestra por sí sola que exista mala intención ni permite afirmar que el operador sea una IA. En una aplicación real, la alarma debería activar una verificación adicional y no una acusación automática.

1.1. Base científica del comportamiento motor

Cuando una persona mueve el mouse, el computador solo guarda una secuencia de datos: en qué momento ocurrió cada evento, dónde estaba el puntero y si hubo un clic. Sin embargo, detrás de esos datos existe una acción humana. La persona mira la pantalla, decide hacia dónde ir y coordina la mano y el brazo para llegar al objetivo. En ese proceso toma muchas decisiones pequeñas: iniciar rápido o despacio, seguir una línea recta o una curva, corregir la dirección, hacer una pausa y presionar el botón. Esas decisiones no se repiten de manera idéntica, pero tampoco son totalmente aleatorias.

Una comparación sencilla es la escritura a mano. Dos firmas de la misma persona nunca son exactamente iguales, aunque suelen compartir rasgos de velocidad, tamaño, inclinación y presión. Con el mouse ocurre algo parecido. El proyecto no busca una trayectoria idéntica que funcione como contraseña. Busca tendencias que aparecen muchas veces y que, juntas, pueden describir la forma habitual de

interactuar de un usuario.

La cinemática es la parte de la física que describe cómo cambia un movimiento con el tiempo. No intenta explicar qué músculo produjo el movimiento ni qué fuerza se aplicó, sino lo que puede observarse en el recorrido. En el caso del mouse, la posición indica dónde está el puntero mediante las coordenadas (x, y) y la trayectoria reúne todas esas posiciones para mostrar el camino completo. Ese camino puede ser recto, curvo o incluir pequeñas correcciones cuando la persona se desvía y vuelve a apuntar hacia su objetivo.

La velocidad indica cuánta distancia recorre el puntero durante un intervalo de tiempo. Si una persona mueve el mouse una distancia grande en poco tiempo, la velocidad es alta; si recorre poca distancia en el mismo tiempo, la velocidad es baja. La aceleración indica cómo cambia esa velocidad. Aparece cuando el usuario comienza a moverse, gana rapidez, reduce la marcha o se detiene antes de llegar a un botón. También se observa cuánto gira el recorrido entre un tramo y el siguiente. Las pausas, los clics y estos cambios de dirección ayudan a describir el ritmo con el que la persona observa la pantalla, decide y actúa.

Flash y Hogan [1] estudiaron movimientos del brazo entre dos puntos y observaron que una persona no suele mover la mano a velocidad constante. Normalmente comienza despacio, acelera, alcanza una velocidad máxima y vuelve a reducirla al acercarse al destino. Cuando la velocidad se representa a lo largo del tiempo, el resultado suele parecer una campana. También observaron que la mano tiende a reducir la velocidad en las partes más curvas del recorrido.

Para explicar ese comportamiento propusieron el modelo de mínimo *jerk*¹. La idea del modelo es que muchos movimientos voluntarios pueden aproximarse como una búsqueda de suavidad. Esto ayuda a entender por qué la forma del camino, la velocidad y la aceleración no son números arbitrarios: reflejan cómo se organiza el movimiento.

El estudio de Flash y Hogan no demostró que cada persona tenga una firma de mouse única. Además, sus experimentos analizaron movimientos del brazo en condiciones controladas, no sesiones de computadora. El proyecto se basa en principios de este tipo para elegir variables con significado físico, como la media y la variación de la aceleración. Estas medidas se relacionan con la suavidad del movimiento, aunque no corresponden al cálculo directo del *jerk*.

Dhawale, Smith y Ölveczky [2] explican que ninguna persona repite un movimiento de forma idéntica. Una parte de la variación proviene de pequeños cambios inevitables en el sistema nervioso y en los músculos. Otra parte puede aparecer porque la persona aprende, se adapta o prueba una forma diferente de alcanzar el mismo objetivo. En el uso de una computadora también pueden influir la tarea, la fatiga, el estado de ánimo, la superficie, la sensibilidad del mouse o el dispositivo utilizado.

Las diferencias que aparecen entre movimientos de una misma persona reciben el nombre de variación intrausuario. Las diferencias entre personas se conocen como variación interusuario. La autenticación solo puede funcionar bien cuando las diferencias entre el propietario y los impostores son mayores que los cambios normales del propio usuario. Si el modelo espera que el propietario se mueva siempre de la misma manera, generará alarmas cada vez que este cambie de ritmo. Por eso el perfil debe representar varios comportamientos legítimos y no una única trayectoria ideal.

¹El *jerk* es la rapidez con la que cambia la aceleración; un valor alto indica un cambio brusco y uno bajo, un movimiento más suave.

La relación entre estas ideas y la seguridad informática aparece en el estudio de Antal y Egyed-Zsigmond [3]. Los autores estudiaron la dinámica de mouse con el mismo conjunto Balabit utilizado en este proyecto. Los datos se recogieron durante el uso general de una computadora y no mediante una sola tarea de laboratorio. El movimiento se dividió en acciones, como mover, apuntar y hacer clic, o arrastrar un objeto. Después se calcularon medidas de tiempo, distancia, velocidad, aceleración, dirección y suavidad.

Su resultado principal para este trabajo es que una sola acción contiene poca evidencia. En la parte más difícil de su evaluación, el AUC pasó de aproximadamente 0.79 con una acción a 0.90 al combinar 20 acciones. Al utilizar sesiones completas alcanzaron un AUC de 0.92. También observaron que varias medidas de aceleración y suavidad aportaban más información que algunas medidas simples de velocidad. Esto respalda la idea de acumular interacción antes de decidir.

Una acción del estudio de Antal y Egyed-Zsigmond reúne varios registros consecutivos; no equivale a un evento o fila individual del conjunto de datos utilizado en este proyecto. Además, ellos utilizaron clasificadores con ejemplos de ambas clases, mientras que este proyecto entrena solo con datos legítimos. Por esas diferencias, sus cifras sirven como antecedente y no como un resultado que el presente experimento deba reproducir exactamente.

Los registros de mouse no contienen el texto escrito por el usuario, pero sí pueden revelar hábitos personales. Por eso son menos sensibles al contenido que las pulsaciones del teclado, aunque deben protegerse como datos biométricos conductuales.

El proyecto se basa en este tipo de medidas y transforma cada ventana de eventos en 15 resúmenes numéricos. La duración, la frecuencia de eventos y las pausas describen el ritmo. Los movimientos y los eventos de botón muestran cómo se distribuyen las acciones. La distancia, el desplazamiento y la eficiencia describen el camino seguido. La velocidad, la aceleración y los cambios angulares resumen cómo se ejecutó el movimiento. Finalmente, la fracción de segmentos con tiempo válido permite controlar la calidad del registro antes de entregarlo al modelo.

El modelo no sabe qué tarea realizaba la persona, qué intención tenía ni por qué se movió de cierta manera. Solo aprende qué combinaciones de esas medidas son habituales en las sesiones legítimas. Una combinación poco habitual recibe un puntaje de anomalía mayor.

En resumen, la base científica no afirma que cada usuario posea una huella motora perfecta e invariable. Afirma algo más limitado y comprobable: el movimiento tiene una estructura, el usuario legítimo presenta variaciones naturales y varias observaciones pueden contener información suficiente para comparar una sesión con su perfil. El experimento determina si esa información alcanza para detectar una suplantación sin confundirla con cambios normales.

1.2. Qué datos se usan para entrenar

En este trabajo, **entrenar** significa construir un perfil numérico del propietario a partir de interacciones conocidas como legítimas. No se enseña al modelo una lista de ataques ni se incluyen ejemplos de impostores durante el ajuste. Por eso se trata de aprendizaje de una clase: el sistema aprende qué es habitual para el usuario y considera anómalo aquello que se aleja de ese patrón.

Balabit guarda en `training_files/user12` siete sesiones realizadas por el propietario de la cuenta. Esas sesiones se separan antes de crear ventanas: cinco forman el **enrolamiento** y dos forman la **validación**. Las 105 sesiones públicas de prueba permanecen aparte. Esta separación impide que un

fragmento de la misma sesión aparezca tanto durante el aprendizaje como durante la evaluación.

El entrenamiento tiene dos pasos. Primero, **StandardScaler** calcula la media y la desviación estándar de cada característica usando únicamente el enrolamiento. Después, un *Isolation Forest* de 200 árboles aprende cómo se distribuyen esas ventanas legítimas. Se repite el proceso para cada tamaño de observación. La validación no vuelve a entrenar el bosque: solo produce puntajes legítimos cuyo percentil 90 fija la frontera entre aceptación y alarma. Las etiquetas de prueba se consultan al final para medir el desempeño, no para escoger esa frontera.

Tabla 1: Datos usados en cada etapa del experimento con **user12**.

Conjunto	Sesiones	Contenido	Función
Enrolamiento	5	Solo legítimas	Ajustar el escalador y el <i>Isolation Forest</i> .
Validación	2	Solo legítimas	Fijar el percentil 90 que funcionará como umbral.
Prueba pública	105	56 legítimas y 49 impostoras	Medir el resultado después de congelar el modelo y el umbral.

1.3. Qué miden las métricas

Cada puntaje se compara con el umbral y genera una de dos decisiones: aceptar la sesión o activar una alarma. Como la clase positiva es el impostor, TP es un impostor detectado, FN es un impostor aceptado, FP es un usuario legítimo enviado a alarma y TN es un usuario legítimo aceptado. A partir de esos cuatro conteos se calculan:

- **Detección de impostores o *recall*:** $R = TP/(TP + FN)$. Indica qué proporción de las suplantaciones produce una alarma; cuanto mayor, mejor.
- **Tasa de falsa aceptación (FAR):** $FAR = FN/(TP + FN) = 1 - R$. Mide qué proporción de impostores consigue permanecer en la sesión; cuanto menor, mayor seguridad.
- **Tasa de falso rechazo (FRR):** $FRR = FP/(TN + FP)$. Mide qué proporción de sesiones legítimas genera una falsa alarma; cuanto menor, mejor experiencia para el propietario.
- **Precisión de las alarmas:** $P = TP/(TP + FP)$. Responde qué proporción de las alarmas emitidas corresponde realmente a un impostor.
- **F1 de la clase impostora:** $F_1 = 2PR/(P + R)$. Es la media armónica entre precisión y detección. Resume ambas, pero no muestra por sí sola cuántos legítimos fueron aceptados correctamente.
- **Área bajo la curva ROC (AUC):** $AUC = \int_0^1 TPR(u) du$, donde la curva se obtiene variando todos los umbrales posibles y u es la tasa de falsos positivos, $FP/(FP + TN)$, que aquí coincide con la FRR. Evalúa la separación de los puntajes sin depender del umbral elegido. El área se estima con `roc_auc_score`; 0.5 equivale al azar y 1 representa separación perfecta.
- **Cobertura:** es el número de sesiones evaluables dividido entre el total de sesiones públicas. Una cobertura de 1 significa que ningún archivo quedó excluido por ser más corto que la ventana solicitada.
- **Pérdida balanceada:** $L = (FAR + FRR)/2$. Penaliza por igual aceptar impostores y rechazar legítimos; cuanto menor, mejor compromiso.

En este documento, una *falsa alarma* corresponde a la FRR, mientras que la FAR describe una aceptación indebida. Por ejemplo, con 100 eventos se obtuvieron $TP = 15$, $FN = 34$, $FP = 2$ y $TN = 54$. De allí se calculan 30.6 % de detección, $FAR = 34/49 = 69.4\%$, $FRR = 2/56 = 3.6\%$, precisión de 88.2 % y $F_1 = 0.455$. El AUC fue 0.692 y la cobertura, $105/105 = 1$. El ejemplo muestra por qué una precisión alta no basta: pocas alarmas fueron incorrectas, pero 34 de los 49 impostores no se detectaron.

Para evitar una conclusión acomodada a los resultados, el criterio se declaró antes de evaluar la prueba. Una ventana solo se considera confiable si alcanza a la vez $AUC \geq 0.80$, $FAR \leq 0.10$, $FRR \leq 0.10$ y cobertura total.

2. Problema de investigación

Pregunta principal. ¿En qué medida las características temporales y cinemáticas derivadas de la dinámica del mouse permiten detectar tempranamente una suplantación durante una sesión activa, manteniendo baja la tasa de falsas alarmas ante variaciones naturales del usuario legítimo?

La pregunta principal se descompone en cuatro preguntas específicas:

1. ¿Qué características discriminan mejor entre usuario legítimo e impostor?
2. ¿Cómo cambia la detección al aumentar la ventana de observación?
3. ¿Cuál es el mínimo de interacciones que satisface el criterio declarado?
4. ¿Qué tan estable es el comportamiento legítimo entre sesiones?

2.1. Objetivo general

Evaluar si un perfil de dinámica de mouse, entrenado exclusivamente con comportamiento legítimo, permite detectar de forma temprana sesiones de suplantación simulada sin generar una tasa excesiva de falsas alarmas para el propietario.

2.2. Objetivos específicos

1. Construir variables temporales, espaciales y cinemáticas a partir de eventos de mouse.
2. Comparar la capacidad discriminante individual de las variables en una ventana de referencia.
3. Medir el efecto de observar distintas cantidades de eventos antes de emitir una decisión.
4. Fijar un umbral solo con datos legítimos de validación y comprobar un criterio operativo previo.
5. Cuantificar el cambio del puntaje legítimo entre sesiones no mezcladas durante el entrenamiento.

3. Metodología

3.1. Diseño y unidad de análisis

Se adopta un estudio de caso cuantitativo y reproducible sobre **user12** del Balabit Mouse Dynamics Challenge Dataset [5]. Una **interacción** es una fila del registro: contiene marca temporal, coordenadas (x, y) , botón y estado. Una **sesión** es la secuencia completa de interacciones de un archivo. La clase

positiva es el impostor y una predicción positiva representa una alarma.

El usuario dispone de siete sesiones legítimas de entrenamiento. Cinco se destinan al enrolamiento y dos a la validación. La prueba pública etiquetada contiene 105 sesiones: 56 legítimas y 49 impostoras. Las sesiones privadas sin etiqueta pública se excluyen de las métricas. Los datos impostores no intervienen ni en el ajuste del modelo ni en el cálculo del umbral.

3.2. Partición y ventanas de observación

La separación se realiza por sesiones completas antes de formar ventanas. Esto evita que fragmentos de una misma sesión aparezcan simultáneamente en enrolamiento, validación y prueba. En enrolamiento y validación se extraen ventanas no superpuestas; se conservan como máximo 300 por sesión para que una sesión extensa no domine el ajuste.

Para simular una decisión temprana, de cada sesión de prueba se usa solamente el prefijo compuesto por los primeros $N \in \{25, 50, 75, 100, 125, 150\}$ eventos. Se entrena y calibra un modelo independiente para cada valor de N . Además del número de eventos, se registra el tiempo real que tardó cada prefijo. Este diseño produce una sola decisión por sesión y por tamaño; las ventanas hermanas no se cuentan como sesiones independientes.

3.3. Construcción de características

Los eventos se ordenan de forma estable por tiempo. Para dos registros consecutivos se calculan

$$\Delta t_i = t_i - t_{i-1}, \quad d_i = \sqrt{(x_i - x_{i-1})^2 + (y_i - y_{i-1})^2}, \quad v_i = \frac{d_i}{\Delta t_i}, \quad (1)$$

donde v_i solo se define para $\Delta t_i > 0$. Entre velocidades válidas sucesivas se obtiene la aceleración absoluta, $a_j = |v_j - v_{j-1}|/(\tau_j - \tau_{j-1})$, siempre que el nuevo intervalo sea positivo. El cambio angular se calcula como la diferencia absoluta entre direcciones consecutivas, envuelta al intervalo $[-\pi, \pi]$.

Cada ventana se resume en las 15 características de la Tabla 2. Los valores inexistentes se representan con cero y se verifica que el vector final sea finito.

Tabla 2: Características extraídas de cada ventana de eventos.

Grupo	Características
Temporales	Duración, frecuencia de eventos, fracción de pausas de al menos 0.5 s y fracción de segmentos con tiempo creciente.
Eventos	Fracción de movimientos y fracción de eventos de botón.
Espaciales	Longitud de trayectoria, desplazamiento neto y eficiencia, definida como desplazamiento dividido entre la longitud de trayectoria.
Cinemáticas	Media, desviación y máximo de velocidad; media y desviación de aceleración absoluta; cambio angular absoluto medio.

3.4. Modelo de una clase y umbral

Las características se estandarizan mediante `StandardScaler`, ajustado solo con ventanas de enrolamiento. Sobre esas ventanas legítimas se entrena un *Isolation Forest* [4] de 200 árboles, con `contamination=auto` y semilla 7. El método aísla observaciones mediante particiones aleatorias y

permite formar un perfil sin necesitar ejemplos de cada posible tipo de impostor.

El puntaje se orienta para que un valor mayor represente más anomalía:

$$s(\mathbf{x}) = -\text{score_samples}(\text{StandardScaler}(\mathbf{x})). \quad (2)$$

El umbral γ es el percentil 90 de los puntajes de validación legítima. Se usa el método **higher**, que selecciona un valor observado. La regla queda $\hat{y} = 1$ si $s(\mathbf{x}) > \gamma$ y $\hat{y} = 0$ en otro caso. El percentil coincide con el máximo tolerado de 10 % de rechazo legítimo en validación. Las etiquetas de prueba se consultan solo después de fijar γ .

3.5. Métricas y criterio operativo

Se aplican las definiciones presentadas en la Sección 1.3. Para cada valor de N , los conteos y las métricas se calculan sobre una sola decisión por sesión pública de prueba. Las unidades de evaluación son, por tanto, sesiones y no las múltiples ventanas legítimas usadas para ajustar el modelo.

Antes de revisar la prueba se declara confiable una ventana únicamente si cumple, de forma simultánea,

$$\text{AUC} \geq 0.80, \quad \text{FAR} \leq 0.10, \quad \text{FRR} \leq 0.10, \quad \text{cobertura} = 1.00. \quad (3)$$

La primera pregunta específica se responde mediante el AUC individual orientado de cada característica en 100 eventos: $\max(\text{AUC}_k, 1 - \text{AUC}_k)$. Es un análisis descriptivo y no se usa para reajustar el bosque. La segunda y la tercera se responden comparando las seis ventanas y buscando la primera que cumpla el criterio. Para la cuarta, el modelo de 100 eventos puntúa por separado todas las ventanas legítimas de cada sesión; se comparan mediana, percentil 95 y tasa de alarma.

4. Resultados

4.1. Efecto del tamaño de observación

La Tabla 3 resume la evaluación. Todas las ventanas alcanzaron cobertura total. Aumentar la cantidad de eventos no produjo una mejora monótona: el AUC pasó de 0.632 con 25 eventos a un máximo de 0.692 con 100, descendió a 0.665 con 125 y terminó en 0.673 con 150. La FRR se mantuvo por debajo de 10 %, pero la FAR fue elevada en todos los tamaños.

Tabla 3: Desempeño por número de eventos observados.

Eventos	Tiempo (s)	AUC	Detección	FAR	FRR	F1	Cumple
25	3.9	0.632	18.4 %	81.6 %	7.1 %	0.290	No
50	9.7	0.652	24.5 %	75.5 %	5.4 %	0.375	No
75	16.9	0.651	28.6 %	71.4 %	8.9 %	0.412	No
100	23.1	0.692	30.6 %	69.4 %	3.6 %	0.455	No
125	31.1	0.665	32.7 %	67.3 %	7.1 %	0.464	No
150	37.2	0.673	24.5 %	75.5 %	5.4 %	0.375	No

El menor valor de la pérdida balanceada apareció con 100 eventos. Esa observación tomó una mediana de 23.1 segundos. No debe interpretarse como un mínimo confiable: ninguna ventana alcanzó a la vez AUC de 0.80, FAR y FRR de 10 % o menos y cobertura total.

La Figura 1 permite ver que el mejor AUC no coincide con una reducción suficiente de la FAR. Aunque la FRR permanece cerca o debajo del límite, la mayoría de los impostores continúa siendo aceptada.




Figura 1: Evolución del AUC, la FAR y la FRR al aumentar la cantidad de eventos observados. Las líneas discontinuas representan los límites establecidos antes de la evaluación.

4.2. Características con mayor discriminación

A 100 eventos, las señales individuales más discriminantes fueron la variación de aceleración, la aceleración media absoluta y la velocidad máxima. En las tres, la mediana fue mayor para las sesiones impostoras. La Tabla 4 presenta las cinco primeras variables.

Tabla 4: Principales características individuales a 100 eventos.

Característica	AUC orientado	Mediana legítima	Mediana impostora
Variación de aceleración	0.769	4433.022	9707.450
Aceleración media absoluta	0.743	2844.057	4809.817
Velocidad máxima	0.665	3273.308	5095.940
Variación de velocidad	0.657	639.502	866.590
Fracción de movimientos	0.626	0.890	0.860

El ranking coincide en dirección general con el antecedente de Antal y Egyed-Zsigmond [3], que encontró información relevante en aceleración y *jerk*. No obstante, los valores presentes son diagnósticos univariados de un solo usuario y no prueban que esas variables sean universales.

La Figura 2 ordena las cinco variables principales. Las barras comienzan en 0.5, valor que representa una separación equivalente al azar, para destacar la señal adicional que aporta cada característica.




Figura 2: AUC individual orientado de las características con mayor discriminación a 100 eventos. La variación de aceleración produjo la separación individual más alta.

4.3. Estabilidad legítima entre sesiones

En las siete sesiones legítimas, la tasa de alarma varió entre 6.3 % y 18.0 %. En las dos sesiones reservadas para validación estuvo entre 7.3 % y 12.5 %. La sesión con mayor tasa pertenecía al propio enrolamiento, lo cual indica que el perfil legítimo conserva heterogeneidad aun dentro de los datos disponibles.

Tabla 5: Puntajes legítimos por sesión con ventanas de 100 eventos.

Sesión	Rol	Ventanas	Mediana	Tasa de alarma
2144641057	Enrolamiento	300	0.397	9.0 %
5265929106	Enrolamiento	300	0.399	12.3 %
5815391283	Enrolamiento	300	0.394	6.3 %
7409188284	Enrolamiento	300	0.429	18.0 %
8872593360	Enrolamiento	300	0.393	8.3 %
9031593624	Validación	300	0.392	7.3 %
9838420452	Validación	297	0.400	12.5 %

La Figura 3 muestra que la tasa de alarma cambia incluso entre sesiones legítimas. Una sesión de enrolamiento llegó al 18.0 %, mientras otras permanecieron por debajo del límite del 10 %.




Figura 3: Tasa de alarma por sesión legítima con ventanas de 100 eventos. El color y el tramado distinguen las sesiones de enrolamiento de las reservadas para validación.

5. Discusión

Los resultados responden las cuatro preguntas de investigación. Primero, las características de aceleración fueron las que mejor separaron individualmente las clases a 100 eventos. Segundo, observar más interacciones ayudó hasta cierto punto, pero el efecto no fue creciente ni suficiente: el mejor AUC apareció en 100 eventos y el menor FAR en 125. Tercero, no existe un mínimo dentro del rango estudiado porque ninguna configuración satisfizo el criterio declarado. Cuarto, el comportamiento legítimo no fue completamente estable; la tasa de alarma cambió en 11.7 puntos porcentuales entre sesiones.

El hallazgo principal no es que 100 eventos sean suficientes, sino que el criterio previo evita presentar como exitoso un modelo que conserva baja FRR a costa de aceptar a la mayoría de los impostores. El percentil 90 protege la experiencia del usuario legítimo, pero la superposición entre distribuciones limita la sensibilidad. Bajar el umbral podría detectar más impostores, aunque aumentaría las falsas alarmas; subirlo tendría el efecto contrario.

La comparación con CAPTCHA también debe mantenerse dentro del alcance empírico. El conjunto de prueba contiene suplantaciones simuladas mediante sesiones de otras personas, no agentes de IA ni automatizaciones. Por ello, el método evalúa continuidad de un patrón personal y podría detectar un agente solo si su interacción resulta anómala. Comprobar esa capacidad exigiría un conjunto específico con distintos agentes, dispositivos, velocidades y estrategias de imitación.

5.1. Limitaciones

- El análisis corresponde a una sola cuenta y no estima generalización entre personas.
- Las suplantaciones son simuladas; una anomalía no equivale a intención maliciosa.
- Solo dos sesiones legítimas fijan el umbral, por lo que la cola de validación puede ser inestable.

- Los primeros N eventos producen una decisión temprana única, no vigilancia secuencial en tiempo real.
- Cambios de dispositivo, resolución, fatiga, lesión, tarea o contexto pueden alterar el patrón legítimo.
- El AUC individual describe asociación y no causalidad ni importancia dentro del modelo multivariado.

5.2. Implicaciones éticas y operativas

La dinámica de mouse debe tratarse como dato biométrico conductual. Una implementación real requiere consentimiento, minimización y protección de los registros, límites de retención, auditoría de desempeño y un mecanismo accesible de recuperación. La salida apropiada del modelo es una señal de riesgo para autenticación escalonada, no una decisión irrevocable sobre identidad o culpabilidad.

6. Conclusiones y trabajo futuro

La dinámica de mouse ofrece una vía conceptualmente diferente y complementaria a los retos puntuales: permite observar si la manera de interactuar continúa siendo compatible con el perfil de la persona autenticada. La base científica explica tanto la estructura de las variables cinemáticas como la necesidad de tolerar variación natural. En el caso de `user12`, la aceleración aportó la señal individual más clara y 100 eventos dieron el mejor compromiso global, pero la elevada FAR impidió satisfacer el criterio operativo. La conclusión válida es negativa y útil: el prototipo detecta señal, aunque todavía no ofrece seguridad suficiente para uso autónomo.

El siguiente paso debe ampliar la evaluación a todas las cuentas, estimar incertidumbre mediante remuestreo por sesión y calibrar el umbral con validación cruzada entre sesiones legítimas. También conviene comparar ventanas definidas por tiempo, transformaciones robustas y actualizaciones controladas del perfil. Para estudiar específicamente suplantación por IA, será necesario recolectar datos de agentes que operen interfaces y evaluar ataques que intenten imitar al usuario.

Referencias

- [1] T. Flash y N. Hogan, *The coordination of arm movements: An experimentally confirmed mathematical model*, *The Journal of Neuroscience*, vol. 5, núm. 7, pp. 1688–1703, 1985.
- [2] A. K. Dhawale, M. A. Smith y B. P. Ölveczky, *The role of variability in motor learning*, *Annual Review of Neuroscience*, vol. 40, pp. 479–498, 2017. doi: 10.1146/annurev-neuro-072116-031548.
- [3] M. Antal y E. Egyed-Zsigmond, *Intrusion detection using mouse dynamics*, *IET Biometrics*, vol. 8, núm. 5, pp. 285–294, 2019. doi: 10.1049/iet-bmt.2018.5126.
- [4] F. T. Liu, K. M. Ting y Z.-H. Zhou, *Isolation Forest*, en *Proceedings of the 8th IEEE International Conference on Data Mining*, pp. 413–422, 2008.
- [5] Balabit, *Mouse Dynamics Challenge Dataset*, 2016. Repositorio `balabit/Mouse-Dynamics-Challenge` en GitHub.