

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

MATEMÁTICAS Y PROGRAMACIÓN PARA IA

Evaluación multiusuario de la detección de suplantación mediante dinámica de mouse

Análisis general de diez cuentas y estudio de caso de detección temprana

Resumen

Los controles de acceso tradicionales verifican credenciales en un instante, pero no garantizan que la persona que continúa operando una sesión sea quien se autenticó. Este trabajo estudia la dinámica de mouse como una biometría conductual para detectar cambios de operador mientras la sesión permanece activa. Se construyen perfiles independientes para las diez cuentas del conjunto Balabit y se evalúan 816 sesiones públicas: 411 legítimas y 405 impostoras. Cada sesión se resume mediante 17 características temporales, espaciales y cinemáticas. Un *baseline RMS-z* y un *Isolation Forest* se entrenan solo con sesiones legítimas y usan un umbral propio por cuenta. En el promedio macro, *RMS-z* obtuvo $AUC = 0.627$ e *Isolation Forest* $AUC = 0.611$; este último alcanzó $FAR = 34.2\%$ y $FRR = 61.0\%$, lo que revela separación modesta e inestabilidad entre usuarios. Como análisis específico, *user12* se estudia con prefijos de 25 a 150 eventos. Su mejor *AUC* apareció con 100 eventos ($AUC = 0.692$, $FAR = 69.4\%$ y $FRR = 3.6\%$), pero ningún tamaño satisfizo el criterio operativo previo. Los resultados muestran una señal conductual medible, aunque insuficiente para un autenticador autónomo.

Palabras clave: autenticación continua, biometría conductual, dinámica de mouse, detección de anomalías, suplantación de identidad.

1. Introducción y contexto

La autenticación mediante contraseña, código de un solo uso o biometría física suele concentrarse en el ingreso al sistema. Una credencial correcta demuestra que alguien superó ese control, pero no que el mismo operador permanezca frente al equipo durante toda la sesión. Una cuenta puede quedar abierta, ser cedida o pasar a manos de otra persona después del acceso. También puede ser controlada por un programa o por un agente de inteligencia artificial capaz de interactuar con la interfaz. El problema de este trabajo no es volver a comprobar una credencial, sino buscar evidencia temprana de que cambió la forma de operar.

Este enfoque es diferente al de un CAPTCHA el cual plantea un reto puntual para estimar si quien responde parece ser humano. La autenticación continua, en cambio, compara una secuencia de comportamiento con el perfil previamente registrado de una persona concreta. La dinámica del mouse puede utilizarse para detectar desviaciones respecto al patrón de comportamiento habitual de un usuario legítimo, independientemente de que estas provengan de otro ser humano o de un sistema automatizado. Sin embargo, la detección de una anomalía no permite determinar directamente su causa ni demostrar, por sí sola, la existencia de una intención maliciosa o la intervención de una inteligencia artificial. Por esta razón, en una aplicación real, una anomalía debería considerarse una señal de riesgo que active mecanismos adicionales de verificación, en lugar de generar automáticamente una alerta.

El estudio se organiza en dos análisis. La evaluación principal repite el protocolo de perfilado en las diez cuentas y resume el desempeño entre usuarios. Después se conserva *user12* como estudio de caso para examinar con mayor detalle cuántos eventos deben observarse, qué características discriminan y cuánto cambia el comportamiento legítimo entre sesiones. El caso no sustituye la evaluación general ni fue escogido por presentar el mejor resultado.

1.1. Base científica del comportamiento

Cuando una persona mueve el mouse, el computador solo guarda una secuencia de datos: en qué momento ocurrió cada evento, dónde estaba el puntero y si hubo un clic. Sin embargo, detrás de esos

datos existe una acción humana. La persona mira la pantalla, decide hacia dónde ir y coordina la mano y el brazo para llegar al objetivo. En ese proceso toma muchas decisiones inconscientemente: iniciar rápido o despacio, seguir una línea recta o una curva, corregir la dirección, hacer una pausa y presionar el botón. Esas decisiones no se repiten de manera idéntica, pero tampoco son totalmente aleatorias.

Una comparación sencilla es la escritura a mano. Dos firmas de la misma persona nunca son exactamente iguales, aunque suelen compartir rasgos de velocidad, tamaño, inclinación y presión. Con el mouse ocurre algo parecido. El proyecto no busca una trayectoria idéntica que funcione como contraseña. Busca tendencias que aparecen muchas veces y que, juntas, pueden describir la forma habitual de interactuar de un usuario.

La cinemática es la parte de la física que describe cómo cambia un movimiento con el tiempo. No intenta explicar qué músculo produjo el movimiento ni qué fuerza se aplicó, sino lo que puede observarse en el recorrido. En el caso del mouse, la posición indica dónde está el puntero mediante las coordenadas (x, y) y la trayectoria reúne todas esas posiciones para mostrar el camino completo. Ese camino puede ser recto, curvo o incluir pequeñas correcciones cuando la persona se desvía y vuelve a apuntar hacia su objetivo.

La velocidad indica cuánta distancia recorre el puntero durante un intervalo de tiempo. Si una persona mueve el mouse una distancia grande en poco tiempo, la velocidad es alta; si recorre poca distancia en el mismo tiempo, la velocidad es baja. La aceleración indica cómo cambia esa velocidad. Aparece cuando el usuario comienza a moverse, gana rapidez, reduce la marcha o se detiene antes de llegar a un botón. También se observa cuánto gira el recorrido entre un tramo y el siguiente. Las pausas, los clics y estos cambios de dirección ayudan a describir el ritmo con el que la persona observa la pantalla, decide y actúa.

Flash y Hogan [1] estudiaron movimientos del brazo entre dos puntos y observaron que una persona no suele mover la mano a velocidad constante. Normalmente comienza despacio, acelera, alcanza una velocidad máxima y vuelve a reducirla al acercarse al destino. Cuando la velocidad se representa a lo largo del tiempo, el resultado suele parecer una campana. También observaron que la mano tiende a reducir la velocidad en las partes más curvas del recorrido.

Para explicar ese comportamiento propusieron el modelo de mínimo *jerk*¹. La idea del modelo es que muchos movimientos voluntarios pueden aproximarse como una búsqueda de suavidad. Esto ayuda a entender por qué la forma del camino, la velocidad y la aceleración no son números arbitrarios: reflejan cómo se organiza el movimiento.

El estudio de Flash y Hogan no demostró que cada persona tenga una firma de mouse única. Además, sus experimentos analizaron movimientos del brazo en condiciones controladas, no sesiones de computadora. El proyecto se basa en principios de este tipo para elegir variables con significado físico, como la media y la variación de la aceleración.

Dhawale, Smith y Ölveczky [2] explican que ninguna persona repite un movimiento de forma idéntica. Una parte de la variación proviene de pequeños cambios inevitables en el sistema nervioso y en los músculos. Otra parte puede aparecer porque la persona aprende, se adapta o prueba una forma diferente de alcanzar el mismo objetivo. En el uso de una computadora también pueden influir la tarea, la fatiga, el estado de ánimo, la superficie, la sensibilidad del mouse o el dispositivo utilizado.

¹El *jerk* es la rapidez con la que cambia la aceleración; un valor alto indica un cambio brusco y uno bajo, un movimiento más suave.

Las diferencias que aparecen entre movimientos de una misma persona reciben el nombre de variación intrausuario. Las diferencias entre personas se conocen como variación interusuario. La autenticación solo puede funcionar bien cuando las diferencias entre el propietario y los impostores son mayores que los cambios normales del propio usuario. Si el modelo espera que el propietario se mueva siempre de la misma manera, generará alarmas cada vez que este cambie de ritmo. Por eso el perfil debe representar varios comportamientos legítimos y no una única trayectoria ideal.

La relación entre estas ideas y la seguridad informática aparece en el estudio de Antal y Egyed-Zsigmond [3]. Los autores estudiaron la dinámica de mouse con el mismo conjunto Balabit utilizado en este proyecto. Los datos se recogieron durante el uso general de una computadora y no mediante una sola tarea de laboratorio. El movimiento se dividió en acciones, como mover, apuntar y hacer clic, o arrastrar un objeto. Después se calcularon medidas de tiempo, distancia, velocidad, aceleración, dirección y suavidad.

Su resultado principal para este trabajo es que una sola acción contiene poca evidencia. En la parte más difícil de su evaluación, el AUC pasó de aproximadamente 0.79 con una acción a 0.90 al combinar 20 acciones. Al utilizar sesiones completas alcanzaron un AUC de 0.92. También observaron que varias medidas de aceleración y suavidad aportaban más información que algunas medidas simples de velocidad. Esto respalda la idea de acumular interacción antes de decidir.

Una acción del estudio de Antal y Egyed-Zsigmond reúne varios registros consecutivos; no equivale a un evento o fila individual del conjunto de datos utilizado en este proyecto. Además, ellos utilizaron clasificadores con ejemplos de ambas clases, mientras que este proyecto entrena solo con datos legítimos. Por esas diferencias, sus cifras sirven como antecedente y no como un resultado que el presente experimento deba reproducir exactamente.

Los registros de mouse no contienen el texto escrito por el usuario, pero sí pueden revelar hábitos personales. Por eso son menos sensibles al contenido que las pulsaciones del teclado, aunque deben protegerse como datos biométricos conductuales.

El proyecto se basa en este tipo de medidas y transforma cada ventana de eventos en 15 resúmenes numéricos. La duración, la frecuencia de eventos y las pausas describen el ritmo. Los movimientos y los eventos de botón muestran cómo se distribuyen las acciones. La distancia, el desplazamiento y la eficiencia describen el camino seguido. La velocidad, la aceleración y los cambios angulares cómo se ejecutó el movimiento. Finalmente, la fracción de segmentos con tiempo válido permite controlar la calidad del registro antes de entregarlo al modelo.

El modelo no sabe qué tarea realizaba la persona, qué intención tenía ni por qué se movió de cierta manera. Solo aprende qué combinaciones de esas medidas son habituales en las sesiones legítimas. Una combinación poco habitual recibe un puntaje de anomalía mayor.

1.2. Qué datos se usan para entrenar

En este trabajo, **entrenar** significa construir un perfil numérico del propietario a partir de interacciones conocidas como legítimas. No se enseña al modelo una lista de ataques ni se incluyen ejemplos de impostores durante el ajuste. Por eso se trata de aprendizaje de una clase: el sistema aprende qué es habitual para el usuario y considera anómalo aquello que se aleja de ese patrón.

El conjunto de datos contiene 65 sesiones legítimas de entrenamiento pertenecientes a diez usuarios. Para cada usuario, sus sesiones se ordenan de manera fija y luego se dividen en dos grupos. Aproximadamente

el 75 % se utiliza para construir el perfil de comportamiento normal del usuario, proceso denominado enrolamiento, mientras que el 25 % restante se reserva para validación.

De esta forma, cada usuario cuenta normalmente con cuatro o cinco sesiones para construir su perfil y con una o dos sesiones adicionales para comprobar si el modelo reconoce correctamente nuevas sesiones legítimas del mismo usuario.

Por otra parte, las 816 sesiones públicas de prueba se mantienen completamente separadas durante el entrenamiento y la validación, y solo se utilizan en la evaluación final. Las sesiones privadas que no poseen una etiqueta conocida no se incluyen en el cálculo de las métricas.

No se construye un único perfil mezclando personas. Para cada usuario se ajustan un escalador, los modelos y un umbral propios usando solo sus datos legítimos. Las sesiones impostoras intervienen exclusivamente al medir el desempeño. La Tabla 1 muestra la composición exacta del experimento.

Tabla 1: Partición por cuenta y composición de la prueba pública.

Usuario	Enrolamiento	Validación	Prueba	Legítimas	Impostoras
user7	5	2	73	36	37
user9	5	2	66	23	43
user12	5	2	105	56	49
user15	4	2	115	45	70
user16	4	2	106	68	38
user20	5	2	50	30	20
user21	5	2	59	37	22
user23	4	2	71	38	33
user29	5	2	63	43	20
user35	4	1	108	35	73
Total	46	19	816	411	405

Dentro de esta cohorte, **user12** conserva un papel analítico específico. Sus cinco sesiones de enrolamiento, dos de validación y 105 de prueba permiten estudiar prefijos tempranos y variación intrausuario. Se presenta como un caso descriptivo fijado de antemano, no como evidencia de que sus resultados representen a las diez cuentas.

1.3. Qué miden las métricas

Cada puntaje se compara con el umbral y genera una de dos decisiones: aceptar la sesión o activar una alarma. Como la clase positiva es el impostor, TP es un impostor detectado, FN es un impostor aceptado, FP es un usuario legítimo enviado a alarma y TN es un usuario legítimo aceptado. A partir de esos cuatro conteos se calculan:

- **Detección de impostores o *recall*:** $R = TP/(TP + FN)$. Indica qué proporción de las suplantaciones produce una alarma; cuanto mayor, mejor.
- **Tasa de falsa aceptación (FAR):** $FAR = FN/(TP + FN) = 1 - R$. Mide qué proporción de impostores consigue permanecer en la sesión; cuanto menor, mayor seguridad.
- **Tasa de falso rechazo (FRR):** $FRR = FP/(TN + FP)$. Mide qué proporción de sesiones legítimas genera una falsa alarma; cuanto menor, mejor experiencia para el propietario.
- **Precisión de las alarmas:** $P = TP/(TP + FP)$. Responde qué proporción de las alarmas emitidas

corresponde realmente a un impostor.

- **F1 de la clase impostora:** $F_1 = 2PR/(P + R)$. Es la media armónica entre precisión y detección. Resume ambas, pero no muestra por sí sola cuántos legítimos fueron aceptados correctamente.
- **Área bajo la curva ROC (AUC):** $AUC = \int_0^1 TPR(u) du$, donde la curva se obtiene variando todos los umbrales posibles y u es la tasa de falsos positivos, $FP/(FP + TN)$, que aquí coincide con la FRR. Evalúa la separación de los puntajes sin depender del umbral elegido. El área se estima con `roc_auc_score`; 0.5 equivale al azar y 1 representa separación perfecta.
- **Cobertura:** es el número de sesiones evaluables dividido entre el total de sesiones públicas. Una cobertura de 1 significa que ningún archivo quedó excluido por ser más corto que la ventana solicitada.
- **Pérdida balanceada:** $L = (FAR + FRR)/2$. Penaliza por igual aceptar impostores y rechazar legítimos; cuanto menor, mejor compromiso.

Para resumir las diez cuentas se distinguen dos agregaciones. Las métricas **micro** se calculan después de reunir las 816 decisiones y, por ello, dan más peso a las cuentas con más sesiones. Las métricas **macro** se calculan primero por usuario y luego se promedian, de modo que cada cuenta pesa lo mismo. La evaluación macro es la referencia principal para hablar del comportamiento general; la micro describe el volumen total de decisiones.

En este documento, una *falsa alarma* corresponde a la FRR, mientras que la FAR describe una aceptación indebida. Por ejemplo, con 100 eventos se obtuvieron $TP = 15$, $FN = 34$, $FP = 2$ y $TN = 54$. De allí se calculan 30.6 % de detección, $FAR = 34/49 = 69.4\%$, $FRR = 2/56 = 3.6\%$, precisión de 88.2 % y $F_1 = 0.455$. El AUC fue 0.692 y la cobertura, $105/105 = 1$. El ejemplo muestra por qué una precisión alta no basta: pocas alarmas fueron incorrectas, pero 34 de los 49 impostores no se detectaron.

Para evitar una conclusión acomodada a los resultados del estudio de caso, el criterio se declaró antes de evaluar la prueba. Una ventana de `user12` solo se considera confiable si alcanza a la vez $AUC \geq 0.80$, $FAR \leq 0.10$, $FRR \leq 0.10$ y cobertura total. Este criterio no se usa para seleccionar retrospectivamente el mejor usuario del análisis general.

2. Problema de investigación

Pregunta principal. ¿En qué medida los perfiles individuales contruidos con características temporales y cinemáticas de la dinámica de mouse permiten distinguir sesiones legítimas e impostoras en diez usuarios, y qué revela el caso de `user12` sobre la posibilidad de emitir una decisión temprana?

La pregunta principal se descompone en cuatro preguntas específicas:

1. ¿Cuál es el desempeño macro y micro de los modelos en las diez cuentas?
2. ¿Cuánto varían la separabilidad, la FAR y la FRR entre usuarios?
3. En `user12`, ¿cómo cambia la detección al observar entre 25 y 150 eventos y existe un mínimo que satisfaga el criterio operativo?
4. En ese caso, ¿qué características discriminan mejor y qué tan estable es el comportamiento legítimo entre sesiones?

2.1. Objetivo general

Evaluar el comportamiento general de perfiles individuales de dinámica de mouse, entrenados exclusivamente con datos legítimos de diez usuarios, y profundizar mediante **user12** en la detección temprana y la variación intrausuario.

2.2. Objetivos específicos

1. Construir variables temporales, espaciales y cinemáticas a partir de eventos de mouse.
2. Ajustar modelos y umbrales independientes por cuenta, sin mezclar identidades ni utilizar impostores durante el entrenamiento.
3. Comparar un baseline RMS-z y un *Isolation Forest* mediante métricas macro, micro y por usuario.
4. Medir en **user12** el efecto de observar distintas cantidades de eventos antes de emitir una decisión.
5. Identificar, en el estudio de caso, las variables con mayor discriminación y cuantificar el cambio del puntaje legítimo entre sesiones.

3. Metodología

3.1. Diseño y unidad de análisis

Se adopta un diseño cuantitativo y reproducible con dos niveles. El nivel principal evalúa las diez cuentas del Balabit Mouse Dynamics Challenge Dataset [5]; la unidad de evaluación es una sesión completa y se entrena un perfil independiente por persona. El segundo nivel profundiza en **user12**; allí se emplean ventanas y prefijos para estudiar detección temprana. Una **interacción** es una fila con marca temporal, coordenadas (x, y) , botón y estado, mientras que una **sesión** es la secuencia completa contenida en un archivo. La clase positiva es el impostor y una predicción positiva representa una alarma.

Los eventos se ordenan de forma estable usando `client timestamp`. En una sesión inspeccionada, este reloj presentó 6.9 % de intervalos repetidos, frente a 71.4 % en `record timestamp`; por ello se utiliza el reloj del cliente para calcular derivadas. Los segmentos con $\Delta t \leq 0$ se conservan para la geometría, pero se excluyen de velocidad y aceleración.

3.2. Evaluación general de las diez cuentas

Cada sesión completa se transforma en 17 características: conteos de eventos, movimientos, interacciones de botón y pausas; duración y frecuencia; longitud, desplazamiento y eficiencia de trayectoria; media, desviación y máximo de velocidad; media y desviación de aceleración absoluta; cambio angular medio; fracción de pausas y fracción de segmentos temporales válidos. La posición absoluta no se usa y se verificó que trasladar una trayectoria no modifica el vector resultante.

En cada cuenta se reserva 25 % de las sesiones legítimas para validación y el resto para enrolamiento, de acuerdo con la Tabla 1. El **StandardScaler** se ajusta solo con enrolamiento. Se comparan dos detectores de una clase: un baseline interpretable,

$$s_{\text{RMS}}(\mathbf{z}) = \sqrt{\frac{1}{17} \sum_{j=1}^{17} z_j^2}, \quad (1)$$

y un *Isolation Forest* de 200 árboles, `contamination=auto` y semilla 7. Para ambos, un puntaje mayor significa mayor anomalía. El umbral individual es el percentil 95 de los puntajes legítimos de validación. Las etiquetas públicas se consultan solo después de congelar transformación, modelo y umbral. Las métricas se reportan por usuario, macro y micro; el promedio macro es la referencia para la conclusión general.

3.3. Estudio de caso: user12 y decisión temprana

La separación se realiza por sesiones completas antes de formar ventanas. En las cinco sesiones de enrolamiento y las dos de validación se extraen ventanas no superpuestas; se conservan como máximo 300 por sesión para que una sesión extensa no domine el ajuste. De cada una de las 105 sesiones públicas de prueba se usa solo el prefijo formado por los primeros $N \in \{25, 50, 75, 100, 125, 150\}$ eventos. Se entrena y calibra un *Isolation Forest* independiente para cada N . El diseño produce una decisión por sesión y tamaño; las ventanas hermanas no se cuentan como sesiones independientes.

3.4. Construcción de características

Los eventos se ordenan de forma estable por tiempo. Para dos registros consecutivos se calculan

$$\Delta t_i = t_i - t_{i-1}, \quad d_i = \sqrt{(x_i - x_{i-1})^2 + (y_i - y_{i-1})^2}, \quad v_i = \frac{d_i}{\Delta t_i}, \quad (2)$$

donde v_i solo se define para $\Delta t_i > 0$. Entre velocidades válidas sucesivas se obtiene la aceleración absoluta, $a_j = |v_j - v_{j-1}|/(\tau_j - \tau_{j-1})$, siempre que el nuevo intervalo sea positivo. El cambio angular se calcula como la diferencia absoluta entre direcciones consecutivas, envuelta al intervalo $[-\pi, \pi]$.

En el estudio de caso, cada ventana se resume en las 15 características de la Tabla 2. A diferencia del análisis de sesión completa, se usan proporciones en lugar de conteos absolutos para que el tamaño N no actúe como predictor. Los valores inexistentes se representan con cero y se verifica que el vector final sea finito.

Tabla 2: Características extraídas de cada ventana del estudio de caso.

Grupo	Características
Temporales	Duración, frecuencia de eventos, fracción de pausas de al menos 0.5 s y fracción de segmentos con tiempo creciente.
Eventos	Fracción de movimientos y fracción de eventos de botón.
Espaciales	Longitud de trayectoria, desplazamiento neto y eficiencia, definida como desplazamiento dividido entre la longitud de trayectoria.
Cinemáticas	Media, desviación y máximo de velocidad; media y desviación de aceleración absoluta; cambio angular absoluto medio.

3.5. Modelo y umbral del estudio de caso

Las características se estandarizan mediante `StandardScaler`, ajustado solo con ventanas de enrolamiento. Sobre esas ventanas legítimas se entrena un *Isolation Forest* [4] de 200 árboles, con `contamination=auto` y semilla 7. El método aísla observaciones mediante particiones aleatorias y permite formar un perfil sin necesitar ejemplos de cada posible tipo de impostor.

El puntaje se orienta para que un valor mayor represente más anomalía:

$$s(\mathbf{x}) = -\text{score_samples}(\text{StandardScaler}(\mathbf{x})). \quad (3)$$

El umbral γ del caso es el percentil 90 de los puntajes de validación legítima. Se usa el método `higher`, que selecciona un valor observado. La regla queda $\hat{y} = 1$ si $s(\mathbf{x}) > \gamma$ y $\hat{y} = 0$ en otro caso. El percentil coincide con el máximo tolerado de 10 % de rechazo legítimo en validación. Este umbral difiere del percentil 95 del experimento general porque el caso temprano usa el criterio operativo previamente declarado; por tanto, sus tasas no se comparan de forma directa con las de sesión completa.

3.6. Métricas y criterio operativo

Se aplican las definiciones de la Sección 1.3. En el nivel general, primero se calculan las métricas de cada cuenta y luego los resúmenes macro y micro. En el caso, para cada N los conteos se calculan sobre una sola decisión por sesión pública. Las unidades de evaluación son sesiones, no las ventanas legítimas usadas para ajustar el modelo.

Antes de revisar la prueba se declara confiable una ventana únicamente si cumple, de forma simultánea,

$$\text{AUC} \geq 0.80, \quad \text{FAR} \leq 0.10, \quad \text{FRR} \leq 0.10, \quad \text{cobertura} = 1.00. \quad (4)$$

En `user12`, el AUC individual orientado de cada característica a 100 eventos, $\max(\text{AUC}_k, 1 - \text{AUC}_k)$, se usa solo como diagnóstico y no para reajustar el bosque. Las seis longitudes se comparan buscando la primera que cumpla el criterio. Por último, el modelo de 100 eventos puntúa por separado todas las ventanas legítimas de cada sesión para comparar mediana, percentil 95 y tasa de alarma.

4. Resultados

4.1. Desempeño general en las diez cuentas

La Tabla 3 resume el comportamiento dando el mismo peso a cada usuario. RMS-z obtuvo el mayor AUC macro (0.627 frente a 0.611), mientras que *Isolation Forest* alcanzó mayor exactitud macro (0.591 frente a 0.487). Ninguno resolvió simultáneamente los dos tipos de error: el baseline aceptó menos impostores, pero rechazó más sesiones legítimas; el bosque redujo la FRR media a costa de elevar la FAR media.

Tabla 3: Resultados macro: promedio de las métricas calculadas por usuario.

Modelo	AUC	F1	Exactitud	FAR	FRR
RMS-z	0.627	0.516	0.487	25.0 %	71.2 %
<i>Isolation Forest</i>	0.611	0.505	0.591	34.2 %	61.0 %

La agregación micro confirma que el punto operativo sigue siendo insuficiente. En *Isolation Forest*, de 405 sesiones impostoras se detectaron 323 y se aceptaron 82; de 411 sesiones legítimas se aceptaron 153 y se enviaron 258 a alarma. Esto equivale a $AUC = 0.591$, $F_1 = 0.655$, exactitud de 58.3 %, $FAR = 20.2\%$ y $FRR = 62.8\%$. RMS-z alcanzó $AUC = 0.623$, exactitud de 48.2 %, $FAR = 28.1\%$ y $FRR = 75.2\%$. La diferencia entre macro y micro se debe a que las cuentas aportan cantidades distintas de sesiones.

4.2. Heterogeneidad entre usuarios

El promedio oculta comportamientos muy distintos. En *Isolation Forest*, el AUC varió entre 0.421 para **user23** y 0.861 para **user7**. Ocho de diez cuentas quedaron por encima de 0.5, pero solo **user7** superó 0.8. Ninguna cuenta obtuvo simultáneamente FAR y FRR de 10 % o menos con el umbral aprendido de validación. La Tabla 4 y la Figura 1 muestran que algunos perfiles aceptan casi todos los impostores, mientras otros rechazan casi toda la actividad legítima.

Tabla 4: Desempeño de *Isolation Forest* por cuenta en sesiones completas.

Usuario	AUC	F1	FAR	FRR
user7	0.861	0.763	0.0 %	63.9 %
user9	0.755	0.789	0.0 %	100.0 %
user12	0.552	0.635	4.1 %	92.9 %
user15	0.678	0.750	5.7 %	88.9 %
user16	0.497	0.483	26.3 %	73.5 %
user20	0.650	0.095	95.0 %	0.0 %
user21	0.611	0.000	100.0 %	0.0 %
user23	0.421	0.571	21.2 %	84.2 %
user29	0.576	0.160	90.0 %	7.0 %
user35	0.507	0.807	0.0 %	100.0 %




Figura 1: Variación de AUC, FAR y FRR de *Isolation Forest* entre cuentas. Los extremos opuestos de FAR y FRR muestran que el umbral estimado con una o dos sesiones de validación no se transfiere de forma estable al test.

4.3. Estudio de caso user12: efecto del tamaño de observación

La Tabla 5 resume la evaluación. Todas las ventanas alcanzaron cobertura total. Aumentar la cantidad de eventos no produjo una mejora monótona: el AUC pasó de 0.632 con 25 eventos a un máximo de 0.692 con 100, descendió a 0.665 con 125 y terminó en 0.673 con 150. La FRR se mantuvo por debajo de 10 %, pero la FAR fue elevada en todos los tamaños.

Tabla 5: Desempeño por número de eventos observados.

Eventos	Tiempo (s)	AUC	Detección	FAR	FRR	F1	Cumple
25	3.9	0.632	18.4 %	81.6 %	7.1 %	0.290	No
50	9.7	0.652	24.5 %	75.5 %	5.4 %	0.375	No
75	16.9	0.651	28.6 %	71.4 %	8.9 %	0.412	No
100	23.1	0.692	30.6 %	69.4 %	3.6 %	0.455	No
125	31.1	0.665	32.7 %	67.3 %	7.1 %	0.464	No
150	37.2	0.673	24.5 %	75.5 %	5.4 %	0.375	No

El menor valor de la pérdida balanceada apareció con 100 eventos. Esa observación tomó una mediana de 23.1 segundos. No debe interpretarse como un mínimo confiable: ninguna ventana alcanzó a la vez

AUC de 0.80, FAR y FRR de 10 % o menos y cobertura total.

La Figura 2 permite ver que el mejor AUC no coincide con una reducción suficiente de la FAR. Aunque la FRR permanece cerca o debajo del límite, la mayoría de los impostores continúa siendo aceptada.




Figura 2: Evolución del AUC, la FAR y la FRR al aumentar la cantidad de eventos observados. Las líneas discontinuas representan los límites establecidos antes de la evaluación.

4.4. Estudio de caso user12: características con mayor discriminación

A 100 eventos, las señales individuales más discriminantes fueron la variación de aceleración, la aceleración media absoluta y la velocidad máxima. En las tres, la mediana fue mayor para las sesiones impostoras. La Tabla 6 presenta las cinco primeras variables.

Tabla 6: Principales características individuales a 100 eventos.

Característica	AUC orientado	Mediana legítima	Mediana impostora
Variación de aceleración	0.769	4433.022	9707.450
Aceleración media absoluta	0.743	2844.057	4809.817
Velocidad máxima	0.665	3273.308	5095.940
Variación de velocidad	0.657	639.502	866.590
Fracción de movimientos	0.626	0.890	0.860

El ranking coincide en dirección general con el antecedente de Antal y Egyed-Zsigmond [3], que encontró información relevante en aceleración y *jerk*. No obstante, los valores presentes son diagnósticos univariados de un solo usuario y no prueban que esas variables sean universales.

La Figura 3 ordena las cinco variables principales. Las barras comienzan en 0.5, valor que representa una separación equivalente al azar, para destacar la señal adicional que aporta cada característica.




Figura 3: AUC individual orientado de las características con mayor discriminación a 100 eventos. La variación de aceleración produjo la separación individual más alta.

4.5. Estudio de caso user12: estabilidad entre sesiones

En las siete sesiones legítimas, la tasa de alarma varió entre 6.3 % y 18.0 %. En las dos sesiones reservadas para validación estuvo entre 7.3 % y 12.5 %. La sesión con mayor tasa pertenecía al propio enrolamiento, lo cual indica que el perfil legítimo conserva heterogeneidad aun dentro de los datos disponibles.

Tabla 7: Puntajes legítimos por sesión con ventanas de 100 eventos.

Sesión	Rol	Ventanas	Mediana	Tasa de alarma
2144641057	Enrolamiento	300	0.397	9.0 %
5265929106	Enrolamiento	300	0.399	12.3 %
5815391283	Enrolamiento	300	0.394	6.3 %
7409188284	Enrolamiento	300	0.429	18.0 %
8872593360	Enrolamiento	300	0.393	8.3 %
9031593624	Validación	300	0.392	7.3 %
9838420452	Validación	297	0.400	12.5 %

La Figura 4 muestra que la tasa de alarma cambia incluso entre sesiones legítimas. Una sesión de enrolamiento llegó al 18.0 %, mientras otras permanecieron por debajo del límite del 10 %.




Figura 4: Tasa de alarma por sesión legítima con ventanas de 100 eventos. El color y el tramado distinguen las sesiones de enrolamiento de las reservadas para validación.

5. Discusión

La evaluación de las diez cuentas cambia el alcance de la conclusión: ya no se describe únicamente una cuenta, sino la heterogeneidad observada dentro de la cohorte. Sin embargo, los AUC macro de 0.627 para RMS-z y 0.611 para *Isolation Forest* indican una separación general modesta. El bosque obtuvo mayor exactitud macro, pero su FAR media de 34.2 % y su FRR media de 61.0 % quedan lejos de un autenticador autónomo. Además, ninguna cuenta mantuvo ambos errores en 10 % o menos.

La variación por usuario permite separar dos problemas. Primero, la calidad del ranking cambia entre perfiles: el AUC del bosque va de 0.421 a 0.861. Segundo, incluso cuando existe separabilidad, el umbral puede fallar. Por ejemplo, **user7** alcanzó el mayor AUC, pero rechazó 63.9 % de sus sesiones legítimas. Una o dos sesiones de validación no bastan para estimar de forma estable el percentil 95; los resultados extremos de FAR y FRR son compatibles con esa inestabilidad.

El caso de **user12** aporta detalle sin representar al conjunto. En sesiones completas, el bosque obtuvo $AUC = 0.552$, $FAR = 4.1\%$ y $FRR = 92.9\%$ con el percentil 95. En el experimento temprano, la representación por ventanas y el percentil 90 produjeron a 100 eventos $AUC = 0.692$, $FAR = 69.4\%$ y $FRR = 3.6\%$. El cambio de dirección del error no es una contradicción: son unidades, características y umbrales distintos. En conjunto, ambos resultados muestran que la decisión es muy sensible a la representación y a la calibración.

Dentro del caso, las características de aceleración fueron las que mejor separaron individualmente las clases a 100 eventos. Observar más interacciones ayudó hasta cierto punto, pero el efecto no fue monótono: el mejor AUC apareció en 100 eventos y el menor FAR en 125. No existe un mínimo dentro del rango estudiado porque ninguna configuración satisfizo el criterio previo. El comportamiento legítimo tampoco fue completamente estable; la tasa de alarma cambió en 11.7 puntos porcentuales entre sus sesiones.

La comparación con CAPTCHA también debe mantenerse dentro del alcance empírico. El conjunto de

prueba contiene suplantaciones simuladas mediante sesiones de otras personas, no agentes de IA ni automatizaciones. Por ello, el método evalúa continuidad de un patrón personal y podría detectar un agente solo si su interacción resulta anómala. Comprobar esa capacidad exigiría un conjunto específico con distintos agentes, dispositivos, velocidades y estrategias de imitación.

5.1. Limitaciones

- Diez cuentas permiten estudiar variación interna en Balabit, pero no representan otras poblaciones, dispositivos o tareas.
- Las suplantaciones son simuladas; una anomalía no equivale a intención maliciosa.
- El análisis general entrena con solo cuatro o cinco vectores de sesión y fija el umbral con una o dos sesiones legítimas; esta escasez vuelve inestable la cola de validación.
- La selección de validación sigue el orden determinista de los nombres de archivo, que no necesariamente expresa una cronología real.
- El experimento general y el caso usan representaciones y percentiles distintos; sus cifras sirven para preguntas complementarias y no para una comparación directa.
- En `user12`, los primeros N eventos producen una decisión temprana única, no vigilancia secuencial en tiempo real; ese análisis todavía no se repitió en las otras nueve cuentas.
- Cambios de dispositivo, resolución, fatiga, lesión, tarea o contexto pueden alterar el patrón legítimo.
- El AUC individual describe asociación y no causalidad ni importancia dentro del modelo multivariado.

5.2. Implicaciones éticas y operativas

La dinámica de mouse debe tratarse como dato biométrico conductual. Una implementación real requiere consentimiento, minimización y protección de los registros, límites de retención, auditoría de desempeño y un mecanismo accesible de recuperación. La salida apropiada del modelo es una señal de riesgo para autenticación escalonada, no una decisión irrevocable sobre identidad o culpabilidad.

6. Conclusiones y trabajo futuro

La dinámica de mouse contiene una señal medible, pero su utilidad no es uniforme entre personas. En las diez cuentas, RMS-z logró el mayor AUC macro (0.627) y *Isolation Forest* la mayor exactitud macro (0.591); ninguno produjo un punto operativo aceptable por sus elevadas FAR o FRR y por la fuerte variación entre usuarios. Por tanto, la evidencia no valida un autenticador autónomo general, aunque sí justifica investigar perfiles personalizados y mejores métodos de calibración.

El estudio de caso explica parte de esa dificultad. En `user12`, la aceleración aportó la señal individual más clara y 100 eventos ofrecieron el mejor AUC del rango, pero la FAR de 69.4% impidió satisfacer el criterio operativo. Su función dentro del trabajo es mostrar con detalle el compromiso entre rapidez, detección y falsas alarmas, no generalizar desde una sola persona.

El siguiente paso debe aplicar el análisis de prefijos a las diez cuentas, estimar incertidumbre mediante remuestreo por sesión y calibrar cada umbral mediante validación fuera de muestra, por ejemplo con

rotación de sesiones legítimas. También conviene comparar ventanas definidas por tiempo, transformaciones robustas y actualizaciones controladas del perfil. Para estudiar específicamente suplantación por IA, será necesario recolectar datos de agentes que operen interfaces y evaluar ataques que intenten imitar al usuario.

Referencias

- [1] T. Flash y N. Hogan, *The coordination of arm movements: An experimentally confirmed mathematical model*, *The Journal of Neuroscience*, vol. 5, núm. 7, pp. 1688–1703, 1985.
- [2] A. K. Dhawale, M. A. Smith y B. P. Ölveczky, *The role of variability in motor learning*, *Annual Review of Neuroscience*, vol. 40, pp. 479–498, 2017. doi: 10.1146/annurev-neuro-072116-031548.
- [3] M. Antal y E. Egyed-Zsigmond, *Intrusion detection using mouse dynamics*, *IET Biometrics*, vol. 8, núm. 5, pp. 285–294, 2019. doi: 10.1049/iet-bmt.2018.5126.
- [4] F. T. Liu, K. M. Ting y Z.-H. Zhou, *Isolation Forest*, en *Proceedings of the 8th IEEE International Conference on Data Mining*, pp. 413–422, 2008.
- [5] Balabit, *Mouse Dynamics Challenge Dataset*, 2016. Repositorio [balabit/Mouse-Dynamics-Challenge](#) en GitHub.