

MAESTRÍA EN INTELIGENCIA ARTIFICIAL
MATEMÁTICAS Y PROGRAMACIÓN PARA IA
PROPUESTA DE PROYECTO DE INVESTIGACIÓN Y DESARROLLO

1. TEMA

Detección de suplantación de identidad frente a variaciones naturales del comportamiento mediante biometría conductual, Feature Engineering y Machine Learning.

2. DESCRIPCIÓN DE LA PROPUESTA

2.1. Descripción Funcional

Los sistemas tradicionales de seguridad y los mecanismos tipo CAPTCHA tradicionales o basados en retos estáticos han demostrado no ser plenamente confiables: generan alta fricción al usuario, son vulnerables a bots avanzados potenciados con IA y únicamente validan la identidad de forma puntual en un instante aislado, dejando la sesión desprotegida tras el acceso inicial. Frente a esto, el proyecto propone desarrollar un sistema de autenticación continua fundamentado en biometría conductual, monitoreando en segundo plano los patrones neuromotores de interacción (teclado y mouse) a lo largo de toda la sesión.

El problema fundamental radica en que el comportamiento humano no es uniforme: un usuario legítimo presenta variaciones naturales intra-usuario (behavioral drift) provocadas por fatiga, estrés o multitarea. Los sistemas rígidos y los CAPTCHAs convencionales fallan en este punto, clasificando erróneamente variaciones humanas legítimas como anomalías o dejando pasar suplantaciones sofisticadas. Por ello, el sistema propuesto integrará modelos adaptativos de Machine Learning capaces de diferenciar de forma precisa entre:

1. Comportamiento habitual del usuario legítimo.
2. Variaciones naturales del comportamiento del mismo usuario entre diferentes sesiones temporales.
3. Comportamiento de suplantación ejecutado por un tercero o mediante herramientas automatizadas (bots).

Pregunta de investigación: ¿Qué características conductuales y transformaciones de Feature Engineering permiten superar la baja confiabilidad de los retos puntuales tipo CAPTCHA, distinguiendo de manera robusta la deriva natural del usuario legítimo de una suplantación real?

Datasets públicos y gratuitos a utilizar:


- Balabit Mouse Dynamics Challenge Dataset: Benchmark público con sesiones de interacción de múltiples usuarios en entornos reales, capturando coordenadas (x, y, t) , acciones de clic y vectores de trayectoria.
Enlace de descarga: <https://github.com/balabit/Mouse-Dynamics-Challenge>
- Keystroke and Mouse Dynamics for UEBA Dataset (Mendeley Data): Repositorio multi-sesión abierto con más de 140 000 registros integrados de eventos de teclado (Hold/Flight Time) y cinemática de mouse.
Enlace de descarga: <https://data.mendeley.com/datasets/f78jsh6zpz9/2>

Definición de clases y escenario de evaluación:

- Clasificación Binaria Supervisada: Clase 0 (Usuario Legítimo, integrando sesiones base y de variación natural) vs. Clase 1 (Impostor, conformado por sesiones de usuarios ajenos y patrones anómalos).
- Detección de Anomalías (One-Class): Perfilado entrenado exclusivamente con el comportamiento del usuario legítimo para evaluar umbrales dinámicos frente a variaciones legítimas vs. ataques.

2.2. Descripción Técnica

El proyecto será desarrollado en el lenguaje Python, empleando las librerías: Pandas, NumPy y SciPy (procesamiento de datos y series temporales), Scikit-learn (modelado, validación y métricas), Matplotlib y Seaborn (visualización) y SHAP (interpretabilidad de características).



Pipeline y Arquitectura de Implementación:

1. Ingesta y Preprocesamiento: Limpieza de ruido, sincronización temporal y segmentación en ventanas móviles.
2. Feature Engineering: Extracción de descriptores cinemáticos y temporales (tiempos de vuelo, pulsación, velocidad de tipeo, aceleración de cursor, curvatura de trayectorias, cambio angular y pausas cognitivas).
3. Análisis Estadístico y Selección: Evaluación de estabilidad intra-sesión vs. poder discriminativo inter-usuario.
4. Entrenamiento y Comparación de Modelos: Comparación entre Modelo Baseline (variables crudas) vs. Modelo con Feature Engineering, evaluando Logistic Regression, Random Forest, SVM RBF e Isolation Forest.
5. Validación Estratificada por Sesión (Out-of-Session Split): Partición temporal de sesiones independientes para verificar robustez ante la deriva natural y evitar filtrado de datos (data leakage).
6. Métricas de Evaluación: Accuracy, Precision, Recall, F1-Score, ROC-AUC, Equal Error Rate (EER) y SHAP.

Tema de investigación complementario (fuera del alcance del curso):

Se investigarán los fundamentos teóricos de la Biometría Conductual Continua, el fenómeno de Behavioral Drift y las limitaciones de confiabilidad de los esquemas tradicionales tipo CAPTCHA, analizando cómo el análisis cinemático adaptativo de señales biométricas mitiga vulnerabilidades frente a bots y suplantadores avanzados sin degradar la usabilidad.

3. OBJETIVOS

3.1. Objetivo General

Desarrollar y evaluar un sistema de Machine Learning fundamentado en Feature Engineering para la autenticación continua mediante biometría conductual de teclado y mouse, capaz de superar las limitaciones de confiabilidad de los métodos tradicionales y discriminar de forma robusta entre variaciones naturales del usuario legítimo y suplantaciones de identidad.

3.2. Objetivos Específicos

1. Adquirir y estructurar datasets públicos de biometría conductual (teclado y mouse) en sesiones independientes.
2. Construir e implementar un pipeline de Feature Engineering para la extracción de descriptores cinemáticos y temporales.
3. Evaluar estadísticamente la estabilidad temporal intra-usuario y el poder discriminativo inter-usuario de las variables.
4. Entrenar y comparar modelos supervisados y de detección de anomalías bajo esquemas Baseline y con Feature Engineering.
5. Validar la robustez del sistema ante variaciones naturales aplicando partición por sesiones desacopladas (out-of-session).
6. Interpretar el rendimiento mediante métricas de clasificación (Precision, Recall, F1, ROC-AUC, EER) y análisis SHAP.
7. Investigar y documentar los fundamentos de biometría conductual, la falta de confiabilidad de los CAPTCHAs y el behavioral drift.