

MAESTRÍA EN INTELIGENCIA ARTIFICIAL
MATEMÁTICAS Y PROGRAMACIÓN PARA IA
PROPUESTA DE PROYECTO DE INVESTIGACIÓN Y DESARROLLO

1. TEMA

Detección de suplantación de identidad frente a variaciones naturales del comportamiento mediante biometría conductual, Feature Engineering y Machine Learning.

2. DESCRIPCIÓN DE LA PROPUESTA

2.1. Descripción Funcional

Los sistemas tradicionales de autenticación basados en factores estáticos (contraseñas, PIN o biometría física) verifican la identidad únicamente al inicio de la sesión. Frente a este esquema, el proyecto propone desarrollar un sistema de autenticación continua fundamentado en biometría conductual, el cual monitorea en segundo plano los patrones de interacción humano-computadora (pulsaciones de teclado y dinámica del mouse) para determinar si la sesión corresponde al usuario legítimo o a una posible suplantación.

El problema fundamental que se pretende estudiar es que el comportamiento de una persona no es constante: un mismo usuario legítimo presenta variaciones naturales intra-usuario (behavioral drift) provocadas por cansancio, nivel de concentración, postura o cambio de dispositivo. Por este motivo, el sistema no buscará únicamente clasificar entre usuario e impostor, sino diferenciar de forma precisa entre:

1. Comportamiento habitual del usuario legítimo.
2. Variaciones naturales del comportamiento del mismo usuario entre diferentes sesiones temporales.
3. Comportamiento correspondiente a una suplantación de identidad por un tercero no autorizado.

Pregunta de investigación: ¿Qué características conductuales y transformaciones de Feature Engineering permiten distinguir de manera robusta una variación natural del usuario legítimo de una suplantación real, minimizando la tasa de falsos rechazos?

Datasets públicos y gratuitos a utilizar:

- Balabit Mouse Dynamics Challenge Dataset: Benchmark público con sesiones de interacción de múltiples usuarios en entornos de escritorio reales, capturando coordenadas continuas (x, y, t) , acciones de clic y vectores de trayectoria. Enlace de descarga: <https://github.com/balabit/Mouse-Dynamics-Challenge>
- Keystroke and Mouse Dynamics for UEBA Dataset (Mendeley Data): Repositorio multi-sesión abierto con más de 140 000 registros integrados de eventos de teclado (Hold Time, Flight Time) y cinemática de mouse. Enlace de descarga: <https://data.mendeley.com/datasets/f78jsh6zp9/2>

Definición de clases y escenario de evaluación:

- Clasificación Binaria Supervisada: Clase 0 (Usuario Legítimo, integrando sesiones base y sesiones con variación natural) vs. Clase 1 (Impostor, conformado por sesiones de usuarios ajenos).
- Detección de Anomalías (One-Class): Perfilado entrenado exclusivamente con el comportamiento del usuario legítimo para evaluar umbrales de tolerancia frente a variaciones legítimas vs. ataques.

2.2. Descripción Técnica

El proyecto será desarrollado en el lenguaje Python, empleando las siguientes librerías:

- Pandas, NumPy y SciPy: Ingesta, limpieza, transformaciones estadísticas, álgebra lineal y tratamiento de series de tiempo.
- Scikit-learn: Escalado robusto, entrenamiento de modelos, validación cruzada y cálculo de métricas de clasificación.
- Matplotlib y Seaborn: Análisis exploratorio, visualización de distribuciones y matrices de confusión.
- SHAP: Análisis de interpretabilidad y explicabilidad del impacto de las características en las decisiones del modelo.

Pipeline y Arquitectura de Implementación:

1. Ingesta y Preprocesamiento: Limpieza de ruido, sincronización temporal y segmentación en ventanas temporales móviles por usuario y sesión.
2. Feature Engineering: Extracción de descriptores conductuales especializados:
 - Teclado: Tiempos de pulsación (Hold Time), tiempos de vuelo entre teclas (Flight Time), velocidad de tipeo (WPM), coeficiente de variación rítmico, frecuencia de correcciones (Backspace) y pausas.
 - Mouse: Velocidad tangencial promedio, aceleración, curvatura de trayectorias, tasa de cambio de dirección angular (jitter), distancia euclidiana vs. real recorrida y tiempo de inactividad.
3. Análisis Estadístico y Selección de Características: Evaluación de la estabilidad temporal intra-usuario vs. poder discriminativo inter-usuario para seleccionar el subconjunto óptimo de variables.
4. Entrenamiento y Comparación de Modelos: Se contrastarán dos configuraciones:
 - Modelo Baseline: Entrenado únicamente con variables crudas o estadísticas elementales directas.
 - Modelo con Feature Engineering: Entrenado con el conjunto optimizado de descriptores.Se evaluarán modelos como: Logistic Regression, Random Forest, Support Vector Machines (SVM RBF) e Isolation Forest.
5. Validación Estratificada por Sesión (Out-of-Session Split): Partición temporal estricta donde las sesiones iniciales se usan para entrenamiento y sesiones posteriores independientes para prueba, asegurando que el modelo generalice ante la deriva natural y no memorice una única sesión.
6. Métricas de Evaluación: Accuracy, Precision, Recall, F1-Score, ROC-AUC y Equal Error Rate (EER).

Tema de investigación complementario (fuera del alcance del curso):

Se investigarán los conceptos de Biometría Conductual Continua y el fenómeno de Behavioral Drift (deriva del patrón conductual a lo largo del tiempo), analizando mecanismos de adaptación dinámica de umbrales para mantener la seguridad sin generar fricción al usuario legítimo.

3. OBJETIVOS

3.1. Objetivo General

Desarrollar y evaluar un sistema de Machine Learning fundamentado en Feature Engineering para la autenticación continua mediante biometría conductual de teclado y mouse, capaz de discriminar de forma robusta entre variaciones naturales del comportamiento de un usuario legítimo y eventos de suplantación de identidad.

3.2. Objetivos Específicos

1. Adquirir y estructurar datasets públicos de biometría conductual (teclado y mouse) organizados en sesiones cronológicas independientes de múltiples usuarios.
2. Construir e implementar un pipeline de Feature Engineering para la extracción de descriptores cinemáticos, estadísticos y temporales a partir de los datos crudos.
3. Evaluar estadísticamente la estabilidad temporal intra-usuario y el poder discriminativo inter-usuario de las características calculadas.
4. Entrenar y comparar múltiples modelos de Machine Learning supervisados y de detección de anomalías bajo configuraciones Baseline y con Feature Engineering.
5. Validar la robustez del sistema ante variaciones naturales del comportamiento aplicando partición por sesiones desacopladas (out-of-session evaluation).
6. Interpretar el rendimiento mediante métricas de clasificación (Precision, Recall, F1, ROC-AUC, EER) y análisis de importancia de variables con SHAP.
7. Investigar y documentar los fundamentos teóricos de biometría conductual, autenticación continua y behavioral drift.