

MAESTRÍA EN INTELIGENCIA ARTIFICIAL
MATEMÁTICAS Y PROGRAMACIÓN PARA IA
PROPUESTA DE PROYECTO DE INVESTIGACIÓN Y DESARROLLO

1. TEMA

Detección de suplantación de identidad frente a variaciones naturales del comportamiento mediante biometría conductual, Feature Engineering y Machine Learning.

2. DESCRIPCIÓN DE LA PROPUESTA

2.1. Descripción Funcional

Los sistemas tradicionales de autenticación estática (contraseñas, PIN) verifican la identidad únicamente al inicio de la sesión. Frente a esto, el proyecto propone desarrollar un sistema de autenticación continua basado en biometría conductual, monitoreando en segundo plano patrones de interacción (pulsaciones de teclado y dinámica de mouse) para determinar si la sesión corresponde al usuario legítimo o a una suplantación.

El problema fundamental radica en que el comportamiento humano no es uniforme: un usuario legítimo presenta variaciones naturales intra-usuario (behavioral drift) por fatiga o estrés. Asimismo, este enfoque se conecta estrechamente con la tecnología de los CAPTCHAs conductuales e invisibles modernos (e.g., reCAPTCHA v3, Turnstile), los cuales analizan micro-movimientos de mouse, trayectorias y tiempos de reacción para diferenciar humanos de bots o atacantes automatizados. En este sistema, la detección de anomalías servirá tanto para identificar impostores como para activar desafíos adaptativos tipo CAPTCHA ante caídas de confianza sin cerrar la sesión abruptamente.

Por este motivo, el sistema analizará la diferenciación entre:

1. Comportamiento habitual del usuario legítimo.
2. Variaciones naturales del comportamiento del mismo usuario entre diferentes sesiones temporales.
3. Comportamiento de suplantación por un tercero o mediante patrones automatizados/sintéticos (bots tipo CAPTCHA).

Pregunta de investigación: ¿Qué características conductuales permiten distinguir de manera robusta una variación natural del usuario legítimo de una suplantación real o automatizada, minimizando los falsos rechazos?

Datasets públicos y gratuitos a utilizar:


- Balabit Mouse Dynamics Challenge Dataset: Benchmark público con sesiones de interacción de múltiples usuarios en entornos reales, capturando coordenadas (x, y, t) , acciones de clic y vectores de trayectoria.
Enlace de descarga: <https://github.com/balabit/Mouse-Dynamics-Challenge>
- Keystroke and Mouse Dynamics for UEBA Dataset (Mendeley Data): Repositorio multi-sesión abierto con más de 140 000 registros integrados de eventos de teclado (Hold/Flight Time) y cinemática de mouse.
Enlace de descarga: <https://data.mendeley.com/datasets/f78jsh6zp9/2>

Definición de clases y escenario de evaluación:

- Clasificación Binaria Supervisada: Clase 0 (Usuario Legítimo, integrando sesiones base y de variación natural) vs. Clase 1 (Impostor, conformado por sesiones de usuarios ajenos y patrones anómalos).
- Detección de Anomalías (One-Class): Perfilado entrenado exclusivamente con el comportamiento del usuario legítimo para evaluar umbrales dinámicos frente a variaciones legítimas vs. ataques.

2.2. Descripción Técnica

El proyecto será desarrollado en el lenguaje Python, empleando las librerías: Pandas, NumPy y SciPy (procesamiento de datos y series temporales), Scikit-learn (modelado, validación y métricas), Matplotlib y Seaborn (visualización) y SHAP (interpretabilidad de características).



Pipeline y Arquitectura de Implementación:

1. Ingesta y Preprocesamiento: Limpieza de ruido, sincronización temporal y segmentación en ventanas móviles.
2. Feature Engineering: Extracción de descriptores cinemáticos y temporales (tiempos de vuelo, pulsación, velocidad de tipeo, aceleración de cursor, curvatura de trayectorias, cambio angular y pausas cognitivas).
3. Análisis Estadístico y Selección: Evaluación de estabilidad intra-sesión vs. poder discriminativo inter-usuario.
4. Entrenamiento y Comparación de Modelos: Comparación entre Modelo Baseline (variables crudas) vs. Modelo con Feature Engineering, evaluando Logistic Regression, Random Forest, SVM RBF e Isolation Forest.
5. Validación Estratificada por Sesión (Out-of-Session Split): Partición temporal de sesiones independientes para verificar robustez ante la deriva natural y evitar filtrado de datos (data leakage).
6. Métricas de Evaluación: Accuracy, Precision, Recall, F1-Score, ROC-AUC, Equal Error Rate (EER) y SHAP.

Tema de investigación complementario (fuera del alcance del curso):

Se investigarán los fundamentos de la Biometría Conductual Continua, el fenómeno de Behavioral Drift y los mecanismos de análisis cinemático empleados en CAPTCHAs invisibles y adaptativos, analizando estrategias para el ajuste dinámico de umbrales y la mitigación de ataques automatizados sin fricción.

3. OBJETIVOS

3.1. Objetivo General

Desarrollar y evaluar un sistema de Machine Learning fundamentado en Feature Engineering para la autenticación continua mediante biometría conductual de teclado y mouse, capaz de discriminar de forma robusta entre variaciones naturales del comportamiento de un usuario legítimo y eventos de suplantación de identidad.

3.2. Objetivos Específicos

1. Adquirir y estructurar datasets públicos de biometría conductual (teclado y mouse) en sesiones independientes.
2. Construir e implementar un pipeline de Feature Engineering para la extracción de descriptores cinemáticos y temporales.
3. Evaluar estadísticamente la estabilidad temporal intra-usuario y el poder discriminativo inter-usuario de las variables.
4. Entrenar y comparar modelos supervisados y de detección de anomalías bajo esquemas Baseline y con Feature Engineering.
5. Validar la robustez del sistema ante variaciones naturales aplicando partición por sesiones desacopladas (out-of-session).
6. Interpretar el rendimiento mediante métricas de clasificación (Precision, Recall, F1, ROC-AUC, EER) y análisis SHAP.
7. Investigar y documentar los fundamentos teóricos de biometría conductual, CAPTCHAs conductuales y behavioral drift.